



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



Escola Tècnica
Superior d'Enginyeria
Informàtica

Escuela Técnica Superior de Ingeniería Informática
Universidad Politécnica de Valencia

Diseño e Implementación de una Plataforma Analítica para el Análisis y Predicción de Patrones de Movilidad Urbana en Nueva York

TRABAJO FIN DE MÁSTER

Máster en Big Data Analytics

Autor: Carlos Monteagudo Tobarra

Tutor: Fernando Martínez Plumed

Curso 2024–2025

Resum

Aquest Treball de Fi de Màster presenta el disseny i la implementació d'una plataforma analítica reproduïble per a l'estudi dels patrons de mobilitat urbana a la ciutat de Nova York i la predicció de la demanda de serveis de taxi i vehicles de lloguer amb conductor. El treball utilitza com a font principal els registres de viatges publicats per la New York City Taxi and Limousine Commission (TLC) i considera les diferents modalitats disponibles: Yellow Taxi, Green Taxi, For-Hire Vehicle (FHV) i High Volume For-Hire Vehicle (HVFHV). L'horitzó temporal d'estudi comprèn el període 2018–2025, fet que permet analitzar tant el comportament previ a la pandèmia de COVID-19 com la ruptura de mobilitat produïda durant 2020 i la posterior recuperació.

La solució s'ha concebut sota una arquitectura de medalló. La capa Bronze conserva els fitxers originals en format Parquet, mentre que les capes Silver i Gold s'implementen sobre PostgreSQL i es transformen mitjançant dbt. La ingesta, la planificació i el control operacional del flux es centralitzen en Apache NiFi, que organitza el processament mitjançant grups de processos, paràmetres, rutes d'èxit i error, reintents i mecanismes de procedència de dades. Docker Compose encapsula els serveis necessaris i permet desplegar de manera reproduïble NiFi, PostgreSQL, dbt, l'entorn Python de machine learning i Apache Superset. El model Gold proporciona taules de fets, dimensions i *data marts* orientats a l'anàlisi de demanda, mobilitat, rendiment econòmic i oportunitats operatives per als conductors.

La component predictiva formula la demanda com el nombre de viatges iniciats per zona TLC i franja horària. S'estableixen dos horitzons de predicció, una hora i vint-i-quatre hores, i es comparen tres famílies de models supervisats: regressió de Poisson, boscos aleatoris i gradient boosting amb LightGBM. L'avaluació segueix una partició estrictament temporal per evitar fuites d'informació i utilitza mètriques com MAE, RMSE i WAPE. Els resultats experimentals definitius s'incorporaran a partir de l'execució reproduïble de la versió final del repositori.

Paraules clau: mobilitat urbana, taxi, NYC TLC, Apache NiFi, arquitectura de medalló, enginyeria de dades, PostgreSQL, dbt, Docker, Apache Superset, predicció de demanda.

Resumen

El presente Trabajo Fin de Máster describe el diseño y la implementación de una plataforma analítica reproducible para estudiar los patrones de movilidad urbana en la ciudad de Nueva York y predecir la demanda de servicios de taxi y vehículos de alquiler con conductor. La fuente principal son los registros de viajes publicados por la New York City Taxi and Limousine Commission (TLC), integrando las modalidades Yellow Taxi, Green Taxi, For-Hire Vehicle (FHV) y High Volume For-Hire Vehicle (HVFHV). El periodo de estudio comprende 2018–2025, de modo que el análisis permite comparar la movilidad previa a la pandemia de COVID-19, la disrupción observada durante 2020 y el proceso de recuperación posterior.

La plataforma se estructura siguiendo una arquitectura de medallón. La capa Bronze conserva los ficheros de origen en formato Parquet; las capas Silver y Gold se materializan en PostgreSQL y se transforman mediante dbt. La ingesta, planificación y control operacional del flujo se centralizan en Apache NiFi, que organiza el procesamiento mediante grupos de procesos, parámetros, rutas de éxito y error, reintentos y mecanismos de procedencia del dato. Docker Compose encapsula los servicios necesarios y permite desplegar de forma reproducible NiFi, PostgreSQL, dbt, el entorno Python de machine learning y Apache Superset. La capa Gold contiene dimensiones, tablas de hechos y *data marts* diseñados para responder a preguntas de negocio relacionadas con demanda, movilidad, congestión aproximada, rendimiento económico y oportunidades operativas para conductores.

La predicción se formula como un problema de regresión sobre el número de viajes iniciados por zona TLC y hora. Se consideran horizontes de una hora y veinticuatro horas y se plantea la comparación de tres aproximaciones complementarias: regresión de Poisson, Random Forest y LightGBM. La evaluación utiliza particiones temporales para evitar fuga de información y métricas MAE, RMSE y WAPE. La memoria separa explícitamente los resultados observados de las estimaciones y simulaciones de rentabilidad, y reserva las cifras experimentales definitivas para la ejecución reproducible del repositorio final.

Palabras clave: movilidad urbana, taxi, NYC TLC, Apache NiFi, arquitectura medallón, ingeniería de datos, PostgreSQL, dbt, Docker, Apache Superset, predicción de demanda.

Abstract

This Master’s Thesis presents the design and implementation of a reproducible analytical platform for studying urban mobility patterns in New York City and forecasting demand for taxi and for-hire vehicle services. The primary source is the trip-record data published by the New York City Taxi and Limousine Commission (TLC), integrating Yellow Taxi, Green Taxi, For-Hire Vehicle (FHV), and High Volume For-Hire Vehicle (HVFHV) services. The analysis covers the 2018–2025 period, enabling a longitudinal comparison between pre-pandemic mobility, the disruption associated with COVID-19 in 2020, and the subsequent recovery.

The solution follows a Medallion Architecture. The Bronze layer preserves the original Parquet files, whereas the Silver and Gold layers are implemented in PostgreSQL and transformed with dbt. Data ingestion, scheduling and operational flow control are centralised in Apache NiFi, using process groups, parameters, explicit success and failure routes, retry policies and data-provenance capabilities. Docker Compose packages the required services and provides a reproducible deployment for NiFi, PostgreSQL, dbt, the Python machine-learning environment and Apache Superset. The Gold layer exposes dimensions, fact tables and analytical data marts intended to support demand analysis, mobility patterns, approximate congestion indicators, economic performance and driver-opportunity analysis.

Demand forecasting is formulated as a regression problem over the number of trips originating in each TLC zone and hourly time slot. Two forecasting horizons are considered: one hour and twenty-four hours. Three complementary supervised models are compared: Poisson regression, Random Forest and LightGBM. Evaluation is based on strictly temporal splits to avoid information leakage, using MAE, RMSE and WAPE. Final experimental figures are intentionally tied to the reproducible execution of the final repository rather than being estimated or manually introduced.

Key words: urban mobility, taxi, NYC TLC, Apache NiFi, Medallion Architecture, data engineering, PostgreSQL, dbt, Docker, Apache Superset, demand forecasting.

Siglas y abreviaturas

BI	Business Intelligence
COVID-19	Coronavirus Disease 2019
DAG	Directed Acyclic Graph, grafo dirigido acíclico
DBT	data build tool
DWH	Data Warehouse
ELT	Extract, Load, Transform
ETL	Extract, Transform, Load
FHV	For-Hire Vehicle
HVHV	High Volume For-Hire Vehicle
KPI	Key Performance Indicator
MAE	Mean Absolute Error
ML	Machine Learning
NYC	New York City
OD	Origen–Destino
PCA	Principal Component Analysis
RMSE	Root Mean Squared Error
SQL	Structured Query Language
TLC	New York City Taxi and Limousine Commission
WAPE	Weighted Absolute Percentage Error

Índice general

Índice general	VII
Índice de figuras	IX
Índice de tablas	IX

1 Introducción	1
1.1 Motivación	1
1.2 Problema de investigación	2
1.3 Objetivo general	2
1.4 Objetivos específicos	2
1.5 Alcance y exclusiones	3
1.6 Metodología de trabajo	4
1.7 Contribuciones principales	4
1.8 Estructura de la memoria	4
2 Movilidad urbana y contexto del problema	7
2.1 La movilidad urbana como sistema de datos	7
2.2 La New York City Taxi and Limousine Commission	7
2.3 Yellow Taxi	8
2.4 Green Taxi	8
2.5 For-Hire Vehicles	8
2.6 High Volume For-Hire Vehicles	9
2.7 Taxi Zones y representación espacial	9
2.8 Dimensión temporal y estacionalidad	9
2.9 Impacto de la pandemia de COVID-19	10
2.10 Meteorología y factores externos	10
2.11 Preguntas de negocio	10
2.11.1 Evolución de la movilidad	10
2.11.2 Distribución geográfica	11
2.11.3 Rendimiento operativo y económico	11
2.11.4 Predicción de demanda	11
2.12 Del análisis descriptivo al producto analítico	11
Bibliografía	13

Índice de figuras

Índice de tablas

CAPÍTULO 1

Introducción

La disponibilidad de datos masivos de movilidad ha modificado de forma sustancial la manera en que pueden estudiarse los sistemas de transporte urbano. Frente a los enfoques basados exclusivamente en encuestas, conteos manuales o muestras reducidas, los registros transaccionales generados por servicios de taxi y vehículos de alquiler con conductor permiten observar millones de desplazamientos con una granularidad temporal y espacial elevada. Nueva York constituye un caso especialmente relevante por la dimensión de su mercado de transporte bajo demanda y por la política de datos abiertos desarrollada por la New York City Taxi and Limousine Commission (TLC), que publica registros de viajes de distintas modalidades de servicio [9, 10].

El valor de estos datos no reside únicamente en su volumen. La combinación de marcas temporales, zonas de origen y destino, duración, distancia, tarifas y otros atributos hace posible analizar regularidades de movilidad, estudiar diferencias entre servicios, detectar episodios anómalos y construir modelos predictivos de demanda. Sin embargo, trabajar con un histórico de varios años y con múltiples tipos de servicio plantea un problema de ingeniería de datos antes incluso de abordar el análisis estadístico. Los esquemas evolucionan, algunos campos aparecen o desaparecen, existen registros incompletos o inconsistentes y la escala obliga a separar el almacenamiento bruto de los modelos analíticos orientados a consulta.

Este Trabajo Fin de Máster aborda conjuntamente ambas dimensiones. Por una parte, se diseña una plataforma de datos local, reproducible y contenerizada, capaz de descargar, validar, transformar y modelar los registros de la comisión; por otra, se construye una capa analítica destinada a describir los patrones de movilidad y a predecir la demanda horaria por zona y tipo de servicio. El resultado se concibe como un proyecto *end-to-end*: desde la obtención del fichero de origen hasta la visualización de indicadores y predicciones en una herramienta de Business Intelligence.

1.1 Motivación

La motivación del trabajo se apoya en tres argumentos complementarios. El primero es de naturaleza urbana y económica. La demanda de taxi no se distribuye de manera homogénea. Cambia según la hora, el día de la semana, la localización, la climatología, el calendario y la presencia de acontecimientos extraordinarios. Estudios previos han mostrado que la demanda de taxi en Nueva York presenta fuertes dependencias espacio-temporales y que la inclusión de estructura espacial y temporal mejora la capacidad predictiva [12, 5, 13]. Desde el punto de vista operativo, anticipar estas variaciones puede contribuir a posicionar mejor la oferta, reducir tiempos improductivos y comprender cómo compiten o se complementan los diferentes servicios.

El segundo argumento es metodológico. Los conjuntos de datos de movilidad suelen utilizarse en ejercicios de análisis o modelado en los que la preparación previa queda reducida a un conjunto de scripts puntuales. Esa aproximación resulta suficiente para una prueba de concepto, pero no reproduce las prácticas habituales de una plataforma de datos mantenible. En un escenario real son necesarios controles de estado, idempotencia, registros de ejecución, validaciones, separación de capas, versionado de transformaciones y mecanismos de despliegue reproducible. El presente trabajo utiliza el caso de movilidad como vehículo para demostrar estas prácticas de ingeniería de datos.

El tercer argumento es académico. La combinación de arquitectura, modelado dimensional, análisis de negocio, calidad de datos y aprendizaje automático permite estudiar el ciclo completo de creación de un producto analítico. La arquitectura de medallón proporciona una separación conceptual entre datos de origen, información depurada y modelos de negocio [2]; dbt permite tratar las transformaciones SQL como código versionado y testeable [3]; Docker facilita que la solución sea ejecutable con las mismas dependencias en distintos equipos [4]; y Apache Superset proporciona una capa de consumo interactiva sobre los modelos analíticos [1].

1.2 Problema de investigación

El problema central puede formularse de la siguiente manera: *¿cómo diseñar una plataforma reproducible que permita transformar un histórico masivo y heterogéneo de viajes de la TLC en información analítica fiable, y hasta qué punto los patrones históricos permiten predecir la demanda futura por zona y franja horaria?*

Esta pregunta combina dos problemas relacionados. El primero es arquitectónico: definir un flujo capaz de incorporar diferentes familias de datos, evolucionar ante cambios de esquema, evitar reprocesamientos innecesarios y dejar trazabilidad de cada ejecución. El segundo es predictivo: construir un conjunto de variables que represente adecuadamente la periodicidad de la demanda y evaluar modelos con una metodología temporal que evite utilizar información del futuro durante el entrenamiento.

La plataforma se diseña para ejecutarse en un único equipo con Docker Desktop, pero aplicando principios que puedan trasladarse a un entorno servidor. Esta restricción es deliberada. El objetivo no es construir una infraestructura distribuida a cualquier coste, sino demostrar que una arquitectura rigurosa puede implementarse con tecnologías abiertas y recursos locales cuando el diseño separa adecuadamente almacenamiento, transformación, control y consumo.

1.3 Objetivo general

El objetivo general del Trabajo Fin de Máster es **diseñar e implementar una plataforma analítica reproducible para analizar los patrones de movilidad de los servicios de taxi y vehículos de alquiler en Nueva York y predecir la demanda de viajes por zona y franja temporal.**

1.4 Objetivos específicos

A partir del objetivo general se definen los siguientes objetivos específicos:

1. Diseñar una arquitectura de datos contenerizada que pueda levantarse mediante Docker Compose y que no requiera instalaciones locales de PostgreSQL, dbt o Apache Superset.
2. Automatizar el descubrimiento y la descarga incremental de los ficheros publicados por la TLC para las modalidades Yellow Taxi, Green Taxi, FHV y HVFHV.
3. Preservar los datos de origen en una capa Bronze basada en Parquet, manteniendo metadatos de procedencia, fecha, servicio y estado de procesamiento.
4. Normalizar y depurar la información en una capa Silver, armonizando esquemas y aplicando reglas explícitas de calidad.
5. Diseñar una capa Gold basada en modelado dimensional y *data marts* orientados a movilidad, comparación de servicios, rendimiento económico y predicción.
6. Incorporar mecanismos de idempotencia, auditoría, control de errores, cuarentena y observabilidad para que el pipeline pueda reejecutarse sin duplicar o corromper resultados.
7. Enriquecer los viajes con dimensiones temporales, información geográfica, festivos y variables meteorológicas cuando su disponibilidad y granularidad lo permitan.
8. Analizar la evolución de la movilidad entre 2018 y 2025, con especial atención al cambio estructural asociado a la pandemia de COVID-19 y a la evolución posterior.
9. Formular la predicción como el número de viajes iniciados por zona TLC y hora, evaluando horizontes de una hora y veinticuatro horas.
10. Comparar tres familias de modelos supervisados con propiedades diferentes: regresión de Poisson, Random Forest y LightGBM, además de un baseline temporal de referencia.
11. Construir dashboards en Apache Superset que permitan explorar resultados descriptivos, geográficos, económicos y predictivos.
12. Documentar la solución de forma que una tercera persona pueda reproducir el modo de demostración a partir del repositorio público.

1.5 Alcance y exclusiones

El trabajo analiza el periodo 2018–2025. Esta ventana proporciona años inmediatamente anteriores a la pandemia, el periodo de mayor disrupción y varios años posteriores. No obstante, la cobertura efectiva varía según la familia de servicio. En particular, la TLC comenzó a publicar los registros HVFHV como conjunto diferenciado en 2019 [9]; por tanto, no se fuerza una homogeneidad temporal inexistente y cada análisis declara el periodo realmente disponible.

El concepto de rentabilidad se aborda mediante indicadores observados y mediante escenarios parametrizables. Los registros TLC contienen importes asociados a determinados servicios, pero no representan una contabilidad completa del conductor. Costes como combustible, mantenimiento, seguros, amortización, licencias o tiempo sin pasajero no pueden inferirse de forma fiable para todos los registros. En consecuencia, el trabajo distingue entre *ingreso observado*, *indicador derivado* y *beneficio estimado*. La memoria evita presentar como beneficio neto una magnitud que no se observa directamente.

Tampoco se plantea un sistema de predicción en tiempo real con garantías de servicio. El objetivo es construir y evaluar un pipeline reproducible de entrenamiento e inferencia por lotes. Una evolución hacia inferencia *streaming*, alta disponibilidad o despliegue en nube se considera una línea futura.

1.6 Metodología de trabajo

El desarrollo sigue una aproximación incremental. En primer lugar se inventaría y audita el código existente, identificando componentes reutilizables y riesgos de publicación. A continuación se estabiliza el entorno Docker y la capa de control. Sobre esa base se implementan las fases de ingesta y transformación. La capa analítica se diseña una vez fijada la granularidad de las tablas Silver, y el modelado predictivo consume exclusivamente entidades Gold preparadas para ese propósito.

Desde el punto de vista experimental, las decisiones se separan en dos grupos. Las decisiones arquitectónicas se validan mediante reproducibilidad, tests, reejecución e inspección de estado. Las decisiones de modelado se validan mediante métricas fuera de muestra y particiones temporales. Esta separación es importante: que un modelo obtenga una buena métrica no compensa un pipeline no reproducible, y una arquitectura técnicamente correcta no implica que las predicciones sean útiles.

El control de versiones con Git registra el desarrollo y permite asociar cada experimento a una revisión concreta del código. Los resultados finales deberán referenciar el *commit* o etiqueta utilizado para que la comparación de modelos pueda repetirse. El repositorio definitivo se publicará en <https://github.com/Cyos98/TFM>.

1.7 Contribuciones principales

Las principales contribuciones esperadas son las siguientes:

- una arquitectura local de datos reproducible que integra almacenamiento de ficheros, PostgreSQL, dbt, validación, machine learning y Superset;
- un proceso de ingestión incremental e idempotente para varios años y varios tipos de servicio regulados por la comisión;
- un modelo dimensional común que permite comparar modalidades con esquemas diferentes sin ocultar sus particularidades;
- un conjunto de KPIs y *data marts* orientados a comprender patrones de movilidad y oportunidades operativas;
- una evaluación predictiva homogénea de tres familias de modelos para dos horizontes temporales y varios servicios;
- un entregable reproducible que puede ejecutarse en modo reducido para demostración y en modo completo cuando existen recursos suficientes.

1.8 Estructura de la memoria

El resto de la memoria comienza con el capítulo 2, que introduce el contexto de movilidad urbana y describe los servicios regulados por la TLC. Los capítulos posteriores

desarrollarán el estado del arte, las tecnologías y fuentes de datos seleccionadas, la arquitectura y la implementación del pipeline, la capa de inteligencia de negocio, la metodología predictiva, los resultados experimentales y, finalmente, las conclusiones, limitaciones y líneas futuras.

CAPÍTULO 2

Movilidad urbana y contexto del problema

2.1 La movilidad urbana como sistema de datos

La movilidad urbana es el resultado agregado de decisiones individuales condicionadas por la estructura de la ciudad, la oferta de transporte, el calendario laboral, la actividad económica y numerosos factores externos. En una gran metrópolis, estas decisiones generan patrones recurrentes —por ejemplo, picos asociados a desplazamientos laborales—, pero también variaciones locales y episodios extraordinarios. Analizar movilidad implica, por tanto, combinar una dimensión temporal con una dimensión espacial.

Los servicios de taxi y transporte bajo demanda constituyen una fuente especialmente informativa porque cada viaje representa una interacción efectiva entre una demanda y una oferta de movilidad. El origen indica dónde se materializa la necesidad de desplazamiento; el destino aproxima la dirección del flujo; la hora revela periodicidades; y la duración, la distancia y el importe permiten estudiar características económicas y operativas. Cuando se dispone de millones de observaciones, la red de viajes puede analizarse como una estructura de flujos urbanos. Riascos y Mateos estudiaron más de mil millones de viajes de taxi en Nueva York y mostraron que las matrices origen-destino permiten caracterizar lugares especialmente relevantes dentro de la red urbana [11].

Esta riqueza presenta una contrapartida: los registros de viaje no son una observación completa de la movilidad de la ciudad. Representan únicamente los servicios regulados por la TLC y reflejan las reglas, tecnologías y prácticas de captura de cada periodo. Por ello, las inferencias deben limitarse al dominio de los datos y evitar identificar automáticamente *demanda de taxi* con *movilidad total*.

2.2 La New York City Taxi and Limousine Commission

La TLC es el organismo de la ciudad de Nueva York responsable de regular diferentes modalidades de transporte de pasajeros. Además de su función regulatoria, publica conjuntos de datos de viajes con fines de transparencia, investigación y análisis. La documentación oficial indica que los registros mensuales se ponen a disposición en formato Parquet y se acompañan de diccionarios de datos específicos para Yellow Taxi, Green Taxi, FHV y HVFHV [9, 10].

Los datos se distribuyen como ficheros mensuales, circunstancia que influye directamente en el diseño del pipeline. El fichero mensual constituye una unidad natural de

descubrimiento, descarga, validación y estado. En lugar de interpretar la fuente como un único dataset estático, el proyecto la modela como una secuencia temporal de activos cuya disponibilidad y esquema pueden evolucionar.

2.3 Yellow Taxi

El taxi amarillo o *Yellow Taxi* es la modalidad más reconocible del sistema neoyorquino. Históricamente concentra una parte muy relevante de los viajes en Manhattan y dispone de un conjunto de atributos especialmente rico para el análisis económico: marcas temporales de recogida y bajada, zonas, distancia, método de pago y componentes de tarifa, entre otros. Esta riqueza lo convierte en el servicio más adecuado para validar de extremo a extremo indicadores como ingreso por viaje, ingreso por milla o distribución de propinas.

Los Yellow Taxi también han sido ampliamente estudiados en la literatura. Hochmair utilizó decenas de millones de registros para analizar variaciones espacio-temporales, infraestructuras de transporte y velocidad de viaje [6]. Safikhani et al. formularon la demanda como un proceso espacio-temporal y evaluaron modelos autorregresivos con regularización sobre datos de taxi amarillo de Nueva York [12]. A partir de estos trabajos, el TFM adopta dos decisiones: utilizar la zona y la hora como unidades fundamentales y considerar la dependencia temporal como una fuente principal de capacidad predictiva.

2.4 Green Taxi

Los Green Taxi o *Street Hail Livery* fueron concebidos para ampliar el servicio de recogida en zonas tradicionalmente menos cubiertas por los taxis amarillos. Desde la perspectiva analítica, permiten comparar patrones geográficos y económicos con Yellow Taxi utilizando un esquema parcialmente similar, aunque no idéntico.

El proyecto evita forzar ambos servicios a compartir todas las columnas. En Silver se define un núcleo semántico común —tipo de servicio, fecha de recogida, fecha de bajada, zonas, duración y campos económicos homologables—, mientras que los atributos específicos permanecen disponibles en modelos auxiliares cuando aportan información. De esta manera, la comparabilidad no exige eliminar las particularidades de cada fuente.

2.5 For-Hire Vehicles

La categoría FHV agrupa servicios de vehículos de alquiler con conductor gestionados mediante bases de despacho. La información publicada no contiene necesariamente el mismo nivel tarifario que los taxis tradicionales y su esquema ha evolucionado con las obligaciones regulatorias. Por ello, su principal utilidad dentro de este trabajo se centra en la movilidad y la demanda, no en una comparación económica campo a campo.

Esta asimetría ejemplifica un principio general del proyecto: un modelo común debe basarse en significados equivalentes y no en nombres de columna aparentemente parecidos. Las transformaciones de Silver incorporan una matriz de correspondencia de campos y reglas por servicio y periodo, de forma que cada atributo compartido tenga una definición explícita.

2.6 High Volume For-Hire Vehicles

Los HVFHV representan servicios de alto volumen asociados al crecimiento de plataformas de movilidad bajo demanda. La TLC publica desde 2019 un conjunto separado y más detallado para esta categoría [9]. Esta diferencia temporal implica que el análisis 2018–2025 no puede presentar una serie HVFHV completa desde 2018. El periodo previo sirve para Yellow, Green y FHV, mientras que las comparaciones que involucren HVFHV comienzan cuando existe cobertura específica.

La incorporación de HVFHV es relevante porque la estructura del mercado de movilidad de Nueva York ha cambiado con la expansión de las plataformas de *ride-hailing*. Trabajos previos han observado diferencias espaciales y temporales entre taxis tradicionales y servicios basados en aplicaciones, y han señalado la necesidad de considerar simultáneamente dependencias espaciales y temporales [5, 13].

2.7 Taxi Zones y representación espacial

La TLC utiliza un sistema de zonas para representar orígenes y destinos. La guía oficial proporciona tanto una tabla de correspondencias como geometrías de las zonas, aproximadamente basadas en áreas vecinales de la ciudad [10]. Esta representación es especialmente adecuada para el presente trabajo por tres motivos.

En primer lugar, reduce la complejidad asociada a coordenadas GPS individuales y proporciona una taxonomía estable para agregación. En segundo lugar, puede conectarse directamente con los identificadores de zona incluidos en los ficheros modernos. En tercer lugar, facilita la construcción de visualizaciones geográficas y rankings comprensibles para un usuario de negocio.

La unidad espacial principal del modelo predictivo es la zona de recogida. Para cada combinación de servicio, zona y hora se calcula el número de viajes iniciados. Las zonas sin viajes deben representarse explícitamente con demanda cero cuando formen parte del universo analizado; de lo contrario, el dataset de entrenamiento estaría sesgado hacia observaciones positivas.

2.8 Dimensión temporal y estacionalidad

La demanda de transporte presenta ciclos de distinta escala. La hora del día captura patrones de entrada y salida laboral, ocio nocturno y movilidad hacia aeropuertos. El día de la semana distingue jornadas laborales de fines de semana. El mes y la estación recogen efectos de clima y actividad turística. Los festivos introducen excepciones recurrentes que no quedan bien descritas únicamente con el número de día.

La dimensión temporal de Gold se diseña para representar estas propiedades de manera explícita. Además de atributos categóricos, el modelado puede incorporar codificaciones cíclicas. Para una variable periódica de periodo P , como la hora del día, se definen:

$$x_{\sin} = \sin\left(2\pi\frac{x}{P}\right), \quad x_{\cos} = \cos\left(2\pi\frac{x}{P}\right). \quad (2.1)$$

Esta representación evita que la distancia numérica entre las 23:00 y las 00:00 sea artificialmente elevada y permite a modelos lineales capturar parte de la periodicidad.

2.9 Impacto de la pandemia de COVID-19

La selección de 2018 como inicio del periodo responde principalmente a la posibilidad de disponer de una base pre-pandemia suficientemente amplia. La pandemia provocó cambios extraordinarios en la movilidad urbana desde 2020. En el caso de Nueva York, investigaciones recientes han analizado específicamente el impacto espacio-temporal de COVID-19 sobre la demanda de taxi, encontrando que sus efectos no fueron homogéneos entre zonas y que variables urbanas y epidemiológicas contribuyeron a explicar la variación [14].

En este TFM el efecto de la pandemia se estudia desde una perspectiva descriptiva y temporal. No se pretende identificar causalidad entre políticas concretas y cambios de demanda. Se comparan niveles, distribución geográfica y ritmos de recuperación entre servicios, utilizando periodos predefinidos y evitando atribuir a COVID-19 cualquier variación que pueda estar asociada a otros factores.

Una consecuencia importante para el machine learning es la presencia de un cambio de régimen. Un modelo entrenado únicamente con años previos a 2020 puede fallar de forma extrema durante la disrupción; un modelo entrenado con todo el periodo puede aprender comportamientos que mezclan contextos heterogéneos. Por ello, el capítulo experimental deberá reportar explícitamente la composición temporal de entrenamiento, validación y test y, cuando sea útil, resultados segmentados por periodos.

2.10 Meteorología y factores externos

La demanda de taxi puede estar relacionada con condiciones meteorológicas, aunque el efecto no es necesariamente lineal ni idéntico en todos los servicios. La literatura sobre predicción de demanda de taxi considera habitualmente variables externas como meteorología, calendario o uso del suelo [12, 7]. El proyecto incorpora una fuente meteorológica oficial de NOAA/NCEI con granularidad compatible con la agregación temporal, siempre que el pipeline final garantice su disponibilidad y trazabilidad [8].

Entre las variables candidatas se incluyen temperatura, precipitación, nieve, viento y visibilidad. El objetivo no es crear un modelo meteorológico, sino representar condiciones que puedan modificar la preferencia relativa por un servicio de transporte. Las variables se agregan a escala horaria o diaria según la fuente y se documenta el método de alineación temporal.

2.11 Preguntas de negocio

La capa analítica se diseña para responder cuatro grupos de preguntas.

2.11.1. Evolución de la movilidad

¿Qué volumen de viajes se realiza por servicio, año, mes, día y hora? ¿Cómo cambia a lo largo del tiempo la participación relativa de los cuatro servicios analizados? ¿Qué diferencias aparecen antes, durante y después de 2020?

2.11.2. Distribución geográfica

¿Qué zonas concentran más recogidas y destinos? ¿Existen zonas cuyo patrón depende especialmente de una franja temporal? ¿Cómo cambia la distribución entre boroughs y servicios?

2.11.3. Rendimiento operativo y económico

Para los servicios con información de tarifa suficiente, ¿qué zonas y franjas presentan mayores ingresos observados por viaje, milla u hora ocupada? ¿Qué combinaciones ofrecen una relación favorable entre demanda y duración? Estas métricas no equivalen a beneficio neto, pero sirven para describir oportunidades relativas.

2.11.4. Predicción de demanda

Dado el historial disponible hasta un instante t , ¿cuántos viajes se iniciarán en cada zona una hora más tarde y veinticuatro horas más tarde? ¿Qué modelo mantiene mejor rendimiento fuera de muestra? ¿El modelo ganador es el mismo para todos los servicios?

2.12 Del análisis descriptivo al producto analítico

El propósito final no es producir únicamente gráficos estáticos, sino transformar las preguntas anteriores en activos reutilizables. Cada KPI debe estar asociado a una tabla Gold o a una definición SQL reproducible; cada dashboard debe consumir modelos documentados; y cada predicción debe persistir junto con el modelo, horizonte y fecha de generación. Esta disciplina conecta el análisis de movilidad con la ingeniería de datos y constituye uno de los elementos diferenciales del proyecto.

Bibliografía

- [1] Apache Software Foundation. Apache superset documentation.
- [2] Databricks. What is the medallion lakehouse architecture?
- [3] dbt Labs. dbt developer hub.
- [4] Docker, Inc. Docker compose documentation.
- [5] Sabiheh Sadat Faghih, Abolfazl Safikhani, Bahman Moghimi, and Camille Kamga. Predicting short-term uber demand in new york city using spatiotemporal modeling. *Journal of Computing in Civil Engineering*, 33(3), 2019.
- [6] Hartwig H. Hochmair. Spatiotemporal pattern analysis of taxi trips in new york city. *Transportation Research Record*, 2542(1), 2016.
- [7] Manik Mondal, Kazushi Sano, Teppei Kato, Chonnipa Puppateravanit, and Tomonori Watari. Predicting taxi demand in urban areas by the application of hybrid machine learning algorithm. *Journal of the Eastern Asia Society for Transportation Studies*, 15:1009–1028, 2024.
- [8] National Centers for Environmental Information. Climate data online and historical climate data.
- [9] New York City Taxi and Limousine Commission. Tlc trip record data. Portal oficial de datos de viajes.
- [10] New York City Taxi and Limousine Commission. Tlc trip records user guide.
- [11] A. P. Riascos and José L. Mateos. Networks and long-range mobility in cities: A study of more than one billion taxi trips in new york city. *Scientific Reports*, 10:4022, 2020.
- [12] Abolfazl Safikhani, Camille Kamga, Sandeep Mudigonda, Sabiheh Sadat Faghih, and Bahman Moghimi. Spatio-temporal modeling of yellow taxi demands in new york city using generalized star models. *International Journal of Forecasting*, 36(3):1138–1148, 2020.
- [13] Patrick Toman, Jingyue Zhang, Nalini Ravishanker, and Karthik Konduri. Spatio-temporal analysis of ridesourcing and taxi demand by taxi zones in new york city. *arXiv preprint arXiv:2008.00568*, 2020.
- [14] Yanan Zhang, Xueliang Sui, and Shen Zhang. Exploring spatio-temporal impact of covid-19 on citywide taxi demand: A case study of new york city. *PLOS ONE*, 19(4):e0299093, 2024.