



Universidad Politécnica
de Madrid

**Escuela Técnica Superior de
Ingenieros Informáticos**



Grado en Ciencia de Datos e Inteligencia Artificial

Trabajo Fin de Grado

Análisis de los trayectos en Uber en la ciudad de Nueva York

Autor: David Lázaró Martín

Tutor(a): Antonio Jesús Díaz Honrubia

Madrid, Junio, 2024

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado

Grado en Ciencia de Datos e Inteligencia Artificial

Título: Análisis de los trayectos en Uber en la ciudad de Nueva York

Junio, 2024

Autor: David Lázaró Martín

Tutor: Antonio Jesús Díaz Honrubia

Departamento de Lenguajes y Sistemas Informáticos e Ingeniería de Software

Escuela Técnica Superior de Ingenieros Informáticos

Universidad Politécnica de Madrid

Resumen

En los últimos años, la proliferación de servicios de vehículos de transporte con conductor (VTC) ha transformado significativamente la movilidad urbana. Entre estos servicios, Uber se ha consolidado como una de las principales opciones a nivel global. La ciudad de Nueva York es el lugar perfecto para analizar esta tendencia y ayudar a Uber a poder mantener y mejorar su posición en el mercado. Se ha observado la ineficiencia de los taxis y VTC al pasar la mayor parte de su tiempo sin pasajeros a bordo. La motivación principal de este proyecto se encuentra precisamente en la potencial mejora de la eficiencia y la calidad del servicio de Uber mediante el análisis de datos. Utilizar un enfoque basado en datos para la toma de decisiones permite responder de manera más precisa a las necesidades de sus usuarios para así mejorar su satisfacción.

El principal desafío que se ha encontrado en este proyecto es la gestión y el análisis de grandes volúmenes de datos generados por los servicios de Uber en Nueva York. Estos datos incluyen información sobre la ubicación, hora y día o datos de otras empresas. Además, se han combinado con datos externos como datos meteorológicos o datos sobre las zonas o barrios de la ciudad. La variedad y cantidad de los datos, supone un reto que ha requerido del uso de diferentes tecnologías para procesarlos y analizarlos de manera efectiva.

El resultado del proyecto ha sido un dashboard o informe publicado en la web con el que se han podido extraer conclusiones que responden a las principales cuestiones planteadas. En primer lugar, se identifican fluctuaciones en la demanda de servicios de Uber a lo largo del día, la semana y el año, mostrando picos de demanda durante las horas de entrada y salida del trabajo, así como una estacionalidad en los datos por semana. Geográficamente, se han mapeado las zonas con mayor y menor demanda de servicios de Uber, destacando áreas como Manhattan y Brooklyn con alta concentración de viajes. Además, con los datos presentes y sin combinarse con el resto de variables, no se puede advertir una correlación entre la meteorología y la demanda de viajes. Con respecto a otras empresas, el análisis comparativo muestra la ventaja competitiva de Uber en términos de número de viajes, aunque se advierten posibles áreas de mejora en ciertos días de la semana.

En conclusión, este proyecto demuestra el valor del análisis de datos en la mejora de los servicios de transporte urbano. Los insights obtenidos no solo ayudan a Uber a optimizar sus operaciones, sino que también contribuyen a una mejor comprensión de la movilidad urbana en Nueva York.

Abstract

In recent years, the proliferation of ride-hailing services (VTC) has significantly transformed urban mobility. Among these services, Uber has established itself as one of the leading options globally. New York City is the perfect place to analyse this trend and help Uber maintain and improve its market position. The inefficiency of taxis and VTCs has been observed as they spend most of their time without passengers on board. The main motivation for this project lies precisely in the potential improvement of Uber's efficiency and service quality through data analytics. Using a data-driven approach to decision making allows it to respond more accurately to the needs of its users to improve their satisfaction.

The main challenge encountered in this project is the management and analysis of large volumes of data generated by Uber services in New York. This data includes information on location, time and day or data from other companies. In addition, they have been combined with external data such as weather data or data of the areas or neighbourhoods of the city. The variety and quantity of the data is a challenge that have required the use of different technologies to process and analyse it effectively.

The result of the project has been a dashboard or report published on the website, which has enabled conclusions to be drawn that respond to the main questions posed. Firstly, fluctuations in the demand for Uber services throughout the day, week and year are identified, showing peaks in demand during the hours of arrival and departure from work, as well as a marked seasonality per week. Geographically, the areas with the highest and lowest demand for Uber services have been mapped, highlighting areas such as Manhattan and Brooklyn with a high concentration of trips. Furthermore, with the data present and without combining it with the rest of the variables, no correlation between weather and trip demand can be observed. Compared to other companies, benchmarking shows that Uber has a competitive advantage in terms of number of trips, although there are areas for improvement on certain days of the week.

In conclusion, this project demonstrates the value of data analysis in improving urban transport services. The insights gained not only help Uber to optimise its operations, but also contribute to a better understanding of urban mobility in New York.

Tabla de contenidos

1. Introducción	1
1.1. Motivación y alcance	2
1.2. Objetivos de negocio	3
1.3. Metodología (CRISP-DM)	5
1.3.1. Entendimiento del negocio	6
1.3.2. Entendimiento de los datos	6
1.3.3. Preparación de los datos	6
1.3.4. Modelado	7
1.3.5. Evaluación	7
1.3.6. Despliegue	7
1.4. Plan de trabajo	7
1.5. Estructura de la memoria	8
2. Tecnologías	9
2.1. Python	10
2.1.1. Pandas \ Geopandas	11
2.1.2. RegEx (RE)	12
2.1.3. Matplotlib	12
2.2. Open Street Maps	13
2.3. Power BI	14
2.3.1. Ventajas de la utilización de Power Bi	15
2.4. Alternativas	16
2.4.1. Lenguajes de programación	16
2.4.2. Bibliotecas para limpieza e integración de datos	16
2.4.3. Bibliotecas de visualización	17
2.4.4. Plataformas de Business Intelligence	17
3. Procesado de los datos	19
3.1. Comprensión del negocio (Business Understanding)	19
3.2. Comprensión de los Datos (Data Understanding)	20
3.3. Preparación de los datos (Data Preparation)	23
3.4. Modelado (Modeling)	26
3.5. Evaluación (Evaluation)	28
3.5.1. Análisis general	30
3.5.2. Dimensión tiempo	30
3.5.3. Dimensión localización	33

TABLA DE CONTENIDOS

3.5.4. Dimensión meteorología	34
3.5.5. Dimensión empresa	36
3.6. Despliegue (Deployment)	37
4. Conclusiones y trabajo futuro	39
4.1. Conclusiones	39
4.2. Trabajo futuro	40
5. Análisis de impacto	43
5.1. Impacto empresarial	43
5.2. Impacto social	43
5.3. Impacto medioambiental	44
5.4. Impacto cultural	44
Bibliografía	45

Índice de figuras

1.1. Average daily taxi/VTC trips in New York City by Month	1
1.2. Plan de trabajo	8
2.1. Cuadrante Mágico de Gartner, 2023	15
3.1. Distribución del número de viajes entre enero y junio de 2015 por código de base	22
3.2. Estructura del archivo ' uber-raw-data-janjune-15.csv'	22
3.3. Estructura del archivo ' uber-raw-data-apr14.csv'	23
3.4. Datos presentes en los ficheros que no pertenecen a ninguna zona de la ciudad de Nueva York	24
3.5. Estructura del fichero 'American-B01362.csv'	25
3.6. Modelo de datos	28
3.7. Pantalla 1: Evolución en el tiempo de los viajes de Uber	31
3.8. Pantalla 2	32
3.9. Pantalla 3: Análisis geográfico de la demanda	33
3.10 Datos sobre la población por distrito de la ciudad de Nueva York .	34
3.11 Pantalla 4: Análisis de la demanda con respecto a la climatología .	35
3.12 Pantalla 5: Comparación de los datos de la competencia con res- pecto a Uber	36

Capítulo 1

Introducción

En los últimos años, debido a la aparición y expansión de servicios de vehículos de transporte con conductor (VTC), se ha observado un cambio en la forma en que las personas se desplazan en entornos urbanos. En este contexto, la ciudad de Nueva York, con una gran densidad poblacional y, por consiguiente, su gran complejidad logística, es uno de los mejores lugares donde analizar esta tendencia.

Dentro de estos servicios, Uber se ha posicionado como uno de los actores fundamentales, con más de 137 millones de usuarios en todo el mundo según los datos de la compañía. Solamente entre 2014 y 2015, en Nueva York, los viajes de Uber crecieron en 10 millones, un 233.3% más que en el año anterior, mientras que los viajes en taxi descendieron en 800.000, un 1% menos [1].




Figura 1.1: Average daily taxi/VTC trips in New York City by Month

Como se puede ver en la figura 1.1, más de 600.000 viajes se llevan a cabo cada día entre taxis y VTCs en la ciudad de Nueva York, siendo Uber la principal elección entre los usuarios. Otra observación que se advierte en el gráfico es este descenso en el uso de los taxis en favor de los VTCs, interrumpido en 2020 por la pandemia, pero que perdura en la actualidad.

1.1. Motivación y alcance

La movilidad urbana es un aspecto clave en la vida contemporánea. Es un importante factor en la forma en la que nos desplazamos, en nuestra percepción del tiempo y el espacio en la ciudad, y en la calidad de vida. Los servicios de vehículos de transporte con conductor, como Uber, están desempeñando un papel importante en la transformación de esta movilidad y de los hábitos de sus usuarios. Sin embargo, al mismo tiempo que estos servicios ganan popularidad, crece a su vez la necesidad de comprender más profundamente los patrones y las tendencias de estos servicios, especialmente en ciudades densamente pobladas como Nueva York.

Un estudio realizado en el área urbana de Taipei, reveló que los taxis de la ciudad estaban vacíos entre un 60 y un 73 % del tiempo [2]. Este tiempo era empleado en la búsqueda de clientes o el regreso de los viajes realizados. Las cifras muestran el alcance que puede tener una optimización del tiempo de estos conductores a la hora de maximizar el beneficio de la empresa, sin olvidar la mejora en la calidad de su servicio. La motivación detrás de este trabajo se encuentra en el potencial del análisis de la inmensa cantidad de datos que producen estas empresas como factor fundamental a la hora de la toma de decisiones.

La toma de decisiones basada en datos (Data-Driven Decision making) se puede definir como "la práctica de basar la toma de decisiones en el análisis de los datos y no en la pura intuición"[3]. Este uso de los datos, ayuda a empresas como Uber a poder responder mejor a las necesidades de los usuarios, optimizando el funcionamiento de sus aplicaciones, y mejorando la eficiencia y la sostenibilidad en sus servicios. La suma de estos factores, deriva en un mejor servicio y, por consiguiente, una mayor satisfacción de los usuarios.

El concepto de Big Data es esencial para comprender la magnitud de los desafíos que encuentran las empresas en la gestión y análisis de sus datos. Según el profesor Kumar Bandyopadhyay, de la Universidad de Calcuta [4], "Big data es un término que se refiere a conjuntos de datos o combinaciones de conjuntos de datos cuyo tamaño (volumen), complejidad (variabilidad) y tasa de crecimiento (velocidad) los hacen difíciles de capturar, gestionar, procesar o analizar con tecnologías y herramientas convencionales, como bases de datos relacionales y paquetes de estadísticas o visualización de escritorio, dentro del tiempo necesario para hacerlos útiles".

Este es precisamente el problema que supone implementar soluciones para la utilización de los datos en los entornos empresariales modernos. La variedad, cantidad y velocidad con las que se producen los datos (comúnmente denominado las 3 V del Big Data: Volume, Variety, Velocity) son factores que hacen del análisis una tarea compleja que conlleva la utilización de diversas tecnologías y recursos para poder ofrecer la información de la forma más precisa posible.

Sin embargo, más allá de la tecnología, no se debe perder de vista que las decisiones van a ser tomadas por directivos y personal de gestión de la empresa. Por lo tanto, la visualización juega un papel vital en este proceso, ya que permite presentar la información también de manera visual e intuitiva para que esta toma de decisiones sea rápida y efectiva.

1.2. Objetivos de negocio

El objetivo general de este trabajo es mejorar la eficiencia y la calidad del servicio Uber en la ciudad de Nueva York, mediante el análisis de los patrones y tendencias de movilidad de sus usuarios.

Para lograr este objetivo, se ha desarrollado un enfoque que abarca desde la recopilación y análisis de datos hasta la implementación de soluciones prácticas para obtener diferentes insights. Se han empleado herramientas avanzadas de análisis de datos, como técnicas de minería de datos, para identificar patrones y tendencias significativas en el comportamiento de los usuarios y en la demanda de servicios de VTC.

El análisis de datos se ha complementado con el desarrollo de un dashboard interactivo como producto final, que permite a los directivos, el personal de gestión de Uber, e incluso conductores y futuros conductores, visualizar y explorar los datos de manera intuitiva. Este dashboard proporciona acceso a visualizaciones dinámicas de los patrones de demanda, la utilización de vehículos y otros indicadores clave de rendimiento. Con base en los insights obtenidos a través del análisis y el uso del dashboard, se propondrán estrategias y medidas específicas orientadas a mejorar la eficiencia operativa y la experiencia del usuario.

Las dimensiones sobre las que se van a evaluar estos viajes definen los objetivos específicos que se han conseguido con este proyecto.

1. **Análisis de los patrones de demanda en función del tiempo:** se ha llevado a cabo un análisis exhaustivo de los datos de viajes históricos para identificar y comprender los patrones de demanda de los servicios de transporte con conductor en diferentes momentos del día, días de la semana o el año. Observando la evolución, estacionalidad y las tendencias que ha llevado la demanda respecto al tiempo, podemos estimar la ocupación de

estos servicios en el futuro, dependiendo de la época del año o momento del día. Esta información es muy útil para los conductores, ya que pueden distribuir su tiempo de trabajo de la manera más óptima posible.

2. **Análisis de los patrones de demanda en función de la zona geográfica:** un insight fundamental para los VTCs y sus conductores son las zonas geográficas con mayor y menor demanda. Por lo tanto, el análisis de esta respecto de las diferentes zonas de la ciudad es un factor que no puede faltar en el reporte. Siendo consciente de la heterogeneidad de la ciudad de Nueva York en términos de densidad de población, actividades económicas y características geográficas, se lleva a cabo un análisis detallado de los patrones de demanda de transporte con conductor en cada una de estas zonas geográficas. Por medio de la utilización de datos geoespaciales, se han identificado áreas de mayor demanda y las variaciones temporales en la actividad de cada región. Este enfoque permite adaptar estratégicamente la oferta y asignar los recursos de la mejor manera posible para satisfacer las necesidades específicas de cada zona, mejorando así la eficiencia operativa y la calidad del servicio para nuestros usuarios en toda la ciudad.
3. **Análisis de los patrones de demanda en función de la meteorología:** la meteorología tiene un papel muy importante en la movilidad urbana, siendo un factor diferencial que influye en los hábitos de desplazamiento de los usuarios. Debido a esta relevancia, se ha integrado el análisis de datos meteorológicos en nuestra evaluación de tendencias en la demanda de transporte con conductor. Este enfoque permite comprender cómo las condiciones climáticas afectan a la demanda de transporte en diferentes momentos y áreas de la ciudad.
4. **Análisis de los patrones de demanda en la competencia:** en un mercado tan competitivo como el de los VTCs, es importante comprender no solo los patrones de demanda de los servicios de una empresa, sino también los de la competencia. Por ello, se lleva a cabo un análisis de los datos de demanda no sólo de Uber, sino también de otras empresas que operan en la ciudad de Nueva York. Este análisis permite identificar las fortalezas y debilidades de nuestros competidores, así como las oportunidades presentes en el mercado.

Al comprender los patrones de demanda de la competencia, podemos ajustar nuestra oferta y nuestras tarifas para ser más competitivos. Además, este análisis nos proporciona información valiosa sobre las preferencias y comportamientos de los usuarios, lo que permite desarrollar estrategias de marketing y fidelización de clientes más efectivas. El objetivo final de analizar la competencia es utilizar este análisis para diferenciarnos en el mercado y ofrecer un servicio que satisfaga las necesidades específicas de nuestros usuarios de manera más efectiva que nuestros competidores.

5. **Promover la sostenibilidad:** Uber es una empresa que se caracteriza por promover el transporte sostenible, usando en su mayoría vehículos híbridos o eléctricos. Al mejorar sus servicios, también se fomenta la movilidad sostenible y se reduce el impacto ambiental, algo beneficioso para toda la población. Por otro lado, optimizar los patrones de demanda y asignar los recursos de manera más eficiente, contribuye significativamente a la reducción de las emisiones de gases de efecto invernadero y la contaminación del aire en la ciudad de Nueva York. Con servicios más eficientes y atractivos, se incentiva a más personas a optar por alternativas de transporte sostenible, como compartir viajes en vehículos eléctricos, en lugar de depender exclusivamente de vehículos privados o menos eficientes desde el punto de vista ambiental.

En resumen, el objetivo general de este trabajo es la generación de un dashboard que sirva para impulsar mejoras significativas en la eficiencia y la calidad del servicio de vehículos de transporte con conductor en la ciudad de Nueva York. Para ello, se analizan los datos en función de varias dimensiones, con lo que se pretende obtener la mayor cantidad de información posible y conseguir evaluar todos los factores que afectan a estos viajes. Al poder entender mejor estos patrones de movilidad de los usuarios y tomar decisiones basadas en los datos, Uber y sus conductores estarán mejor posicionados para satisfacer las necesidades de sus usuarios y mejorar su competitividad en el mercado de transporte urbano.

1.3. Metodología (CRISP-DM)

Para que cualquier proyecto llegue a buen puerto, es muy importante seguir una metodología adecuada. El objetivo de seguir una metodología es garantizar la calidad y el rigor del análisis, así como la estructuración del trabajo durante el proceso. Para abordar este proyecto, se ha utilizado la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining) [5], un estándar ampliamente conocido en la industria para desarrollar proyectos de análisis de datos y extracción de conocimientos. CRISP-DM proporciona un marco de trabajo estructurado y flexible que abarca todas las etapas de este proceso; desde la comprensión del negocio y los datos, hasta la evaluación y el despliegue de los resultados. Esta metodología es especialmente relevante en el contexto del análisis de datos de movilidad urbana, ya que permite abordar los desafíos específicos de este campo, como la gran cantidad de datos generados por los servicios de VTC, la necesidad de integrar datos de diversas fuentes y la importancia de obtener resultados para la toma de decisiones.

A continuación, se detalla el cómo se ha aplicado cada fase de la metodología CRISP-DM a este proyecto específico. Se describen las tareas realizadas, las herramientas y técnicas que se han utilizado, y los resultados de cada etapa. Los detalles técnicos se explican en capítulos posteriores.

1.3.1. Entendimiento del negocio

El primer paso de esta metodología es comprender los objetivos de este proyecto. En este caso, el objetivo principal es analizar y visualizar los datos de viajes de Uber y otros VTC en la ciudad de Nueva York para obtener información sobre patrones de movilidad, la oferta y la demanda, y otros factores que afectan los precios. Para lograr esto, se ha intentado responder a preguntas clave como:

1. ¿Cuáles son las horas de mayor demanda de VTC en Nueva York?
2. ¿Cómo varía la demanda de los viajes según la zona de la ciudad?
3. ¿Existen patrones de movilidad específicos en función de eventos especiales o condiciones climáticas?
4. ¿Cuál es la relación o diferencias entre el número de viajes de Uber con respecto a la competencia?

La utilidad de este proyecto se basa en la capacidad de responder a estas preguntas de manera clara y concisa, proporcionando visualizaciones y diferentes KPIs (Key Performance Indicator) respaldados por el análisis de los datos. Además, los resultados de este proyecto pueden ser utilizados para futuras investigaciones o aplicaciones prácticas en este ámbito de la movilidad urbana.

1.3.2. Entendimiento de los datos

Esta fase engloba la elección, recopilación y descripción de los datos necesarios para el análisis. En el proyecto, se ha utilizado un conjunto de datos proveniente de [Kaggle](#). Este dataset está compuesto por 19 ficheros con datos de Uber y diferentes empresas de alquiler de vehículos con conductor. Estos datos han sido tomados de la página oficial de la comisión de taxis y limusinas de Nueva York ([NYC Taxi and Limousine Commission \(TLC\)](#)) Los datos son muy variados y cada uno de los ficheros contiene información diferente. Esto ha complicado el análisis, pero la información más relevante se ha podido extraer de todos ellos: la hora del día del viaje y la zona o dirección de recogida. Con esta información, unida a otras fuentes externas de zonas de la ciudad o meteorología, se han podido explorar los datos para identificar valores atípicos, datos nulos o posibles errores. Este primer análisis se denomina EDA (Exploratory Data Analysis) y se ha realizado en Python.

1.3.3. Preparación de los datos

Esta es una de las fases más importantes del desarrollo del proyecto fuera exitoso. En esta fase, se han limpiado y transformado los datos para prepararlos para su análisis y su visualización. Se han tratado los valores atípicos, los datos nulos y los errores identificados en la fase anterior. Además, se han integrado las diferentes fuentes (los 19 ficheros) para poder facilitar su análisis y uso. Esto es también fundamental para poder ajustar nuestros datos al modelo elegido.

1.3.4. Modelado

Junto con la fase anterior, el modelado es la parte más importante y crítica de este tipo de proyectos. Un mal modelado supone problemas de optimización de espacio y velocidad de carga. En este caso, se ha utilizado un modelo multidimensional, una técnica ampliamente utilizada en proyectos de Big Data debido a su capacidad para manejar grandes volúmenes de datos y analizar múltiples dimensiones simultáneamente. Este enfoque permite establecer relaciones entre las diferentes variables y tablas, como la ubicación o el tiempo, lo que ayuda a comprender los factores que influyen en la demanda y su interrelación.

El modelo multidimensional se construye utilizando las variables relevantes identificadas en la fase de preparación de datos; Se definen las dimensiones como la ubicación, el tiempo (hora del día, día de la semana, mes) y otras características relevantes del viaje.; y Se calculan métricas como el número de viajes, variación por días o casos relevantes para cada combinación de dimensiones. El modelo resultante permite tanto realizar consultas y análisis complejos, como visualizarlos fácilmente. Este proceso de modelado, junto con la visualización, se ha llevado a cabo en Power BI.

1.3.5. Evaluación

En esta fase, se han evaluado los resultados de las visualizaciones determinado si cumplen con los objetivos establecidos. Esto incluye la interpretación de los resultados y extracción de conclusiones importantes para las partes implicadas.

1.3.6. Despliegue

Esta es la fase final del proyecto. En ella, se presentan los resultados del análisis y se comunican las conclusiones a las partes interesadas. En este caso, el reporte generado se ha publicado en Power BI Service, donde es accesible y los usuarios pueden interaccionar con él.

1.4. Plan de trabajo

En este Trabajo de Fin de Grado, se busca comprender mejor cómo funcionan la demanda de viajes en Uber en Nueva York, para tomar decisiones más informadas sobre el transporte en la ciudad. Se han usado diversas fuentes de datos relacionadas con los viajes de Uber en Nueva York, creando un modelo común que unifica las diferentes fuentes. Luego, se han aplicado técnicas avanzadas de minería de datos para extraer información valiosa y patrones significativos.

El diagrama de Gantt presentado en la Figura 1.2 muestra la distribución de las tareas a lo largo del tiempo para conseguir estos objetivos. Comienza con la unificación de datos, seguida del análisis de los mismos. Después, se integran datos externos y se sacan conclusiones prácticas. Finalmente, se crea un panel de visualización para presentar los resultados. Cabe destacar que, como se

Capítulo 1. Introducción

puede ver en la Figura 1.2, las tareas se pueden solapar debido a la iteración constante entre las fases para conseguir un buen desarrollo final.




Figura 1.2: Plan de trabajo

El diagrama de Gantt se ha modificado respecto a las primeras estimaciones para reflejar el aumento del tiempo dedicado a la integración de datos debido a las diferencias entre las fuentes. También, se ha retrasado la parte de las conclusiones y se ha añadido un parte de la integración con fuentes externas.

En resumen, el plan de trabajo refleja lo que es un proyecto en la vida real, con fechas límites, complicaciones y modificaciones. Sin embargo, se ha cumplido con los objetivos impuestos y se han obtenido unos buenos resultados.

1.5. Estructura de la memoria

En esta sección, se explica brevemente la estructura que sigue esta memoria. El resto de la memoria consta de 5 capítulos, cada uno de ellos abordando un aspecto clave del proyecto.

- Tecnologías: Se presentan las herramientas tecnológicas utilizadas en el proyecto, como Python y Power BI, justificando su elección y mencionando posibles alternativas.
- Procesado de los datos: Se describe en detalle el proceso de diseño y tratamiento de los datos, incluyendo el modelo del sistema y las técnicas de visualización empleadas.
- Evaluación: Se evalúan los resultados obtenidos mediante las técnicas de modelado y visualización, analizando su utilidad y relevancia para los objetivos del proyecto.
- Conclusiones y trabajo futuro: Se resumen las principales conclusiones del trabajo, destacando los hallazgos más relevantes y las implicaciones para el negocio. Se proponen líneas de investigación futuras y posibles mejoras al proyecto.
- Análisis de impacto: Se analiza el potencial impacto del proyecto en el ámbito de la movilidad urbana y se discuten las posibles aplicaciones prácticas de los resultados obtenidos.

Capítulo 2

Tecnologías

El papel de la tecnología en el análisis de datos es fundamental a la hora de aprovechar al máximo la información disponible y derivar conclusiones significativas de estos. En la era digital, se producen una gran cantidad de datos. La tecnología proporciona las herramientas necesarias para recopilar, almacenar, procesar y analizar estos datos de manera eficiente y efectiva.

A continuación, se va a detallar el papel que tiene la tecnología en cada uno de los aspectos nombrados anteriormente, indicando particularmente su utilidad en este proyecto concreto.

En primer lugar, la tecnología permite recoger datos de una gran variedad de fuentes, incluidas bases de datos, sensores, dispositivos móviles e internet, entre otros. Esto proporciona una amplia y diversa visión de la realidad que queremos estudiar. En este caso, los datos de cada viaje se recogen por medio de la aplicación de la empresa, a la que los conductores acceden desde sus dispositivos. Entre estos datos, se encuentra información sobre la geolocalización de los vehículos, que se recogen por medio de sensores IoT situados en estos.

Una vez se han recopilado los datos necesarios, la tecnología ayuda también a almacenarlos de manera segura y accesible. Los sistemas de gestión de bases de datos y almacenamiento en la nube permiten organizar grandes volúmenes de datos, lo que permite su posterior análisis y consulta. En este caso, estas dos etapas del ciclo de vida de los datos quedan fuera del alcance del proyecto, ya que se tiene acceso a los archivos con los datos ya generados. La tecnología juega también un papel fundamental al permitir integrar estos datos en una fuente única que facilite su análisis. Los datos tienen formatos muy diferentes, errores o inconsistencias que permite corregir para un análisis óptimo.

Una vez tenemos esta fuente única, se pueden procesar y analizar los datos de manera eficiente. Desde técnicas de minería de datos, hasta algoritmos de aprendizaje automático y estadísticas avanzadas; estas herramientas permiten identificar patrones, tendencias y relaciones dentro de los datos que pueden no ser evidentes a simple vista, y que proporcionan la información necesaria para poder tomar las mejores decisiones.

En este proceso de toma de decisiones, la visualización y presentación de los resultados es una parte vital. Las decisiones de gestión en las empresas no son tomadas por los analistas, sino que su función es presentar los datos de una manera atractiva e intuitiva a los gerentes, que son los que realmente tienen el poder de decisión, para que puedan aprovechar la información que se extraen de ellos. Las herramientas de visualización de datos permiten crear gráficos, tablas y paneles interactivos que facilitan la comunicación de conclusiones y descubrimientos de manera clara, precisa y efectiva.

En resumen, la tecnología desempeña un papel fundamental en todo el proceso de análisis de datos, desde la recopilación hasta la presentación de resultados. Al aprovechar las herramientas y plataformas tecnológicas adecuadas, se puede obtener información valiosa y derivar conclusiones significativas que favorezcan la correcta toma de decisiones. A continuación, se describirán las principales tecnologías utilizadas en este proyecto, incluyendo algunas alternativas y los motivos de las decisiones tomadas.

2.1. Python

Python [6], un lenguaje de programación de alto nivel conocido por su legibilidad y versatilidad. Ha emergido como una herramienta fundamental en el campo de la ciencia de datos debido a su intuitiva sintaxis y su amplio abanico de bibliotecas especializadas. Esto lo convierte en una opción ideal para abordar los desafíos inherentes al análisis de datos moderno. La elección de este lenguaje se basa en una serie de ventajas técnicas y en la capacidad de Python para adaptarse a diversas tareas dentro del proceso de análisis.

1. **Legibilidad y facilidad de aprendizaje:** la sintaxis clara y concisa de Python reduce la curva de aprendizaje, permitiendo centrarse en el análisis de datos en lugar de en la complejidad del código. Aunque se disponía de conocimientos previos, un proyecto de esta magnitud siempre supone un reto a nivel técnico. Facilitar este aprendizaje y solución de problemas a nivel de código supone una gran ventaja para este lenguaje.
2. **Amplia gama de bibliotecas especializadas:** Python cuenta con un amplio ecosistema de bibliotecas diseñadas para tareas de ciencia de datos. Bibliotecas como Pandas, NumPy y Scikit-learn ofrecen herramientas para la manipulación de datos o el análisis estadístico, agilizando el proceso de desarrollo y análisis. En el resto de esta sección se explicarán algunas de las que han sido utilizadas en este proyecto
3. **Soporte para visualización de datos:** Python cuenta también con gran cantidad de bibliotecas como Matplotlib y Seaborn, que permiten crear visualizaciones informativas y atractivas. A pesar de las visualizaciones de resultados no han sido desarrolladas en Python, estas juegan un papel fundamental en la limpieza de los datos, permitiendo observar anomalías o casos especiales fácilmente por medio de gráficos de diverso tipo.

4. **Comunidad activa y recursos abundantes:** la comunidad de Python es grande y activa. Esto que garantiza un flujo constante de actualizaciones, mejoras y soporte. Además, existen numerosos recursos en línea, foros, tutoriales y documentación que facilitan la resolución de problemas.

En este proyecto, Python ha sido la piedra angular de la parte de limpieza e integración de los datos, proporcionando las herramientas y la flexibilidad necesarias para abordar los desafíos específicos del conjunto de datos, contribuyendo significativamente al éxito del proyecto. Algunas de las bibliotecas más importantes utilizadas han sido las siguientes.

2.1.1. Pandas \ Geopandas

La biblioteca más importante en este proyecto es Pandas, una biblioteca de Python que se encuentra entre las más usadas actualmente. La elección de pandas se basa en su capacidad para solventar las carencias de otras herramientas y en su amplio abanico de funcionalidades [7].

Pandas es una solución para estructurar conjuntos de datos y proporciona herramientas de análisis integradas en Python para trabajar con estos conjuntos. Para esto, Pandas introduce el DataFrame, una estructura de datos tabular análoga al data.frame de R, pero con mejoras sustanciales.

El DataFrame de pandas es una estructura de datos bidimensional con etiquetas en ambos ejes, capaz de almacenar datos de diversos tipos, lo que lo hace idóneo para conjuntos de datos heterogéneos comunes en la ciencia de datos. Cada eje del DataFrame posee un objeto Index que almacena información de etiquetado, lo que posibilita un acceso a los datos basado en etiquetas y una alineación automática de datos de alta eficiencia.

Algunas de las características principales son:

1. **Indexación jerárquica (MultiIndex):** esta característica permite representar datos multidimensionales en una estructura bidimensional, lo que facilita el análisis de datos complejos y la selección de subconjuntos a través de múltiples niveles de etiquetas.
2. **Manejo eficiente de datos nulos:** Pandas emplea NaN (Not a Number) para representar estos nulos y proporciona funciones para su manejo efectivo, como fillna (rellenar) y dropna (eliminar). Esto ha sido importante en este proyecto debido a la gran cantidad de valores erróneos y nulos que se tienen.
3. **Amplia gama de operaciones:** Pandas proporciona un extenso repertorio de operaciones para manipular y transformar datos, desde la limpieza y el preprocesamiento hasta la fusión (merge) y concatenación (concat) de conjuntos de datos.
4. **Rendimiento y escalabilidad:** si bien pandas introduce cierta sobrecarga en comparación con los arrays de NumPy, su flexibilidad y expresividad compensan con creces esta diferencia. Además, pandas ha sido optimiza-

do para trabajar con grandes volúmenes de datos, aumentando con parte crítica de su código fuente escrito en CPython o C. [8]

Como se ha explicado en apartados anteriores de esta memoria, una parte importante de este proyecto consiste en la utilización y análisis de datos geográficos. Estos datos, requieren de herramientas especiales para su tratamiento. GeoPandas es una biblioteca excelente para abordar esta necesidad, extendiendo las capacidades de pandas para trabajar con este tipo de datos de manera eficiente y efectiva.

GeoPandas introduce el concepto de GeoDataFrame, una extensión del DataFrame que incorpora una columna geométrica especial. Esta columna almacena objetos geométricos, como puntos (latitud, longitud), líneas y polígonos, que representan las ubicaciones y formas geográficas de los datos. Esta integración de datos tabulares y geometría permite realizar análisis espaciales y visualizar datos geoespaciales de manera intuitiva. Otro de los factores fundamentales para su uso es la posibilidad de leer formatos geoespaciales. GeoPandas facilita la importación y exportación de datos en formatos, como Shapefile, GeoJSON y KML, lo que permite la interoperabilidad con otras herramientas y plataformas geoespaciales. En nuestro caso, hemos extraído información de las zonas de la ciudad de un archivo GeoJSON que hemos podido cargar gracias a esta librería.

En síntesis, la elección de pandas y geopandas en este proyecto se fundamenta en su capacidad para superar las limitaciones de otras herramientas, su rica funcionalidad y su ajuste a las necesidades de nuestros datos y objetivos. Pandas no solo simplifica el análisis de datos, sino que también empodera a los científicos de datos para extraer conocimiento valioso de manera eficiente y efectiva, mientras que Geopandas permite aprovechar al máximo la información geoespacial.

2.1.2. RegEx (RE)

En el proceso de limpieza de datos, las direcciones han sido un desafío debido a su formato variado y la presencia de información irrelevante. Para solucionar este problema, se ha empleado la biblioteca re de Python, que proporciona herramientas poderosas para trabajar con expresiones regulares (regex). El uso de expresiones regulares ofrece numerosas ventajas como la flexibilidad y precisión para definir patrones de búsqueda complejos. Además, la biblioteca re de Python, ofrece un rendimiento optimizado para el procesamiento de grandes volúmenes de datos, algo vital en este proyecto.

2.1.3. Matplotlib

Matplotlib es una biblioteca de visualización ampliamente utilizada en Python, que se integra de manera fluida con pandas y GeoPandas. Esta facilidad de integración ha sido uno de los principales motivos para su uso, permitiendo fácilmente crear una amplia gama de gráficos y mapas informativos que permiten explorar y analizar los datos manera efectiva. Algunas de las funciones utilizadas en el proceso han sido:

1. **Visualización directa desde DataFrames:** Pandas ofrece métodos de visualización integrados que utilizan Matplotlib como backend. Esto permite generar gráficos básicos, como histogramas o diagramas de dispersión, directamente desde DataFrames sin necesidad de manipulación adicional.
2. **Personalización y flexibilidad:** Matplotlib proporciona también un control detallado sobre todos los aspectos de una visualización, desde la elección de colores y estilos hasta anotaciones y leyendas. Esta flexibilidad permite crear gráficos a medida para tareas particulares de nuestro análisis.
3. **Visualización de datos geoespaciales:** GeoPandas aprovecha las capacidades de Matplotlib para crear mapas interactivos y estáticos a partir de GeoDataFrames. Esto permite superponer datos geoespaciales en mapas base para poder visualizar patrones en estos mapas.

En este proyecto, Matplotlib ha sido una herramienta indispensable para la limpieza de los datos, tanto tabulares como geoespaciales. Su integración con pandas y GeoPandas ha permitido crear gráficos y mapas informativos que han mejorado la comprensión de los datos y han facilitado la generación de datos consistentes y fiables de los que derivar el análisis.

2.2. Open Street Maps

En el análisis de los datos geoespaciales, se han encontrado direcciones expresadas en formato de texto, como "1065 University Ave High Bridge, BX". Para poder integrar estos datos con información geográfica existente, como mapas y bases de datos espaciales, se ha tenido que convertir estas direcciones en coordenadas geográficas (latitud y longitud). Este proceso se conoce como geocodificación. Para ello, se ha utilizado la API de Open Street Maps [9], un proyecto colaborativo que crea y mantiene mapas libres y editables del mundo.

Una API (Interfaz de Programación de Aplicaciones) es un conjunto de reglas y especificaciones que permiten que diferentes programas informáticos se comuniquen entre sí. En el contexto de la geocodificación, esta API proporciona una forma de enviar una dirección a un servicio externo y recibir a cambio las coordenadas geográficas correspondientes. La implementación de esta geocodificación se ha realizado en Python por medio de la librería geopy, utilizando el conector de Nominatim.

Nominatim es un servicio de geocodificación basado en los datos de OpenStreetMap que permite convertir direcciones en coordenadas geográficas y viceversa. El proceso consta de las siguientes fases:

1. **Solicitud a la API:** se envía una solicitud HTTP a la API de Nominatim, incluyendo la dirección que se desea geocodificar.
2. **Procesamiento de la Solicitud:** Nominatim procesa la solicitud, busca la dirección en su base de datos y calcula las coordenadas geográficas correspondientes.

3. Respuesta de la API: Nominatim devuelve una respuesta en formato JSON que incluye las coordenadas geográficas (latitud y longitud) de la dirección, así como información adicional, como el tipo de lugar y la dirección completa.

En este proyecto, se ha utilizado la biblioteca geopy de Python para interactuar con la API de Nominatim. Se ha creado una función que toma una dirección como entrada, realiza la solicitud a la API y devuelve las coordenadas geográficas obtenidas. Esta función se aplica a todos los elementos de la columna que contiene las direcciones. Una vez tenemos estas coordenadas, podemos utilizar las funcionalidades de Geopandas para cruzarlos con los datos existentes. Algunas de las ventajas de utilizar esta API son las siguientes:

1. **Datos abiertos y gratuitos:** OpenStreetMap y Nominatim son proyectos de código abierto y ofrecen sus servicios de forma gratuita.
2. **Cobertura global:** OpenStreetMap cuenta con una amplia cobertura geográfica, lo que permite geocodificar direcciones en todo el mundo. En nuestro caso, solamente necesitamos las direcciones de la ciudad de Nueva York y alrededores, los cuales por supuesto contiene.
3. **Flexibilidad:** la API de Nominatim ofrece diversas opciones de configuración, como la elección del formato de salida y la posibilidad de filtrar los resultados.
4. **Integración con Python:** la biblioteca geopy de Python facilita la interacción con la API de Nominatim y la integración de los resultados en el flujo de trabajo de análisis de datos.

En resumen, en este proyecto, la geocodificación con OpenStreetMap y Nominatim ha ayudado a convertir las direcciones en coordenadas geográficas y poder analizar su distribución espacial. Esta integración de datos textuales y geoespaciales ha enriquecido el análisis y ha permitido obtener una comprensión más completa de los viajes.

2.3. Power BI

Una vez hemos realizado el análisis y procesamiento de los datos con las tecnologías explicadas anteriormente, se ha recurrido a Power BI[10][11] para el modelado y la visualización de los resultados. Power BI es una potente herramienta de inteligencia empresarial que se ha usado para llevar a cabo el modelado y la visualización de los datos de manera atractiva e interactiva. Power BI permite crear informes dinámicos y paneles visuales que facilitan la comprensión de los hallazgos y la toma de decisiones basadas en datos. Como se puede ver en la Figura 2.1, según el Cuadrante Mágico de Gartner, Power BI es reconocido como el líder para plataformas de análisis y BI, destaca por su amplio alcance en el mercado, su integración con otras herramientas de Microsoft y su funcionalidad superior a la media [12].



Figura 2.1: Cuadrante Mágico de Gartner, 2023

2.3.1. Ventajas de la utilización de Power BI

La principal ventaja que ofrece es la facilidad para poder crear informes a partir de cualquier tipo de datos. Power BI ofrece una interfaz muy intuitiva y muchas herramientas visuales que facilitan la creación de estos informes y paneles sin necesidad de conocimientos técnicos avanzados. Además, ofrece diversar funcionalidades en cada etapa del ciclo de los datos muy útiles para el análisis.

Modelado de datos en Power BI

1. **Importación de datos:** Power BI permite importar datos de diversas fuentes, tanto archivos como documentos en la nube. En nuestro caso, los datos procesados y limpiados con Python, incluyendo aquellos enriquecidos con información geoespacial, se han subido a la nube, desde donde se importan a Power BI. De esta manera, cada vez que actualicemos los archivos, el reporte se actualizará automáticamente.
2. **Relaciones y transformaciones:** Power BI permite establecer relaciones entre las diferentes tablas de datos para crear un modelo. En nuestro caso, se ha creado un multidimensional. Además, permite realizar transformaciones sobre estas tablas como con la creación de columnas calculadas, medidas y jerarquías, lo que permite la exploración de los datos a diferentes niveles de detalle.

Visualización de datos en Power BI

1. **Diseño de informes dinámicos:** Power BI permite crear informes interactivos que permiten a los usuarios explorar los datos a través de filtros, segmentaciones y otras herramientas de interacción.
2. **Paneles visuales personalizados:** Power BI ofrece una amplia gama de opciones de gráficos diferentes, desde mapas a tarjetas o gráficos más convencionales como gráficos de dispersión o gráficos de barras.
3. **Publicación en Power BI Service:** los informes y paneles creados pueden ser publicados en Power BI Service, lo que permite acceder a ellos desde cualquier dispositivo con conexión a internet y compartirlos con otros usuarios de forma segura.

2.4. Alternativas

En la selección de las tecnologías para este proyecto, se evaluaron diversas alternativas en cada etapa del proceso, considerando sus fortalezas, debilidades y ajuste a los requisitos específicos del este proyecto y sus necesidades. Es importante destacar que la elección de las tecnologías adecuadas depende en gran medida de los requisitos específicos de cada proyecto. En este caso, la combinación de Python, pandas, GeoPandas, Matplotlib y Power BI demostró ser la más adecuada para solventar los retos del análisis y visualización de nuestros datos, ofreciendo un flujo de trabajo eficiente y resultados de alta calidad.

A continuación, se presentan las principales alternativas consideradas y las razones que justificaron las elecciones finales.

2.4.1. Lenguajes de programación

- **R:** un lenguaje ampliamente utilizado en estadística y análisis de datos, R ofrece una gran cantidad de paquetes especializados para diversas tareas. Sin embargo, su sintaxis es menos intuitiva. Además, no dispone de tanta versatilidad como Python y la curva de aprendizaje es mayor.
- **Julia:** es un lenguaje bastante nuevo. Julia destaca por su rendimiento en cálculos numéricos y su capacidad para manejar grandes volúmenes de datos. No obstante, su ecosistema de bibliotecas aún está en desarrollo y puede no ser tan completo como el de Python. Además, existe menos documentación y foros online para poder resolver dudas y problemas que han surgido durante el proyecto.

2.4.2. Bibliotecas para limpieza e integración de datos

- **Dask:** es una biblioteca de Python para el procesamiento paralelo y distribuido de grandes conjuntos de datos. Aunque Dask ofrece una escalabilidad superior a pandas para tareas específicas, su curva de aprendizaje puede ser más pronunciada. Además, a pesar de que el volumen de datos es

grande, no se han detectado problemas de rendimiento con las herramientas utilizadas. Otro punto a favor de pandas, y quizás el más importante, ha sido su extensión de geopandas, vital para el tipo de datos de los que disponemos.

- **Vaex:** otra biblioteca de Python diseñada para el análisis de grandes conjuntos de datos. Vaex utiliza técnicas de memoria virtual para procesar datos que no caben en la memoria RAM, pero su funcionalidad es más limitada que la de pandas.

2.4.3. Bibliotecas de visualización

- **Seaborn:** una biblioteca de visualización basada en Matplotlib que ofrece una interfaz de alto nivel para crear gráficos estadísticos atractivos. Si bien Seaborn simplifica la creación de ciertos tipos de gráficos, Matplotlib proporciona un mayor control y flexibilidad en la personalización de visualizaciones.
- **Plotly:** una biblioteca que permite crear gráficos interactivos y visualizaciones web. Aunque Plotly ofrece una experiencia de usuario más interactiva, Matplotlib puede ser más adecuado para la creación de gráficos estáticos útiles para la limpieza.

Al no utilizarse estas librerías para el reporte final, sino para la limpieza y EDA (Exploratory Data Analysis) con los datos, se ha elegido la opción más sencilla y rápida que cumpliera los estándares. Su integración con pandas y geopandas ha hecho que Matplotlib sea la opción elegida para este proyecto.

2.4.4. Plataformas de Business Intelligence

- **Tableau:** una plataforma de BI líder en el mercado que destaca por su facilidad de uso y sus capacidades de visualización. Sin embargo, su costo puede ser un factor limitante para algunos proyectos.
- **Qlik Sense:** otra plataforma de BI popular que ofrece una experiencia de análisis asociativo y descubrimiento de datos.

Ambas herramientas, podrían habernos sido útiles en este proyecto pero, como se muestra en la Figura 2.1, Power BI se encuentra en la vanguardia en este momento en cuestión de plataformas de BI. Sus amplias funcionalidades y su constante actualización hacen de él la herramienta perfecta para este proyecto.

Capítulo 3

Procesado de los datos

En este capítulo, titulado "Procesado de los Datos", se detallará el proceso llevado a cabo para transformar los datos brutos en información valiosa, siguiendo la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining). Cada fase de esta metodología, ya introducida previamente en este trabajo, se desglosará en una sección específica para facilitar la comprensión del lector y resaltar la importancia de completar cada paso antes de empezar el siguiente para conseguir los mejores resultados.

3.1. Comprensión del negocio (Business Understanding)

Esta sección se enfocará en la primera fase de la metodología CRISP-DM: la comprensión del negocio. Esta etapa es fundamental para garantizar que el análisis de datos se alinee con los objetivos y necesidades del proyecto. Para este proyecto, que se centra en los viajes de Uber, es esencial comprender no solo cómo operan los servicios de Uber, sino también cómo los datos pueden proporcionar información valiosa para los diferentes implicados.

Esta comprensión del negocio conlleva identificar los objetivos del análisis, entender el contexto en el que se recopilan los datos y definir claramente las preguntas de investigación que guiarán el proceso de análisis. Como casi cualquier proyecto dentro de una empresa, este análisis debe conducir hacia una optimización de las actividades o un beneficio económico. A continuación, se presentan los motivos clave por los cuales es crucial y de gran utilidad desarrollar un reporte que nos proporcione una comprensión más profunda de la demanda de los viajes de Uber. Estos motivos definen a su vez las preguntas y objetivos que queremos responder y cumplimentar con nuestro análisis:

- **Conocimiento del comportamiento del usuario:** analizar los datos de viajes de Uber permite comprender cómo los usuarios utilizan la plataforma, qué factores influyen en sus decisiones de viaje (como precio, tiempo de espera y distancia), y cómo varían sus patrones de viaje según la hora del día, el día de la semana y la ubicación. Este conocimiento es crucial para personalizar y mejorar la experiencia del usuario y el beneficio de la

Capítulo 3. Procesado de los datos

empresa. Por ejemplo, si se identifica que los usuarios prefieren viajar en ciertas horas del día, Uber puede ajustar sus tarifas para ajustarse a esta demanda.

- **Innovación y mejora del servicio:** el entendimiento de la demanda por parte de los usuarios ayuda a la empresa a identificar áreas de mejora en su servicio, como optimizar los tiempos de espera, ajustar los precios de manera dinámica y personalizar la experiencia del usuario.
- **Análisis de la competencia:** al comprender también los datos de la competencia, se pretende observar las posibles áreas de mejora que pueden hacer a la empresa ganar terreno con respecto a sus competidores.

A su vez, Uber siempre se ha caracterizado por su gran implicación en los temas sociales como la reducción de la contaminación, la seguridad o la igualdad. Aquí, una mejor comprensión de los datos puede ser un factor fundamental para mejorar algunos aspectos de la vida social de la ciudad. Algunos de estos aspectos son:

- **Planificación urbana y transporte:** los datos de viajes de Uber pueden proporcionar información valiosa para la planificación urbana y el transporte. Identificar áreas con alta demanda de viajes puede ayudar a planificar rutas de transporte público más eficientes, mejorar la infraestructura vial u optimizar la ubicación de estaciones de transporte. Por ejemplo, si se detecta una alta demanda en una zona específica de la ciudad, las autoridades de transporte pueden considerar la expansión de rutas de autobuses o la construcción de nuevas estaciones de metro en esas áreas.
- **Impacto socioeconómico:** comprender los patrones de viajes puede revelar el impacto socioeconómico de la plataforma en las ciudades. La distribución de los viajes puede mostrar si Uber está sirviendo a todas las áreas de una ciudad por igual o si existen diferencias en el uso del servicio. Esta información puede ser útil para abordar problemas de equidad y garantizar que todos los ciudadanos tengan acceso a opciones de transporte asequibles. Por ejemplo, si se descubre que ciertas áreas de bajos ingresos tienen menos acceso a Uber, se pueden implementar políticas para incentivar a los conductores a operar en esas áreas.

3.2. Comprensión de los Datos (Data Understanding)

La segunda fase de la metodología CRISP-DM, la comprensión de los datos, se construye sobre la base establecida en la etapa de comprensión del negocio. Esta fase es crucial ya que dirige el enfoque hacia la identificación, recolección y análisis de los conjuntos de datos necesarios para alcanzar los objetivos del proyecto. La comprensión de los datos asegura que los datos utilizados sean apropiados y de calidad suficiente para proporcionar insights valiosos. Esta fase consta de cuatro tareas principales: recolección de datos iniciales, descripción de los datos, exploración de los datos y verificación de la calidad de los datos.

3.2. Comprensión de los Datos (Data Understanding)

1. **Recolección de datos iniciales:** el primer paso en la fase de comprensión de los datos es la recolección de los datos iniciales necesarios para el análisis. Este paso implica adquirir los datos pertinentes y cargarlos en la herramienta de análisis. En el caso de este proyecto, la búsqueda de los datos ha formado también ha sido parte del trabajo, ya que no se tienen acceso a fuentes de la empresa. Esto ha hecho que no se tengan a disposición todos los datos ni con tanto detalle como se hubiera deseado. Sin embargo, también refleja la importancia de un buen sistema de recogida y estructuración de datos para poder trabajar posteriormente con ellos.

El conjunto de datos que se ha seleccionado proviene de la página oficial de la comisión de taxis y limusinas de Nueva York ([NYC Taxi and Limousine Commission \(TLC\)](#)) y se han descargado desde la plataforma [Kaggle](#). Este dataset está compuesto por 19 ficheros con datos de Uber y otras empresas de alquiler de vehículos con conductor.

Además de los datos de los propios viajes, se han buscado datos de cada dimensión sobre la que se han estudiado estos hechos. El proyecto estudia la influencia de la zona geográfica, el horario y la climatología sobre la demanda.

Los datos sobre las zonas geográficas se han recogido de la [página oficial de datos de gobierno de los Estados Unidos](#) [13]. La división de en zonas está basado en el "Área de tabulación de barrios del Departamento de Urbanismo de Nueva York"(NYC Department of City Planning's Neighborhood Tabulation Areas (NTAs)). Estos datos proporcionan información sobre las coordenadas de cada zona e incluye a su vez una jerarquía de barrio, zona que permite dividir la ciudad en 6 grandes secciones: Bronx, Staten Island, Manhattan, Brooklyn, Queens y EWR (Newark Liberty International Airport).

En cuanto a los datos sobre la climatología, se han obtenido de la API de [Visual Crossing](#). Esta API propociona acceso a datos sobre previsiones, histórico y y condiciones actuales del clima de diferentes zonas geográficas entre las que se encuentra la ciudad de Nueva York. Algunos de los campos a los que tenemos acceso son la temperatura, humedad, precipitaciones o viento a nivel de día u hora.

2. **Descripción de los datos** Después de recolectar los datos iniciales, el siguiente paso es evaluar sus propiedades. Esto es lo que se conoce como EDA (Exploratory Data Analysis). El *Exploratory Data Analysis* consiste en el resumen, análisis estadístico y visualización de los datos que nos permite evaluar qué tipo de modelización vamos a poder realizar con los datos[14]. También, permite generar algunas hipótesis preliminares que se confirmarán o descartarán a lo largo del análisis.

Algunos de los descriptivos más importante de los datos son:

- **Formato de datos:** en este caso, los datos sobre viajes y meteorología se encuentran en ficheros CSV, mientras que los datos geográficos tienen la extensión .geojson.

Capítulo 3. Procesado de los datos

- **Número de registros:** análisis exploratorio sobre el número de registros totales o la distribución sobre las principales categorías. Una de las conclusiones que se busca obtener en el proyecto es la distribución de los viajes por zonas geográficas. Como se observa en la Figura 3.1, la distribución de la demanda no es igual para todas las bases. La base con código B02764 correspondiente a Danach-NY es la que tiene más viajes asignados mientras que las bases B02835 y B02836 correspondientes a Dreist y Drinnen respectivamente, no tienen apenas ninguno. Más adelante, se combinarán estos resultados con la información geográfica de los viajes en visualizaciones más complejas que permiten obtener conclusiones más claras.




Figura 3.1: Distribución del número de viajes entre enero y junio de 2015 por código de base

- **Identificación de los campos:** en esta parte, se busca analizar cada uno de los campos que contienen los ficheros del dataset y su relevancia para el análisis. En las figuras 3.2 y 3.3 se puede observar la estructura de los ficheros 'uber-raw-data-jan-june-15.csv' y 'uber-raw-data-apr14.csv', correspondientes a los datos de Uber. Ya a simple vista, se pueden ver diferencias en la forma en la que se guarda la información dependiendo del archivo.

Dispatching_base_num	Pickup_date	Affiliated_base_num	locationID
B02617	17/05/2015	B02617	141
B02617	17/05/2015	B02617	65
B02617	17/05/2015	B02617	100
B02617	17/05/2015	B02774	80
B02617	17/05/2015	B02617	90

Figura 3.2: Estructura del archivo 'uber-raw-data-jan-june-15.csv'

3.3. Preparación de los datos (Data Preparation)

Date/Time	Lat	Lon	Base
4-1-14 12:11 AM	40.769	-739.549	B02512
4-1-14 12:17 AM	407.267	-740.345	B02512
4-1-14 12:21 AM	407.316	-739.873	B02512
4-1-14 12:28 AM	407.588	-739.776	B02512
4-1-14 12:33 AM	407.594	-739.722	B02512

Figura 3.3: Estructura del archivo 'uber-raw-data-apr14.csv'

Como se puede observar en la Figura 3.2, la localización del viaje viene dada por el location-id ID de la zona de taxi a la que pertenece, mientras que en el segundo caso (Figura 3.3), la información geográfica viene en forma de latitud y longitud. Esta información es muy necesaria para realizar una posterior integración y armonización de los datos.

-Tipos de datos: se disponen de datos diferentes datos de longitud y latitud como tipos float, además de identificadores de las zonas o bases como strings y datos referentes a la fecha y hora en formato texto.

Este proceso del EDA, da una visión general de los datos y ayuda a identificar cualquier necesidad de limpieza o transformación antes de las siguientes fases. Además, permite observar pequeñas conclusiones sobre las que se profundiza en el resto del proyecto.

3.3. Preparación de los datos (Data Preparation)

La fase de preparación de los datos implica transformar los datos brutos recolectados a un formato adecuado para el análisis. Sin una preparación adecuada, los datos pueden contener errores o inconsistencias que pueden comprometer la validez y la precisión de los resultados del análisis. En esta etapa, se llevan a cabo diversas tareas como la limpieza de datos, la integración de múltiples fuentes de datos, la selección de variables relevantes, y la transformación de los datos en un formato adecuado para los algoritmos de análisis.

El objetivo principal de esta fase es garantizar que los datos estén limpios, consistentes y en el formato correcto para ser utilizados en las etapas posteriores del análisis. Algunas de las tareas clave realizadas han sido:

- **Limpieza de datos:** se busca identificar y corregir errores en los datos, como nulos, duplicados u outliers. Al provenir los datos de una fuente oficial como la **NYC Taxi and Limousine Commission (TLC)**, los datos no contienen nulos ni valores duplicados. De igual manera, estas comprobaciones se han realizados para tener la seguridad de su integridad. Sin embargo, sí que se han detectado algunos outliers. Se consideran 'outliers' o datos atípicos en este análisis a viajes que no pertenecen a la ciudad de Nueva York. Este fenómeno, que se puede ver en la Figura 3.4, se ha solucionado eliminando los registros correspondientes a dichos viajes ya que representaban un porcentaje ínfimo con respecto del total.




Figura 3.4: Datos presentes en los ficheros que no pertenecen a ninguna zona de la ciudad de Nueva York

- **Integración de datos:** en esta fase, se combinan datos de múltiples fuentes para crear un conjunto de datos coherente y unificado. Esta ha sido una de las fases más complejas del análisis debido a la variabilidad y complejidad de algunos campos. En el fichero "NYC-Taxi-Zones.geojson", se tiene la información de la localización de cada zona. Esta información viene dada en formato Multipolygon, una lista de coordenadas que contiene los vértices del polígono que contiene dicha zona. Como se puede observar en la Figura 3.3, en algunos de los ficheros no disponemos de la información sobre la zona a la que pertenecen, solamente la latitud y longitud. .Gracias a la librería geopandas, se han podido cruzar estos datos con los polígonos, obteniendo para cada viaje, la zona a la que pertenece (el polígono que contiene sus coordenadas) a partir de la latitud y longitud del punto de partida.

Otros de los ficheros, contenían la información geográfica en formato texto, con el nombre de la dirección de recogida. Esto ha supuesto problemas mayores que en el caso anterior ya que no existe ninguna funcionalidad en geopandas que sea capaz de transformar direcciones en coordenadas o zonas. Para solventar este problemas, se ha hecho uso de la API de Open Street Maps. Como se puede ver en la Figura 3.5, la información está contenida en la columna *PICK UP ADDRESS* en formato texto. Por medio de llamadas a la API, se han transformado estas direcciones a latitudes y longitudes que han seguido el mismo proceso que en el caso anterior para obtener finalmente la información de la zona. Cabe destacar en este punto que estas direcciones parecen un muchos casos manuscritas, contienen errores y añadidos que la API no puede resolver. Esto genera que muchas de las llamadas a la API no den ningún resultado, produciendo valores nulos en los campos 'Lat' y 'Lon', campos en los que se almacenan la latitud y longitud respectivamente. Para reducir al máximo estos inconvenientes, se

3.3. Preparación de los datos (Data Preparation)

han llevado a cabo transformaciones en las direcciones por medio de expresiones regulares para convertirlas a un formato o lenguaje entendible por la API. Un ejemplo de esto puede ser la conversión de BX por Bronx, ya que Open Street Maps no detecta que estos conceptos son iguales. Entre las transformaciones realizadas se encuentran sustituciones por diccionario, eliminación de palabras o adición de partículas como th al final de los números de las calles. Este proceso ha sido el más largo, no sólo por la complejidad computacional de llevar a cabo millones de consultas a la API, sino porque ha sido un trabajo muy manual y exhaustivo el comprobar qué valores o palabras eran reconocidos o aquellos valores que se reconocían en su defecto. Sin embargo, después de estas transformaciones, se ha conseguido que el margen de error de las consultas sea de en torno a un 5 %, reduciéndolo del casi 50 % inicial.

DATE	TIME	PICK UP ADDRESS	Column1	1	2
07/01/2014	0:00:00	874 E 139th St Mott Haven, BX			
07/01/2014	0:01:00	628 E 141st St Mott Haven, BX			
07/01/2014	0:01:00	601 E 156th St South Bronx, BX			
07/01/2014	0:01:00	708 E 138th St Mott Haven, BX			
07/01/2014	0:02:00	700 E 140th St Mott Haven, BX			
07/01/2014	0:03:00	514 E 163rd St Cortlandt, BX			
07/01/2014	0:08:00	300 E 150th St Cortlandt, BX			

Figura 3.5: Estructura del fichero 'American-B01362.csv'

- **Selección de variables:** en esta etapa, se debe determinar qué variables son relevantes para el análisis y cuáles pueden ser eliminadas. En nuestro caso, se ha decidido que la zona es suficiente granularidad como información geográfica, ya que ni para la empresa ni para los conductores es demasiado relevantes el número de la calle en el que se realiza la recogida a la hora de tomar decisiones de más alto nivel como para las que está enfocado este proyecto. Por lo tanto, los datos de latitud y longitud que nos han servido para obtener la zona han sido eliminados. A su vez, ha sido eliminada la columna *Dispatching-base-num* de los ficheros que la contenían como 'uber-raw-data-janjun-15.csv' que se puede ver en la Figura 3.2, en favor de la *Affiliated-base-num*. Con esto, priorizamos la base asignada a la recodiga del viaje que al envío. (Viene también influenciado por la ausencia de este segundo dato en muchas de las fuentes).
- **Transformación de datos:** se convierten los datos en un formato adecuado para el análisis, lo cual incluye modificación de los tipos de datos o su formato. Un ejemplo de estas transformaciones en el proyecto han sido las fechas. En algunos de los ficheros se podían encontrar un tipo date-time, en otros separados fecha y hora o con diferentes formatos de fecha ('2014.07.04', '9/30/2014' o '2014-04-01 00:11:00'). En este caso, la primera transformación ha consistido en separar la fecha y la hora de aquellos ficheros que tenían los campos juntos por medio de expresiones regulares. En segundo lugar, se ha unificado el formato del campo 'Date' a un formato común. En este caso el formato elegido ha sido '%d/%m/%Y'. Una vez unificado el formato se ha cambiado a tipo date. Otra transformación

ha sido cambiar el tipo de datos de los identificadores a tipo string. Esto se considera una buena práctica ya que, aunque sean números, no tiene sentido realizar operaciones sobre estos IDs.

Cada una de estas tareas tiene una repercusión en el éxito del análisis. Esta fase de la metodología contribuye a crear una base que asegure que los datos sean aptos y que los resultados obtenidos sean precisos y significativos.

3.4. Modelado (Modeling)

La fase de modelado de este proyecto, se ha centrado en el diseño de un modelo multidimensional con los datos. Este modelo es esencial para organizar y estructurar los datos de manera que facilite su análisis y consulta. Para ello, se establecen relaciones entre las diferentes tablas de datos.

El modelado multidimensional permite la creación de estructuras que soportan el análisis de datos en múltiples dimensiones, esto permite enfocar el análisis en los diferentes factores que afectan a la demandas para realizar un análisis complejo y obtener conclusiones valiosos.

Para ello, como se ha explicado anteriormente, se ha diseñado un modelo multidimensional. En 1970, Codd introdujo el modelo relacional para el almacenamiento de los datos en bases de datos [15]. En torno a 1990, emerge un nuevo tipo de modelo, llamado modelo multidimensional, que se enfocaba en proyectos donde el objetivo no era almacenar datos, sino analizarlos. Este tipo de modelo clasifica las tablas en dos tipos: tablas de hechos y tablas de dimensiones. Las tablas de hechos suelen estar formadas por información numérica y almacenan los datos de aquel fenómeno que queremos analizar. En este caso, la tabla de hecho contiene la información de cada viaje. Por contra, las tablas de dimensiones almacenan al información que nos describe estos datos, tiempo, espacio...Por último, se tienen las medidas. Las medidas son operaciones que se aplican a los datos para generar resultados útiles para el análisis [16]. Un ejemplo de medida puede ser el número de viajes.

Algunas de las principales ventajas que tiene en el análisis y por las cuales se ha decidido su utilización:

- **Organización eficiente de los datos:** estructuración de los datos de una manera óptima en su almacenamiento y recuperación.
- **Facilitación del análisis:** el modelo multidimensional permite realizar análisis más intuitivos y detallados, ya que los datos están organizados en dimensiones que representan diferentes aspectos del negocio. Esto facilita la creación de informes y visualizaciones, como tablas dinámicas y gráficos.
- **Claridad en las relaciones:** al establecer relaciones claras y bien definidas entre las tablas de dimensiones y las tablas de hechos, se asegura la integridad y consistencia de los datos. Esto permite comprender fácilmente cómo se interrelacionan diferentes elementos del negocio y propagar diferentes filtros a través de estas relaciones.

- **Flexibilidad y escalabilidad:** los modelos multidimensionales son flexibles y escalables, lo que permite adaptar el modelo a medida que evolucionan las necesidades del negocio. Permite añadir nuevas dimensiones y medidas sin necesidad de reestructurar completamente el modelo existente, permitiendo un proceso continuo y actualizado.

Observando los beneficios de este tipo de modelo en el contexto del proyecto, a continuación se definen los pasos seguidos para su implementación:

- **Definición de la tabla de hechos:** se ha decidido combinar los datos de todas las empresas en una misma tabla, diferenciándolas con un *company-id* y generar otra tabla con el diccionario de *company-id*, nombre de la compañía. De esta manera, tenemos solamente una tabla de hechos en la que combinamos todos los viajes en vez de varias con cada empresa. También influye aquí las decisiones sobre los campos relevantes y tipos de datos que se han tomado anteriormente.
- **Definición de dimensiones:** identificación y definición de las dimensiones clave que se usarán para organizar los datos. Las dimensiones son los ejes de análisis, en este proyecto; el tiempo, el lugar y la meteorología.
- **Definición de las medidas:** determinación de las medidas que se analizarán. Las medidas son los datos cuantitativos que se quieren analizar, como el número de viajes o variaciones con respecto a días pasados.
- **Diseño del cubo de datos:** creación del cubo de datos, que es la propia estructura multidimensional que organiza las dimensiones y las medidas. Este diseño incluye la definición de jerarquías dentro de las dimensiones para permitir análisis detallados en diferentes niveles de granularidad. Una de las jerarquías añadidas es distrito-zona.
- **Definición de las relaciones:** definición de las relaciones entre las tablas de dimensiones y las tablas de hechos. Esto incluye la creación o selección de claves primarias y foráneas para asegurar la integridad referencial de los datos. Las fechas serán la propia clave que una cada viaje con la dimensión tiempo y con la climatología del día, mientras que el código de empresa, código de base y código de zona las claves que lo unan con las dimensiones de empresa, base y lugar respectivamente.
- **Optimización del modelo:** ajuste y optimización del modelo para mejorar su rendimiento y eficiencia. Aquí se han optimizado el cálculo de las medidas con el uso de las funciones más adecuadas a cada caso o creado índices en las tablas de dimensiones que optimizan la propagación de las relaciones y el espacio que ocupan.

La consecuencia de estos pasos ha resultado en el modelo reflejado en la Figura 3.6. Como se observa en dicha figura, el modelo se compone de una tabla de hechos central *Fact Viajes* rodeada de las dimensiones *Dim Calendar*, *Dim Climatología*, *Dim Zonas*, *Dim Bases* y *Dim Empresas*, sobre las que se realizará el análisis.




Figura 3.6: Modelo de datos

El modelado multidimensional es un elemento fundamental en el diseño de un sistema de análisis de datos. Al estructurar los datos de manera lógica y optimizada, se facilita el análisis y se asegura que los datos sean accesibles y útiles para la toma de decisiones. En el contexto de la empresa Uber, un modelo multidimensional bien diseñado permite explorar los datos desde las diferentes dimensiones y descubrir patrones valiosos que pueden ayudar a mejorar la eficiencia operativa y la experiencia del usuario.

3.5. Evaluación (Evaluation)

En los proyectos de Ciencia de Datos que involucran Machine Learning o la creación de modelos predictivos, la fase de evaluación consistiría en evaluar la capacidad predictiva de dichos modelos. En este caso, debido a la ausencia de modelos de aprendizaje automático, la evaluación se realizará analizando la capacidad de los visuales hechos en Power BI para responder a los objetivos marcados al comienzo. El reporte se ha realizado siguiendo los siguientes principios [17] [18]:

- **Intuitivo:** el reporte se ha realizado en formato de página web para que sea lo más intuitivo posible. Dispone de su portada correspondiente y un menú de navegación en cada una de las páginas.

3.5. Evaluación (Evaluation)

- **Interactivo:** cada una de las páginas se puede filtrar por fecha o zona. Además, seleccionando sobre los propios visuales, el resto de gráficos se actualizan para mostrar solamente la información seleccionada
- **Uniforme:** uno de los principios para el buen desarrollo de un dashboard es mantener el estilo durante todas las pantallas. Esto es importante ya que se 'enseña' al usuario a dónde tiene que mirar para poder ver cierta información. Manteniendo una distribución de los visuales lo más uniforme posible se consigue facilitar la tarea del análisis además de mejorar la apariencia visual de el reporte. Otro signo más de la uniformidad son los filtros, al cambiar los filtros en una página, estos se actualizan a su vez en el resto de páginas.
- **Estructurado:** el informe se divide en 5 páginas más la portada. Cada una de estas páginas corresponde a un objetivo o dimensión del análisis. Con esto, el usuario sabe exactamente dónde encontrar la información que busca usando el navegador de pantallas. Una correcta ordenación de los visuales puede ser variable entre las diferentes regiones. En el caso de occidente, donde se lee de arriba hacia abajo y de izquierda a derecha, esta es la ordenación más efectiva para los visuales. Aquellos más importantes arriba a la izquierda, y aquellos que lo son menos en la esquina de abajo a la derecha (Esta técnica se denomina procesamiento de la pre-atención). Además, las pantallas están ordenadas según la importancia de los objetivos a los que responden.
- **Uso de colores:** los colores no sólo se utilizan para mejorar el aspecto del reporte, sino que dan información extra sobre los datos. Se utiliza la intensidad o la paleta de colores a lo largo del informe para denotar el grado de intensidad o valor de las medidas utilizadas.
- **Distracciones:** se evita el uso de elementos distractores. En el reporte se colocan únicamente visuales que responden a un objetivo del análisis, y no meramente estéticos.
- **Comparativas:** el análisis de un dato por separado no resulta demasiado útil. Es la comparación de estos valores con otras dimensiones lo que hace del análisis algo productivo para la empresa. En el informe se combinan varias dimensiones y medidas para lograr ese efecto comparativo entre los diferentes valores.
- **Actualización:** el dashboard se nutre de datos subido a GitHub. Esto hace que se actualice automáticamente al actualizarse estos datos. Esto resulta muy útil en empresas como Uber que generan datos diariamente. De esta manera, los visuales se mantienen actualizados y el análisis es más productivo.

Una vez resumidos las principales buenas prácticas que se han seguido en el diseño del análisis, a continuación, se detallarán los elementos visuales elegidos para poder responder a cada uno de los objetivos. Para ello, se relacionarán cada una de las pantallas del reporte con estos objetivos.

3.5.1. Análisis general

Respondiendo a la buena práctica de Uniformidad, como se puede observar en la Figura 3.7 se ha generado una cabecera que acompaña a todas las pantallas del informe. En ella, se puede observar un título: 'Uber Trips Dashboard' que nos indica el tema del reporte acompañado de algunos logos de la empresa. Justo por debajo, se colocan los filtros que se pueden aplicar a cada pantalla, junto con el panel de navegación en el lateral izquierdo. En la esquina superior derecha, se han colocado varios KPIs (Key Performance Indicators) que se consideran útiles en el análisis de todas las pantallas. Estos KPIs son el número de viajes de Uber, el número total de viajes de la competencia y el número de zonas en las que se divide la ciudad de Nueva York. Una visión general del número total de viajes, y su comparación con la competencia, puede ayudar al usuario a interpretar datos particulares de una visualización. A su vez, un descriptivo del número de zonas puede servir de ayuda a la hora de analizar los datos de un vecindario o conjunto de zonas, al poder compararlo con el total. Justo por debajo de estos KPIs, se ha incluido una tarjeta aclaratoria indicando la primera y última fecha de las que se disponen datos acompañado con un botón para reestablecer los filtros.

3.5.2. Dimensión tiempo

La dimensión temporal es una dimensión fundamental en casi todos los informes de análisis de datos. Esta dimensión proporciona el contexto necesario para entender cómo evolucionan los patrones y tendencias a lo largo del periodo estudiado. En este proyecto, la dimensión temporal permite desglosar y analizar los datos en intervalos específicos como horas, días, semanas o meses, ofreciendo una visión más clara de los comportamientos y preferencias de los usuarios en diferentes momentos del tiempo.

En esta subsección, se presentan dos pantallas del informe que utiliza la dimensión tiempo para mostrar cómo varían los viajes de Uber a lo largo de los días y a lo largo del día. Este análisis temporal ayuda a identificar las horas pico de demanda, patrones diarios y variaciones estacionales, proporcionando información crucial para la planificación y optimización del servicio; y respondiendo a nuestro objetivo número 1: 'Análisis de los patrones de demanda en función del tiempo'.

Dentro de la dimensión temporal, se han realizado dos tipos de análisis. Por un lado, un análisis del evolutivo a nivel más general durante periodos más largos; por otro lado, un análisis más detallado a nivel de hora y día de la semana.

Pantalla 1

Como se observa en la pantalla 1 (Figura 3.7) se ha utilizado un gráfico de líneas para mostrar la evolución del número de viajes realizados por Vehículos de Transporte con Conductor de la empresa Uber. Analizando los datos, se pueden obtener dos insights. En primer lugar, se observa un constante aumento en la

3.5. Evaluación (Evaluation)




Figura 3.7: Pantalla 1: Evolución en el tiempo de los viajes de Uber

demanda de viajes a lo largo de todo el periodo estudiado. Esto se puede ver reflejado en la 'Trend line' o línea de tendencia que se ha incluido en el gráfico.

En segundo lugar, se observa una estacionalidad de la demanda con respecto a cada semana, siendo los jueves, viernes y sábados los días con mayor demanda, y los domingos y lunes los días en los que menos viajes se realizan. Además, se han añadido los detalles del día de la semana y la climatología de dicho día en cada valor del gráfico para que se pueda consultar al situarse sobre cada valor. Con estos datos, la empresa y conductores pueden elegir de manera más fundada los días de la semana en los que aumentar sus servicios, incrementándolo en los días con mayor demanda y sabiendo que es un servicio que está en auge ya que cada día, más usuarios hacen uso de él. Cabe destacar que, tanto en esta pantalla como en la siguiente, podemos aplicar el filtro temporal para mostrar datos de una o varias semanas, además de un filtro seleccionando la zona o zonas deseadas.

Pantalla 2

En la pantalla 2 (Figura 3.8), se realiza un análisis más en detalle de la demanda en función del día de la semana y la hora del día. Para ello, se ha hecho uso del tres gráficos. En el primero, más a la izquierda, se construye una tabla con el número de viajes realizados en cada rango horario del día (eje Y separado por horas) y por cada día de la semana (eje X). El color de cada celda se establece según el valor que contenga, correspondiendo el rojo más intenso a horarios con gran número de viajes y el azul a horarios con escasa demanda. A la derecha de este gráfico, se han utilizado dos gráficos de columnas para mostrar en detalle y por separado la distribución de los viajes.

Capítulo 3. Procesado de los datos




Figura 3.8: Pantalla 2

Esta pantalla, proporciona varios descubrimientos. En primer lugar, se puede confirmar aquello que se podía observar en la anterior pantalla: los jueves, viernes y sábados son aquellos días con mayor demanda, mientras que los lunes y domingos los que menos. A su vez, se pueden observar el detalle de los viajes por hora, siendo el rango horario de entre las 18 y las 22 horas el más concurrido.

En segundo lugar, observando la tabla, se puede observar cómo en los días de entre semana, se observa un pequeño repunte en torno a las 8-9 de la mañana. Esto puede corresponder al horario en los usuarios entran a trabajar y hacen uso de los servicios de Uber. Para mejorar estos datos, quizás se podrían desarrollar alguna estrategia o plan de marketing que invite a más usuarios a utilizar Uber como medio de transporte para llegar al trabajo.

En tercer lugar, también se puede observar cómo es ese periodo entre las 18 y las 22 el más concurrido en cuanto a viajes, observando cómo sobre todo aumenta en las noches de los jueves, viernes y sábados, llegando incluso a mantenerse hasta el domingo de madrugada. Estos viajes pueden corresponderse con la vuelta a casa del trabajo o la ida o vuelta a cenas. Según un estudio realizado por la empresa Benenson Strategy Group [19], el uso de Uber ha reducido las cifras de accidente por conductores bajo los efectos del alcohol en Estados Unidos. Uniendo esta encuesta con los datos que observamos en el reporte, se podrían realizar campañas para fomentar el uso de Uber como sustitutivo al coche particular cuando se va a ingerir alcohol, aumentando el beneficio de la empresa y la seguridad del usuario y conciudadanos.

3.5.3. Dimensión localización

La dimensión de localización permite entender cómo varían los patrones y tendencias en las diferentes áreas geográficas. En este proyecto, analizar la información basada en la ubicación nos proporciona una comprensión más profunda de las dinámicas espaciales y la distribución de la demanda en distintos barrios y zonas de la ciudad, respondiendo al objetivo número 2: 'Análisis de los patrones de demanda en función de la zona geográfica'

En esta subsección, se presenta una pantalla del informe que utiliza la dimensión de localización para mostrar cómo se distribuyen los viajes de Uber en diferentes áreas de Nueva York. Este análisis geográfico nos ayudará a identificar las zonas con mayor demanda, los puntos calientes de recogida y cómo estos patrones pueden variar en función del periodo seleccionado. Al entender mejor cómo la localización influye en los viajes, podemos desarrollar estrategias más precisas para optimizar el servicio de Uber, mejorando así la eficiencia operativa.




Figura 3.9: Pantalla 3: Análisis geográfico de la demanda

Como se observa en la Figura 3.9, la Pantalla 3 está formada por 5 secciones. En primer lugar, se observa la cabecera y panel de navegación presente en todas las pantallas. En este caso, un filtro temporal por rango de fechas es aplicable. Justo por debajo de esta cabecera, se han colocado unas tarjetas con el rango de fechas analizado en tamaño más grande y el número de viajes aplicados los filtros. Estos filtros pueden ser de tiempo, en el selector de la cabecera, o de zona, en la parte izquierda de la pantalla. En la parte central, se presenta un mapa cargado en un archivo .topojson en el que se refleja por medio del color el número de viajes por zona. Acompañando al mapa, se encuentra un gráfico de columnas en el cuál se puede observar con más detalle las cifras de viajes, tanto

Capítulo 3. Procesado de los datos

por distrito como por zona, acompañado de una leyenda. Tanto en el mapa como en el gráfico de columnas, se puede situarse sobre cualquiera de las zonas para obtener información más detallada.

New York City's five boroughs							V·T·E
Jurisdiction		Population	Land area		Density of population		GDP
Borough	County	Census (2020)	square miles	square km	people/ sq. mile	people/ sq. km	billions (2022 US\$) ²
The Bronx	Bronx	1,472,654	42.2	109.2	34,920	13,482	\$43.7
Brooklyn	Kings	2,736,074	69.4	179.7	39,438	15,227	\$107.3
Manhattan	New York	1,694,251	22.7	58.7	74,781	28,872	\$781.0
Queens	Queens	2,405,464	108.7	281.6	22,125	8,542	\$103.3
Staten Island	Richmond	495,747	57.5	149.0	8,618	3,327	\$17.5
City of New York		8,804,190	300.5	778.2	29,303	11,314	\$1,052.8
State of New York		20,201,249	47,123.6	122,049.5	429	166	\$1,763.5

Figura 3.10: Datos sobre la población por distrito de la ciudad de Nueva York [13]

Analizando los datos que nos muestran los gráficos, podemos ver cómo el distrito con más densidad de viajes es con diferencia Manhattan. Manhattan es el distrito de la ciudad de Nueva York con mayor densidad de población como se muestra en la tabla de la Figura 3.10. Sin embargo, otras zonas de Nueva York están pobladas por muchas más personas, e incluso la densidad de población no llega a duplicar a distritos como Brooklyn. En el reporte, se observa como Manhattan en el distrito con más viajes llegando a quintuplicar las cifras de los siguientes más concurridos, Brooklyn y Queens.

Combinando los datos del reporte con los mostrados en la Figura 3.10, se puede observar cómo la distribución de viajes está mucho más relacionada con el GDP (Producto Interior Bruto) de la zona que con la densidad de población o número de habitantes. Observando este fenómeno, y acorde también a las políticas de inclusión por las que se caracteriza Uber, se podría fomentar su uso en zonas de menores ingresos, reduciendo los precios u ofreciendo ventajas alternativas a las opciones tomadas mayormente para la movilidad en esas zonas.

3.5.4. Dimensión meteorología

Las condiciones climáticas pueden tener un impacto significativo en los patrones y comportamientos de muchos fenómenos. En el contexto del proyecto, considerar la meteorología permite entender cómo las diferentes condiciones climáticas, como la lluvia o la nieve, afectan la demanda y el rendimiento del servicio. Esto responde al objetivo número 3: 'Análisis de los patrones de demanda en función de la meteorología'.

En esta sección, se presenta una pantalla del informe que utiliza la dimensión meteorológica para analizar cómo las condiciones del clima influyen en la demanda de viajes de Uber. Este análisis ayuda a identificar las diferentes condiciones climáticas y su impacto en la movilidad urbana.

3.5. Evaluación (Evaluation)




Figura 3.11: Pantalla 4: Análisis de la demanda con respecto a la climatología

Como se observa en la Figura 3.11, la pantalla sigue la misma estructura que el resto del informe. En este caso, los filtros a aplicar son sobre la fecha o la categoría meteorológica a estudiar. Se presentan 3 visuales diferentes. En el primero, se analiza por medio de un gráfico columnar el número de viajes en el periodo seleccionado. Justo por debajo, en una tabla, se observan los mismos valores acompañados de los mismos normalizados. De esta manera, se observa como de manera general, se realizan más viajes en días parcialmente nublados, pero esto se produce debido a que es el tiempo predominante. Al fijarse en los datos normalizados, se ve una visión mucho más real de la distribución, siendo los días con peor meteorología correspondientes a la categoría *Snow, rain, partially cloudy*.

Otros factores importante a tener en cuenta son la diferencia mínima entre las diferentes categorías y la gran variabilidad del ranking en función del periodo seleccionado. Además, no existe ninguna correlación entre las categorías que se podrían considerar como 'buen' y 'mal' tiempo, existiendo categorías que se podrían catalogar como 'mal tiempo' con un número menor de viajes que aquellas que se catalogarían como 'buen tiempo'.

Una vez analizados estos datos se podría concluir que, siendo cierto que los días de nieve, lluvia y parcialmente nublados son en los que más viajes se realizan, y sin haber combinado la influencia de los otros factores en el análisis, no se puede afirmar que hay ningún tipo de correlación entre la meteorología y la cantidad de viajes.

3.5.5. Dimensión empresa

La dimensión empresa permite comprender el panorama competitivo y evaluar el desempeño de una empresa en su sector. En el contexto del proyecto, analizar los datos de otras empresas de vehículos de transporte con conductor (VTC) nos permite obtener una visión más completa del mercado y entender cómo Uber se posiciona frente a su competencia. Esto responde al objetivo número 4: 'Análisis de los patrones de demanda en la competencia'.

En esta sección se presenta una pantalla que utiliza la dimensión empresa para comparar los datos de Uber con los de otras empresas de VTC. Este análisis ayuda a identificar las fortalezas y debilidades de Uber en relación con sus competidores, observar las diferencias en la demanda servicios y en los patrones de comportamiento de los usuarios.




Figura 3.12: Pantalla 5: Comparación de los datos de la competencia con respecto a Uber

Como se observa en la Figura 3.12, la Pantalla 5 contiene una comparativa de la evolución del número de viajes de las empresas de VTC más importantes de la ciudad de Nueva York. Este gráfico se puede filtrar seleccionando el periodo de tiempo de estudio o las empresas a comparar.

Lo más destacable que se puede denotar del gráfico es la diferencia que existe entre Uber y sus competidores, confirmando los datos que se podían observar en la Figura 1.1. Sin embargo, observando más en detalle la periodicidad de la demanda de las diferentes empresas, se pueden notar diferencias entre los días de menor demanda de cada empresa, y por tanto una diferencia de fase entre ellos. La diferencia de demanda entre empresas en los diferentes días puede ayudar a analizar los motivos de los usuarios para optar por diferentes compañías a lo

largo de la semana y tomar medidas para incrementar la competitividad de Uber en sus picos más bajos.

3.6. Despliegue (Deployment)

El despliegue del proyecto es la última fase de la metodología CRISP-DM. Al desplegarlo, las diferentes partes involucradas en él pueden acceder a la información que contiene y beneficiarse de las conclusiones que se extraen. Este proyecto se ha desplegado en Power BI Service para garantizar su accesibilidad a todos los interesados, tanto la empresa como los conductores. Power BI Service es una plataforma de análisis de datos basada en la nube que permite compartir, colaborar y acceder a informes y dashboards de manera eficiente y segura. A continuación, se detalla el funcionamiento y ventajas de Power BI Service.

Funcionamiento de Power BI Service

Power BI Service es una herramienta de Microsoft que ofrece una funcionalidad para la visualización y análisis de datos. Entre sus principales características destacan:

- **Publicación y compartición de informes:** los informes y dashboards creados en Power BI Desktop pueden publicarse en Power BI Service, facilitando el acceso y la distribución de información dentro de la propia empresa o a usuarios externos. Permite compartir estos informes con otros miembros de la empresa o con grupos específicos, asegurando que la información relevante llegue a las personas adecuadas.
- **Acceso en la nube:** al estar basado en la nube, Power BI Service permite a los usuarios acceder a los informes y dashboards desde cualquier lugar y en cualquier momento, utilizando un navegador web o la aplicación móvil de Power BI. Esto es particularmente útil para los conductores de Uber que quieran buscar información desde sus dispositivos móviles entre viajes.
- **Actualización automática de datos:** Power BI Service permite configurar actualizaciones automáticas de los datos, garantizando que los informes reflejen la información más reciente. Esta funcionalidad es crucial para la toma de decisiones informadas y oportunas, especialmente en un entorno dinámico como el de los servicios de transporte.
- **Seguridad y control de acceso:** Power BI Service ofrece robustas medidas de seguridad para proteger los datos, incluyendo la posibilidad de establecer permisos de acceso y roles específicos para diferentes usuarios. Esto asegura que la información sensible esté protegida y que solo los usuarios autorizados puedan acceder a determinados datos. En este caso, se asignarían permisos solamente a personal interno de la empresa o conductores.

Los pasos a seguir para la publicación del informe han sido:

1. **Publicar los ficheros de datos en GitHub:** Se han subido todos los ficheros necesarios a un repositorio en GitHub. Ahí, se pueden ir actualizándolos paulatinamente con nuevos datos.

Capítulo 3. Procesado de los datos

2. **Generación de la conexión:** Desde Power BI, se selecciona el conector Web para obtener los datos y se añaden las url de cada ficheros del repositorio repositorio en formato raw.
3. **Cambios en el dataflow:** Al crear esta conexión, se genera en Power BI Services un Dataflow. Un Dataflow es un conjunto de tablas que se crean y manejan en Power BI services. Desde este Dataflow, se pueden realizar modificaciones como cambiar el tipo de datos, añadir columnas o filtrar los datos. En este proyecto, ese proceso se ha realizado previamente por lo que simplemente se cargan las tablas.
4. **Carga de datos en el reporte:** A partir del ID del Dataflow, se conecta el reporte y de esta forma quedan actualizados los datos.
5. **Recarga programada:** Para que la actualización de datos sea automática, se ha programado el flujo de datos para que se actualice de forma automática cada semana.

Una vez terminado este proceso, el reporte se actualizará automáticamente y quedará vinculado al repositorio con los datos. Para facilitar el acceso al informe, se genera un link que permite a los usuarios de la empresa y a los conductores de Uber visualizar y analizar los datos de manera sencilla.

Capítulo 4

Conclusiones y trabajo futuro

4.1. Conclusiones

Este proyecto ha demostrado que la aplicación de técnicas de análisis puede aportar un gran valor a las empresas de transporte de pasajeros, mejorando la eficiencia y calidad de sus servicios a través de los datos generados por su actividad. En concreto, se analizan datos relativos a la demanda de viajes de Uber en la ciudad de Nueva York en función de diferentes dimensiones como el tiempo, la localización, la meteorología y la competencia.

Para ello, la limpieza de datos en Python y el modelado han sido factores fundamental que han permitido realizar un análisis riguroso e intuitivo. Este análisis se realiza desde diferentes perspectivas representadas por las dimensiones del modelo.

El análisis de la demanda en función del tiempo ha permitido identificar cómo la demanda de viajes de Uber ha ido aumentando con el tiempo. Además, se ha observado una estacionalidad presente en los datos, teniendo los jueves, viernes y sábados los mayores picos de demanda, mientras que los domingos y lunes son los días con menor número de viajes. El análisis detallado por horas del día muestra que el rango horario entre las 18:00 y las 22:00 horas es el más concurrido, y se observa un pequeño aumento en la demanda alrededor de las 8-9 de la mañana durante los días laborables.

El análisis de la influencia de la meteorología ha permitido concluir que, aunque los días con lluvia, nieve o parcialmente nublados registran un mayor número de viajes, no existe una correlación significativa entre las condiciones climáticas y la demanda de Uber.

Finalmente, el análisis de la competencia ha puesto de manifiesto la posición dominante de Uber en el mercado de VTC de Nueva York. Además, ha revelado también diferencias en la estacionalidad de los patrones de demanda entre Uber y sus competidores, lo que podría indicar la existencia de nichos de mercado específicos que podrían ser explotados por la empresa.

El desarrollo del dashboard en Power BI ha permitido presentar los resultados de una manera accesible y comprensible para que los usuarios exploren los datos y obtengan los insights más relevantes de forma intuitiva. Este dashboard facilita la toma de decisiones fundadas en datos y permite realizar consultas con facilidad.

4.2. Trabajo futuro

Este proyecto ha sentado las bases de un análisis de la demanda de viajes de Uber en la ciudad de Nueva York, proporcionando información valiosa sobre los patrones de movilidad urbana y su relación con algunos factores. Sin embargo, existen diversas líneas de investigación que podrían complementar y enriquecer este estudio:

- **Ampliación del conjunto de datos:** los datos utilizados, tienen muy poco nivel de detalle sobre los viajes. Con la ampliación de esos datos, por ejemplo con el precio del viaje, duración o destino, se obtendría una comprensión más amplia y general de los servicios. Además, incorporar datos de otras fuentes relevantes, como información sobre tráfico o eventos locales podría mejorar aún más la precisión y utilidad del análisis, ofreciendo más detalles de zonas y días específicos.
- **Modelos predictivos avanzados:** desarrollar y aplicar modelos de aprendizaje automático avanzados para predecir la demanda y el comportamiento de los usuarios. Aquí se podrían incluir técnicas de Deep Learning con redes neuronales o algoritmos de clustering. Estos modelos avanzados podrían identificar patrones complejos en los datos, mejorando la capacidad de prever fluctuaciones en la demanda y optimizar la asignación de recursos.
- **Optimización en tiempo real:** integrar el dashboard con sistemas de gestión en tiempo real podría permitir ajustes inmediatos a las operaciones de Uber, mejorando la respuesta a cambios en la demanda de manera continua. Esta integración permitiría a los conductores reaccionar de manera más ágil y eficiente a las condiciones cambiantes como picos inesperados en la demanda en cierta zona.
- **Análisis de impacto ambiental:** evaluar el impacto ambiental de las operaciones de Uber para promover acciones más sostenibles es un área crucial para el desarrollo futuro alineado con la visión de la empresa. Esto podría incluir el análisis de la huella de carbono de los viajes o la promoción del uso de vehículos completamente eléctricos en la flota.
- **Expansión geográfica:** aplicar el mismo enfoque a otras ciudades y regiones para identificar patrones de movilidad específicos de dichas zonas y adaptar las estrategias a cada contexto puede ayudar a escalar los beneficios del análisis. Cada ciudad presenta características diferentes en términos de movilidad y adaptar las estrategias a estos contextos puede mejorar la eficiencia y la calidad del servicio en cada área.

4.2. Trabajo futuro

Las futuras investigaciones y desarrollos pueden aprovechar los resultados de este proyecto para seguir optimizando y expandiendo el impacto positivo de este tipo de análisis en la empresa, contribuyendo tanto a mejorar la eficiencia operativa como a la sostenibilidad ambiental y la satisfacción del usuario.

Capítulo 5

Análisis de impacto

En este capítulo, se analizará el impacto potencial de los resultados obtenidos en este trabajo, destacando tanto los beneficios esperados como los posibles efectos adversos.

5.1. Impacto empresarial

- **Beneficios:** conocer los patrones de demanda de viajes en la ciudad de Nueva York ayuda a la empresa a tomar decisiones más informadas sobre la asignación de vehículos, el ajuste de tarifas y el desarrollo de nuevas estrategias de marketing. Al comprender mejor las necesidades y preferencias de los usuarios, Uber puede mejorar la calidad de su servicio y aumentar su cuota de mercado, lo que se traduce en mayores beneficios y una mejor experiencia para el usuario. Este enfoque estratégico basado en datos se alinea con el ODS 9: Industria, innovación e infraestructura, ya que demuestra cómo la aplicación de la tecnologías puede impulsar la eficiencia y la sostenibilidad en el sector del transporte.

5.2. Impacto social

- **Beneficios:** identificar las zonas de la ciudad con mayor demanda de viajes y los horarios de mayor congestión, puede ayudar a las autoridades a planificar y mejorar el transporte público, la infraestructura vial y la seguridad con el desarrollo de políticas públicas de transporte más efectivas, contribuyendo así al ODS 11: Ciudades y comunidades sostenibles. Además, al analizar la relación entre la meteorología y la demanda de viajes, se pueden identificar patrones que ayuden a prever y gestionar mejor el transporte en condiciones climáticas adversas,
- **Desventajas:** el aumento del uso de servicios de VTC como Uber podría llevar a una disminución del uso del transporte público y a un aumento del tráfico y la congestión en las ciudades. Si bien Uber ofrece una alternativa

de transporte conveniente y flexible, su popularidad podría tener un impacto adverso en el uso del transporte público aumentando la congestión del tráfico y dificultando la movilidad en la ciudad.

5.3. Impacto medioambiental

- **Beneficios:** al fomentar el uso compartido de vehículos y promover el uso de vehículos eléctricos, Uber puede contribuir a la reducción de las emisiones de gases de efecto invernadero y la contaminación del aire. De esta manera, contribuye a la mejora de la calidad del aire y la lucha contra el cambio climático como indica el ODS 13: Acción por el clima.
- **Desventajas:** el aumento del número de vehículos de VTC en circulación podría contrarrestar los beneficios ambientales del uso compartido y los vehículos eléctricos. Si bien Uber está realizando esfuerzos para promover un transporte más sostenibles, el aumento del número de vehículos de VTC en las calles podría tener un impacto negativo en el medio ambiente si no se gestiona adecuadamente.

5.4. Impacto cultural

- **Beneficios:** uno de los descubrimientos que se ha obtenido del análisis ha sido la diferencia en la demanda de las zonas con mayores y menores ingresos. Revelados estos hechos, Uber puede tomar cartas en el asunto y fomentar su uso en las zonas más desfavorecidas, contribuyendo así al ODS 10: Reducción de las desigualdades

Bibliografía

- [1] K. X. P. K. O. P. Diego Correa Ph.D. *, «Exploring the Taxi and Uber Demands in New York City: An Empirical Analysis and Spatial Modeling», 2021.
- [2] T. Y.-c. Chang H-w. y J.-j. Hsu, «Context-aware taxi demand hotspots prediction», *Int. J. Business Intelligence and Data Mining*, Vol. 5, No. 1, pp.3–18.r», 2010.
- [3] M. J. Diván, «Data Driven Decision making», 2020.
- [4] S. K. Bandyopadhyay, «Big Data- A Review on Analysing 3Vs», 216.
- [5] IBM, «IBM SPSS Modeler CRISP-DM Guide»,
- [6] M. K. Ranjan, «Python: Empowering Data Science Applications and Research», *Journal of Operating Systems Development Trends*, 2023.
- [7] W. Mckinney, «pandas: a Foundational Python Library for Data Analysis and Statistics», 2011.
- [8] *About Pandas*, <https://pandas.pydata.org/about/index.html>, 2024.
- [9] *Open Street Map*, <https://www.openstreetmap.org/about>.
- [10] S. Widjaja y T. Mauritsius, «The development of performance dashboard visualization with power BI as platform», *Int. J. Mech. Eng. Technol*, vol. 10, n.º 5, págs. 235-249, 2019.
- [11] B. Powell, *Microsoft Power BI cookbook: Creating business intelligence solutions of analytical data models, reports, and dashboards*. Packt Publishing Ltd, 2017.
- [12] J. S. Kurt Schlegel, «Magic Quadrant for Analytics and Business Intelligence Platforms», 2019.
- [13] *Government Data*, <https://catalog.data.gov/dataset/nyc-taxi-zones>.
- [14] S. K. Mukhiya y U. Ahmed, *Hands-On Exploratory Data Analysis with Python: Perform EDA techniques to understand, summarize, and investigate your data*. Packt Publishing Ltd, 2020.
- [15] E. F. Codd, «A relational model of data for large shared data banks», *Communications of the ACM*, vol. 13, n.º 6, págs. 377-387, 1970.
- [16] C. Jensen, T. B. Pedersen y C. Thomsen, *Multidimensional databases and data warehousing*. Morgan & Claypool Publishers, 2010.

BIBLIOGRAFÍA

- [17] A. Janes, A. Sillitti, G. Succi et al., «Effective dashboard design», *Cutter IT journal*, vol. 26, n.º 1, págs. 17-24, 2013.
- [18] A. Pinar, J. C. Bennett, P. P. Pebay, H. Kolla y D. Thompson, «A Dashboard for Comparative Visualization of Many-variate Data.», Sandia National Lab.(SNL-CA), Livermore, CA (United States), inf. téc., 2015.
- [19] J. Meyer, «How Uber Saves Lives», *Manhattan Institute*, 2015.

Este documento esta firmado por



Firmante	CN=tfgm.fi.upm.es, OU=CCFI, O=ETS Ingenieros Informaticos - UPM, C=ES
Fecha/Hora	Mon Jun 03 21:53:38 CEST 2024
Emisor del Certificado	EMAILADDRESS=camanager@etsiinf.upm.es, CN=CA ETS Ingenieros Informaticos, O=ETS Ingenieros Informaticos - UPM, C=ES
Numero de Serie	561
Metodo	urn:adobe.com:Adobe.PPKLite:adbe.pkcs7.sha1 (Adobe Signature)