

MÁSTER UNIVERSITARIO EN DIRECCIÓN DE PROYECTOS

TRABAJO FIN DE MÁSTER

PREDICCIÓN DE COSTOS Y PLAZOS EN PROYECTOS A TRAVÉS DEL ANÁLISIS DE MÉTRICAS HISTÓRICAS Y DATOS EN TIEMPO REAL



Estudiante: Eguia Ercilla, Ane

Director/Directora: Tejo Otero, Aitor

Curso: 2024-2025

Fecha: Bilbao, 5 de julio del 2025

Resumen

La falta de una gestión adecuada en los proyectos sigue siendo una cuestión clave que afecta a diversos sectores, en los que las desviaciones presupuestarias y el incumplimiento de los plazos son causa frecuente de resultados negativos. El presente Trabajo Fin de Máster analiza este tema a través de un estudio cuantitativo basado en más de 4.000 proyectos reales extraídos de fuentes públicas y distintos sectores, con el fin de medir el impacto que tienen las metodologías de gestión avanzada en el rendimiento de los proyectos.

Para ello, lo primero que se ha realizado ha sido un análisis de resultados y de indicadores de rendimiento (como el CPI y SPI) de los distintos proyectos. Asimismo, se ha llevado a cabo una comparación entre los resultados de cada conjunto de datos, diferenciando entre los proyectos gestionados con técnicas avanzadas y los que no. Finalmente, se han desarrollado varios modelos de predicción basados en algoritmos de *Machine Learning* (ML) que permiten identificar patrones relevantes de comportamiento según las variables del proyecto (Árboles de Decisión, *Random Forest*, etc.).

Los resultados del análisis revelan una correlación positiva y relevante entre la adopción de técnicas de gestión avanzadas y una tendencia positiva en las métricas de rendimiento. Una de las principales conclusiones que se ha obtenido a partir de este análisis es una base empírica consistente de que una gestión más sistematizada con soporte tecnológico favorece de manera relevante al desempeño del proyecto, permitiendo un mayor control de costes y plazos.

Palabras claves: Gestión de Proyectos, SPI (*Schedule Performance Index*), CPI (*Cost Performance Index*), *Machine Learning*, Árboles de Decisión, *Random Forest*, desempeño del proyecto, técnicas avanzadas.

Impacto en los Objetivos de Desarrollo Sostenible (ODS): ODS9, ODS11, ODS12.

Laburpena

Proiektuetan kudeaketa egokirik ez izatea oraindik ere funtsezko arazo bat da sektore askotan, non aurrekontu-desbideratzeek eta epeen ez-betetzeak sarritan emaitza negatiboak eragiten dituzten. Master Amaierako Lan honek gai hori aztertzen du ikerketa kuantitatibo baten bidez, 4.000 proiektu erreal baino gehiago oinarri hartuta, iturri publikoetatik eta sektore ezberdinetatik hartuak, kudeaketa-metodologia aurreratuek proiektuen errendimenduan duten eragina neurtzeko helburuarekin.

Horretarako, lehenik eta behin, proiektu ezberdinen emaitzak eta errendimendu-adierazleak (hala nola CPI eta SPI) aztertu dira. Halaber, datu multzo bakoitzeko emaitzak alderatu dira, kudeaketa aurreratuko teknikak erabili dituzten proiektuen eta ez dituztenen arteko desberdintasunak nabarmenduz. Azkenik, hainbat aurreikuspen-eredu garatu dira *Machine Learning* (ML) algoritmoetan oinarrituta (Erabaki-zuhaitzak, *Random Forest*, etab.), proiektuen aldagai nagusien arabera jokabide-eredu esanguratsuak identifikatzeko.

Azterketaren emaitzek erakusten dute kudeaketa aurreratuko teknikak erabiltzeak errendimendu-adierazleetan joera positiboa eta esanguratsua izaten duela. Ondorio nagusietako bat da analisi honek oinarri enpiriko sendo bat eskaintzen duela, zeinaren arabera kudeaketa sistematikoagoak eta teknologiaren laguntzarekin hobekuntza nabarmena ekartzen dion proiektuaren errendimenduari, kostu eta epeen kontrol handiagoa ahalbidetuz.

Hitz gakoak: Proiektuen Kudeaketa, SPI (*Schedule Performance Index*), CPI (*Cost Performance Index*), *Machine Learning*, Erabaki-zuhaitzak, *Random Forest*, proiektuaren errendimendua, teknika aurreratuak.

Garapen Jasangarriko Helburuetan (GJH) eragina: SDG9, SDG11, SDG12.

Abstract

The lack of proper project management remains a key issue affecting various sectors, where budget overruns and missed deadlines are frequent causes of negative outcomes. This Master's Thesis addresses the problem through a quantitative study based on more than 4,000 real-world projects, drawn from public sources and a range of industries, with the aim of measuring the impact of advanced project management methodologies on performance.

To this end, the first step involved analysing the results and performance indicators (such as CPI and SPI) of the different projects. A comparison was then conducted across the datasets, distinguishing between projects managed using advanced techniques and those that were not. Finally, several predictive models based on Machine Learning (ML) algorithms—such as Decision Trees and Random Forest—were developed to identify relevant behavioural patterns according to key project variables.

The results of the analysis reveal a strong and positive correlation between the adoption of advanced management techniques and improved performance metrics. One of the main conclusions drawn from this study is that a more systematic, technology-supported management approach significantly enhances project performance, enabling better control over both costs and schedules.

Keywords: Project Management, SPI (Schedule Performance Index), CPI (Cost Performance Index), Machine Learning, Decision Trees, Random Forest, project performance, advanced techniques.

Sustainable Development Goals (SDG) impact: GJH9, GJH11, GJH12.

Índice de contenidos

1. Introducción.....	11
2. Contexto y motivación del trabajo.....	12
3. Objetivos y alcance	14
3.1 Work Breakdown Structure (WBS)	15
4. Beneficios del TFM y su relación con los ODS	16
5. Estado del arte	17
5.1 Introducción a la Estimación de Costes y Plazos en Proyectos	17
5.2 Métodos tradicionales de estimación y sus limitaciones	17
5.3 Inteligencia Artificial y Machine Learning en la Gestión de Proyectos.....	19
5.4 Modelos de Machine Learning aplicados a la Predicción de Costos y Plazos.....	19
5.5 Factores Humanos y su Impacto en las Estimaciones Predictivas.....	20
5.6 Desafíos y Oportunidades en la Implementación de Modelos Predictivos	21
6. Revisión de la literatura	22
6.1 Fundamentos de la Gestión de Proyectos	22
6.2 Factores que afectan en costes y plazos de los proyectos	24
6.3 Aplicaciones de la Ciencia de Datos en la Gestión de Proyectos	25
6.4 Herramientas tecnológicas para la predicción	26
6.4.1 Business Intelligence.....	26
6.4.2 Inteligencia Artificial y Machine Learning.....	27
6.4.3 Big Data	27
7. Metodología	28
7.1 Análisis de proyectos gestionados con metodologías avanzadas.....	28
7.1.1 Estudio I (BIM-AI Integrated Dataset).....	28
7.1.2 Estudio II (Empirical Project Data).....	40
7.2 Análisis de proyectos sin emplear modelos predictivos	47
7.2.1 Estudio III (Capital Project Schedules and Budgets).....	48
7.2.2 Estudio IV (Capital Projects Dashboard)	59
8. Resultados	68
8.1 Comparativa entre cuatro conjuntos de proyectos	68
8.1.1 Análisis Comparativo de CPI y SPI en Función del Enfoque de Gestión	68
8.1.2 Análisis estadístico de diferencias significativas	71
8.1.3 Conclusiones de la comparativa realizada	72
8.2 Diseño de técnicas predictivas	72
8.2.1 Generación de árboles de decisión	73
8.2.2 Análisis de Importancia de Variables mediante Random Forest.....	79
8.2.3 Interpretación y Discusión de los Resultados	82

9. Diagrama Gantt del TFM	83
10. Descargos de gastos del TFM	84
10.1 Costes asociados al tiempo dedicado al trabajo	84
10.2 Costes de recursos materiales	84
10.3 Costes indirectos	85
10.4 Resumen del presupuesto	85
11. Conclusiones	86
12. Líneas futuras	88
13. Valoración personal	89
14. Bibliografía	90

Índice de Figuras

Ilustración 1: WBS del TFM	15
Ilustración 2: Objetivos de Desarrollo Sostenible (ODS)	16
Ilustración 3: Project Management Triangle	22
Ilustración 4: Factores que influyen en los costes y plazos de los proyectos.....	25
Ilustración 5: Visualización datos importados (R-Studio) I.....	30
Ilustración 6: Visualización resumen estadístico datos (R-Studio).....	30
Ilustración 7: <i>Boxplot</i> SPI y CPI (R-Studio) I	35
Ilustración 8: Visualización clasificación de proyectos según SPI y CPI (R-Studio) I.....	37
Ilustración 9: Visualización histogramas SPI y CPI (R-Studio) I	38
Ilustración 10: Porcentaje cumplimiento SPI y CPI (BIM)	38
Ilustración 11: Visualización relación Nivel de Riesgo Vs. CPI (R-Studio) I.....	39
Ilustración 12: Verificación tipo de valor de SPI y CPI (R-Studio) II.....	42
Ilustración 13: Resumen estadístico SPI y CPI (R-Studio) II	43
Ilustración 14: Visualización <i>boxplot</i> CPI y SPI (R-Studio) II	44
Ilustración 15: Resumen estadístico SPI (R-Studio) II.....	44
Ilustración 16: Visualización clasificación de proyectos según CPI y SPI (R-Studio) II	45
Ilustración 17: Visualización histograma SPI y CPI (R-Studio) II	46
Ilustración 18: Porcentaje cumplimiento SPI y CPI (Valor Ganado)	47
Ilustración 19: Resumen estadístico (R-Studio) III.....	50
Ilustración 20: Resumen estadístico de Valor Gando (R-Studio) III.....	53
Ilustración 21: Visualización <i>outliers</i> SPI y CPI (R-Studio) III	54
Ilustración 22: Visualización <i>boxplot</i> CPI y SPI (R-Studio) III	55
Ilustración 23: Visualización gráfica de dispersión SPI y CPI (R-Studio) III	57
Ilustración 24: Visualización histograma distribución SPI y CPI (R-Studio) III	58
Ilustración 25: Porcentaje proyectos que cumplen SPI y CPI (New York Projects).....	58
Ilustración 26: Visualización nombres de las variables del dataset (R-Studio) IV	60
Ilustración 27: Resumen estadístico CPI y SPI (R-Studio) IV	62
Ilustración 28: Visualización <i>boxplot</i> CPI y SPI (R-Studio) IV	63
Ilustración 29: Visualización <i>boxplot</i> de valores CPI y SPI sin <i>outliers</i> (R-Studio) IV.....	64
Ilustración 30: Gráfica de dispersión entre CPI y SPI por proyecto (R-Studio) IV.....	65
Ilustración 31: Visualización histograma CPI y SPI (R-Studio) IV.....	67
Ilustración 32: Porcentaje proyectos que cumplen SPI y CPI (Capital Dashboard)	67

Ilustración 33: Comparación SPI y CPI según tipo de gestión (R-Studio).....	70
Ilustración 34: Árbol de decisión - SPI (Proyectos con gestión avanzada)	74
Ilustración 35: Árbol de decisión - CPI (Proyectos con gestión avanzada)	75
Ilustración 36: Árbol de decisión - SPI (Proyectos sin gestión avanzada)	76
Ilustración 37: Árbol de decisión - CPI (Proyectos sin gestión avanzada)	77
Ilustración 38: Importancia variables - SPI (Proyectos con Gestión Avanzada).....	79
Ilustración 39: Importancia variables - CPI (Proyectos con Gestión Avanzada)	80
Ilustración 40: Importancia variables - SPI (Proyectos sin Gestión Avanzada).....	81
Ilustración 41: Importancia variables - CPI (Proyectos sin Gestión Avanzada).....	81
Ilustración 42: Planificación del TFM.....	83

Índice de Tablas

Tabla 1: Ventajas y limitaciones de las metodologías del PM	23
Tabla 2: Carga y recopilación de datos (R-Studio) I	29
Tabla 3: Resumen estadístico (R-Studio) I	30
Tabla 4: Tipos de distribución para la medición del progreso de las actividades	32
Tabla 5: Cálculo métricas de Valor Ganado (R-Studio) I	34
Tabla 6: Visualización valores de Valor Ganado (R-Studio) I	34
Tabla 7: Visualización <i>outliers</i> (R-Studio) I	35
Tabla 8: Clasificación de proyectos según valor de SPI y CPI (R-Studio) I	36
Tabla 9: Histogramas SPI y CPI (R-Studio) I	37
Tabla 10: Análisis relación entre CPI y Nivel de Riesgo de proyectos (R-Studio) I	39
Tabla 11: Carga y adecuación de datos (R-Studio) II	41
Tabla 12: Conversión valores SPI y CPI a tipo numérico (R-Studio) II	42
Tabla 13: Filtro de proyectos con valores nulos y resumen estadístico de SPI y CPI (R-Studio) II	42
Tabla 14: <i>Boxplot</i> CPI y SPI (R-Studio) III	43
Tabla 15: Clasificación de desempeño CPI y SPI (R-Studio) II	45
Tabla 16: Histograma SPI y CPI (R-Studio) II	46
Tabla 17: Carga de paquetes necesarios (R-Studio) III	48
Tabla 18: Carga de datos (R-Studio) III	49
Tabla 19: Visualización de datos (R-Studio) III	49
Tabla 20: Convertir texto a columna de tipo numérico (R-Studio) III	49
Tabla 21: Resumen estadístico (R-Studio) III	50
Tabla 22: Cálculo <i>Cost Overrun</i> y <i>Schedule Deviation</i> (R-Studio) III	51
Tabla 23: Visualización valores de Valor Ganado (R-Studio) III	52
Tabla 24: Eliminar filas con valores faltantes y visualización de los valores (R-Studio) III	52
Tabla 25: Visualización valores calculados (R-Studio) III	52
Tabla 26: Cálculo SPI y CPI (R-Studio) III	53
Tabla 27: Visualización <i>outliers</i> SPI y CPI (R-studio) III	54
Tabla 28: Depuración valores atípicos (R-Studio) III	55
Tabla 29: <i>Boxplot</i> SPI y CPI (R-Studio) III	55
Tabla 30: Grafica de dispersión SPI y CPI (R-Studio) III	56
Tabla 31: Histograma SPI y CPI (R-Studio) III	57
Tabla 32: Carga de paquetes y datos (R-Studio) IV	59

Tabla 33: Adecuación de nombres de las variables y visualización (R-Studio) IV	60
Tabla 34: Selección y definición adecuada del formato de los datos (R-Studio) IV	60
Tabla 35: Cálculo y resumen estadístico de CPI y SPI (R-Studio) IV	62
Tabla 36: Generación <i>boxplot</i> de CPI y SPI (R-Studio) IV.....	62
Tabla 37: Eliminación de <i>outliers</i> y nueva visualización <i>boxplot</i> de valores CPI y SPI (R-Studio) IV..	63
Tabla 38: Gráfica de dispersión entre CPI y SPI (R-Studio) IV.....	65
Tabla 39: Histograma SPI y CPI (R-Studio) IV	66
Tabla 40: Comparación valores estadísticos CPI y SPI de cuatro dataset (R-Studio)	68
Tabla 41: Visualización resumen estadístico CPI y SPI de cuatro <i>datasets</i> (R-Studio)	69
Tabla 42: Análisis estadístico de diferencias significativas (R-Studio).....	71
Tabla 43: Resultados del análisis estadístico de diferencias significativas.....	71
Tabla 44: Entrenamiento y generación de árboles de predicción (R-Studio)	73
Tabla 45: Resumen resultados árboles de decisión	78
Tabla 46: Presupuesto del TFM	85

Símbolos y abreviaturas

ODS	Objetivos de Desarrollo Sostenible
TFM	Trabajo Fin de Máster
IA	Inteligencia Artificial
ML	Machine Learning (Aprendizaje Automático)
BIM	Building Information Modeling
SPI	Schedule Performance Index
CPI	Cost Performance Index
CV	Cost Variance
SV	Schedule Variance
AC	Actual Cost
PV	Planned Value
EV	Earned Value
PMI	Project Management Institute
PERT	Program Evaluation and Review Technique
CPM	Critical Path Method
EVM	Earned Value Management
ANN	Artificial Neural Network
NLP	Natural Language Processing
WBS	Work Breakdown Structure

1. Introducción

En la actualidad, la previsión de costes y plazos en la gestión de proyectos constituye un desafío constante en diversos sectores. A pesar de la existencia de metodologías estructuradas como PMBOK, PRINCE2 y Agile, las desviaciones en los presupuestos y cronogramas continúan presentando problemas recurrentes que impactan negativamente en la rentabilidad, la eficiencia operativa y la satisfacción de los *stakeholders*. La dependencia de los métodos tradicionales de estimación, basados en datos históricos o en la experiencia subjetiva de los gestores, limita la capacidad de anticiparse a imprevistos y dificulta la óptima toma de decisiones.

El avance de las tecnologías de análisis de datos ha dado lugar a nuevas oportunidades para hacer frente a este problema, integrando modelos predictivos basados en la inteligencia artificial y el *machine learning*. Estas herramientas facilitan el procesamiento de grandes volúmenes de información, la identificación de los patrones subyacentes en la ejecución de los proyectos y la generación de estimaciones más precisas. En particular, la combinación de datos históricos e información en tiempo real permite optimizar la capacidad de adaptación ante posibles desviaciones, lo que permite una planificación más eficaz y monitorizar proyectos de forma proactiva.

El objetivo del presente trabajo es demostrar mediante un análisis cuantitativo que las técnicas avanzadas de gestión permiten mejorar el rendimiento de los proyectos en cuanto a costes y plazos. Asimismo, se desarrollará un modelo predictivo que facilite la estimación de costes y plazos de los proyectos con mayor exactitud. Para hacerlo posible, se realizará un análisis de los indicadores de rendimiento SPI y CPI a partir de cuatro conjuntos de datos de proyectos históricos, que contienen tanto proyectos gestionados con metodologías avanzadas como proyectos que no. A partir de estos datos, se realizará un análisis comparativo que permita evaluar las diferencias en los resultados entre tipos de gestión. Posteriormente, se van a construir modelos de árboles de decisión y random forest, empleando como variables principales el coste y la duración planificada. Estos modelos van a ayudar a identificar umbrales clave y factores determinantes que faciliten la toma de decisiones en la gestión de proyectos.

La creciente disponibilidad de datos, junto con los avances en tecnologías analíticas, ofrece una oportunidad significativa de transformar la gestión de los proyectos, al tiempo que se minimizan los riesgos y se mejora la eficiencia. En este contexto, la implementación de modelos de predicción es un paso fundamental hacia una gestión más ágil, basada en la evidencia y adaptada a las exigencias actuales del mercado.

2. Contexto y motivación del trabajo

La gestión de proyectos se enfrenta a un entorno que se está convirtiendo cada vez más complejo, caracterizado por plazos estrictos, presupuestos limitados y una alta incertidumbre tanto en la planificación como en la ejecución de los mismos. En diversos sectores, tales como la construcción y la industria manufacturera[1][2], se han identificado discrepancias significativas en los costos y cronogramas, lo cual repercute negativamente a la rentabilidad y beneficios de los proyectos. De acuerdo con el informe CHAOS del Standish Group solamente el 16,2% de los proyectos se llevan a cabo dentro del tiempo y los costos previstos, mientras que el 52,7% sufre alteraciones notables en términos de gastos y cronogramas, y el 31,1% se anulan antes de que terminen. [3] Estas desviaciones suelen derivarse de estimaciones indeterminadas, alteraciones en los requisitos del cliente, dificultades en la asignación de recursos y una carencia de herramientas óptimas que permitan prever posibles riesgos e imprevistos.

En el ámbito de la construcción, un estudio elaborado por McKinsey & Company, titulado "*Reinventing Construction: A Route to Higher Productivity*", revela que los grandes proyectos de infraestructura tienden a sobrepasar sus presupuestos en un 80% y sus plazos en un 20% en promedio. [4] Estas cifras revelan la magnitud del desafío que enfrentan los gestores de proyectos en relación con el control de costes y tiempos.

Además, de acuerdo al informe *Pulse of the Profession (2021)* del *Project Management Institute* (PMI), se revela que el 34% de los proyectos presentan desviaciones en el alcance, mientras que el 12% son considerados fracasos. [5] Estos datos destacan la necesidad urgente de mejorar los métodos de planificación y control, especialmente la gestión de riesgos y la previsión de costes y plazos. Uno de los factores críticos que influye en el fracaso de los proyectos es la planificación inadecuada, que supone el 33% de los casos. [5]

En lo que respecta al uso de tecnología avanzada para la gestión de proyectos, este mismo informe indica que únicamente el 23% de los equipos de proyectos están utilizando inteligencia artificial (IA) en la gestión de sus actividades. [5] Este dato sugiere que, a pesar de los avances tecnológicos, muchas organizaciones aún no han logrado aprovechar en su totalidad las herramientas predictivas y analíticas que podrían optimizar la precisión en la estimación de costes y plazos. De hecho, solo el 33% de las organizaciones consideran como una prioridad el empleo de herramientas impulsadas por IA y de ML. [5]

Tradicionalmente, los métodos de planificación de proyectos han estado basadas en planteamientos deterministas que dependen de la experiencia de los gestores y de datos históricos. Sin embargo, este tipo de planteamientos presentan limitaciones al no considerar la variabilidad de los factores dinámicos que influyen en la ejecución de un proyecto. En este contexto, la implementación de modelos predictivos que empleen inteligencia artificial y aprendizaje automático se presenta como una alternativa innovadora para mejorar la precisión de las estimaciones y optimizar la toma de decisiones.

La razón principal de este estudio radica en la necesidad de integrar enfoques basados en datos en la gestión de proyectos, demostrando el potencial de la analítica avanzada para anticipar desviaciones en costes y plazos. La creciente digitalización de los procesos y la disponibilidad de información en tiempo real

constituyen una oportunidad para desarrollar herramientas predictivas que permitan una gestión más eficiente y proactiva.

A través de este trabajo, se busca contribuir a la optimización de la planificación y el seguimiento de proyectos, abordando las limitaciones de los métodos tradicionales y explorando el potencial de los modelos predictivos basados en datos históricos. La integración de estas tecnologías no solo permitirá mejorar la precisión de las estimaciones, sino también fomentar una cultura de toma de decisiones fundamentada en datos, lo que se traducirá en una mayor eficiencia, rentabilidad y éxito en la ejecución de proyectos. En un mundo donde la incertidumbre y la complejidad son cada vez más relevantes, la capacidad de prever y adaptarse a los cambios se convierte en un factor clave para el éxito de cualquier iniciativa.

3. Objetivos y alcance

El objetivo principal de este trabajo consiste en el desarrollo de un modelo predictivo que facilite la estimación con mayor precisión de los costos y plazos en la planificación y ejecución de proyectos, empleando tanto datos históricos como datos en tiempo real. Para alcanzar este propósito, se procederá al análisis de métricas clave que influyen en la evolución de los proyectos, y se implementarán algoritmos de aprendizaje automático que permitan identificar patrones y tendencias en la información recopilada.

Los objetivos específicos del estudio son los siguientes:

1. Identificar las métricas más relevantes en la predicción de costos y plazos en distintos tipos de proyectos.
2. Desarrollar y evaluar modelos predictivos basados en datos históricos para mejorar la precisión de las estimaciones de costos y plazos en proyectos gestionados con y sin técnicas avanzadas.
3. Comparar la efectividad del modelo propuesto con los métodos tradicionales de estimación en la gestión de proyectos.

El presente estudio se enfocará en la aplicación de modelos de aprendizaje automático para la predicción de costes y plazos en el ámbito de la gestión de proyectos. Se contemplarán proyectos de diversos sectores que cuenten con datos accesibles para el análisis; no obstante, se priorizarán aquellos en los que la disponibilidad de información permita una evaluación del desempeño del modelo con un alto nivel de precisión. Otros aspectos de la gestión de proyectos, tales como la gestión de riesgos, los recursos humanos o la calidad, no serán tratados en profundidad, salvo en la medida en que sea necesario para contextualizar la aplicación del modelo mencionado. Esta decisión se debe a que en el presente trabajo se quiere mantener un enfoque práctico en métricas cuantificables directamente vinculadas a costes y plazos, evitando desviar el estudio hacia variables que son más subjetivas o complejas de gestionar.

Toda la información con la que se va a trabajar en el presente trabajo se trata de fuentes de información que están disponibles en las plataformas tanto de Google Scholar como Scopus. Asimismo, a la hora de seleccionar el estudio del que extraer la información con el que trabajar en este TFM, siempre se premiarán dichos documentos académicos y de carácter profesional.

3.1 Work Breakdown Structure (WBS)

Con el fin de lograr una planificación adecuada del presente TFM, se ha definido una estructura de desglose del trabajo (*Work Breakdown Structure*, WBS) que hay que realizar para cumplir con el objetivo. Este desglose de trabajo se trata de una estructura jerárquica y detallada de todas las tareas que son necesarias para el desarrollo del trabajo. Este WBS (Ilustración 1) proporciona una visión integral y clara de las tareas y sub-tareas que se van a desarrollar en el trabajo.




Ilustración 1: WBS del TFM

4. Beneficios del TFM y su relación con los ODS

La implementación de modelos predictivos en la gestión de proyectos puede ofrecer múltiples beneficios, tanto a nivel organizacional como en términos sociales y ambientales. Entre las principales aportaciones de este estudio se pueden destacar:

- **Optimización de los recursos y reducción de desperdicios**
Al mejorar la precisión en la estimación de costes y plazos, se reducen los sobrecostos y los retrasos, lo que favorece un uso más eficiente de los recursos financieros, materiales y humanos.
- **Toma de decisiones basada en datos**
El modelo predictivo ofrece información objetiva y cuantificable que facilita la toma de decisiones estratégicas, disminuyendo la dependencia de decisiones subjetivas y fortaleciendo la capacidad de adaptación ante alteraciones en el proyecto.
- **Mejora de la sostenibilidad en la gestión de proyectos**
La disminución de ineficiencias y la optimización en el uso de recursos contribuyen a la reducción del impacto ambiental, lo cual se encuentra alineado con las estrategias de desarrollo sostenible.
- **Aumento de la competitividad empresarial**
Las organizaciones que implementan herramientas fundamentadas en datos pueden mejorar su capacidad de respuesta, disminuir los riesgos y optimizar su planificación, lo que les permite mantener una posición competitiva en el mercado.

El contenido de este trabajo se encuentra en consonancia con diversos Objetivos de Desarrollo Sostenible (ODS) establecidos por las Naciones Unidas, que se pueden observar a continuación (Ilustración 2).

- **ODS 9 (Industria, Innovación e Infraestructura):** La implementación de modelos predictivos en la gestión de proyectos fomenta la utilización de tecnologías avanzadas con el propósito de optimizar la eficiencia en diversos sectores industriales.
- **ODS 11 (Ciudades y Comunidades Sostenibles):** Una planificación más detallada de proyectos de infraestructura contribuye al desarrollo de ciudades más eficientes y sostenibles.
- **ODS 12 (Producción y Consumo Responsables):** La optimización en la asignación de recursos y la reducción de desperdicios contribuyen a la implementación de un modelo de producción más sostenible.



Ilustración 2: Objetivos de Desarrollo Sostenible (ODS)

El presente estudio no solo ejerce un impacto directo en la eficiencia operativa de las empresas, sino que también fomenta la adopción de prácticas más sostenibles en la ejecución de proyectos, lo cual genera beneficios tanto en el ámbito económico como en el ambiental.

5. Estado del arte

5.1 Introducción a la Estimación de Costes y Plazos en Proyectos

La estimación precisa de costes y plazos en proyectos forma un área de investigación fundamental dentro de la gestión de proyectos, dado que influye de manera directa en la viabilidad, rentabilidad y éxito de cualquier iniciativa. A lo largo del tiempo, se han desarrollado diversos enfoques para abordar este desafío, abarcando desde metodologías tradicionales hasta soluciones que incorporan inteligencia artificial y análisis de datos en tiempo real. No obstante, la variabilidad inherente de los proyectos, junto con la influencia de factores externos como cambios en la normativa, alteraciones del mercado y la disponibilidad de recursos, continúa generando incertidumbre en las estimaciones.

En este contexto, los modelos predictivos han presentado como una alternativa prometedora para mejorar la precisión en la planificación de proyectos. La combinación de datos históricos con métricas en tiempo real permite identificar patrones y realizar ajustes a lo largo del ciclo de vida del proyecto. Este enfoque se alinea con la transformación digital en la gestión de proyectos y con la creciente adopción de herramientas basadas en aprendizaje automático e inteligencia artificial.

5.2 Métodos tradicionales de estimación y sus limitaciones

La estimación de costes y plazos en proyectos ha sido, desde sus inicios, un pilar esencial en la gestión de proyectos. A lo largo de los años, se han implementado metodologías estructuradas con el objetivo de abordar la complejidad de esta tarea. No obstante, a pesar de su uso generalizado, estas técnicas presentan limitaciones significativas que se han hecho más evidentes en los entornos actuales, caracterizados por la volatilidad y la incertidumbre. A continuación, se llevará a cabo un análisis de las metodologías más destacadas, resaltando tanto sus fortalezas como sus debilidades.

- **Análisis PERT (Program Evaluation and Review Technique)**

El método PERT fue desarrollado en enero de 1958 por la *Special Projects Office* para gestionar el programa Polaris, integrando técnicas estadísticas en la planificación de proyectos complejos.[6] Este método transformó sustancialmente el enfoque hacia la planificación de proyectos mediante la introducción de un modelo de probabilidad. Este método se fundamenta en la estimación de tres escenarios: optimista, pesimista y más probable; permitiendo calcular la duración de una tarea teniendo en cuenta un margen de incertidumbre. En su momento, esta aproximación fue pionera al integrar la variabilidad en las estimaciones de tiempo. Sin embargo, su principal limitación es la incapacidad para incorporar datos en tiempo real o factores externos dinámicos, lo que puede reducir su efectividad en proyectos caracterizados por cambios frecuentes e impredecibles. [7] [8]

- **Método de la Cadena Crítica (Critical Path Method - CPM)**

El Método de Camino Crítico (CPM), se enfoca en identificar la secuencia de actividades que determina la duración mínima de un proyecto. Su enfoque hacia la optimización de los plazos lo ha convertido en una herramienta fundamental para la planificación de proyectos complejos. No obstante, una de las desventajas que presenta es su falta de flexibilidad para adaptarse a cambios imprevistos en las actividades o recursos, lo que ocasiona que su uso quede muy limitado en entornos dinámicos. En un contexto donde la flexibilidad resulta fundamental, el CPM podría llegar a considerarse obsoleto si no se complementa con otras metodologías más ágiles. [8]

- **Gestión del Valor Ganado (Earned Value Management - EVM)**

La metodología del Valor Ganado (EVM, por sus siglas en inglés) muestra un avance significativo al tener en cuenta el coste, el avance y el cronograma del proyecto. Al comparar el desempeño real con las estimaciones iniciales, esta metodología ofrece una visión clara del progreso y permite la identificación temprana de desviaciones. Sin embargo, su enfoque estático y su dependencia de estimaciones iniciales fijas limitan su efectividad en entornos volátiles, donde los cambios son constantes y las previsiones iniciales pueden quedar desactualizadas. [9] [10]

- **Análisis Monte Carlo**

El método de Monte Carlo, fundamentado en la simulación de múltiples escenarios, propone un enfoque basado en la probabilidad más sólido para la estimación de costes y tiempos. Al generar miles de combinaciones posibles, este método permite evaluar el impacto de la incertidumbre en los resultados de un proyecto. Esta capacidad lo convierte en una herramienta eficaz para la toma de decisiones en contextos complejos. No obstante, su efectividad está directamente relacionada con la calidad y precisión de los datos de entrada. En proyectos donde se cuenta con información limitada o de baja calidad, los resultados obtenidos pueden resultar engañosos, lo cual limita su aplicabilidad en determinados contextos. [8] [9]

A pesar de que estas metodologías han establecido las bases de la gestión de proyectos en el contexto actual, su aplicación en entornos actuales, marcados por la volatilidad, la incertidumbre y la necesidad de adaptabilidad, revela sus limitaciones. En un mercado donde los proyectos se caracterizan por su creciente dinamismo y complejidad, resulta relevante investigar enfoques más flexibles y adaptativos que no solo complementen, sino que también superen estas metodologías tradicionales. Este análisis no solo enfatiza la relevancia de innovar en la estimación de proyectos, sino que también abre la posibilidad de integrar nuevas tecnologías y enfoques que puedan enfrentar los desafíos de la actualidad.

Las exigencias del siglo XXI en la gestión de proyectos se caracterizan por los siguientes aspectos: la volatilidad e incertidumbre de los mercados, lo cual requiere una mayor capacidad de respuesta y una planificación dinámica; la creciente complejidad de los proyectos, que es consecuencia de la globalización y la interconectividad de las cadenas de valor; la necesidad de una adaptación ágil ante los cambios constantes en el entorno; los avances tecnológicos, que, si bien generan oportunidades, también presentan desafíos en términos de implementación y competitividad; y las exigencias de sostenibilidad y medidas frente al cambio

climático, que demandan modelos de gestión más eficientes en el uso de recursos y alineados con criterios de responsabilidad ambiental.

5.3 Inteligencia Artificial y Machine Learning en la Gestión de Proyectos

El uso de la inteligencia artificial (IA) y el aprendizaje automático (ML) ha aumentado significativamente en los últimos años en la gestión de proyectos por su alta capacidad para analizar grandes volúmenes de datos y detectar patrones complejos que de otro modo quedarían ocultos.

Estos resultados subrayan el potencial del aprendizaje automático en la gestión de proyectos, no únicamente como una herramienta complementaria, sino como un modelo que permite optimizar procesos críticos más allá de las limitaciones humanas. Esta ventaja se asocia en gran medida a la habilidad de estos sistemas para procesar información de forma ágil y objetiva, reduciendo así las tendencias propias de la toma de decisiones humanas. [11]

Sin embargo, es fundamental resaltar que la integración de estas tecnologías no debe interpretarse como un sustituto de la experiencia humana, sino como un medio complementario que aumenta la eficacia y precisión en la planificación y ejecución de los proyectos. La combinación de la intuición y el juicio humano con el poder analítico de la IA y el ML representa, sin duda, un avance significativo en la evolución de la gestión de los proyectos. [12]

Para maximizar su potencial es imprescindible que los profesionales del sector comprendan las fortalezas y limitaciones de estas tecnologías, garantizando una integración eficaz y ética en los procesos de gestión. Este enfoque permitirá, además de optimizar los resultados, establecer bases más informadas y estratégicas para la toma de decisiones en el ámbito de la gestión de proyectos. [13]

5.4 Modelos de Machine Learning aplicados a la Predicción de Costos y Plazos

En el ámbito de la gestión de proyecto, para la predicción de costes y plazos, existen varios modelos de aprendizaje automático. Entre ellos, destacan:

- **Regresión Lineal Múltiple:** Este enfoque permite establecer relaciones lineales entre las variables de entrada y las variables de salida. Aunque es sencillo de implementar, se reduce su eficacia en escenarios en los que las relaciones entre variables no son lineales. [14]
- **Redes Neuronales Artificiales (ANNs):** Estas redes han demostrado una notable eficacia al detectar relaciones no lineales y complejas entre distintas variables, lo que las convierte en una herramienta de alta capacidad para predecir costes y plazos de los proyectos. Sin embargo, la eficiencia de este modelo depende en gran medida de la disponibilidad de grandes volúmenes de datos. [15]
- **Random Forest y XGBoost:** Los dos algoritmos, basados en la combinación de múltiples árboles para decidir, han mostrado un excelente rendimiento en la predicción de costes y plazos, especialmente en proyectos que manejan datos estructurados. Su potencial para abordar relaciones complejas y agilizar el ajuste las hace especialmente adecuadas en este contexto. [16]

- **Procesamiento del Lenguaje Natural (NLP):** Estas técnicas permiten identificar patrones de riesgo que pueden afectar a costes y plazos, y ofrecen un enfoque innovador para la gestión predictiva. [17], [18]

Cada uno de estos modelos tiene sus ventajas y limitaciones particulares, por lo que su selección debe basarse en las características específicas del proyecto y en la disponibilidad de datos. La aplicación de estos enfoques, junto con la experiencia humana, puede aumentar considerablemente la precisión y eficiencia en la gestión de los proyectos.

5.5 Factores Humanos y su Impacto en las Estimaciones Predictivas

Un aspecto que frecuentemente se omite en la literatura es la influencia del factor humano en la precisión de las estimaciones predictivas. Diversos estudios han demostrado que las tendencias cognitivas juegan un papel fundamental en la toma de decisiones en el ámbito de la gestión de proyectos, lo que puede tener un impacto significativo en la precisión de las predicciones. [20], [21]

Entre los sesgos más importantes se encuentran:

- **Sesgo de optimismo:** Se refiere a la tendencia a subestimar los costes y plazos asociados a un proyecto debido a una percepción excesivamente positiva del mismo, lo que puede llevar a planificaciones poco realistas. [19][20]
- **Sesgo de anclaje:** Este fenómeno implica una tendencia a la confianza excesiva en los cálculos iniciales o en los datos históricos, sin tener en cuenta la información actualizada ni los cambios en el contexto del proyecto. [20]
- **Efecto Dunning-Kruger:** Se refiere a una sobreestimación de habilidades y conocimientos de grupos con menor experiencia, lo que puede llevar a cálculos imprecisos y a tomar decisiones basadas en la escasa información. [20][21]

Estas tendencias no sólo pueden afectar a las estimaciones iniciales, sino también en la ejecución y control del proyecto. Por tanto, la incorporación de los principios de psicología y ciencia del comportamiento a los modelos de predicción podría ser una solución innovadora para mitigar estos errores. Al combinar el análisis cuantitativo de los datos con una comprensión precisa de los factores humanos, sería posible desarrollar herramientas más sólidas y precisas para la gestión de proyectos.

5.6 Desafíos y Oportunidades en la Implementación de Modelos Predictivos

Aunque la utilización de modelos predictivos en la gestión de proyectos ofrece ventajas evidentes, como una mayor precisión en los cálculos y la optimización del proceso de toma de decisiones, su implementación plantea algunos retos. Entre los principales obstáculos se encuentran:

- **Calidad de los datos:** Los modelos de aprendizaje automático (*machine learning*) dependen en gran medida de la disponibilidad de datos necesarios, completos y debidamente estructurados. La falta de información fiable o la existencia de datos no verificados puede poner en peligro la eficacia de las predicciones. [22]
- **Resistencia al cambio:** Un número significativo de organizaciones siguen sometidas a métodos tradicionales de gestión y pueden expresar desconfianza o rechazo ante la adopción de herramientas basadas en la inteligencia artificial (IA). Esta resistencia puede retrasar o impedir la implementación de soluciones innovadoras en las organizaciones. [23], [24]
- **Interoperabilidad con software existente:** Para que los modelos de predicción funcionen correctamente con herramientas de gestión como Primavera o Microsoft Project, es fundamental que los sistemas puedan compartir datos de forma eficaz, lo que significa "hablar en el mismo idioma". Además, es fundamental actualizar continuamente los modelos con la información más reciente para asegurar que las predicciones son precisas y útiles.

A pesar de los retos presentados, la digitalización y el avance de las herramientas analíticas ofrecen una oportunidad excepcional para optimizar la gestión de los proyectos. La implementación de modelos predictivos no sólo tiene un potencial para reducir la incertidumbre existente en la planificación y ejecución, sino que puede optimizar el proceso de toma de decisiones, lo que permite a las entidades alcanzar mayores niveles de eficiencia y competitividad.

6. Revisión de la literatura

En este contexto de la digitalización, donde la sociedad experimenta una transformación acelerada, la gestión de proyectos también se enfrenta a numerosos retos. Uno de los mayores desafíos es la capacidad de anticiparse a posibles variaciones en los costes y plazos con el objetivo de permanecer competitivos dentro del mercado y la industria. Esto es, ya no vale con sólo ejecutar los proyectos de manera eficiente y eficaz.

Este apartado de la revisión de la literatura aborda los fundamentos, las técnicas tradicionales, las innovaciones basadas en datos reales y varias herramientas tecnológicas que son utilizadas frecuentemente para la predicción de costes y plazos. El objetivo de este apartado es poder ofrecer una perspectiva global que sirva de base teórica, además de fomentar nuevas prácticas dentro de este ámbito de los proyectos.

Asimismo, antes de proceder con la revisión bibliográfica, es relevante mencionar que hoy en día, que las organizaciones adopten una estrategia fundamentada en el análisis predictivo no se trata de una ventaja competitiva adicional, sino de una necesidad estratégica para poder garantizar la continuidad y el éxito en los mercados volátiles e inciertos.

6.1 Fundamentos de la Gestión de Proyectos

Durante los últimos años, el área de dirección de proyectos ha evolucionado hacia nuevos enfoques para poder cumplir de manera más eficiente con los tres pilares fundamentales de un proyecto: alcance, plazo y presupuesto. Estas son las tres limitaciones que forman el triángulo de oro en la gestión de proyectos (el famoso “*project management triangle*” o “*iron triangle*” denominados en inglés).

Este triángulo (Ilustración 3) es un modelo de gestión de proyectos que muestra cómo el equilibrio entre estas tres limitaciones (alcance, plazo y presupuesto) afectan de forma directa a la calidad del proyecto. Esto es, para poder mantener la calidad deseada o exigida por el cliente, si se modifica una de estas restricciones, se debe ajustar una o las otras dos limitaciones. [25]




Ilustración 3: Project Management Triangle

Con el propósito de optimizar estas tres limitaciones de cualquier proyecto, existen varias disciplinas que son adoptadas por distintas organizaciones. Entre las principales metodologías reconocidas internacionalmente destacan las siguientes tres.

1. Project Management Body of Knowledge (PMBOK)

El PMBOK constituye una recopilación de procesos y áreas de conocimiento que son ampliamente reconocidas como prácticas óptimas en la disciplina de la gestión de proyectos. Se trata de un estándar de referencia a nivel internacional que establece los fundamentos aplicables a una gran variedad de proyectos. Según el PMBOK (2012), se identifican cinco grupos principales de procesos y diez áreas de conocimiento que son comunes en la mayoría de los proyectos.

El éxito de esta metodología radica en la capacidad de proporcionar una estructura adaptable a distintos proyectos según su tamaño y el sector al que se aplica.

2. Projects In Controlled Environments (PRINCE 2)

PRINCE2 se fundamenta en principios similares a los del PMBOK, expandiendo los conceptos planteados en éste y ofreciendo técnicas complementarias destinadas a minimizar riesgos y elevar la calidad de los proyectos de manera eficiente. Además, incorpora un énfasis particular en la gestión del cambio, apoyándose en diversos elementos estructurales para su implementación.

Esta segunda metodología se enfoca más en la justificación de la parte del negocio, la gestión de riesgos y el aprendizaje. Esto es fundamental en aquellos sectores donde la trazabilidad y la documentación son críticos e indispensables, por ejemplo: la industria farmacéutica o la aeroespacial.

3. Agile

Este tercer método surgió como respuesta a la rigidez de los modelos tradicionales que se empleaban hasta ese momento. Se enfoca en la capacidad de adaptación y de respuesta ante los cambios. Algunas de las metodologías ágiles son la metodología Scrum y Kanban, donde se prioriza la mejora continua. Este tipo de metodologías están mucho más desarrolladas en la industria del software, aunque poco a poco son más las organizaciones de otras industrias que introducen en su día a día estas nuevas técnicas.

A continuación, se presenta una tabla resumen (Tabla 1) que compara y resume las características, ventajas y limitaciones de las metodologías mencionadas anteriormente.

Tabla 1: Ventajas y limitaciones de las metodologías del PM

Metodología	Ventajas	Limitaciones
PMBOK	Una amplia cobertura de áreas de conocimiento, con capacidad de adaptación a distintos ámbitos.	Puede ser un proceso muy lento para proyectos pequeños o cambiantes.
PRINCE2	Basado en el control continuo desde el inicio del proyecto hasta su finalización.	Exige mucha documentación y puede resultar muy rígido para entorno muy dinámicos.
Agile	Alta flexibilidad.	No es lo más adecuado para proyectos con requisitos muy definidos desde el inicio.

6.2 Factores que afectan en costes y plazos de los proyectos

El coste y el plazo de un proyecto se constituyen o son influenciados por una variedad de factores que están interrelacionados entre sí. Muchas veces, en la fase de definición del proyecto, se comete el error de no definir adecuadamente o no darle la importancia suficiente a estos factores que son claves para el desarrollo correcto del proyecto. Son muchos los factores que pueden influir en el coste y plazo del proyecto, pero entre los más relevante se pueden encontrar los siguientes.

- Falta de una definición clara del alcance: un alcance de proyecto que no está claramente definido puede llevar a realizar cambios frecuentes en su definición, provocando esfuerzos innecesarios y sobrecostes. Según un estudio publicado por el *Project Management Institute (PMI)* en el año 2017, el 37% de los proyectos fallidos es debido a una mala definición inicial del alcance e hitos del mismo para una adecuada monitorización. [26]
- Planificación inadecuada: una planificación inadecuada o muy optimista del proyecto, frecuentemente lleva a desajustes en los costes y plazos del proyecto. Un estudio realizado por el *Project Management Institute (PMI)* en 2021, muestra que, entre el total de los proyectos fallidos, el 33% de esos proyectos es debido a una planificación inicial inadecuada.[27]
- Cambios frecuentes en los requisitos del proyecto: unos cambios frecuentes en los requisitos y objetivos del cliente en el proyecto repercute directamente en el presupuesto y cronograma de dicho proyecto.
- Una gestión inadecuada de los recursos: no identificar ni planificar respuestas ante cualquier riesgo potencial del proyecto en las fases tempranas, puede provocar que se deban afrontar estos problemas inesperados con soluciones más costosas y afectando los plazos establecidos.
- Definición inadecuada de los riesgos: cuando los recursos disponibles no son gestionados adecuadamente, se generan retrasos en los plazos, errores en la ejecución y mayores costes derivados de trabajos repetidos.

Todos estos factores que se han mencionado se pueden respaldar mediante datos estadísticos sacados de un estudio realizado por *Project Management Institute (PMI)* en el año 2021. [27] A continuación, se pueden observar los factores que inciden en los plazos y costos de los proyectos, clasificados según su nivel de impacto (Ilustración 4).




Ilustración 4: Factores que influyen en los costes y plazos de los proyectos

Estos factores reflejan la necesidad de una planificación adecuada y realista, además de trabajar con técnicas o sistemas de monitorización y control durante todas las fases del proyecto.

6.3 Aplicaciones de la Ciencia de Datos en la Gestión de Proyectos

Durante décadas, la estadística ha estado presente en cada aspecto de la vida cotidiana siendo una herramienta poderosa que ayuda a interpretar la realidad. Sin embargo, en el contexto actual de la era digital, ha empezado a tener protagonismo debido al verdadero potencial que tiene esta práctica en la gestión de proyectos y para las organizaciones. Lo que antes era una disciplina empleada para el análisis a posteriori, hoy en día se ha convertido en un pilar fundamental para la toma de decisiones estratégicas en tiempo real.

La ciencia de datos, en el ámbito de la gestión de proyectos, es considerada como una disciplina muy útil y enriquecedora. Muchas veces se define como un componente fundamental e importante de la cultura de las organizaciones. Si las organizaciones emplean la ciencia de datos en sus ocupaciones diarias, tendrán la capacidad de gestionar de manera óptima sus recursos, prever riesgos y prevenir desviaciones, además de mejorar otros aspectos.

Hoy en día vivimos sumergidos en una gran cantidad de información y datos. Cuando se analizan adecuadamente estos datos, nos revelan tendencias y patrones, además de, posibles oportunidades y amenazas estratégicas que de otra manera quedarían ocultas. Cada uno de estos datos es una oportunidad para identificar estas tendencias, una vía para tomar una decisión y guiar a las organizaciones para avanzar en una dirección más sólida. Estos datos pueden servir como unión entre el conocimiento y la acción o decisión que se vaya a tomar. Además, gracias a los avances tecnológicos, especialmente en el análisis predictivo, los proyectos no sólo pueden ser planificados con mayor precisión, sino que también tienen la capacidad de aprender y adaptarse a cada momento y entorno. Esto es, los proyectos pueden ir mejorando su rendimiento en función de la información que se reciba.

A continuación, se mencionan cuáles son algunos de estos métodos y tecnologías avanzadas basados en esta ciencia de datos.

- *Análisis de series temporales*

El análisis de series temporales es realmente útil para identificar tendencias, patrones y desviaciones anómalas que se repiten de manera implícita en el comportamiento de los costes y tendencias temporales de los proyectos.

Algunos de los modelos utilizados para este tipo de análisis son: ARIMA, Prophet o LSTM. Estos modelos no sólo sirven para interpretar el pasado, sino que también dan la oportunidad de anticiparse a los futuros escenarios. Asimismo, permiten detectar de manera inmediata desviaciones en el alcance del proyecto, antes de causar consecuencias significativas. [28]

- *Importancia de los datos históricos y en tiempo real*

Para gestionar de manera eficaz y adecuada los proyectos, es fundamental emplear conjuntamente datos del pasado y datos recientes. Esto es, los datos históricos ofrecen la experiencia en proyectos similares del pasado, y los datos recogidos en tiempo real, permiten a las organizaciones responder de manera inmediata a las desviaciones en la definición del proyecto.

De esta manera, con las herramientas de *machine learning* se pueden realizar distintas simulaciones para prever como puede impactar una variación en el alcance y actuar estratégicamente antes de que ocurra ese cambio.

6.4 Herramientas tecnológicas para la predicción

6.4.1 Business Intelligence

Las herramientas de *Business Intelligence*, como pueden ser Power BI y Tableau, ofrecen transformar los datos sin tratar en información práctica a través de elementos visuales que ayudan a interpretar la información de manera más sencilla y rápida. Por ejemplo, mediante estas herramientas, los gestores de proyectos pueden hacer un seguimiento de los indicadores clave de rendimiento (KPI) del proyecto. Asimismo, monitorizar y controlar el progreso del proyecto e identificar riesgos potenciales en tiempo real.

Aplicaciones prácticas

- Power BI: Esta herramienta es utilizada por las organizaciones para diseñar paneles de mando interactivos que les proporciona la información necesaria en tiempo real sobre las métricas del proyecto. Por ejemplo, suele ser utilizado para controlar el cumplimiento del presupuesto o los plazos del proyecto. [29]
- Tableau: Esta herramienta también proporciona elementos visuales para ayudar a identificar tendencias y patrones ocultos en los datos del proyecto. También, las organizaciones aprovechan las oportunidades que proporciona esta herramienta, para analizar los datos históricos del proyecto, calcular su rendimiento futuro, y así, sacar las conclusiones necesarias. [30]

6.4.2 Inteligencia Artificial y Machine Learning

Existen varias plataformas de Inteligencia Artificial y *Machine Learning* en las que se pueden generar modelos predictivos para optimizar el rendimiento del proyecto. Estos modelos desempeñan su función aprendiendo de los datos históricos, y mediante este aprendizaje, realizar predicciones precisas sobre los resultados futuros del proyecto.

Aplicaciones prácticas

- TensorFlow: Esta herramienta se suele utilizar para predicciones de actividades con cierto nivel de complejidad. Esta aplicación ayuda a las organizaciones a predecir distintos plazos del proyecto e identificar posibles retrasos. [31]
- Scikit-Learn: Esta aplicación se compone de distintos algoritmos que están adecuados para el análisis de regresión y clasificación, lo que hace valioso para la predicción de costes y recursos del proyecto. Además, se trata de una herramienta sencilla y eficaz, por lo que muchas organizaciones recurren a esta aplicación y la convierten en una opción popular en el ámbito de la ciencia de datos. [32]

6.4.3 Big Data

La analítica de Big Data permite procesar y analizar grandes volúmenes de datos en tiempo real, ayudando a realizar unas predicciones mucho más exactas y tomando decisiones más informadas. De esta manera, si se aplica este tipo de análisis de datos a la gestión de proyectos, las organizaciones tendrían la oportunidad de procesar datos recogidos de distintas fuentes e identificar posibles riesgos y aplicar de manera anticipada, estrategias de mitigación.

Casos prácticos

- DeepL Thunder de IBM: Se trata de una iniciativa que utiliza información muy precisa y grandes volúmenes de datos para realizar predicciones meteorológicas teniendo en cuenta la localización. De esta manera, los gestores de proyectos pueden planificar la ejecución de sus proyectos que dependen de las condiciones meteorológicas para su realización. Así, los gestores tienen la oportunidad de programar tareas para mitigar posibles retrasos relacionados con el tiempo. [33]

7. Metodología

El objetivo de este apartado es realizar un análisis con el que se pueda evaluar el impacto que tiene la aplicación de modelos predictivos en la eficiencia y eficacia de los proyectos. Esto es, el objetivo de este trabajo es demostrar cómo las organizaciones de hoy en día tienen la necesidad de implantar modelos predictivos en sus procesos si desean seguir siendo competitivos y proactivos en el mercado.

Para este estudio, se ha optado por emplear un proceso comparativo, donde se analizarán dos tipos de proyectos: por un lado, proyectos en los que las organizaciones no han optado apoyarse en modelos predictivos, y por otro, aquellos proyectos en los que sí se han aplicado técnicas de predicción como apoyo en la toma de decisiones. Esto va a permitir clasificar casos de éxito y fracaso, facilitando la elaboración de conclusiones sustentadas en datos reales y verificables.

La herramienta que se ha elegido para realizar todos los análisis necesarios es R-Studio, que es un medio muy valioso y robusto en el entorno estadístico. Esta herramienta está diseñada para programar en el lenguaje R, que es muy utilizado en el ámbito de la estadística y análisis de datos. Con R-Studio se pueden realizar desde análisis estadísticos básicos hasta modelos predictivos avanzados.

7.1 Análisis de proyectos gestionados con metodologías avanzadas

En este apartado se van a analizar dos conjuntos de datos con información necesaria sobre proyectos que han sido gestionados con herramientas predictivas. Para ello, como se ha mencionado anteriormente, se va a utilizar la herramienta de R-Studio que es muy utilizada para análisis estadísticos.

7.1.1 Estudio I (BIM-AI Integrated Dataset)

7.1.1.1 Recopilación y preparación de datos

Este conjunto de datos contiene información relevante sobre 1.000 proyectos distintos de la rama de la ingeniería civil. Para el desarrollo de estos proyectos, se han implementado metodologías de BIM (Building Information Modeling) y técnicas de Inteligencia Artificial.

Estos conjuntos de datos contienen atributos clave sobre el proyecto, como son: tipo de proyecto, coste planificado, coste actual (AC), duración planificada, duración real, variación en el cronograma, etc.

¿Por qué son relevantes algunas de estas variables para el análisis?

- Coste planificado y coste real: a través de estas dos variables, se pueden examinar las desviaciones en el presupuesto de cada proyecto. Además, se puede calcular el *Cost Performance Index* (CPI); indicador muy relevante para el análisis del rendimiento financiero de un proyecto a lo largo de sus ciclos.
- Duración planificada y duración real: mediante estos dos atributos se puede conseguir información sobre la desviación en plazo de cada proyecto. Asimismo, se puede calcular el *Schedule Performance Index* (SPI).

- Nivel de riesgo del proyecto: esta variable se puede utilizar para clasificar los proyectos según su nivel de riesgo.

¿Qué es BIM?

Building Information Modeling (BIM) es una herramienta que ayuda a diseñar un modelo 3D del proyecto en el ámbito de la construcción. No se trata sólo de dibujar de manera digital tu proyecto antes de construirlo, también te da la oportunidad de calcular cuánto costara tu proyecto, calculando qué materiales se necesitarán. Para esto, cuenta con información real y actual sobre distintos materiales, plazos, costes, mantenimiento, infraestructura, etc.

Además, permite simular distintos escenarios en caso de que se introduzcan cambios en el proyecto, proyectando con precisión cómo dichos ajustes afectarían al presupuesto, los plazos o el consumo energético. [34]

7.1.1.1.1 Carga y adecuación de datos

Lo primero que se ha realizado ha sido cargar el archivo que contiene el conjunto de dato a R-Studio. Para ello, se han cargado varios paquetes en R-Studio que van a ser necesarios tanto para leer o importar el archivo Excel donde están todos los datos que se van a analizar, como para para graficar distintas variables.

Una vez que están cargados los paquetes que van a ser necesarios, se ha subido el conjunto de datos y se le ha llamado *df*. Para comprobar que se han cargado correctamente los datos, se han visualizado las primeras filas del conjunto de datos cargado (Tabla 2) (Ilustración 5).

Tabla 2: Carga y recopilación de datos (R-Studio) I

```
install.packages("readr") # Para leer archivos CSV
install.packages("dplyr") # Para manipular datos
install.packages("ggplot2") # Para hacer gráficos
# Cargar paquetes
library(readr)
library(dplyr)
library(ggplot2)
library(readxl)
# Leer el archivo CSV con formato europeo y codificación correcta
df1 <- read.csv2(file.choose(), fileEncoding = "latin1", stringsAsFactors = FALSE)
#Mostrar las primeras filas de la tabla
head(df1)
```

Project_ID	Project_Type	Location	Start_Date	End_Date	Planned_Cost	Actual_Cost	Cost_Overrun	Planned_Duration
1	PJT_1	Tunnel	Houston	01/01/2020	26/09/2021	12260784	15054504	2793720
2	PJT_2	Dam	Houston	02/01/2020	06/12/2020	2369277	3507054	1137777
3	PJT_3	Building	Houston	03/01/2020	05/12/2021	23299783	21692127	1607656
4	PJT_4	Dam	Houston	04/01/2020	12/04/2022	24499306	29469661	4970355
5	PJT_5	Dam	Seattle	05/01/2020	12/02/2022	1749971	2329338	579367
6	PJT_6	Road	Seattle	06/01/2020	18/09/2020	16711072	23689353	6978281
Actual_Duration	Schedule_Deviation	Vibration_Level	Crack_Width	Load_Bearing_Capacity	Temperature	Humidity		
1	813.92	114.92	1.5341722	2.809385	471.1974	18.54156	49.88337	
2	384.12	115.12	0.6879789	3.704416	355.1551	23.31677	58.64127	
3	1081.78	182.78	0.9511461	3.309302	236.4934	42.95788	36.16592	
4	974.57	165.57	0.8703962	1.777649	360.2904	22.42089	72.04518	
5	347.99	-6.01	1.9697700	4.044293	204.7908	15.91449	57.23918	
6	379.86	124.86	0.6552730	1.473507	174.7663	21.53709	76.63242	
Weather_Condition	Air_Quality_Index	Energy_Consumption	Material_Usage	Labor_Hours	Equipment_Utilization			
1	Snowy	210	25202.99	244.8433	6602	76.30018		
2	Snowy	195	49066.17	263.1230	7121	63.32767		
3	Cloudy	127	48192.55	608.9850	9956	47.09944		
4	Cloudy	71	19811.15	673.5743	3725	86.84639		
5	Cloudy	113	44866.57	765.4761	4368	61.82716		
6	Sunny	70	43142.51	262.9453	4497	84.16324		
Accident_Count	Safety_Risk_Score	Image_Analysis_Score	Anomaly_Detected	Completion_Percentage	Risk_Level	SPI		
1	8	6.192198	52.98833	95.01	High	0.858068		
2	5	2.134473	50.88575	0	25.29	Low	0.7003020	
3	2	3.113728	93.90584	0	97.48	Medium	0.8310377	
4	5	4.070101	90.45432	1	95.10	High	0.8301097	
5	6	2.759351	78.39107	0	43.62	Low	1.0172706	
6	6	2.351205	99.93616	0	98.46	Low	0.6713000	
CPI	Cumple_Coste							
1	0.8144263	No						
2	0.6755747	No						
3	1.0741124	Si						
4	0.8313399	No						
5	0.7512740	No						
6	0.7054254	No						

Ilustración 5: Visualización datos importados (R-Studio) I

Como se puede observar, los datos se han cargado correctamente a la plataforma de R. Por lo tanto, es correcto seguir con el análisis.

7.1.1.1.2 Cálculo de datos estadísticos descriptivos

Una vez teniendo todos los datos adecuadamente preparados para el estudio, se han calculado la media, mediana y otras variables que permiten conocer y realizar un resumen estadístico rápido de los proyectos que se están analizando en este estudio (Tabla 3) (Ilustración 6).

Tabla 3: Resumen estadístico (R-Studio) I

#Resumen estadístico de los datos

summary(df1)

```

> summary(df1)
Project_ID      Project_Type      Location      Start_Date      End_Date      Planned_Cost
Length:1000    Class :character  Length:1000  Length:1000    Length:1000    Length:1000
Class :character  Mode :character  Class :character  Class :character  Class :character  Class :character
Mode :character  Mode :character  Mode :character  Mode :character  Mode :character  Mode :character

Actual_Cost      Cost_Overrun      Planned_Duration  Actual_Duration  Schedule_Deviation  Vibration_Level
Min. : 1180252    Min. : 1552      Min. :180.0      Min. : 165.3      Min. : -79.14      Min. : 0.1074
1st Qu.:16096547  1st Qu.:1281754  1st Qu.:361.0    1st Qu.: 424.3    1st Qu.: 22.40     1st Qu.:0.5669
Median :31339224  Median :3386803  Median :535.5    Median : 635.5    Median : 84.06     Median :1.0418
Mean :31541079   Mean : 5578065   Mean :538.6      Mean : 645.6      Mean :106.94       Mean :1.0444
3rd Qu.:45327469  3rd Qu.:8665132  3rd Qu.:713.0    3rd Qu.: 831.6    3rd Qu.:173.95     3rd Qu.:1.5350
Max. :72519387   Max. :24012292   Max. :899.0      Max. :1340.3      Max. :446.35       Max. :1.9990

Crack_Width      Load_Bearing_Capacity  Temperature      Humidity      Weather_Condition  Air_Quality_Index
Min. : 0.001205      Min. : 50.11          Min. : -9.997     Min. :20.02     Length:1000        Min. : 50.0
1st Qu.:1.223689     1st Qu.:153.96        1st Qu.: 4.578    1st Qu.:37.63   Class :character    1st Qu.:112.8
Median :2.419953     Median :255.50        Median :17.195    Median :55.74   Mode :character      Median :177.0
Mean :2.456479       Mean :266.05         Mean :17.114      Mean :55.48     Mean :character      Mean :174.8
3rd Qu.:3.659447     3rd Qu.:373.42       3rd Qu.:29.868    3rd Qu.:73.19   3rd Qu.:character    3rd Qu.:236.0
Max. :4.996036       Max. :498.51         Max. :44.924      Max. :89.97     Max. :character      Max. :299.0

Energy_Consumption  Material_Usage      Labor_Hours      Equipment_Utilization  Accident_Count  Safety_Risk_Score
Min. : 5054         Min. :101.2         Min. :1001       Min. : 40.02       Min. :0.000        Min. :1.004
1st Qu.:16154       1st Qu.:311.3       1st Qu.:3155     1st Qu.: 54.15     1st Qu.:2.000       1st Qu.:3.061
Median :27043       Median :534.2       Median :5371     Median : 69.53     Median :5.000       Median :5.338
Mean :27404         Mean :543.4         Mean :5395       Mean : 69.45     Mean :4.567         Mean :5.333
3rd Qu.:38909       3rd Qu.:773.8       3rd Qu.:7616     3rd Qu.: 84.78     3rd Qu.:7.000       3rd Qu.:7.489
Max. :49941         Max. :999.0         Max. :9997       Max. :100.00      Max. :9.000         Max. :9.966

Image_Analysis_Score  Anomaly_Detected  Completion_Percentage  Risk_Level      SPI      CPI
Min. :50.04          Min. :0.000       Min. :10.09        Length:1000     Min. :0.6670      Min. :0.6668
1st Qu.:62.13        1st Qu.:0.000     1st Qu.:32.53      Class :character  1st Qu.:0.7435     1st Qu.:0.7447
Median :74.88         Median :0.000     Median :55.31      Mode :character   Median :0.8428     Median :0.8389
Mean :74.92          Mean :0.197       Mean :55.18        Mean :0.8547     Mean :0.8547     Mean :0.8548
3rd Qu.:87.53        3rd Qu.:0.000     3rd Qu.:78.20      3rd Qu.:0.9562   3rd Qu.:0.9562   3rd Qu.:0.9562
Max. :99.98          Max. :1.000       Max. :99.95        Max. :1.1109     Max. :1.1109     Max. :1.1106

Cumple_Coste
Length:1000
Class :character
Mode :character

```

Ilustración 6: Visualización resumen estadístico datos (R-Studio)

Este resumen estadístico permite conocer el conjunto de proyectos que se van a analizar y contextualizar las dimensiones de los proyectos que se van a medir.

Los valores conseguidos de la columna del Coste Planificado informan sobre las dimensiones de los proyectos. Esto es, en este estudio se van a analizar proyectos con una media de 26.415.088 €, siendo el proyecto con menor presupuesto de unos 1.045.475€, y habiendo proyectos que alcanzan los 49.968.538€. En estos datos se puede evidenciar que los proyectos que se van a analizar tienen una considerable variabilidad entre sus presupuestos.

En cuanto a los valores de la columna del Coste Real de los proyectos, este presenta una media de 31.541.079 €, siendo este mayor que la media del Coste Planificado de los proyectos. Por lo tanto, aquí se identifica que generalmente, los proyectos del *dataset* tienen una tendencia hacia desviaciones de sobrecostes de los proyectos.

Esta tendencia se puede corroborar con los valores calculados de la columna de *Cost Overrun*, que tiene una media positiva de 5.578.065 €.

Para finalizar, en cuanto a los plazos de proyectos, los valores de la Duración Planificada indican que se trata de proyectos con un plazo medio de unos 538,6 días (casi 18 meses). Y el resumen de la Duración Actual permite conocer que la duración media real de los proyectos ha sido de 645,6 días (alrededor de 21 meses). Este retraso medio de los plazos se puede afirmar con los valores obtenidos de la variable Desviación de Plazo, donde se han registrados desviaciones medias de casi 107 días (3 meses y medio).

En resumen, gran parte de los proyectos a analizar presentan desviaciones significativas tanto en costes como en plazos. Por lo tanto, el propio conjunto de datos revela la importancia de emplear modelos predictivos para identificar y anticipar dichas desviaciones en los proyectos.

7.1.1.1.3 Cálculo de variables de Valor Ganado

El Valor Ganado en la gestión de proyectos es una manera de medir y monitorizar el progreso de un proyecto en tiempo real, teniendo en cuenta el plan que se ha definido inicialmente. Esto es, este método permite analizar y determinar de una manera sencilla y rápida si el proyecto está atrasado, adelantado o según lo establecido en tiempo y presupuesto. [35]

“Earned value management (EVM) compares the performance measurement baseline to the actual schedule and cost performance. EVM integrates the scope baseline with the cost baseline and schedule baseline to form the performance measurement baseline.” PMBOKv6

Para el análisis del Valor Ganado existen las siguientes métricas que dan información relevante sobre la situación del proyecto.

- **Earned Value (EV)**

El valor ganado de una actividad, a fecha del control, es el valor del trabajo que requiere dicha actividad que ya se ha completado, teniendo en consideración el presupuesto inicial establecido. Por lo tanto, el valor ganado de un proyecto es la suma de los valores ganados de todas las actividades hasta la fecha de control.

Para realizar este cálculo, se requiere tener definido desde la fase de planificación del proyecto, cómo se asignarán los costes de cada una de las actividades y cómo se medirá su progreso. Es clave definir cómo se va a relacionar el coste de cada actividad con su grado de avance. Para ello, existen distintos tipos de distribución para medir el progreso (Tabla 4). [25]

Tabla 4: Tipos de distribución para la medición del progreso de las actividades

Distribución	Método de medición
Uniforme El coste de las tareas se distribuye uniformemente a lo largo de su duración.	Estimación subjetiva del progreso por parte del responsable.
Hitos valorados Para las tareas largas, se establecen hitos. Cada hito tiene asignado un % del coste total de las tareas.	Se comprueba si se ha alcanzado el hito. Si el hito está completo, se asigna el % correspondiente.
Unidades completadas Para las tareas que realizan la misma actividad. El coste total de la actividad se divide por el número de unidades a completar.	Se mide el número de unidades completadas y se aplica su coste por unidad.
Método 25/75 o 50/50 Para tareas cortas. El planificador asigna un coste inicial a la tarea y el resto al final.	Se comprueba si la tarea ha comenzado o no. Si se ha iniciado, se asigna el coste inicial.

- **Planned Value (PV)**

El Valor Planificado es el coste del trabajo previsto para esa fecha teniendo en cuenta el presupuesto inicial. [25]

- **Actual Cost (AC)**

El Coste Real es el coste real del trabajo real realizado para esa fecha. [25]

- **Cost Variance (CV)**

La Variación en Coste es la diferencia entre el Valor Gando (EV) y el coste real incurrido (AC). [25]

$$CV = EV - AC$$

Esta variación de coste se interpreta de la siguiente manera para conocer la situación de proyecto en cuanto al progreso del presupuesto.

- Si **CV > 0**; el proyecto se encuentra **por debajo del presupuesto** establecido inicialmente. Esto es, se ha gastado menos de lo que se ha previsto.
- Si **CV = 0**; el proyecto progresa **según lo planificado**.
- Si **CV < 0**; el proyecto se encuentra **por encima del presupuesto** establecido inicialmente. Esto es, se ha gastado más de lo que se ha previsto (sobrecoste).

- **Schedule Variance (SV)**

La Variación en Plazo es la diferencia entre el Valor Gando (EV) y el Valor Planificado (PV). [25]

$$SV = EV - PV$$

La Variación en Plazo es interpretado de la siguiente manera para conocer la situación del proyecto según el cronograma.

- Si **SV > 0**; el proyecto se encuentra **adelantado** en comparación con lo que se planificó.
- Si **SV = 0**; el proyecto **avanza según lo planificado**.
- Si **SV < 0**; el proyecto se encuentra **retrasado** según el cronograma inicial.

- **Cost Performance Index (CPI)**

Este índice representa la ejecución de los costes de los trabajos realizados hasta la fecha. Esto es, este valor permite conocer cómo de bien se están utilizando los recursos económicos en el proyecto. Es la relación entre el Valor Ganado (EV) y el Coste Real (AC). [25]

$$CPI = \frac{EV}{AC}$$

Este índice se interpreta de la siguiente manera según el valor conseguido en el análisis.

- Si **CPI > 1** ($AC < EV$); por cada unidad monetaria invertida en el proyecto, se ha realizado un trabajo de mayor valor. **Situación favorable**.
- Si **CPI = 1**; el proyecto **avanza según el presupuesto**.
- Si **CPI < 1** ($AC > EV$); por cada unidad monetaria invertida en el proyecto, se ha realizado un trabajo de menor valor. **Situación desfavorable**.

- **Schedule Performance Index (SPI)**

Este índice representa la eficacia del trabajo realizado de acuerdo con el plan. Esto es, evalúa el progreso del proyecto según la planificación inicial. Es la relación entre el Valor Ganado (EV) y el Valor Planificado (PV). [25]

$$SPI = \frac{EV}{PV}$$

Este índice es interpretado del siguiente modo, según cual sea el valor conseguido.

- Si **SPI > 1** (PV < EV); el avance de las obras es más rápido de lo previsto. Situación favorable.
- Si **SPI = 1**; el proyecto **avanza según lo planificado**.
- Si **SPI < 1** (PV > EV); el avance de las actividades es más lento de lo previsto. **Situación desfavorable**.

Teniendo en cuenta la relevancia y el significado de cada una de estas métricas, en R-Studio se han calculado todos estos valores mencionados para cada proyecto (Tabla 5).

Tabla 5: Cálculo métricas de Valor Ganado (R-Studio) I

```

#Calcular EV (Earned Value)
df1$EV <- df1$Planned_Cost * (df1$Completion_Percentage / 100)

#Calcular PV (Planned Value)
df1$PV <- df1$Planned_Cost * (df1$Planned_Duration / df1$Actual_Duration)

#Calcular CV (Cost variance) y SV (Schedule Variance)
df1$CV <- df1$EV - df1$Actual_Cost
df1$SV <- df1$EV - df1$PV

# Schedule Performance Index
df1$SPI <- df1$Planned_Duration / df1$Actual_Duration

# Cost Performance Index
df1$CPI <- df1$Planned_Cost / df1$Actual_Cost

#Visualizar valores calculados
View(select(df1,EV,PV,CV,SV,SPI,CPI))
  
```

Una vez calculadas estas métricas, se han visualizado en una tabla (Tabla 6).

Tabla 6: Visualización valores de Valor Ganado (R-Studio) I

	EV	PV	CV	SV	SPI	CPI
1	11.648.970,90 €	10.529.644,00 €	-3.405.533,00 €	1.119.326,67 €	0,8588	0,8144
2	599.190,20 €	1.659.209,00 €	-2.907.864,00 €	-1.060.019,24 €	0,7003	0,6756
3	22.712.628,50 €	19.362.999,00 €	1.020.502,00 €	3.349.629,60 €	0,8310	1,0741
4	23.298.840,00 €	20.337.111,00 €	-6.170.820,00 €	2.961.728,71 €	0,8301	0,8313
5	763.337,40 €	1.780.194,00 €	-1.566.001,00 €	-1.016.856,72 €	1,0173	0,7513
6	16.453.721,50 €	11.218.142,00 €	-7.235.632,00 €	5.235.579,65 €	0,6713	0,7054
7	6.232.556,80 €	44.866.514,00 €	-41.232.550,00 €	-38.633.956,99 €	0,9524	0,9925

8	29.717.136,00 €	45.313.865,00 €	-29.315.122,00 €	-15.596.728,57 €	1,0593	0,7246
9	8.666.480,30 €	19.668.177,00 €	-22.773.423,00 €	-11.001.696,94 €	0,7705	0,8119
10	1.182.149,80 €	4.343.066,00 €	-5.031.274,00 €	-3.160.916,01 €	0,7954	0,8788

Con el objetivo de comprobar si existe algún valor atípico en el conjunto de datos que pueda alterar los resultados del análisis, se ha visualizado una gráfica de cajas (boxplot) tanto de los valores SPI como de CPI que se han calculado anteriormente (Tabla 7) (Ilustración 7).

Tabla 7: Visualización *outliers* (R-Studio) I

```

#Boxplot para visualizar outliers de SPI y CPI
library(tidyr)
library(ggplot2)

# Convertir a formato largo
df1_long <- df1 %>%
  pivot_longer(cols = c(SPI, CPI), names_to = "Índice", values_to = "Valor")

# Graficar boxplot
ggplot(df1_long, aes(x = Índice, y = Valor, fill = Índice)) +
  geom_boxplot() +
  labs(title = "Distribución de SPI y CPI",
       x = "Índice de Rendimiento",
       y = "Valor") +
  theme_minimal() +
  scale_fill_manual(values = c("SPI" = "skyblue", "CPI" = "salmon"))
  
```




Ilustración 7: *Boxplot* SPI y CPI (R-Studio) I

Con la visualización de esta gráfica de cajas, se puede comprobar que no existe ningún valor atípico en el conjunto de datos tanto de SPI como de CPI que pueda alterar el estudio que se va a realizar a continuación. Esto es, la distribución de ambos indicadores de rendimiento es homogénea y no se presentan valores atípicos que puedan generar ruido al estudio.

Respecto al indicador de rendimiento en términos de coste (CPI), se observa una mediana alrededor del 0,83, con un rango intercuartílico de entre 0,74 y 0,96. En cuanto a los valores mínimos y máximos de este conjunto, son aproximadamente de 0,67 y 1,11, por lo que no se ha registrado ningún *outlier*.

Siguiendo con el indicador de rendimiento temporal (SPI), presenta una mediana muy similar al CPI, en este caso, ronda al 0,84. Asimismo, la dispersión de los valores se puede decir que es exactamente igual al CPI, con valores mínimos de 0,67 y valores máximos de 1,11. Por lo tanto, en el conjunto de los valores SPI también se confirma la ausencia de *outliers*.

7.1.1.2 Análisis de datos

Una vez teniendo todos los datos recopilados y adecuados para el análisis, se procederá a graficar e interpretar distintas gráficas que van a permitir conocer e identificar el estado de los proyectos, en cuanto al presupuesto como plazos.

7.1.1.2.1 Clasificación de proyectos por desempeño

Con el objetivo de conocer la situación en cuanto a plazo y coste de los proyectos a analizar, se van a clasificar los proyectos según si están en plazo ($SPI \geq 1$) y en coste ($CPI \geq 1$). Por lo tanto, en R-Studio se ha introducido el siguiente código (Tabla 8).

Tabla 8: Clasificación de proyectos según valor de SPI y CPI (R-Studio) I

```

# Crear clasificación por desempeño
df1$Cumple_Plazo <- ifelse(df1$SPI >= 1, "Sí", "No")
df1$Cumple_Coste <- ifelse(df1$CPI >= 1, "Sí", "No")

# Graficar el desempeño
print(
  ggplot(df1, aes(x = SPI, y = CPI, color = Cumple_Coste)) +
  geom_point(size = 4) +
  geom_hline(yintercept = 1, linetype = "dashed", color = "red") +
  geom_vline(xintercept = 1, linetype = "dashed", color = "blue") +
  labs(title = "Clasificación de Proyectos según SPI y CPI",
       x = "SPI (Índice de Plazo)", y = "CPI (Índice de Coste)") +
  theme_minimal())

```

Cada punto graficado (Ilustración 8) representa cada proyecto del conjunto de datos que se está analizando, y su color depende de si cumple con el objetivo definido en cuanto a coste del proyecto o no. Esto es, los proyectos con un CPI menor que 1 se han identificado con un color rojo, y el resto con color azul.

Asimismo, se han visualizado dos líneas de referencia donde definen los umbrales de SPI=1 y CPI=1. El eje X informa sobre el rendimiento en plazos de los proyectos, donde aquellos proyectos con un SPI mayor a 1, avanzan más rápido de lo planificado. En cuanto al eje Y, representa el rendimiento económico de los proyectos, donde los proyectos con un valor de CPI mayor que 1, son eficientes en cuanto a los costes.

Es este caso, la distribución de los puntos muestra que un alto porcentaje de los proyectos que se encuentran situadas en la zona inferior izquierda; es decir, con valores de CPI y SPI inferiores al umbral de 1. Esto quiere decir que la gran mayoría de los proyectos que se están analizando, han presentado sobrecostes y retrasos en los plazos establecidos en las fases iniciales del proyecto.




Ilustración 8: Visualización clasificación de proyectos según SPI y CPI (R-Studio) I

7.1.1.2.2 Histograma de SPI y CPI

Para conocer más en detalle la distribución de cada una de estas métricas de rendimiento (SPI y CPI), se ha visualizado en R-Studio una gráfica de barras para cada indicador. Estos dos histogramas van a permitir conocer el comportamiento de estos valores en los proyectos que se están analizando (Tabla 9) (Ilustración 9).

Tabla 9: Histogramas SPI y CPI (R-Studio) I

```

#Histogramas distribución SPI
ggplot(df1, aes(x = SPI)) + geom_histogram(bins = 30) + theme_minimal()

#Histogramas distribución CPI
ggplot(df1, aes(x = CPI)) + geom_histogram(bins = 30) + theme_minimal()
  
```




Ilustración 9: Visualización histogramas SPI y CPI (R-Studio) I

En ambas gráficas de distribución se puede observar que en la mayoría de los proyectos que se están analizando se han registrado valores de CPI y SPI inferiores al umbral de desempeño ideal ($SPI=1$ y $CPI=1$). Esto es, en términos generales estos proyectos tienden a retrasarse respecto a plazos ($SPI < 1$) y a superar el presupuesto ($CPI < 1$).

Respecto a los valores de SPI, se puede apreciar una mayor concentración de proyectos comprendidos entre 0,65 y 0,9. En el caso del CPI, la distribución es muy similar al SPI; predominando proyectos con valores por debajo del 1.

7.1.1.2.3 Porcentaje cumplimiento SPI y CPI

A continuación, se presentan los porcentajes de proyectos que cumplen con los índices de desempeño SPI y CPI. En la visualización de la izquierda (Ilustración 10) se muestran los valores del índice de desempeño del cronograma (SPI) de los proyectos que han sido gestionados por el modelo BIM. Se puede observar que en el 83% de los casos no han alcanzado el umbral de SPI ($SPI \geq 1$). Esto es, sólo el 17% de los proyectos han sido ejecutados dentro de los plazos establecidos.

En cuanto a la visualización de la derecha (Ilustración 10), en el que se realiza el análisis del índice de desempeño de costes (CPI) de estos mismos proyectos, se puede observar que el 83,6% de los proyectos han terminado con sobrecostos. En otras palabras, sólo el 16,4% de los proyectos han sido finalizados dentro del presupuesto establecido.




Ilustración 10: Porcentaje cumplimiento SPI y CPI (BIM)

7.1.1.2.4 Relación del CPI según el riesgo del proyecto

Es innegable que dependiendo del nivel de riesgo que tienen los proyectos, la tendencia del presupuesto de dicho proyecto dependerá directamente de ese riesgo. Esto es, generalmente aquellos proyectos con un nivel alto de riesgo suelen finalizar su actividad con sobrecostes significativos. Por lo tanto, es particularmente destacable analizar la tendencia de sobrecoste que tienen dichos proyectos según su nivel de riesgo. Este análisis se puede realizar gracias al indicador CPI, ya que permite conocer cómo de bien se están utilizando los recursos económicos en el proyecto hasta la fecha.

De este modo, el siguiente paso ha sido realizar este análisis en R-Studio para el conjunto de datos que se está evaluando. Por lo tanto, para evaluar si existe relación entre el riesgo del proyecto y el control de costes, se ha introducido el siguiente código (Tabla 10).

Tabla 10: Análisis relación entre CPI y Nivel de Riesgo de proyectos (R-Studio) I

```

# Análisis relación entre CPI y Riesgo del proyecto
ggplot(df1, aes(x = Risk_Level, y = CPI, fill = Risk_Level)) +
  geom_boxplot() +
  labs(title = "Relación entre Nivel de Riesgo y CPI",
       x = "Nivel de Riesgo", y = "CPI") +
  theme_minimal()
  
```

Aunque tradicionalmente en la gestión de proyectos un nivel significativo de riesgo siempre se ha relacionado con una mayor probabilidad de desviación en coste y plazo, estas gráficas (Ilustración 11) demuestran lo contrario. Esto es, cuando los proyectos son gestionados y controlados con técnicas avanzadas de gestión, en este caso BIM e IA, el impacto del riesgo apenas afecta a los resultados del proyecto.




Ilustración 11: Visualización relación Nivel de Riesgo Vs. CPI (R-Studio) I

A través de los valores estadísticos analizados, se puede observar que en este conjunto de unos 1.000 proyectos son muy pocos los proyectos en los que se han desarrollado dentro de los límites del presupuesto y plazo establecidos al inicio del proyecto. Esto es, a pesar de utilizar técnicas avanzadas de BIM e IA, la mayoría de los proyectos se encuentran por debajo de los valores ideales de $CPI < 1$ y $SPI < 1$.

Aunque también se ha visto que, gracias a las herramientas avanzadas utilizadas, los proyectos valorados como “High Risk” mantienen un rendimiento (CPI) medio muy similar a los proyectos considerados como “Low Risk”. Esto es, en lugar de visualizar una caída del rendimiento con el aumento del nivel de riesgo, como es habitual, estas herramientas neutralizan el impacto negativo que el riesgo puede tener en el rendimiento de los proyectos.

De modo que, la verdadera contribución de las metodologías BIM y de la inteligencia artificial no está exclusivamente en garantizar el éxito total de todos los proyectos. Más bien, en uniformar los resultados, controlando las variaciones y previniendo que el riesgo se convierta en fracasos significativos. Asimismo, gracias al análisis, se demuestra que estas herramientas avanzadas no son una garantía de éxito.

7.1.2 Estudio II (Empirical Project Data)

Se va a realizar un segundo análisis de proyectos que han sido gestionados con metodologías avanzadas de gestión de costes y plazos.

7.1.2.1 Recopilación y preparación de datos

Para este segundo estudio, se van a emplear datos reales de proyectos que fueron empleados para un estudio publicado en *International Journal of Project Management* bajo el nombre de *Construction and evaluation framework for real-life Project database*. [36] Este conjunto de datos llamado DSLib (Dynamic Scheduling Library) fue diseñado y desarrollado por Batselier y Vanhoucke en 2015 como parte de las investigaciones realizadas por el departamento de dirección de proyectos de la Universidad de Gante (Ghent University). [37]

Este dataset nace como respuesta a una de las carencias de la literatura académica: la falta de conjuntos de datos reales, variados y de calidad para estudios de investigación de control y planificación de proyectos.

De esta manera, para este segundo estudio se va a emplear el conjunto de datos mencionado, que cuenta con la información necesaria sobre más de 200 proyectos reales de diferentes sectores y organizaciones que han sido controlados y monitorizados de manera exhaustiva en cuanto a costes (*Cost Variance*, Coste final y Presupuesto Estimado) y plazos (*Schedule Variance*, Duración Real y Duración Planificada).

Además, este conjunto de datos destaca por haber sido gestionado bajo metodologías avanzadas de gestión: adopción de la técnica de *Earned Value Management (EVM)*, complementado con el seguimiento periódico durante la ejecución de los proyectos. Por lo tanto, este tipo de gestión en los proyectos convierte este conjunto de datos en una fuente idónea para evaluar el desempeño real en costes y plazos de proyectos gestionados bajo metodologías predictivas.

7.1.2.1.1 Carga y adecuación de datos

Al igual que se ha procedido con el anterior conjunto de datos, primero se han instalado y cargado los paquetes de R-Studio que van a ser necesarios para la carga y análisis del conjunto de datos. Asimismo, se ha cargado el archivo Excel que contiene el *dataset* a R.

Siempre que se hace una carga de datos, suele ser adecuado asegurar si los datos se han cargado adecuadamente y con la correcta estructura. En este caso, al observar que en varios títulos de las columnas se empleaban paréntesis y otros símbolos, se ha empleado la función *clean_names()* para homogeneizar todos los encabezados, y así, facilitar su posterior tratamiento. Para finalizar, se ha vuelto a visualizar el *dataset* para comprobar que la estructura de los datos es la correcta y proceder con el análisis (Tabla 11).

Tabla 11: Carga y adecuación de datos (R-Studio) II

```
# 1. Instalar y cargar paquetes necesarios
install.packages("readr")    # Para leer CSV
install.packages("dplyr")    # Manipulación de datos
install.packages("ggplot2")  # Gráficos
install.packages("tidyr")    # Manipulación formato largo

library(readr)
library(dplyr)
library(ggplot2)
library(tidyr)

install.packages("readxl")
library(readxl)

# 2. Importar el archivo con los datos de los proyectos reales
df2 <- read_excel(file.choose())

# 3. Visualizar la estructura de los datos
View(df2)

# 4. Adecuar los nombres de las columnas
names(df2)
install.packages("janitor")
library(janitor)
df2 <- df2 %>% clean_names()
```

```
names(df2)
```

5. Visualizar la estructura de los datos

```
View(df2)
```

Cuando se ha intentado sacar un resumen estadístico de los valores de SPI y CPI registrados en la base de datos, se ha visto que el programa no estaba leyendo bien estos valores numéricos. Esto es, en vez de identificarlos como valores numéricos, los estaba interpretando como de tipo carácter. Por lo tanto, ha sido necesario indicar al programa que estos valores son de tipo numérico (Tabla 12). Después, se ha verificado que ya está cogiendo estos valores adecuadamente (Ilustración 12).

Tabla 12. Conversión valores SPI y CPI a tipo numérico (R-Studio) II

Convertir SPI y CPI a numérico eliminando símbolos

```
df2 <- df2 %>%
```

```
mutate(
```

```
`cpi_final` = as.numeric(gsub("[^0-9\\.]", "", `cpi_final`)),
```

```
`spi_final` = as.numeric(gsub("[^0-9\\.]", "", `spi_final`)) )
```

Verifica que ahora son numéricas

```
str(select(df2, `cpi_final`, `spi_final`))
```

```
> # Verifica que ahora son numéricas
> str(select(df, `cpi_final`, `spi_final`))
tibble [233 × 2] (S3: tbl_df/tbl/data.frame)
 $ cpi_final: num [1:233] NA NA NA NA 1 NA 0.95 NA NA 0.98 ...
 $ spi_final: num [1:233] NA NA NA NA 1 NA 1 NA NA 1 ...
```

Ilustración 12: Verificación tipo de valor de SPI y CPI (R-Studio) II

Otro paso imprescindible para el posterior análisis es eliminar del conjunto de datos aquellos proyectos que no tienen información válida sobre valores de SPI y CPI; ya que estos valores no registrados podrían alterar los resultados finales del estudio. Además, se ha realizado un resumen estadístico de estos dos indicadores de rendimiento, para tener una visión general del comportamiento de los proyectos en términos de costes y plazos (Tabla 13) (Ilustración 13).

Tabla 13: Filtro de proyectos con valores nulos y resumen estadístico de SPI y CPI (R-Studio) II

Filtrar proyectos que tengan valores de CPI y SPI finales válidos

```
df2_filtrado <- df2 %>%
```

```
filter(!is.na(`cpi_final`), !is.na(`spi_final`))
```

Resumen estadístico de SPI y CPI

```
summary(select(df2_filtrado, `cpi_final`, `spi_final`))
```

```

> # Resumen estadístico de SPI y CPI
> summary(select(df_filtrado, `cpi_final`, `spi_final`))
  cpi_final      spi_final
Min.   :0.0000   Min.   :0.0100
1st Qu.:0.8850   1st Qu.:1.0000
Median :0.9800   Median :1.0000
Mean   :0.9339   Mean   :0.9851
3rd Qu.:1.0000   3rd Qu.:1.0000
Max.   :1.2500   Max.   :1.2500
  
```

Ilustración 13: Resumen estadístico SPI y CPI (R-Studio) II

En cuanto al indicador de rendimiento de los costes (CPI), se ha calculado una media de 0,9339, que indica que, en términos generales, los proyectos tienden a finalizar con sobrecostes. El valor mínimo registrado es de 0, lo que podría deberse a un posible error a la hora de registrar los datos o a proyectos cuyo coste real ha sido significativamente superior al valor ganado. No obstante, el valor máximo de CPI registrado es de 1,25, indicando que algunos proyectos han sido ejecutados eficientemente en costes. Para finalizar, la mediana es de 0,98 y el valor del tercer cuartil de 1; por lo que se sabe que al menos el 50% de los proyectos que se están analizando han sido finalizados dentro del presupuesto o han estado muy cerca.

Por otro lado, en el SPI se ha calculado un valor medio de 0,9851 y una mediana de 1; lo que señala que la mayoría de los proyectos han sido ejecutados dentro del plazo o con retrasos insignificantes. Sin embargo, el valor mínimo que se indica en el resumen es de 0,01, lo cual indica un desempeño de la planificación muy poco eficiente en algún caso concreto.

En resumen, aunque la mayoría de los proyectos han tenido un desempeño eficiente en cuanto a plazos, ha habido mayores desviaciones en el control de costes. Esto va a ser analizado en mayor profundidad en los siguientes apartados.

7.1.2.2 Análisis de datos

En el presente apartado, se van a analizar en mayor profundidad los valores del conjunto de datos, tales como CPI y SPI.

7.1.2.2.1 Análisis de la variabilidad de CPI y SPI

Con el fin de visualizar la distribución y variabilidad de los índices de rendimiento (CPI y SPI), se ha realizado un gráfico de cajas (*boxplot*) a partir de los datos filtrados previamente (Tabla 14) (Ilustración 14).

Tabla 14: *Boxplot* CPI y SPI (R-Studio) III

Boxplot comparativo SPI y CPI

```

df2_long <- df2_filtrado %>%
  pivot_longer(cols = c(`cpi_final`, `spi_final`),
    names_to = "Índice",
    values_to = "Valor")
  
```

```

ggplot(df2_long, aes(x = Índice, y = Valor, fill = Índice)) +
  geom_boxplot() +
  labs(title = "Distribución de SPI y CPI",
       y = "Valor del índice", x = "Índice de desempeño") +
  scale_fill_manual(values = c("spi_final" = "skyblue", "cpi_final" = "salmon")) +
  theme_minimal()

```




Ilustración 14: Visualización *boxplot* CPI y SPI (R-Studio) II

Gracias a ambas gráficas de cajas, se observa que gran parte de los valores de CPI y SPI se encuentran alrededor del umbral ideal (CPI=1 y SPI=1). Esto quiere decir que la gran mayoría de los proyectos tienen un rendimiento apropiado en cuanto a los costes y plazos.

Lo que respecta al valor de CPI, el rango intercuartílico es más amplio comparando con los valores de SPI, y se han registrado valores atípicos (*outliers*) en la parte inferior de la visualización. Esto refleja que ha habido proyectos con sobrecostes muy significativos. Por el contrario, el SPI tiene una distribución mucho más concentrada que el CPI. No obstante, también se han registrado valores atípicos (*outliers*) en los valores inferiores del SPI.

Para terminar, en el caso de los valores SPI, en la gráfica de caja no se visualiza la caja característica de este tipo de visualización, ya que los valores del primer y tercer cuartil son iguales a la mediana (Ilustración 15). Esto genera que el rango intercuartílico, en este caso, sea nulo. Por lo tanto, como resultado, la caja de la gráfica de SPI no es visible.

```

> summary(df_filtrado$spi_final)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
0.0100  1.0000   1.0000  0.9851  1.0000  1.2500

```

Ilustración 15: Resumen estadístico SPI (R-Studio) II

7.1.2.2.2 Clasificación de proyectos por desempeño

El siguiente paso es analizar el desempeño de los proyectos a través de los índices de CPI y SPI. Para ello, se ha utilizado una gráfica de dispersión para conocer la dispersión del desempeño de los proyectos de manera rápida y visual (Tabla 15) (Ilustración 16).

Tabla 15: Clasificación de desempeño CPI y SPI (R-Studio) II

```

# Clasificación por desempeño
df2_filtrado <- df2_filtrado %>%
  mutate(
    Cumple_Coste = ifelse(`cpi_final` >= 1, "Sí", "No"),
    Cumple_Plazo = ifelse(`spi_final` >= 1, "Sí", "No") )

# Gráfico de dispersión SPI vs CPI
ggplot(df2_filtrado, aes(x = `spi_final`, y = `cpi_final`, color = Cumple_Coste)) +
  geom_point(size = 3) +
  geom_vline(xintercept = 1, linetype = "dashed", color = "blue") +
  geom_hline(yintercept = 1, linetype = "dashed", color = "red") +
  labs(
    title = "Clasificación de Proyectos según SPI y CPI",
    x = "SPI (Índice de Plazo)",
    y = "CPI (Índice de Coste)" +
  theme_minimal()
  
```




Ilustración 16: Visualización clasificación de proyectos según CPI y SPI (R-Studio) II

Cada punto de la gráfica de dispersión representa un proyecto, donde en el eje X se registran los valores de SPI y en el eje Y los de CPI. Mediante los colores de los puntos se ha querido realizar una clasificación visual de aquellos proyectos que se terminaron dentro del objetivo del coste (representados en color azul), y los que terminaron con sobrecostos (representado en color rojo).

Esta visualización permite conocer que una gran parte de los proyectos han sido ejecutados dentro del plazo planificado ($SPI \geq 1$), aunque no todos estos proyectos han estado dentro del presupuesto establecido ($CPI \geq 1$).

7.1.2.2.3 Histograma de SPI y CPI

El último análisis de los valores de rendimiento de los proyectos es realizar una última visualización de la dispersión y comportamiento de estos valores de manera individual. Para ello, se han empleado graficas de barras (histogramas) que permiten conocer el tipo de distribución que siguen los valores de cada uno de estos indicadores (Tabla 16) (Ilustración 17).

Tabla 16: Histograma SPI y CPI (R-Studio) II

#Histogramas por separado

```
ggplot(df2, aes(x = spi_final)) + geom_histogram(bins = 30) + theme_minimal()
ggplot(df2, aes(x = cpi_final)) + geom_histogram(bins = 30) + theme_minimal()
```




Ilustración 17: Visualización histograma SPI y CPI (R-Studio) II

La gráfica de barras de la izquierda, que pertenece a los valores de SPI, presenta una gran concentración de casos en torno al valor 1, indicando la finalización exacta del proyecto respecto a la fecha planificada. En cuanto al resto de los proyectos, se sitúan ligeramente por encima del valor ideal ($SPI=1$). No obstante, también existen proyectos por debajo del umbral y con valores por debajo de 0,75. A pesar de estos valores más dispersos al resto de los proyectos, se observa un desempeño temporal muy uniforme entre los proyectos analizados.

Respecto al histograma de CPI, aunque se aprecia un pico significativo en torno al valor 1, en comparación al SPI, muestra mayor dispersión de los datos. Asimismo, se observan un número bastante alto de proyectos que se sitúan por debajo del umbral ideal ($CPI=1$), significando que estos proyectos terminaron con sobrecostes.

Para finalizar, con este último análisis se comprueba lo que se ha estado mencionando en los apartados anteriores: los proyectos del conjunto analizado presentan una mayor dificultad en el control del presupuesto que en el control de plazos.

7.1.2.2.4 Porcentaje proyectos que cumplen SPI y CPI

Al igual que se ha realizado para el caso anterior, se han sacado los porcentajes de los proyectos que cumplen con el rendimiento de plazos y costes (Ilustración 18). En este caso, la primera visualización muestra que el 92,16% de los proyectos analizados muestran un SPI mayor o igual a 1, indicando que este porcentaje de los proyectos han cumplido con el cronograma planificado. En este caso, solo el 7,87% de los casos han presentado retrasos en cuanto a plazos.

Si se observa la gráfica del rendimiento del coste (CPI) en los proyectos, se contemple que el 58,82% de estos mismos proyectos, han presentado sobrecostes en la ejecución.




Ilustración 18: Porcentaje cumplimiento SPI y CPI (Valor Ganado)

7.2 Análisis de proyectos sin emplear modelos predictivos

Una vez analizados los conjuntos de proyectos en los que se han aplicado herramientas predictivas como BIM y EVM, se va a realizar un tercer análisis en R-Studio para cumplir con el objetivo del presente TFM: analizar el impacto que tienen las metodologías avanzadas emergentes sobre los costes y plazos de los proyectos, basándose en datos de proyectos reales. Para ello, es imprescindible disponer de un punto de referencia para contrastar los resultados obtenidos con proyectos que no han sido gestionados con metodologías avanzadas de gestión y control.

Como se mencionó anteriormente, para el estudio de este trabajo se ha optado por un proceso comparativo que va a permitir comprobar de manera objetiva si las mejoras de la adopción de metodologías avanzadas en la gestión de proyectos se reflejan en los resultados reales de ejecución.

7.2.1 Estudio III (Capital Project Schedules and Budgets)

Para este tercer análisis, donde se van a analizar aquellos proyectos en los que se ha optado por no emplear técnicas avanzadas de predicción de costes y plazos, se ha optado por un conjunto de datos de carácter público y accesible a cualquier usuario. El conjunto de datos ha sido extraído de una fuente oficial del Gobierno de Estados Unidos, titulada “Capital Project Schedules and Budgets”. [38] Esta plataforma permite que cualquier persona consulte esta información, promoviendo la transparencia y el estudio de proyectos públicos, asegurando la veracidad de los datos empleados.

Este dataset contiene información completa sobre distintos proyectos de financiación pública realizadas en el ámbito educativo en la ciudad de Nueva York. Por ejemplo, algunos de estos proyectos están enfocados en:

- Reformas estructurales.
- Instalaciones de luminarias, cámaras de seguridad y mejoras exteriores.
- Trabajos de mantenimiento y restauración en espacios públicos.
- Instalación de sistemas de ventilación y calefacción.
- Reformas de suelos o cubiertas.

Asimismo, para cada uno de estos proyectos contiene variables de entrada muy valiosos para el estudio que se quiere realizar en R-Studio:

- Presupuesto planificado
- El coste real del proyecto
- Fechas de inicio y finalización del proyecto (previstas y reales)

A diferencia de los conjuntos analizados anteriormente, los proyectos que se encuentran en este conjunto de datos no han sido gestionados a través de metodologías predictivas ni tecnologías avanzadas, convirtiéndolos en una opción ideal para realizar la comparativa que se desea.

7.2.1.1 Recopilación y preparación de datos

7.2.1.1.1 Carga y adecuación de datos

Como se ha realizado con los conjuntos de datos de los análisis anteriores, con esta información se van a seguir los mismos pasos para la carga y adecuación de los datos con los que se va a trabajar (Tabla 17).

Tabla 17: Carga de paquetes necesarios (R-Studio) III

```
#Instalación de paquetes necesarios
install.packages("readr") # Para leer archivos CSV
install.packages("dplyr") # Para manipular datos
install.packages("ggplot2") # Para hacer gráficos

#Carga de paquetes necesarios
```

```
library(readr)
library(dplyr)
library(ggplot2)
```

Una vez que se han instalado y se ha hecho la carga de los paquetes necesarios para el estudio, el siguiente paso ha sido importar el archivo Excel, donde está el conjunto de datos, a R-Studio. En este caso, se ha indicado que este segundo conjunto de datos le llame *df2* (Tabla 18).

Tabla 18: Carga de datos (R-Studio) III

```
#Cargar archivo
df3 <- read_csv(file.choose())
```

Además, para comprobar que se han cargado correctamente los datos, se han visualizado las primeras filas del conjunto de datos (Tabla 19).

Tabla 19: Visualización de datos (R-Studio) III

```
#Verificar estructura de los datos
glimpse(df3)
summary(df3)
head(df3)

# Mostrar tabla con los nuevos cálculos
View(df3)
```

Se ha observado que el programa está considerando algunos valores que debería considerar de carácter numérico en texto. Esto es, la columna de “*Project Budget Amount*” está considerado de valor categórico. Como se trata del presupuesto de los proyectos, esta columna se tiene que definir cómo carácter numérico. Por lo tanto, se va a indicar al programa que considere esta columna como valor.

Asimismo, con la expresión *gsub("[^0-9.]", "", ...)* se va a conseguir eliminar todo lo que no sea un número o un punto decimal para que no distorsione el análisis (Tabla 20).

Tabla 20: Convertir texto a columna de tipo numérico (R-Studio) III

```
#Convertir columna de texto a numérico
library(dplyr)

df3 <- df3 %>%
  mutate(
    `Project Budget Amount` = as.numeric(gsub("[^0-9.]", "", `Project Budget Amount`)),
    `Final Estimate of Actual Costs Through End of Phase Amount` = as.numeric(gsub("[^0-9.]", "", `Final Estimate of Actual Costs Through End of Phase Amount`)),
```

```
`Total Phase Actual Spending Amount` = as.numeric(gsub("[^0-9.]", "", `Total Phase Actual Spending Amount`))
)
```

De este modo, se ha asegurado el tratamiento correcto de los valores en R-studio, evitando así complicaciones en el análisis posterior

7.2.1.1.2 Cálculo de datos estadísticos descriptivos

Una vez que se dispone del adecuado conjunto de datos en R-Studio, el siguiente paso es conocer las características de los proyectos con los que se va a realizar el estudio. Para ello, la función del resumen estadístico es muy valioso, ya que permite con una única función disponer de un resumen estadístico en términos generales (Tabla 21).

Tabla 21: Resumen estadístico (R-Studio) III

```
#Resumen estadístico de los datos
summary(df3)
```

Con la función aplicada, se han conseguido los siguientes valores (Ilustración 19).

```
Project Phase Actual End Date Project Budget Amount Final Estimate of Actual Costs Through End of Phase Amount
Length:14093 Min. : 0 Min. : 0
Class :character 1st Qu.: 16768 1st Qu.: 23999
Mode :character Median : 125000 Median : 110350
Mean : 2025923 Mean : 1294840
3rd Qu.: 650946 3rd Qu.: 353866
Max. :202994750 Max. :199619196
NA's :5226 NA's :17

Total Phase Actual Spending Amount DSF Number(s)
Min. : 0 Length:14093
1st Qu.: 0 Class :character
Median : 7879 Mode :character
Mean : 462808
3rd Qu.: 120016
Max. :195252948
NA's :117
```

Ilustración 19: Resumen estadístico (R-Studio) III

Mediante este resumen estadístico se pretenden comprender la situación económica de los proyectos que se recogen en el dataset que se analiza. Este conjunto de datos recoge información sobre más de 14.000 proyectos reales, convirtiéndolo ideal para el presente estudio.

El resumen estadístico desvela una dispersión significativa en el presupuesto planificado y real de los proyectos. Esto es, el presupuesto planificado (*Project Budget Amount*) muestra un valor medio de aproximadamente 2.025.923 \$, mientras que el valor medio del coste real (*Final Estimate of Actual Cost*) es algo inferior: esto es, de aproximadamente 1.294.840 \$. Realizando una primera lectura de estos valores, esto presenta que, en reglas generales, los proyectos han consumido menos recursos económicos de lo que se había estimado. No obstante, esta conclusión no es exactamente cierta, debido a que es importante considerar que se han encontrado más de 5.200 valores ausentes (NA's) en la variable del presupuesto planificado. Esto podría distorsionar el análisis de las desviaciones presupuestarias.

Con respecto al coste real de los proyectos (Total Phase Actual Spending Amount), el valor medio de este conjunto es de unos 462.808 \$, con valores que oscilan desde proyectos sin gasto alguno hasta algunos que han superado los 19 millones de dólares. Esto es, el conjunto contiene tanto proyectos con un presupuesto bajo hasta proyectos con presupuestos considerables.

En resumen, este contexto informa de una base de datos completa y estadísticamente relevante que facilita la investigación de los métodos tradicionales de gestión de proyectos, enfocándose específicamente en el cumplimiento de los objetivos económicos y temporales.

7.2.1.1.3 Cálculo de variables de Valor Ganado

Para poder analizar el desempeño de los proyectos en términos de coste y plazo, en el caso de este dataset, es necesario transformar los datos intrínsecos del propio conjunto a valores clave para la evaluación del Valor Gando. Esto es, con los datos del propio conjunto, se han calculado los indicadores fundamentales como el *Cost Overrun* (diferencia entre el coste real y el presupuesto inicial) y *Schedule Deviation* (variación entre la duración real y la planificada) (Tabla 22).

Tabla 22: Cálculo *Cost Overrun* y *Schedule Deviation* (R-Studio) III

```

#Estrae variables para análisis
df3 <- df3 %>%
  mutate(
    # Limpia comas, comillas, espacios, letras
    Planned_Cost = as.numeric(gsub("[^0-9.]", "", `Project Budget Amount`)),
    Actual_Cost = as.numeric(gsub("[^0-9.]", "", `Final Estimate of Actual Costs Through End of Phase Amount`)),
    Cost_Overrun = Actual_Cost - Planned_Cost,
    Planned_Start = as.Date(`Project Phase Actual Start Date`, format = "%m/%d/%Y"),
    Planned_End = as.Date(`Project Phase Planned End Date`, format = "%m/%d/%Y"),
    Actual_End = as.Date(`Project Phase Actual End Date`, format = "%m/%d/%Y"),
    Planned_Duration = as.numeric(Planned_End - Planned_Start),
    Actual_Duration = as.numeric(Actual_End - Planned_Start),
    Schedule_Deviation = Actual_Duration - Planned_Duration
  )

```

Una vez calculados los parámetros del Valor Gando, se han visualizado para comprobar si el cálculo se ha realizado correctamente (Tabla 23).

Tabla 23: Visualización valores de Valor Ganado (R-Studio) III

	Planned_Cost	Actual_Cost	Cost_Overrun	Planned_Start	Planned_End	Actual_End	Planned_Duration	Actual_Duration	Schedule_Deviation
1	NA	448.119,00 €	NA	19/07/2024	NA	09/10/2024	NA	82	NA
2	NA	206.654,00 €	NA	28/06/2024	NA	NA	NA	NA	NA
3	NA	814.540,00 €	NA	19/02/2024	NA	NA	NA	NA	NA
4	68.660,00 €	76.648,00 €	7.988,00 €	13/04/2021	13/09/2021	01/07/2021	153	79	-74
5	343.300,00 €	385.777,00 €	42.477,00 €	06/07/2021	07/12/2021	29/11/2021	154	146	-8
6	7.724.250,00 €	7.190.070,00 €	- 534.180,00 €	18/07/2022	16/07/2024	NA	729	NA	NA
7	480.620,00 €	211.172,00 €	-269.448,00 €	18/07/2022	16/07/2024	NA	729	NA	NA
8	4.240,00 €	2.496,00 €	-1.744,00 €	22/06/2023	23/10/2023	06/07/2023	123	14	-109
9	19.080,00 €	9.986,00 €	- 9.094,00 €	06/07/2023	03/01/2024	13/12/2023	181	160	-21
10	245.920,00 €	224.898,00 €	- 21.022,00 €	27/05/2024	26/05/2025	NA	364	NA	NA

Como se puede observar en la tabla superior, existen muchos valores ausentes en la tabla. Estos valores que faltan pueden distorsionar el análisis estadístico, por lo que se ha optado por eliminar estas filas que contengan valores faltantes y se han visualizado de nuevo la tabla de valores calculados (Tabla 24)(Tabla 25).

Tabla 24: Eliminar filas con valores faltantes y visualización de los valores (R-Studio) III

```
#Eliminar filas con valores faltantes
df3 <- df3 %>% filter(! is.na(Planned_Cost), !is.na(Actual_Cost), !is.na(Planned_Duration),
!is.na(Actual_Duration))

# Mostrar tabla con los nuevos cálculos
View(df3)
```

Tabla 25: Visualización valores calculados (R-Studio) III

	Planned_Cost	Actual_Cost	Cost_Overrun	Planned_Start	Planned_End	Actual_End	Planned_Duration	Actual_Duration	Schedule_Deviation
1	68.660,00 €	76.648,00 €	7.988,00 €	13/04/2021	13/09/2021	01/07/2021	153	79	-74,00 €
2	343.300,00 €	385.777,00 €	42.477,00 €	06/07/2021	07/12/2021	29/11/2021	154	146	-8,00 €
3	4.240,00 €	2.496,00 €	-1.744,00 €	22/06/2023	23/10/2023	06/07/2023	123	14	-109,00 €
4	19.080,00 €	9.986,00 €	-9.094,00 €	06/07/2023	03/01/2024	13/12/2023	181	160	-21,00 €
5	124.674,00 €	160.838,00 €	36.164,00 €	26/05/2021	12/10/2021	21/01/2022	139	240	101,00 €
6	613.841,00 €	522.010,00 €	-91.831,00 €	21/01/2022	22/06/2022	10/05/2022	152	109	-43,00 €
7	12.987.707,00 €	12.230.812,00 €	-756.895,00 €	19/09/2022	09/06/2024	19/11/2024	629	792	163,00 €
8	944.133,00 €	358.472,00 €	-585.661,00 €	19/09/2022	09/06/2024	19/11/2024	629	792	163,00 €

9	195.550,00 €	194.302,00 €	-1.248,00 €	22/04/2021	07/09/2021	21/12/2021	138	243	105,00 €
10	977.750,00 €	611.348,00 €	-366.402,00 €	22/12/2021	10/06/2022	16/09/2022	170	268	98,00 €

Una vez depuradas las variables para el análisis, se ha generado un segundo resumen estadístico de los principales parámetros relacionados con los costes y plazos de los proyectos. Este resumen proporciona una visión general del comportamiento que han tenido los proyectos durante su ejecución (Ilustración 20).

Planned_Cost	Actual_Cost	Cost_Overrun	Planned_Duration	Actual_Duration	Schedule_Deviation
Min. : 0	Min. : 0	Min. : -10373614	Min. : -657.0	Min. : 0.0	Min. : -564.00
1st Qu.: 14960	1st Qu.: 17666	1st Qu.: -16003	1st Qu.: 124.0	1st Qu.: 97.5	1st Qu.: -48.00
Median : 66000	Median : 86488	Median : 1852	Median : 150.0	Median : 160.0	Median : 0.00
Mean : 588322	Mean : 528144	Mean : -60179	Mean : 182.2	Mean : 233.2	Mean : 51.09
3rd Qu.: 243588	3rd Qu.: 252002	3rd Qu.: 30614	3rd Qu.: 179.0	3rd Qu.: 262.0	3rd Qu.: 83.00
Max. : 202994750	Max. : 199619196	Max. : 4596419	Max. : 2498.0	Max. : 2557.0	Max. : 2451.00

Ilustración 20: Resumen estadístico de Valor Gando (R-Studio) III

Anteriormente se han observado los valores del resume estadístico de las variables Coste Planificado y Coste real, por lo que en este caso no se va a hacer ninguna mención. En cuanto a la variable de *Cost Overrun*, se puede observar que presenta una media negativa de -60.179 \$, indicando que en términos generales los proyectos han finalizado con menos gastos de los previsto. No obstante, hay presencia de proyectos que han tenido sobrecostes significativos, en algunas ocasiones llegando a un sobrecoste de 4,5 millones de dólares por encima del presupuesto inicial.

Si se observan los plazos de los proyectos, tanto la variable Duración Planificada como la Duración Actual tienen una mediana en torno al 150-160 días. Esto es, con esta información se puede conocer que los proyectos que se están analizando contienen un conjunto de tareas con una duración relativamente larga. En relación a los valores de la variable *Schedule Deviation*, contienen una media de +51 días, lo que presenta una tendencia generalizada al retraso de los proyectos, aunque la mediana es de 0 días; lo que refleja que la mitad de los proyectos de este conjunto se ejecutaron dentro de los plazos establecidos al inicio del proyecto.

Con los valores *Planned Duration*, *Actual Duration*, *Planned Cost* y *Actual Cost*, se han calculado los valores del Índice de Desempeño del Cronograma (SPI) y el Índice de Desempeño del Coste (CPI). Como se ha mencionado en el apartado anterior, el índice SPI permite evaluar la eficiencia en la ejecución temporal del proyecto, comparando los valores de la duración planificada y la real. El índice CPI permite medir la eficiencia en términos de costes, relacionando el presupuesto inicial con el coste real (Tabla 26).

Tabla 26: Cálculo SPI y CPI (R-Studio) III

```

# Schedule Performance Index
df3$SPI <- df3$Planned_Duration / df3$Actual_Duration

# Cost Performance Index
df3$CPI <- df3$Planned_Cost / df3$Actual_Cost
  
```

Posteriormente, para comprobar si existe algún valor atípico en el conjunto que pueda distorsionar los resultados del análisis, se ha visualizado una gráfica de cajas (boxplot) tanto de los valores SPI como de CPI (Tabla 27) (Ilustración 21).

Tabla 27: Visualización *outliers* SPI y CPI (R-studio) III

```

#Descarga paquete para visualizaciones tipo boxplot
library(ggplot2)

df3_long <- df3 %>%
  pivot_longer(cols = c(SPI, CPI), names_to = "Índice", values_to = "Valor")

# Graficar boxplot para SPI y CPI
ggplot(df3_long, aes(x = Índice, y = Valor, fill = Índice)) +
  geom_boxplot() +
  labs(title = "Distribución de SPI y CPI",
       x = "Índice de Rendimiento",
       y = "Valor") +
  theme_minimal() +
  scale_fill_manual(values = c("SPI" = "skyblue", "CPI" = "salmon"))
  
```




Ilustración 21: Visualización *outliers* SPI y CPI (R-Studio) III

En la visualización anterior se puede identificar que entre los valores de CPI se encuentran varios valores atípicos (por ejemplo, un CPI de 8000). Por lo tanto, lo siguiente que se ha realizado ha sido eliminar estos valores atípicos (*outliers*) del conjunto para asegurar la calidad y fiabilidad del estudio. Esta depuración se ha aplicado mediante un filtro en R-Studio (Tabla 28).

Tabla 28: Depuración valores atípicos (R-Studio) III

```

# Filtro valores atípicos
df3 <- df3 %>%
  filter(
    SPI > 0 & SPI < 2,
    CPI > 0 & CPI < 2,
    !is.na(SPI), !is.na(CPI))
  
```

Una vez filtrados los valores atípicos del conjunto de datos, se han vuelto a graficar los valores de SPI y CPI para comprobar que el filtro ha sido aplicado correctamente (Tabla 29) (Ilustración 22).

Tabla 29: *Boxplot* SPI y CPI (R-Studio) III

```

# Convertir a formato largo
df3_long <- df3 %>%
  pivot_longer(cols = c(SPI, CPI), names_to = "Índice", values_to = "Valor")

# Graficar boxplot de SPI y CPI
ggplot(df3_long, aes(x = Índice, y = Valor, fill = Índice)) +
  geom_boxplot() +
  labs(title = "Distribución de SPI y CPI",
       x = "Índice de Rendimiento",
       y = "Valor") +
  theme_minimal() +
  scale_fill_manual(values = c("SPI" = "skyblue", "CPI" = "salmon"))
  
```




Ilustración 22: Visualización *boxplot* CPI y SPI (R-Studio) III

Ambas gráficas de cajas muestran una media cercana al 1, lo que indica, que en general los proyectos tienden a cumplir el presupuesto y plazo planificado. Sin embargo, se observan valores tanto por debajo como por encima del umbral ideal de estos dos indicadores (valor 1), planteando que dentro del conjunto figuran proyectos con desviaciones significativas, ya sea por variaciones positivas o negativas, en plazo y coste.

El rango intercuartílico en ambos indicadores es similar, pero se aprecia una mayor concentración de datos inferiores al umbral en el caso del CPI, mostrando una tendencia más frecuente a exceder los costes planificados de los proyectos. Asimismo, la visualización de numerosos datos atípicos (*outliers*) con valores entre 1,5 y 2 en ambos indicadores revela que una parte de los proyectos ha logrado unos niveles excepcionales de eficiencia en coste y plazo durante su ejecución, aunque se trata de proyectos poco comunes.

7.2.1.2 Análisis de datos

Una vez que los datos están adecuadamente preparados para el análisis, se va a proceder a la valoración de las distintas variables que se encuentran en el *dataset*.

7.2.1.2.1 Clasificación de proyectos por desempeño

Se ha visualizado gráficamente la relación entre las variables SPI y CPI en cada uno de estos proyectos. Esta grafica se ha realizado con el objetivo de valorar el comportamiento conjunto entre estos dos indicadores de rendimiento, y la tendencia de los proyectos en cuanto a cumplimientos de los objetivos de presupuesto y plazo (Tabla 30) (Ilustración 23).

Tabla 30: Grafica de dispersión SPI y CPI (R-Studio) III

```

#Grafica de desempeño CPI y SPI
df3 <- df3 %>%
  mutate(Cumple_Coste = ifelse(CPI >= 1, "Sí", "No"))

library(ggplot2)

ggplot(df3, aes(x = SPI, y = CPI, color = Cumple_Coste)) +
  geom_point(size = 3) +
  geom_vline(xintercept = 1, linetype = "dashed", color = "red") +
  geom_hline(yintercept = 1, linetype = "dashed", color = "blue") +
  labs(
    title = "Comparación SPI vs CPI",
    x = "SPI (Índice de Plazo)",
    y = "CPI (Índice de Coste)" +
  theme_minimal()

```




Ilustración 23: Visualización gráfica de dispersión SPI y CPI (R-Studio) III

Cada uno de los puntos representados en la gráfica simboliza un proyecto, y el su color indica si el proyecto ha cumplido con el presupuesto (azul para “Sí” y rojo para “No”). Si se analiza la distribución de estos puntos, se puede observar que la mayoría de los proyectos se encuentran por debajo del límite de CPI igual a 1. Esto indica que un alto porcentaje de los proyectos no han logrado mantenerse dentro del objetivo de coste.

Respecto al SPI, se visualiza una mayor dispersión, aunque una proporción significativa de los proyectos también están por debajo del valor 1, lo cual indica retrasos respecto a los plazos establecidos inicialmente. Sin embargo, cabe destacar que muchos puntos que se encuentran en la parte izquierda de la línea SPI igual a 1 (proyectos con retrasos), han conseguido mantenerse dentro del presupuesto (CPI=1). Esto es, aunque se hayan retrasado en cuanto a plazos, estos proyectos se han mantenido dentro de los costes.

En resumen, gracias a esta gráfica se puede concluir que donde más han fallado estos proyectos ha sido en el tema de la gestión y control de costes, ya que es la cuadrícula donde más proyectos se concentran.

7.2.1.2.2 Histograma de SPI y CPI

Con el objetivo de comprender en mayor profundidad el comportamiento de manera individual de cada una de estas dos métricas (SPI y CPI), se va a analizar la distribución de cada uno por separado. Para ello, se graficarán estas distribuciones en un histograma (Tabla 31) (Ilustración 24).

Tabla 31: Histograma SPI y CPI (R-Studio) III

```

#Histogramas por separado (SPI y CPI)
ggplot(df3, aes(x = SPI)) + geom_histogram(bins = 30) + theme_minimal()
ggplot(df3, aes(x = CPI)) + geom_histogram(bins = 30) + theme_minimal()
  
```




Ilustración 24: Visualización histograma distribución SPI y CPI (R-Studio) III

En estas dos graficas se pueden observar la distribución de los valores SPI y CPI. En cuanto a los valores de SPI, la mayor parte de los proyectos se encuentran por debajo del umbral de SPI=1, lo cual representa que la mayoría de los proyectos han superado los plazos planificados.

Por otro lado, los valores del CPI muestran una tendencia predominante hacia valores inferiores al umbral CPI=1, lo cual quiere decir que en la mayoría de los casos que se están analizando, los costes reales han superado a los costes planificados.

7.2.1.2.3 Porcentaje de proyectos que cumplen SPI y CPI

En este conjunto de datos analizados, la fracción porcentual de los proyectos que no alcanzaron el umbral del índice SPI ($SPI \geq 1$) es de 60,65% (Ilustración 25). En otras palabras, el 39,35% de los proyectos analizados han finalizado sus actividades dentro de los plazos establecidos.

En cuanto al índice de desempeño de costes (CPI) de este conjunto de proyectos, el 41,48% de los proyectos han cumplido con el presupuesto inicial, mientras que el 58,52% de los casos han presentado gastos superiores a lo previsto.




Ilustración 25: Porcentaje proyectos que cumplen SPI y CPI (New York Projects)

7.2.2 Estudio IV (Capital Projects Dashboard)

Hasta este momento se han realizado tres análisis: los dos primeros centrados en proyectos que han sido gestionados bajo técnicas avanzadas de gestión (como el empleo de *Earned Value Method*, EVM), y un tercero empleando datos de proyectos que no fueron gestionados mediante dichas técnicas avanzadas. Con el objetivo de reforzar esta comparación, se ha realizado un cuarto y último estudio, esta vez empleando un conjunto de datos también de proyectos sin ninguna evidencia de haber sido gestionados con estas metodologías avanzadas de gestión.

7.2.2.1 Recopilación y preparación de datos

Para este último análisis en R-Studio, se ha cogido un dataset titulado *Capital Projects Dashboard- Citywide Budget and Schedule*. Este conjunto de datos fue publicado en una plataforma oficial y de uso público de la Ciudad de Nueva York. [39]

El *Capital Projects Dashboard* recoge información detallada sobre distintos proyectos de infraestructura que han sido gestionadas por agencias públicas neoyorquinas. Esta información se basa tanto en datos financieros como en datos de planificación y seguimientos de los cronogramas de cada proyecto. Al igual que se ha realizado con el resto de datasets, en este análisis también se va a emplear la herramienta de R-Studio para el cálculo y visualización de indicadores CPI (*Cost Performance Index*) y SPI (*Schedule Performance Index*); permitiendo identificar posibles tendencias, patrones y desviaciones de estos proyectos.

7.2.2.1.1 Carga y adecuación de datos

Como en el resto de los análisis anteriores, lo primero que se ha realizado ha sido la carga e instalación de paquetes de R-Studio que van a ser necesarios para el posterior cálculo y visualización de datos. Asimismo, se ha cargado el conjunto de datos que va a ser analizando (Tabla 32).

Tabla 32: Carga de paquetes y datos (R-Studio) IV

```
#Carga de paquetes
install.packages("tidyverse") # Incluye dplyr, ggplot2, readr...
install.packages("janitor")  # Para limpiar nombres de columnas
library(tidyverse)
library(janitor)

# Cargar archivo CSV
df4 <- read_csv(file.choose()) # Te abrirá un explorador para elegir el archivo
```

El siguiente paso ha sido adecuar la tabla de datos para facilitar el análisis, ya que, en este caso, el dataset original posee varios nombres de las columnas con espacios, mayúsculas u otros caracteres que podrían dificultar el análisis en R-Studio. Por esta razón, se ha empleado una función de R que permite limpiar automáticamente los títulos de las variables, dándoles un formato más simple y uniforme. Después, se han

visualizado los nombres de las columnas para comprobar que los nombres de las variables han sido correctamente transformados, y conocer estos títulos para emplearlos en los siguientes códigos para llamar a distintas variables (Tabla 33).

Tabla 33: Adecuación de nombres de las variables y visualización (R-Studio) IV

```

# Limpiar nombres de columnas (por si tienen espacios o mayúsculas)
df4 <- clean_names(df4)

# Verificar columnas disponibles
names(df4)
  
```

Es la siguiente imagen (Ilustración 26) se pueden observar los nombres de las distintas variables con las que se va a trabajar.

```

> names(df4)
 [1] "reporting_period"      "managing_agency"
 [3] "sponsor_agency"       "pid"
 [5] "fms_id"                "total_budget"
 [7] "spend_to_date"         "spend_to_date_percent"
 [9] "fms_project_name"     "agency_project_name"
[11] "agency_project_description" "current_phase"
[13] "current_phase_start"   "forecast_current_phase_end"
[15] "forecast_completion"   "actual_design_start"
[17] "actual_design_end"     "actual_construction_procurement_start"
[19] "actual_construction_procurement_end" "actual_construction_start"
[21] "actual_construction_end" "borough"
[23] "community_board"       "budget_line"
[25] "ten_year_plan_category" "agency_data_date"
[27] "fms_data_date"
  
```

Ilustración 26: Visualización nombres de las variables del dataset (R-Studio) IV

El siguiente paso ha sido seleccionar sólo aquellas variables que resultan relevantes para el análisis, por ejemplo: las fechas de inicio y finalización de los proyectos, y el presupuesto inicial y el coste real. Asimismo, se ha aplicado un filtro para descartar del conjunto de datos aquellos proyectos que no disponen de información necesaria para el estudio.

Por último, en cuanto a la adecuación de los datos, se han transformado las variables a su formato adecuado, lo cual es imprescindible para que el programa realice correctamente los cálculos de los distintos parámetros (Tabla 34).

Tabla 34: Selección y definición adecuada del formato de los datos (R-Studio) IV

```

# Selección y renombrado de columnas útiles (ajusta si es necesario)
df4_proyectos <- df4 %>%
  select(
    project_id = pid,
    project_title = agency_project_name, # O usa fms_project_name si prefieres
    managing_agency = managing_agency,
  
```

```

planned_start_date = current_phase_start,
planned_end_date = forecast_completion,
actual_start_date = actual_construction_start,
actual_end_date = actual_construction_end,
budget_total = total_budget,
total_project_spent = spend_to_date
) %>%
filter(!is.na(budget_total), !is.na(total_project_spent))

# Asegurarse de que las fechas sean tipo Date
df4_proyectos <- df4_proyectos %>%
mutate(
  planned_start_date = as.Date(planned_start_date, format = "%m/%d/%Y"),
  planned_end_date = as.Date(planned_end_date, format = "%m/%d/%Y"),
  actual_start_date = as.Date(actual_start_date, format = "%m/%d/%Y"),
  actual_end_date = as.Date(actual_end_date, format = "%m/%d/%Y")
) %>%
mutate(
  planned_duration = as.numeric(planned_end_date - planned_start_date),
  actual_duration = as.numeric(actual_end_date - actual_start_date)
) %>%
mutate(
  total_project_spent = as.numeric(total_project_spent),
  budget_total = as.numeric(budget_total))

```

7.2.2.2 Cálculo de valores de Valor Ganado

Una vez que los datos han sido debidamente preparados, se han calculado los índices de desempeño que miden el rendimiento de los proyectos en cuanto a costes y plazos (CPI y SPI). Como se ha mencionado anteriormente, el CPI (*Cost Performance Index*) se obtiene dividiendo el gasto total de proyecto entre su presupuesto inicial, permitiendo conocer si el coste real es mayor o menor que el presupuesto. En lo que respecta al SPI (*Schedule Performance Index*), se calcula dividiendo la duración real del proyecto entre la duración planificado. Este último índice, permite conocer el grado de avance del proyecto respecto al cronograma inicial.

Una vez calculados los valores de estos dos índices para cada proyecto que se está analizando, se ha generado un resumen estadístico permitiendo conocer el estado de manera generalizada de estos proyectos (Tabla 35) (Ilustración 27).

Tabla 35: Cálculo y resumen estadístico de CPI y SPI (R-Studio) IV

```

#Calcular SPI y CPI
df4_proyectos <- df4_proyectos %>%
  mutate(
    cpi = total_project_spent / budget_total,    # Índice de coste
    spi = actual_duration / planned_duration    # Índice de plazo (estimación))

# Ver resumen de CPI y SPI
summary(select(df4_proyectos, cpi, spi))
  
```

cpi		spi	
Min.	:-543.5545	Min.	:0.479
1st Qu.	: 0.0000	1st Qu.	:0.945
Median	: 0.0000	Median	:0.998
Mean	: 0.2179	Mean	:1.109
3rd Qu.	: 0.5737	3rd Qu.	:1.050
Max.	: 3.9842	Max.	:8.261
NA's	:101	NA's	:15026

Ilustración 27: Resumen estadístico CPI y SPI (R-Studio) IV

En este resumen estadístico de CPI y SPI se pueden identificar los siguientes puntos. En cuanto al CPI, tiene un valor mínimo extremadamente bajo (-543,55), lo que se podría interpretar como un posible error a la hora de introducir los datos de un proyecto o valores atípicos. En relación al SPI, este presenta valores más estables en comparación al CPI, aunque se han registrado valores máximos de 8,261; indicando la presencia de posibles valores atípicos.

Observando los resultados obtenidos del resumen estadístico, y con el objetivo de facilitar la comparación de ambos índices y verificar si existe algún valor atípico en el conjunto de datos que podría alterar el análisis, se han generado dos gráficas de cajas (uno para CPI y otro para SPI) (Tabla 36) (Ilustración 28).

Tabla 36: Generación *boxplot* de CPI y SPI (R-Studio) IV

```

# Boxplot comparativo
df4_long <- df4_proyectos %>%
  pivot_longer(cols = c("cpi", "spi"), names_to = "indice", values_to = "valor")

ggplot(df4_long, aes(x = indice, y = valor, fill = indice)) +
  geom_boxplot() +
  labs(title = "Distribución de SPI y CPI",
    x = "Índice de desempeño", y = "Valor del índice") +
  
```

```
scale_fill_manual(values = c("spi" = "skyblue", "cpi" = "salmon")) +
theme_minimal()
```




Ilustración 28: Visualización *boxplot* CPI y SPI (R-Studio) IV

A primera vista, se puede analizar que ambos indicadores poseen unas distribuciones extremadamente desviadas, en particular el índice de CPI. Para el caso del CPI, se puede identificar la presencia de valores atípicos negativos. En el caso del SPI, aunque los valores se encuentran más concentrados, también se muestran algunos casos con valores aislados al resto de datos.

En ambos casos, esta visualización de datos en tipo *boxplot* resulta muy práctico para evidenciar la necesidad de depurar los datos, mediante la eliminación de estos valores atípicos (*outliers*), con el propósito de realizar un análisis más preciso del comportamiento general de los proyectos.

Por esta razón, el siguiente paso ha sido proceder con la eliminación de estos valores atípicos, filtrando primero aquellos casos cuyos valores de CPI y SPI estén dentro de unos valores razonables (entre 0 y 2).

Una vez aplicado el filtro, se ha generado un nuevo resumen estadístico para conocer el estado actual de los proyectos una vez depurados los valores de situaciones atípicas. Esto va a permitir obtener una visión más real del desempeño medio de los proyectos que forman el conjunto de datos. Además, para comprobar que no ha quedado ningún valor que pueda distorsionar los resultados del análisis, se han vuelto a visualizar los dos *boxplot* de los valores de CPI y SPI (Tabla 37) (Ilustración 29).

Tabla 37: Eliminación de *outliers* y nueva visualización *boxplot* de valores CPI y SPI (R-Studio) IV

```
#Eliminar valores atipicos
df_plot_raw <- df4_proyectos %>%
  filter(cpi > 0, cpi < 1.5, spi > 0, spi < 1.5)

#Resumen de los valores CPI y SPI (eliminados los outliers)
summary(select(df_plot_raw, cpi, spi))
```


Eliminar valores atípicos extremos (rango típico: 0 a 5)

```
df_plot <- df4_proyectos %>%
  filter(cpi > 0, cpi < 2, spi > 0, spi < 2) %>%
  select(cpi, spi) %>%
  pivot_longer(cols = everything(), names_to = "indice", values_to = "valor")
```

#Volver a graficar boxplot

```
ggplot(df_plot, aes(x = indice, y = valor, fill = indice)) +
  geom_boxplot() +
  labs(title = "Distribución de SPI y CPI sin valores atípicos extremos",
       x = "Índice de desempeño",
       y = "Valor del índice") +
  scale_fill_manual(values = c("spi" = "skyblue", "cpi" = "salmon")) +
  theme_minimal()
```




Ilustración 29: Visualización *boxplot* de valores CPI y SPI sin *outliers* (R-Studio) IV

En esta segunda visualización de tipo *boxplot* se observa que, respecto a los valores del CPI, hay una mayor variabilidad que en los valores de SPI. La mediana de estos valores (CPI) se encuentra por debajo del 1, lo que implica que una gran parte de los proyectos tiene o ha tenido sobrecostes. El rango intercuartílico también es bastante amplio, lo que representa que hay desviaciones relevantes en el rendimiento de los gastos. Por lo que respecta a SPI, esta posee una distribución más concentrada alrededor de 1, con una mediana también entorno al valor 1. Esto sugiere que generalmente, los proyectos se desarrollan según lo planificado, sin grandes desviaciones.

7.2.2.3 Análisis de datos

7.2.2.3.1 Clasificación de proyectos por desempeño

A continuación, se va a generar una gráfica de dispersión para analizar la relación entre el CPI y SPI para cada proyecto analizado (Tabla 38) (Ilustración 30).

Tabla 38: Gráfica de dispersión entre CPI y SPI (R-Studio) IV

```

# Gráfico de dispersión CPI vs SPI sin valores atípicos
ggplot(df_plot_raw, aes(x = spi, y = cpi, color = cumple_coste)) +
  geom_point(size = 3) +
  geom_vline(xintercept = 1, linetype = "dashed", color = "blue") +
  geom_hline(yintercept = 1, linetype = "dashed", color = "red") +
  labs(
    title = "Clasificación de proyectos según SPI y CPI (sin valores atípicos)",
    x = "SPI (Índice de Plazo)",
    y = "CPI (Índice de Coste)" +
    theme_minimal()
  
```




Ilustración 30: Gráfica de dispersión entre CPI y SPI por proyecto (R-Studio) IV

En la gráfica de dispersión, como en las anteriores ocasiones, cada punto representa un proyecto, y el color de cada punto distingue entre aquellos proyectos que han sido ejecutados dentro del presupuesto (CPI ≥ 1 , en azul) y aquellos que han tenido sobrecostos (CPI < 1 , en rojo).

Esta gráfica de dispersión indica que la mayoría de los proyectos han superado el presupuesto establecido, esto es evidenciado por la alta concentración de puntos rojos situados por debajo de la línea horizontal roja

(CPI=1). Sin embargo, la mayoría de los puntos se encuentra muy cerca de la línea vertical de referencia (SPI=1); indicando que en la mayoría de los casos el plazo inicial sí se ha cumplido o ha estado muy cerca de cumplirse.

Aun así, sólo se observa un punto de color azul, indicando que sólo un proyecto ha sido ejecutado dentro del presupuesto y plazo inicial. Esta visualización representa una tendencia generalizada al sobrecoste, aun cuando los plazos son respetados.

7.2.2.3.2 Histograma de SPI y CPI

Para finalizar, al igual que se ha realizado en el resto de los análisis, se van a generar dos histogramas, uno para el indicador CPI y otro para SPI. El objetivo de estas dos visualizaciones es analizar de una manera visual la distribución que siguen estos dos valores en los proyectos que se están analizando. Además, van a permitir identificar patrones generales de comportamiento (Tabla 39) (Ilustración 31).

Tabla 39: Histograma SPI y CPI (R-Studio) IV

```

# Filtrar valores atípicos antes de clasificar
df_plot_raw <- df4_proyectos %>%
  filter(cpi > 0, cpi < 1.5, spi > 0, spi < 1.5) %>%
  mutate(
    cumple_coste = ifelse(cpi >= 1, "Sí", "No"),
    cumple_plazo = ifelse(spi >= 1, "Sí", "No") )

# Histograma CPI
ggplot(df_plot_raw, aes(x = cpi)) +
  geom_histogram(bins = 30, fill = "salmon", color = "black") +
  geom_vline(xintercept = 1, color = "red") +
  labs(title = "Histograma del CPI", x = "CPI", y = "Cantidad") +
  theme_minimal()

# Histograma SPI
ggplot(df_plot_raw, aes(x = spi)) +
  geom_histogram(bins = 30, fill = "skyblue", color = "black") +
  geom_vline(xintercept = 1, color = "blue") +
  labs(title = "Histograma del SPI", x = "SPI", y = "Cantidad") +
  theme_minimal()
  
```




Ilustración 31: Visualización histograma CPI y SPI (R-Studio) IV

En lo que respecta a la distribución de CPI, se aprecia una distribución de valores con una alta concentración de casos cercanos o encima del valor 1; lo cual representa que estos proyectos han cumplido o han quedado cerca de cumplir el presupuesto. No obstante, un porcentaje muy alto de los proyectos se encuentra por debajo del umbral de referencia ($CPI=1$), indicando que en muchos casos ha habido desviaciones considerables en el presupuesto (sobrecostos). En cuanto a SPI, muchos de los proyectos se encuentran concentrados en el umbral de referencia ($SPI=1$), sugiriendo que una gran parte de los proyectos han sido finalizados dentro del plazo establecido. Sin embargo, en esta gráfica también se pueden identificar varios casos con un SPI inferior a 1 (retrasos en el proyecto).

7.2.2.3.3 Proyectos que cumplen SPI y CPI

Para terminar, en la siguiente imagen (Ilustración 32) se han visualizado los porcentajes de proyectos que cumplen con el SPI y CPI en este último conjunto de datos. En cuanto al SPI, se aprecia que el 53,16% los proyectos tienen un valor de SPI menor a 1, indicando que en estos casos ha habido retrasos en el cronograma. Es decir, el 46,84% de estos proyectos han cumplido con los plazos establecidos inicialmente.

Por otro lado, en el 96,2% de los proyectos se han presentado sobrecostos significativos ($CPI < 1$). Sólo el 3,8% de estos proyectos han alcanzado un valor de CPI mayor o igual a 1, lo que significa que han tenido un control adecuado de los gastos con relación al presupuesto.




Ilustración 32: Porcentaje proyectos que cumplen SPI y CPI (Capital Dashboard)

8. Resultados

En este apartado se va a realizar una comparativa entre los resultados obtenidos de los análisis llevados a cabo en el apartado anterior, sobre el rendimiento de los proyectos en función del método de gestión utilizado (gestión con técnicas avanzadas o sin técnicas avanzadas). A través de esta comparación, se expondrán los resultados obtenidos y las conclusiones alcanzadas. Además, con el objetivo de profundizar en el análisis y validación de la existencia de patrones diferenciadores entre ambos enfoques, se van a implementar técnicas de aprendizaje automático.

8.1 Comparativa entre cuatro conjuntos de proyectos

En este apartado se van a presentar los resultados de la comparativa de los indicadores de rendimiento CPI (*Cost Performance Index*) y SPI (*Schedule Performance Index*), que se han obtenido a través de los cuatro estudios realizado en el apartado anterior. Los primeros dos conjuntos de datos contienen información sobre proyectos que han sido gestionados con técnicas avanzadas de gestión, mientras que los otros dos corresponden a proyectos en los que no se han empleado dichas técnicas.

Esta comparación se realiza con el objetivo de evaluar si la aplicación de metodologías avanzadas de gestión influye de manera positiva al rendimiento del proyecto, centrándose en aspectos clave como el presupuesto y la planificación del proyecto. Mediante el análisis de los valores medios y la desviación estándar de los indicadores CPI y SPI en cada conjunto de datos, se busca verificar si aquellos proyectos que han aplicado técnicas de gestión avanzada (como BIM y EVM) presentan, en términos generales, un rendimiento superior.

8.1.1 Análisis Comparativo de CPI y SPI en Función del Enfoque de Gestión

Esta comparación va a permitir contrastar de manera sencilla, rápida y clara las ventajas potenciales de la gestión avanzada frente a enfoques tradicionales. Para ello, lo primero que se ha realizado ha sido diseñar una tabla donde se resuman los resultados obtenidos de los promedios y variaciones de SPI y CPI para cada conjunto de proyectos (Tabla 40) (Tabla 41).

Tabla 40: Comparación valores estadísticos CPI y SPI de cuatro dataset (R-Studio)

```
# Cargar paquetes necesarios
library(dplyr)
library(tidyr)
library(ggplot2)

# Asignar tipo de gestión a cada dataframe
df1$Tipo <- "BIM"
df2_filtrado$Tipo <- "Valor Ganado"
df3$Tipo <- "Tradicional"
```

```
df_plot_raw$Tipo <- "Proyectos NYC"

# Homogeneizar nombres de columnas SPI y CPI
df1 <- df1 %>% rename(SPI = SPI, CPI = CPI)
df2_filtrado <- df2_filtrado %>% rename(SPI = spi_final, CPI = cpi_final)
df3 <- df3 %>% rename(SPI = SPI, CPI = CPI)
df_plot_raw <- df_plot_raw %>% rename(SPI = spi, CPI = cpi)

# Seleccionar columnas comunes
df1_sel <- df1 %>% select(SPI, CPI, Tipo)
df2_sel <- df2_filtrado %>% select(SPI, CPI, Tipo)
df3_sel <- df3 %>% select(SPI, CPI, Tipo)
df4_sel <- df_plot_raw %>% select(SPI, CPI, Tipo)

# Unir todos los dataframes
df_comparado <- bind_rows(df1_sel, df2_sel, df3_sel, df4_sel)

# Calculos estadísticos descriptivos
resumen_comparativo <- df_comparado %>%
  group_by(Tipo) %>%
  summarise(
    Media_SPI = mean(SPI, na.rm = TRUE),
    SD_SPI = sd(SPI, na.rm = TRUE),
    Media_CPI = mean(CPI, na.rm = TRUE),
    SD_CPI = sd(CPI, na.rm = TRUE))

#Visualización tabla valores estadísticos CPI y SPI
View(resumen_comparativo)
```

Tabla 41: Visualización resumen estadístico CPI y SPI de cuatro *datasets* (R-Studio)

	Tipo	Media_SPI	SD_SPI	Media_CPI	SD_CPI
1	BIM	0.8546725	0.1260175	0.8547713	0.1257615
2	Proyectos NYC	1.0085798	0.2595622	0.6924937	0.3092483
3	Tradicional	0.8869888	0.4072544	0.9244424	0.4002128
4	Valor Ganado	0.9850980	0.1518733	0.9339216	0.1948751

Los resultados muestran que aquellos proyectos que han sido gestionados mediante la metodología de EVM (el *dataset* llamado Valor Ganado) muestran el mejor rendimiento tanto en costes como en plazos. Esto es, contiene un valor medio de CPI de 0,93 y de SPI 0,98, presentando una variabilidad muy baja en ambos indicadores. Estos valores indican una gestión muy eficaz en el control de costes y cumplimiento de plazos.

Los proyectos que no han sido gestionados por ninguna técnica de gestión avanzada muestran un valor medio de CPI de 0,95, algo por debajo al valor de EVM; pero con una variabilidad más alta, sugiriendo una mayor inestabilidad en su rendimiento. El SPI en este mismo conjunto de datos, contiene un valor medio de 0,88, indicando retrasos en la ejecución del cronograma.

En cuanto a los Proyectos de Nueva York, en los que tampoco se han aplicado técnicas de gestión avanzada, presentan un valor medio de SPI ligeramente mayor a 1 (1,0085798). Esto se interpreta como un adelanto en la ejecución del cronograma. No obstante, el valor medio CPI en este conjunto es mucho más bajo (Media CPI = 0,69), indicando deficiencias importantes en el control de costes, además de presentar desviaciones significantes en los resultados (*Standard Deviation* CPI=0,30).

Para finalizar, los proyectos que han sido gestionados con técnicas BIM contienen un rendimiento más equilibrado, con valores medios de 0,85 en CPI y SPI, y una dispersión relativamente baja. Si bien los valores medios no se sitúan entre los más altos, destacan por la estabilidad de los resultados, siendo este aspecto clave en contextos donde la estabilidad de los proyectos es muy valiosa. En resumen, estos datos respaldan la hipótesis de que los proyectos gestionados con técnicas avanzadas como EVM y BIM suelen obtener mejores resultados que aquellos que no las utilizan.

Todo esto que se ha mencionado se puede ver reflejado de manera visual y fácil de interpretar en la siguiente visualización *boxplot* de los valores de rendimiento por conjunto de proyectos (Ilustración 33).




Ilustración 33: Comparación SPI y CPI según tipo de gestión (R-Studio)

8.1.2 Análisis estadístico de diferencias significativas

Para seguir profundizando en el análisis comparativo entre los resultados obtenidos en los proyectos con distintos enfoques, se ha empleado la prueba estadística de "Test-t". Este test va a permitir comprobar si las diferencias entre los valores promedio de los indicadores de rendimiento CPI y SPI de los distintos grupos son estadísticamente significativos, considerando que la variación de datos entre los distintos grupos no es igual (Tabla 42).

Tabla 42: Análisis estadístico de diferencias significativas (R-Studio)

```
# Comparación de SPI entre tipos de gestión
t.test(
  Valor ~ Tipo,
  data = df_comparado %>% filter(Indice == "SPI", Tipo %in% c("BIM", "Valor Ganado")))

# Comparación de CPI entre tipos de gestión
t.test(
  Valor ~ Tipo,
  data = df_comparado %>% filter(Indice == "CPI", Tipo %in% c("BIM", "Valor Ganado")))

# Comparación de SPI para los no avanzados
t.test(
  Valor ~ Tipo,
  data = df_comparado %>% filter(Indice == "SPI", Tipo %in% c("Proyectos NYC", "Tradicional")))

# Comparación de CPI para los no avanzados
t.test(
  Valor ~ Tipo,
  data = df_comparado %>% filter(Indice == "CPI", Tipo %in% c("Proyectos NYC", "Tradicional")))
```

A continuación, se pueden observar los resultados de las comparaciones realizadas por pares de conjuntos de datos. Para esta comparación se ha centrado en los valores medios de CPI y SPI (Tabla 43).

Tabla 43: Resultados del análisis estadístico de diferencias significativas

Comparativa	Media Grupo 1	Media Grupo 2	t	df	p-valor	Intervalo de confianza
SPI: BIM vs Valor	0,8546725	0,985098	-6,028	53,57	1,578e-07	[-0,1738, -0,0870]
CPI: BIM vs Valor	0,8547713	0,9339216	-2,8702	52,145	0,005913	[-0,1345, -0,0238]

SPI: Proyectos NYC vs Tradicional	1,0085798	0,8869888	4,0039	91,197	0,0001268	[0,0613, 0,1819]
CPI: Proyectos NYC vs Tradicional	0,6924937	0,9244424	-6,4892	86,87	5,117e-09	[-0,3030, - 0,1609]

Esta tabla que se ve arriba (Tabla 43), resume los resultados que se han obtenido en el análisis estadístico realizado para comprobar los indicadores de rendimiento entre distintos conjuntos de datos. En todos los casos, el valor de “p-value” es inferior a 0,05; demostrando que las diferencias entre los grupos comparados tienen relevancia estadística.

8.1.3 Conclusiones de la comparativa realizada

Aunque algunos proyectos en los que se han empleado técnicas avanzadas de gestión pueden ocasionalmente presentar buenos resultados en determinados indicadores de rendimiento, lo que realmente destaca a aquellos proyectos gestionados con técnicas avanzadas es la capacidad para mantener un rendimiento estable en lo que respecta a costes y plazos. En esta ocasión, esta robustez en los resultados se ha conseguido gracias a la aplicación de técnicas BIM y EVM.

En los resultados obtenidos a lo largo del presente trabajo se ha observado una alta variabilidad y poca robustez en los resultados de los proyectos que no han sido gestionados con ninguna de estas metodologías predictivas. Esta falta de homogeneidad entre los resultados hace que estos datos obtenidos dependan directamente de factores externos al proyecto y a las decisiones reactivas o improvisadas que se toman a medida que el proyecto avanza.

8.2 Diseño de técnicas predictivas

En este apartado se va a realizar el entrenamiento y diseño de árboles de decisión para cada tipo de gestión empleada en los proyectos analizados. El objetivo del diseño de estos modelos es poder identificar las variables que influyen de manera más significativa a la hora de realizar predicciones de coste y plazo de los proyectos.

Estos árboles de decisión no sólo permiten anticipar el rendimiento futuro de los proyectos, sino que también generan estructuras lógicas y fáciles de interpretar, que permiten conocer bajo qué condiciones o variables un proyecto es más propenso a alcanzar los niveles deseados de eficiencia.

8.2.1 Generación de árboles de decisión

A continuación, se va a proceder a la generación de los árboles de decisión en R-Studio para conocer el comportamiento de los proyectos en relación con el tipo de gestión empleada y su correlación con los indicadores de rendimiento CPI y SPI. Cada modelo se va a entrenar por separado para poder distinguir entre las técnicas de gestión avanzada y la gestión tradicional. Esto se realiza con el fin de identificar las variables más relevantes que influyen en el rendimiento de los proyectos (Tabla 44).

Tabla 44: Entrenamiento y generación de árboles de predicción (R-Studio)

```
# Árbol para SPI - Gestión Avanzada
arbol_spi <- rpart(SPI_Class ~ ., data = df_spi_balanceado, method = "class")
rpart.plot(arbol_spi, main = "Árbol de decisión - SPI (Proyectos Avanzados)")

# Árbol para CPI - Gestión Avanzada
arbol_cpi <- rpart(CPI_Class ~ ., data = df_cpi_balanceado, method = "class")
rpart.plot(arbol_cpi, main = "Árbol de decisión - CPI (Proyectos Avanzados)")

# Árbol para SPI - Gestión Tradicional
arbol_spi2 <- rpart(SPI_Class ~ ., data = df_spi_balanceado2, method = "class")
rpart.plot(arbol_spi2, main = "Árbol de decisión - SPI (Proyectos Tradicionales)")

# Árbol para CPI - Gestión Tradicional
arbol_cpi2 <- rpart(CPI_Class ~ ., data = df_cpi_balanceado2, method = "class")
rpart.plot(arbol_cpi2, main = "Árbol de decisión - CPI (Proyectos Tradicionales)")
```

Es importante mencionar que en este código que se muestra arriba no están todos los pasos que se han realizado con anterioridad a la generación de los árboles, tales como: renombrar columnas para que coincidan los títulos de las columnas de ambos conjuntos de datos, unificar tablas, etc. Todo esto se podrá ver en los anexos de R-Studio.

8.2.1.1 Árbol de decisión para SPI – Gestión Avanzada

ÁRBOLES DE DECISIÓN – SPI (PROYECTOS AVANZADOS)




Ilustración 34: Árbol de decisión - SPI (Proyectos con gestión avanzada)

Este árbol de decisión (Ilustración 34) que se ha entrenado y posteriormente generado, da la oportunidad de clasificar los proyectos que han sido o son gestionados por técnicas avanzadas según su capacidad para cumplir con los tiempos acordados (SPI). En esta estructura de clasificación se han empleado dos parámetros clave: el coste planificado (*Planned Cost*) y la duración planificada (*Planned Duration*).

El primer nodo de clasificación de este árbol se trata del valor del presupuesto planificado de cada proyecto. La mayoría de los proyectos que tienen un presupuesto inferior a 1.100.000€ no suelen cumplir con los plazos establecidos (solo el 3% de los proyectos cumple), esto es, suelen terminar el proyecto con un SPI<1. A través de esta primera clasificación, se podría deducir que los proyectos con un presupuesto bajo son más susceptibles a incumplir los plazos, probablemente por una planificación no muy detallada o falta de recursos.

No obstante, si este presupuesto del proyecto supera los 1.100.000€, el modelo diseñado sugiere analizar cuál es la duración estimada del proyecto para poder predecir el valor de SPI. Se ha visto que si el proyecto

tiene un presupuesto superior a 1.100.000€ y dura, según la planificación acortada, menos de 612 días, todavía hay una alta probabilidad de cumplir con el cronograma inicial. Sin embargo, si la planificación es menor que estos 612 días, la probabilidad de cumplimiento de la planificación cae drásticamente.

Este modelo predictivo también permite conocer distintas casuísticas dentro de determinados umbrales: por un lado, se puede ver que en los casos con un presupuesto de entre 1.100.00€ y 6.100.000€, si la duración es inferior a 331 días, se incrementa la probabilidad de cumplir con el SPI. En cambio, en proyectos con una duración menor a 331 días (con mismo presupuesto), la probabilidad de éxito es menor.

Otro dato interesante que se puede sacar de este árbol de clasificación es que en proyectos con un presupuesto superior a 9.000.000€ las probabilidades de éxito en cuanto al SPI son muy bajas, independientemente de la duración.

En resumen, para que la probabilidad de cumplimiento del cronograma de los proyectos gestionados con técnicas avanzadas sea más alta, es imprescindible que el proyecto dure entre 331 y 612 días, en particular con presupuesto elevados (*Planned Cost* > 1.100.000e). Asimismo, en los casos que el presupuesto supera los 9.000.000€ se debería de realizar un control y seguimiento exhaustivo durante su ejecución, debido a que, con estos valores tan altos de costes, los proyectos se convierten significativamente vulnerables a presentar desviaciones en los plazos.

8.2.1.2 Árbol de decisión para CPI – Gestión Avanzada




Ilustración 35: Árbol de decisión - CPI (Proyectos con gestión avanzada)

Este segundo árbol de decisión (Ilustración 35) se ha diseñado con el fin de clasificar los proyectos con una gestión avanzada según su rendimiento en costes (CPI). En este caso, también se han utilizado las variables del coste planificado (*Planned Cost*) y la duración planificada (*Planned Duration*).

En este segundo caso, el primer nodo de clasificación se basa en el valor del coste planificado del proyecto; si su valor es inferior a 3.300.000€, los proyectos tienden a cumplir con el presupuesto establecido ($CPI > 1$), mientras que los proyectos superiores a este presupuesto tienen una probabilidad considerada de presentar desviaciones en el CPI. Esto es, en los casos que el coste planificado es superior a 3.300.000€, el riesgo de no cumplir el presupuesto es muy alta, donde el riesgo de incumplimiento es más evidente en los casos que este coste es superior a los 29.000.000€, con una probabilidad de incumplimiento del 79%.

También, unas largas duraciones de proyectos hacen que el riesgo de incumplimiento del presupuesto sea menor: por ejemplo, en los casos que la duración supera los 799 días y un coste alto, la probabilidad de cumplimiento del CPI es de 79%. Esto es, este árbol sugiere que unas largas duraciones de los proyectos permiten una mejor planificación de los recursos para poder ajustarse al presupuesto inicial.

En general, este segundo árbol presenta que en los proyectos que son gestionados con técnicas avanzadas de gestión, unos presupuestos elevados son el principal factor de riesgo en el cumplimiento del CPI; y en ciertos casos, el prolongar el plazo de ejecución hace mitigar este riesgo de incumplimiento.

8.2.1.3 Árbol de decisión para SPI – Gestión Tradicional

Árbol de decisión - SPI (Proyectos Tradicionales)




Ilustración 36: Árbol de decisión - SPI (Proyectos sin gestión avanzada)

En este caso (Ilustración 36), se ha generado un árbol de decisión a través del aprendizaje de datos de proyectos que no han sido gestionados con ninguna técnica de gestión avanzada. Este árbol de decisión se basa en predecir el rendimiento de estos proyectos en cuanto a plazos (SPI).

La primera división que hace en este árbol es según la duración planificada del proyecto. Esto es, la primera bifurcación define si la duración planificada es mayor o menor a 175 días; en los casos que este valor sea inferior a dicho umbral, la tendencia suele ser tener retrasos en los plazos establecidos, con una probabilidad del 57% de no alcanzar un SPI igual o mayor a 1. No obstante, en los casos que la duración

estimada sea mayor a 175 días, presentan mejores valores de CPI con una probabilidad del 36% de cumplir el cronograma.

Siguiendo la primera bifurcación con una planificación menor a 175 días, el árbol plantea una segunda división según el valor del coste planificado; en el caso de que este segundo valor es inferior a 16.000€, la probabilidad de cumplir el plazo sigue siendo baja. No obstante, aquellos proyectos con una duración de entre 175 y 268 días, comienzan a presentar mejores resultados en cuanto al cumplimiento del cronograma.

Para terminar, los proyectos con unos presupuestos altos y plazos largos (*Planned Duration* $\geq$ 452 días) tienden a tener mejores resultados del SPI (cumplimiento de plazos), en algunos casos registrando una probabilidad de hasta 86%.

8.2.1.4 Árbol de decisión para CPI – Gestión Tradicional

Árbol de decisión - CPI (Proyectos Tradicionales)




Ilustración 37: Árbol de decisión - CPI (Proyectos sin gestión avanzada)

Este último árbol de decisión (Ilustración 37) se ha realizado para predecir el comportamiento de los costes (CPI) de aquellos proyectos que no han sido gestionados con técnicas avanzadas. En este último caso, la única variable de bifurcación utilizada ha sido la del coste planificado (*Planned Cost*),

El árbol realiza una división clave cuando el coste planificado es aproximado a 178.000€. Los proyectos con un presupuesto inferior a esta cifra tienen una probabilidad del 63% de presentar sobrecostes, mientras que en los casos en que el coste planificado es igual o mayor a 178.000€, tienen un 42% de probabilidad de finalizar el proyecto dentro del presupuesto establecido.

Sin embargo, los proyectos con presupuestos muy bajos, cuando el coste planificado es menor a 1.394€, muestran el mayor riesgo de desviación en el rendimiento de costes (CPI). Asimismo, los proyectos de entre 1.394€ y 178.000€ también tienen una tasa de cumplimiento del presupuesto muy baja; apenas un 1% de los proyectos consigue mantenerse dentro del presupuesto.

En resumen, este árbol muestra que cuanto mayor sea el presupuesto de un proyecto, mayor va a ser la probabilidad de éxito en términos de coste. Sin embargo, los proyectos de un presupuesto bajo o mediano, son los que más tendencia tienen a no cumplir el presupuesto. Esto recalca la relevancia de adaptar los métodos de gestión económica en función de la magnitud del proyecto.

8.2.1.5 Conclusiones de los árboles de decisión

Tabla 45: Resumen resultados árboles de decisión

Variable	Tipo de Gestión	Umbral Clave	% Cumple SPI	% Cumple CPI	Interpretación Clave
Planned_Duration	Tradicional	≥ 175 días	43%	—	Proyectos con plazos largos suelen tener mayor probabilidad de cumplimiento de plazos.
	Avanzada	≥ 331 días	74%	—	Este es el umbral donde aumenta la probabilidad de cumplimiento de plazos.
Planned_Cost	Tradicional	$\geq 178.000\text{€}$	—	42%	Proyectos con presupuestos altos tienden a mejores cumplimientos de CPI.
	Avanzada	$\geq 3,3\text{M€}$	—	64%	Proyectos con costes superiores a 3,3M€ presentan un alto riesgo de incumplimiento de CPI.
Coste + Duración	Tradicional	$\geq 178\text{k€}$ y ≥ 452 días	86%	42%	Alta duración + alto coste, combinación ideal para SPI en tradicional.
	Avanzada	≥ 331 días y $\geq 3,3\text{M€}$	87%	68%	Combinación de umbrales importante, donde aumenta la probabilidad de cumplimiento de SPI y CPI si el proyecto es gestionado adecuadamente.

A través de los resultados obtenidos en los árboles de decisión generados, se han identificado puntos críticos de coste y duración que mejor permiten diferenciar los niveles de cumplimiento de los indicadores CPI y SPI. En esta tabla (Tabla 45) además de poder observar estos umbrales críticos, también se muestran los porcentajes de proyectos que han cumplido con un rendimiento aceptable el indicador analizado.

Estos resultados muestran variaciones significativas entre los dos modelos de gestión aplicados a los proyectos analizados. En primera instancia, se observa que en cuanto a la variable *Planned Duration*, aquellos proyectos que no han sido gestionados con ninguna metodología en particular requieren de menores duraciones (≥ 175 días) para alcanzar un valor de SPI adecuado (43%). Sin embargo, en los

proyectos gestionados bajo metodologías de gestión avanzada se logran valores considerables de SPI (SPI = 74%) cuando los plazos de los proyectos superan los 331 días.

En lo que respecta a la variable *Planned Cost*, estos resultados indican que en los proyectos que no se ha empleado ninguna gestión avanzada, en términos generales, los que tiene un presupuesto elevado (*Planned Cost* $\geq$ 178.000 €) suelen obtener mejores valores de rendimiento en cuanto a los costes (42% de cumplimiento del CPI).

Asimismo, en los proyectos con una gestión avanzada se aprecian mejores resultados con proyectos de mayor presupuesto (*Planned Cost* $\geq$ 3,3M€), alcanzando un 64% de los casos que consiguen alcanzar el umbral de CPI (CPI $\geq$ 1). Estos resultados recalcan el planteamiento de que las metodologías avanzadas de gestión favorecen una gestión más eficiente de los recursos, particularmente en los casos con presupuestos elevados y duraciones significativamente largas.

8.2.2 Análisis de Importancia de Variables mediante Random Forest

Para poder entender y conocer los factores o variables que más impacto tienen en el cumplimiento de los indicadores de rendimiento SPI y CPI de los proyectos, se ha realizado un análisis basado en el algoritmo de *Random Forest*. Esta técnica forma parte del conjunto de técnicas de *Machine Learning* (ML). El *Random Forest* es una técnica muy conocida en la rama de la estadística que permite realizar estudios de clasificación y de regresión, además de evaluar la relevancia de cada variable sobre el resultado que se busca. [40]

En este contexto, para el presente trabajo, se ha empleado esta técnica con el objetivo de analizar las variables que más influyen en los resultados de SPI y CPI.

8.2.2.1 Resultados del Análisis Random Forest – SPI (Proyectos Avanzados)

Para los resultados obtenidos del indicador de SPI en proyectos gestionados con técnicas avanzadas, se ha empleado la técnica de *Random Forest* con variables del coste planificado (*Planned Cost*) y duración planificada (*Planned Duration*). El objetivo es identificar cuál de estas dos variables tiene mayor impacto en el cumplimiento de los plazos.

Importancia de Variables - SPI (Proyectos Avanzados)




Ilustración 38: Importancia variables - SPI (Proyectos con Gestión Avanzada)

Los resultados obtenidos (Ilustración 38) muestran que ambas variables analizadas son significativas para el modelo, aunque el coste planificado tiene una influencia ligeramente mayor. Por lo tanto, dentro de este modelo de *Random Forest*, la variable del coste planificado es el parámetro más determinante para predecir el cumplimiento del indicador SPI en proyectos con gestión avanzada. Esto puede ser debido a que generalmente, los proyectos con presupuestos elevados suelen tender a mejores planificaciones.

8.2.2.2 Resultados del Análisis Random Forest – CPI (Proyectos Avanzados)

Este segundo modelo muestra que para el caso del CPI en proyectos con una gestión avanzadas, ambas variables analizadas (Coste Planificado y Duración Planificada) son relevantes. No obstante, como ha ocurrido en el análisis anterior, la variable del coste planificado es más determinante que la variable de la duración planificada (Ilustración 39).

Importancia de Variables – CPI (Proyectos Avanzados)




Ilustración 39: Importancia variables - CPI (Proyectos con Gestión Avanzada)

Esto confirma que el presupuesto de un proyecto refleja adecuadamente el tamaño o la complejidad de este, influyendo directamente en la probabilidad de cumplir con el CPI. Además, esto podría entenderse como que los proyectos con un coste planificado elevado suelen disponer de unos márgenes que facilitan el cumplimiento del presupuesto.

8.2.2.3 Resultados del Análisis Random Forest – SPI (Proyectos Tradicionales)

Al igual que se ha realizado para los proyectos con una gestión avanzada, se ha realizado un modelo para analizar las variables que más influyen en el cumplimiento del SPI. Para este caso, también la variable del coste planificado es el más relevante en los resultados del SPI (Ilustración 40).




Ilustración 40: Importancia variables - SPI (Proyectos sin Gestión Avanzada)

8.2.2.4 Resultados del Análisis Random Forest - CPI (Proyectos Tradicioanles)

Para finalizar, se ha procedido a generar el mismo modelo para CPI en proyectos que no han sido gestionados con técnicas avanzadas de gestión. En este caso también, la variable del coste planificado tiene la mayor importancia respecto al cumplimiento de los costes (Ilustración 41).




Ilustración 41: Importancia variables - CPI (Proyectos sin Gestión Avanzada)

En conclusión, en los cuatro modelos generados de *Random Forest* se ha podido observar que la variable del coste planificado emerge de manera clara como el parámetro que mayor influencia tiene en el cumplimiento del CPI y SPI, independientemente de si los proyectos han sido gestionados con técnicas avanzadas o no. Con este resultado, se puede detectar que el presupuesto de un proyecto no sólo refleja los recursos disponibles para dicho caso, sino que actúa como reflejo del tamaño, complejidad y exigencia de la actividad a realizar.

Por lo tanto, estos modelos pueden actuar como *inputs* valiosos para la toma de decisiones tempranas de los proyectos: definir presupuestos realistas, adecuar la planificación y, asignar y enfocar adecuadamente los recursos.

8.2.3 Interpretación y Discusión de los Resultados

Como se ha mencionado anteriormente, estos resultados contribuyen a identificar distintas tendencias en los resultados de desempeño de los proyectos en función del tipo de gestión empleada. Los proyectos que han empleado técnicas avanzadas de gestión muestran comportamientos más estables en los resultados de los indicadores de rendimiento de plazo y coste (SPI y CPI). Sin embargo, los proyectos que no han sido gestionados con estas técnicas avanzadas de gestión tienden a presentar una mayor dispersión en estas métricas de rendimiento, dando a entender una mayor incertidumbre tanto en el cumplimiento de costes como en el de plazos.

Este comportamiento de los valores SPI y CPI en los proyectos con técnicas avanzadas que se ha podido observar en el análisis del presente trabajo, se alinea conforme a un estudio realizado por D. Bryde, M. Broquetas y J. Volm en el año 2013 [41], donde se presenta que la implementación de la herramienta BIM favorece la estabilidad de costes y plazos de los proyectos, a pesar de que no asegura necesariamente mejores resultados en todos los proyectos. Igualmente, la relevancia de las variables *Planned Cost* y *Planned Duration* que se ha observado en los árboles de decisión generados, es coherente con los descubrimientos de C. Benitez-Ávila, A. Hartmann, G. Dewulf y J. Henseler en el año 2018 [42], que identificaron estos dos parámetros como determinantes en el desempeño de los proyectos predictivos.

Otro estudio realizado por E. Kim, W. Wells y M. Duffey en 2013 [43], expone la importancia de definir de manera precisa y clara los costes y plazos del proyecto desde una fase temprana del proyecto para minimizar posibles variaciones durante su ejecución. En el caso de este trabajo, este planteamiento también se ha corroborado mediante los árboles de decisión que se han desarrollado, en los cuales se ve claro que el coste y la duración planificada de un proyecto actúan como umbrales clave que marcan probabilidades notablemente distintas para cumplir con los valores deseados de SPI y CPI.

Otra tendencia interesante que se puede observar en este estudio es el comportamiento de los resultados de los proyectos gestionados por el gobierno de Nueva York, donde presentan un SPI medio superior al umbral de 1, pero un CPI medio significativamente bajo (CPI = 0,69). Según el estudio realizado por B. Hwang, X. Zhao y L. Toh en el año 2019 [44], en grandes ciudades y en entornos con marcos normativos rigurosos, los gestores de proyectos suelen dar prioridad al cumplimiento del plazo sacrificando el coste, con el objetivo de evitar penalizaciones derivadas del contrato. Esta tendencia generalizada podría explicar las desviaciones detectadas en el CPI de estos proyectos.

Estas comparaciones entre los resultados obtenidos en el TFM y la literatura académica ayudan a comprender que, aunque los datos analizados en este trabajo no muestran valores significativamente favorables en los indicadores de rendimiento de los proyectos gestionados con técnicas avanzadas, sí reflejan que la adopción de estos modelos en la gestión de proyectos supone un avance hacia proyectos más controlados y predecibles.

9. Diagrama Gantt del TFM

Para la realización de este trabajo, se ha diseñado la siguiente planificación (Ilustración 42) donde se han incluido todos los apartados que se consideran necesarios para conseguir el alcance de este TFM.

Para el diseño de este cronograma, se ha definido una secuencia lógica de ejecución de las tareas, teniendo en cuenta la complejidad estimada de cada apartado. Esta secuencia de tareas actúa como guía para la ejecución lógica del trabajo.




Ilustración 42: Planificación del TFM

En esta planificación se han definido en color morado las fechas definidas durante la planificación inicial y en color naranja las fechas reales en las que se ha llevado a cabo cada tarea.

10. Descargos de gastos del TFM

En este apartado se realizará una valoración y estimación de los recursos económicos que van a ser necesarios para la realización del presente Trabajo Fin de Máster. Para el desarrollo de este trabajo va a ser fundamental valor los costes indirectos, como son el tiempo dedicado al análisis y estudio, y la inversión de los medios utilizados para poder desarrollar el trabajo.

10.1 Costes asociados al tiempo dedicado al trabajo

El principal coste indirecto atribuible a este trabajo es el coste relacionado con el tiempo dedicado por el autor al desarrollo. Para la valoración de este coste indirecto, se ha cogido como referencia el coste medio real por hora de un puesto en una empresa de ingeniería que se dedica a la gestión de proyectos.

- **Coste por hora:** 31€/hora
- **Total horas dedicadas:** 300 horas
- **Coste total:** 31€/hora x 300 horas = **9.300€**

Este presupuesto se basa en una estimación conservadora de todas las horas dedicadas al proyecto, incluyendo el análisis, estudio de datos, redacción, revisiones y correcciones del documento.

10.2 Costes de recursos materiales

A pesar de que para el desarrollo del trabajo no se han obtenido herramientas o recursos específicos, sí se ha hecho uso de otros recursos ya existentes, pero que son relevantes valorar en el presupuesto del trabajo.

1. Ordenador personal

Para poder desarrollar y documentar el trabajo, ha sido esencial disponer de un ordenador propio. Considerando que se trata de un portátil con un coste estimado de unos 1.200€, con una vida útil de 4 años, y que se ha empleado para el desarrollo del TFM un 40% durante un año, el coste de este recurso sería:

- **Amortización anual:** 1.200€ / 4 años = 300€
- **Coste imputable al TFM:** 300€ x 0,40 = **120€**

2. Aplicación de Microsoft Word

Aunque no se ha adquirido expresamente para la realización de este trabajo una licencia de Microsoft Word, ha sido la herramienta principal para la redacción del documento. Para poder estimar el coste del uso de esta aplicación, se ha tomado como referencia el coste anual de una licencia de Microsoft 365.

- **Precio de una licencia:** 70€/año
- **Coste imputable al TFM:** 70€/año x 0,40 = **28€**

3. Aplicación de R-Studio

Para el análisis estadístico del trabajo se ha empleado la aplicación de R-Studio, pero como se trata de una aplicación gratuita, no se va a imputar ningún coste al TFM respecto a este recurso.

4. Material de oficina

Otro coste imputable al TFM son los costes del material de oficina utilizados durante momentos puntuales del proyecto, tales como: bolígrafos, papel, post-it, etc.

- **Coste imputable al TFM: 20€**

10.3 Costes indirectos

Para finalizar, también hay que tener en cuenta los costes indirectos asociados a los servicios y recursos generales que, aunque no han sido pagados directamente, han sido otro de los aspectos relevantes a la hora de realizar el TFM.

- **Coste de electricidad e internet al mes: 10€/mes**
- **Coste imputable al TFM: 10€/mes x 6 meses = 60€**

10.4 Resumen del presupuesto

Teniendo en cuenta todos los costes detallados anteriormente, en la siguiente tabla se resumen todos los costes imputables al TFM (Tabla 46).

Tabla 46: Presupuesto del TFM

RECURSOS	COSTE IMPUTABLE AL TFM
Tiempo de dedicación	9.300€
Ordenador personal	120€
Aplicación de Microsoft Word	28€
Aplicación de R-Studio	-
Material de oficina	20€
Electricidad e internet	60€
Presupuesto estimado	9.528€

La estimación del presupuesto de este trabajo alcanza los 9.528€, donde el principal coste del proyecto proviene de las horas dedicadas al desarrollo, análisis y redacción del trabajo. Esta valoración del presupuesto destaca la importancia de valorar y considerar adecuadamente el esfuerzo personal que se le ha dedicado al TFM por parte del autor.

11. Conclusiones

En el presente Trabajo Fin de Máster se ha realizado un análisis exhaustivo de las métricas clave de rendimiento de costes y plazos de los proyectos: *Schedule Performance Index* (SPI) y *Cost Performance Index* (CPI). El objetivo principal, que ha marcado la dirección del trabajo desde el inicio, ha sido comprender y evaluar el impacto que tienen las técnicas avanzadas de gestión en los resultados de distintos proyectos.

Sorprendentemente, los resultados obtenidos en este trabajo muestran que los proyectos que han sido gestionados con técnicas avanzadas como BIM, AI y Valor Ganado poseen valores promedios de SPI y CPI cercanos o inferiores a los valores medios de aquellos proyectos que no han sido gestionados con ninguna de estas técnicas avanzadas. No obstante, este aparente mejor resultado de los indicadores está asociado a una desviación estándar significativamente más alta en el caso de los proyectos sin una gestión avanzada. Esto es, si bien este segundo grupo de proyectos presenta mayores valores promedio de SPI y CPI, sus resultados muestran una variabilidad mayor: abarcando desde casos de éxito sorprendentes hasta casos con fracasos importantes. En cambio, los proyectos con técnicas avanzadas muestran una mayor consistencia en sus resultados (menor variabilidad en SPI y CPI).

Generalmente, una desviación estándar alta es un indicador claro de mayor volatilidad y riesgo, y una desviación estándar baja de más consistencia y mayor estabilidad en el desempeño. [45] En lo que respecta a la gestión de riesgos, como se ha mencionado, una dispersión alta de SPI y CPI sugiere una incertidumbre más alta en lo que concierne a los resultados. Sin embargo, una dispersión baja implica mayor consistencia y capacidad de diseñar una planificación más acertada.

Es decir, aunque a primera vista puede dar la impresión de que los resultados del análisis contradicen el objetivo del presente TFM, es imprescindible analizar estos resultados minuciosamente y entender el contexto en el que se presentan antes de llegar a ninguna conclusión. Un rendimiento óptimo en la gestión de proyectos no sólo se demuestra con valores altos de los indicadores de rendimiento CPI y SPI; sino que, además, tiene que compartir valores mínimos de desviación estándar.

Otro factor clave a la hora de sacar conclusiones de estos resultados, es comprender y tener claro el objetivo de las técnicas avanzadas de gestión. Esto es, las técnicas ágiles priorizan la creación del valor ganado y la satisfacción del cliente antes que el cumplimiento estricto del presupuesto y cronograma. Asimismo, en estas metodologías el equipo de trabajo tiende al óptimo empleo del tiempo y costes para agregar valor añadido a las tareas. Esto es, a medida que el proyecto avanza, muchas veces se van incorporando cambios y trabajos complementarios al alcance inicial del proyecto, lo que crea variaciones en el presupuesto y plazos establecidos al inicio, y los que se emplean en el cálculo del CPI y SPI. Esto puede llevar a que el proyecto termine haciendo uso de la totalidad del presupuesto y plazos establecidos al inicio, pero creando mayor valor ganado y satisfacción del cliente; lo que implica valores de CPI y SPI más aproximados al 1, en lugar de obtener valores más altos. Por lo tanto, en proyectos con una gestión tradicional se han podido obtener valores superiores al 1 en los indicadores de CPI y SPI, ya que no se ha empleado o consumido todo lo planificado, mientras que en los proyectos con una gestión avanzada se han aprovechado al máximo los recursos asignados.

En resumen, las metodologías avanzadas de gestión no siempre implican terminar un proyecto con menores costes y antes de lo planificado. Sin embargo, sí favorecen el control del proyecto en cuanto a costes y plazos, además de ayudar en la predicción y detección de posibles imprevistos y riesgos en las fases tempranas del proyecto. [46] Esto es reflejado en los resultados obtenidos, donde se reflejan menores desviaciones estándar, probablemente porque las técnicas avanzadas han permitido identificar y gestionar problemas a tiempo, evitando desviaciones significantes en los resultados.

Estos son los factores que se han identificado y que generan diferencias significativas en los resultados de los proyectos de gestión avanzada, frente a los proyectos que no emplean estas técnicas:

1. La eficiencia de las técnicas avanzadas se refleja según el valor añadido por unidad de coste/tiempo.
2. Los valores de CPI y SPI en los proyectos con una gestión avanzada no destacan en comparación a los proyectos que no emplean estas metodologías, debido a que el objetivo de estas técnicas no es ahorrar el presupuesto o terminar el proyecto antes de lo planificado, sino usar estos recursos disponibles de manera eficiente para optimizar el alcance y la calidad.
3. A medida que avanza la ejecución de los proyectos avanzados, se van redefiniendo y alineando nuevos objetivos en vez de simplemente finalizar el proyecto más barato o antes de lo previsto (ajuste dinámico de las contingencias de los proyectos).
4. Aunque el promedio de los indicadores CPI y SPI de los proyectos con técnicas avanzadas no sea 1 o mayor que este, han obtenido menores variaciones representando una mejor gestión de las contingencias.
5. En lugar de desarrollar proyectos “record” en lo que respecta a costes y plazos, las técnicas avanzadas crean proyectos más controlados y estables evitando desviaciones significativas en los objetivos iniciales del proyecto.

Por tanto, el presente trabajo demuestra que el empleo de las técnicas avanzadas de gestión no sólo permite ayudar a obtener buenos resultados en los indicadores de rendimiento de costes y plazos (CPI y SPI), sino que también favorecen la variabilidad de los resultados; factor clave para aquellas organizaciones que tienen que lidiar con entornos muy volátiles e inciertos.

12. Líneas futuras

Los resultados del presente Trabajo Fin de Máster enfatizan la relevancia de la gestión avanzada con el objetivo de optimizar el cumplimiento de los plazos y presupuesto de los proyectos, demostrando que la implementación de técnicas como el Valor Ganado o BIM ayudan a tener un mayor control sobre los indicadores de rendimiento SPI y CPI. Sin embargo, esta rama de investigación y los resultados obtenidos en este trabajo abren un abanico de futuras posibles investigaciones para reforzar el análisis y la predicción del rendimiento de los proyectos, principalmente analizando el potencial de la aplicación de la Inteligencia Artificial (IA).

Una propuesta potencial sería continuar con la depuración e investigación de los datos estudiados durante el trabajo. Mientras que los árboles de decisión y el modelo de *Random Forest* permiten identificar patrones ocultos en grandes conjuntos de datos, las redes neuronales profundas (*Deep Learning*) posibilitan una mayor precisión en la anticipación de las desviaciones. De acuerdo con un estudio titulado “*Application of Artificial Intelligence in Project Management*”, escrito por F. Shoushtari, A. Daghighi y E. Ghafourian en el año 2024 [47], los modelos basados en la inteligencia artificial proporcionan resultados más favorables que las técnicas estadísticas comunes a la hora de predecir posibles riesgos.

Otra posible vía de investigación es analizar la posibilidad de automatizar el cálculo y análisis de los indicadores de rendimiento (CPI y SPI) en tiempo real, empleando sistemas de Inteligencia Artificial (IA). A través de este planteamiento, se podrían crear simulaciones o Digital Twins para la gestión de los proyectos en tiempo real. Como se menciona en el artículo “*Techonologies for digital twin applications in construction*” escrito por V. Tuhaise, J. Tah y F. Abanda en el año 2023 [48], ya se están desarrollando este tipo de modelos que permiten simular distintos escenarios de un mismo proyecto, y de esta manera, poder tomar decisiones anticipadas que minimicen el impacto negativo en los costes y plazos.

Respecto a la evolución de las organizaciones en esta rama de la gestión, es muy probable que, a corto plazo, las empresas empiecen a integrar en sus procesos modelos inteligentes que ayuden a la gestión de los proyectos. Esto es, se espera que en los próximos cinco años las organizaciones se orienten hacia metodologías de Project Management 5.0, donde los equipos humanos trabajan estrechamente con algoritmos de inteligencia artificial para detectar, analizar y mitigar los posibles riesgos de manera más fácil y rápida. Este nuevo paradigma de la gestión se detalla en el artículo escrito por el *Project Management Institute (PMI)* titulado “*AI Innovators: Cracking the Code on Project Performance*” [49]. Esta publicación menciona que el rol de los gestores de proyecto va a cambiar con la integración de la IA en las organizaciones: estos dejarán de enfocar su trabajo a tareas de control manual para centrarse en la toma de decisiones estratégicas apoyada en el análisis e inteligencia de datos.

En resumen, la adopción gradual de la inteligencia artificial en la gestión de proyectos representa el camino más relevante y notorio que adoptarán tanto los trabajos de investigación como las instituciones durante los próximos años.

13. Valoración personal

Todo este trabajo de investigación ha sido de gran ayuda para comprender la importancia que tienen el análisis de datos, las técnicas de gestión avanzada y la inteligencia artificial para una adecuada gestión de los proyectos. Sin duda, el análisis de datos es una herramienta que abre muchas posibilidades para los distintos sectores y ámbitos de trabajo. Estas técnicas, permiten el análisis de grandes cantidades de datos que difícilmente se podría realizar de otra forma y que supone un enorme avance.

Asimismo, resulta muy interesante cómo estas herramientas identifican tendencias y patrones ocultos, además permiten comprender los comportamientos analizando los datos históricos, y prever comportamientos futuros. Sin duda, si estas herramientas son utilizadas de forma adecuada, ofrecen grandes posibilidades de innovación y competitividad, factores clave para optimizar procesos y gestionar los riesgos que puedan existir.

Otra de las ventajas del análisis de datos y de la gestión avanzada es que son herramientas transversales y flexibles, porque se pueden adaptar a cualquier ámbito y circunstancia. Prueba de ello, es el gran desarrollo que han tenido estas disciplinas y la aplicación en todos los campos. De hecho, la formación en esta disciplina está adquiriendo una gran importancia y cada vez son más las organizaciones que necesitan comprender su propia actividad a través de este análisis de datos. A medida que la cantidad de datos que las empresas generan van creciendo, surge por lo tanto la necesidad de recurrir a analíticas más avanzadas.

También, otro de los elementos en los que se ha centrado este trabajo ha sido la valoración del impacto que tienen las técnicas de gestión avanzada en los resultados de rendimiento de costes y plazos de los proyectos. Respecto a este tema, son interesantes los resultados analizados que permiten mostrar que estas metodologías contribuyen a un mayor control de los posibles riesgos y cambios en el entorno.

En definitiva, este es un campo en constante evolución y siempre ofrece nuevas oportunidades. Por todas estas razones, resulta de gran interés y fundamental utilizar estas técnicas de análisis porque suponen una ventaja competitiva y un valor añadido.

14. Bibliografía

- [1] FasterCapital, 'Desviacion de costos analisis de tendencias de desviacion de costos estudios de casos'. [Online]. Available: https://fastercapital.com/es/contenido/Desviacion-de-costos--analisis-de-tendencias-de-desviacion-de-costos--estudios-de-casos.html?utm_source=chatgpt.com
- [2] F. Barbosa *et al.*, 'Reinventing Construction: a Route To Higher Productivity', *McKinsey Global Institute.*, no. February, p. 158, 2017, [Online]. Available: https://www.mckinsey.com/~media/mckinsey/business_functions/operations/our_insights/reinventing_construction_through_a_productivity_revolution/mgi-reinventing-construction-a-route-to-higher-productivity-full-report.pdf
- [3] F. Record, T. Standish, and G. International, 'The Standish Group International , Inc . All Rights Reserved', *Group (New York)*, 1995.
- [4] F. Barbosa *et al.*, 'Reinventing Construction: a Route To Higher Productivity', *McKinsey Global Institute.*, no. February, p. 158, 2017, [Online]. Available: https://www.mckinsey.com/~media/mckinsey/business_functions/operations/our_insights/reinventing_construction_through_a_productivity_revolution/mgi-reinventing-construction-a-route-to-higher-productivity-full-report.pdf
- [5] Project Management Institute, 'Beyond Agility', *Pulse of the Profession*, pp. 1–22, 2021, [Online]. Available: https://www.pmi.org/-/media/pmi/documents/public/pdf/learning/thought-leadership/pulse/pmi_pulse_2021.pdf?v=b5c9abc1-e9ff-4ac5-bb0d-010ea8f664da&sc_lang=temp=en
- [6] R. Obasa, 'Research Task', vol. 1, no. 2, 2016.
- [7] R. Adolph, '済無No Title No Title No Title', no. September, pp. 1–23, 2016.
- [8] Asiva Noor Rachmayani, *No 主観的健康感を中心とした在宅高齢者における 健康関連指標に関する共分散構造分析Title*. 2015.
- [9] Project Management Institute, *PMBOK® Guide Sixth Edition (PMI, 2017)*, vol. 6. 2017. [Online]. Available: <http://www.citeulike.org/group/14887/article/9008974>
- [10] *Earned value*, vol. 3. 2012. doi: 10.4324/9780203741764-2.
- [11] R. B. Babu, M. Anand, and M. R. Kumar, 'Predictive Analytics in Project Management for Outcome Prediction and Resource Optimization', *African Journal of Biological Sciences (South Africa)*, vol. 6, pp. 1370–1390, 2024, doi: 10.33472/AFJBS.6.Si2.2024.1381-1390.
- [12] A. T. Foster, 'Artificial Intelligence in Project Management.', *Cost Engineering (Morgantown, West Virginia)*, vol. 30, no. 6, pp. 21–24, 1988, doi: 10.33516/maj.v54i3.34-37p.

- [13] I. A. Hashimzai and M. Q. Mohammadi, 'The Integration of Artificial Intelligence in Project Management: A Systematic Literature Review of Emerging Trends and Challenges', vol. 5, no. 2, 2024.
- [14] G. K. Uyanik and N. Güler, 'A Study on Multiple Linear Regression Analysis', *Procedia Soc Behav Sci*, vol. 106, pp. 234–240, 2013, doi: 10.1016/j.sbspro.2013.12.027.
- [15] J. Zupan, 'Introduction to Artificial Neural Network (ANN) Methods : What They Are and How to Use Them *.', no. September, pp. 327–352, 1994.
- [16] P. Durbin, B. Uzzell, and E. Monteleone, 'Artificial Intelligence Applied To Project Management.', 1986.
- [17] B. Drabble, 'Artificial intelligence for project planning', *IEE Colloquium (Digest)*, no. 183, 1995, doi: 10.1049/ic:19951125.
- [18] M. Kumar and Bhawna, 'Introduction to Machine Learning', *Studies in Computational Intelligence*, vol. 1169, pp. 51–94, 2024, doi: 10.1007/978-981-97-5624-7_2.
- [19] G. Sassano, 'The holistic view in forecasting: A conceptual framework to analyze and mitigate cost underestimation arising from optimism bias', *Project Leadership and Society*, vol. 6, no. January, p. 100177, 2025, doi: 10.1016/j.plas.2025.100177.
- [20] I. Porvarðardóttir, 'How can project managers mitigate their cognitive biases?: cognitive biases in decision-making', *Skemman.Is*, 2020, [Online]. Available: https://skemman.is/bitstream/1946/36384/1/Cognitive_biasis_in_decision-making.pdf
- [21] C. S. Dunkel, J. Nedelec, and D. van der Linden, 'Reevaluating the Dunning-Kruger effect: A response to and replication of Gignac and Zajenkowski (2020)', *Intelligence*, vol. 96, no. Cc, 2023, doi: 10.1016/j.intell.2022.101717.
- [22] L. Budach *et al.*, 'The Effects of Data Quality on Machine Learning Performance', 2022, [Online]. Available: <http://arxiv.org/abs/2207.14529>
- [23] R. A. Kiefer, 'Leading change', *Rehabilitation Nursing*, vol. 35, no. 1, pp. 41–43, 2010, doi: 10.1002/j.2048-7940.2010.tb00029.x.
- [24] M. Holland, *The change agent*. 2017. doi: 10.4324/9781315263434-16.
- [25] M. A. Ajam, 'Project Control', *Project Management beyond Waterfall and Agile*, pp. 233–238, 2019, doi: 10.1201/9781315202075-35.
- [26] Project Management Institute, 'Success Rates Rise: Transforming the high cost of low performance', *Pulse of the Profession - 9th Global Project Management Survey*, pp. 1–32, 2017, [Online]. Available: <https://www.pmi.org/-/media/pmi/documents/public/pdf/learning/thought-leadership/pulse/pulse-of-the-profession-2017.pdf>
- [27] P. M. Practices, T. Development, P. Scope, O. Profile, and R. Profile, 'PMO Trends', no. November 2020, pp. 23–38, 2021.

- [28] X. Song, L. Deng, H. Wang, Y. Zhang, and Y. He, 'Deep learning-based time series forecasting', 2025.
- [29] ProjectPro, '20 Power BI Projects Examples and Ideas for Practice'. [Online]. Available: <https://www.projectpro.io/article/power-bi-microsoft-projects-examples-and-ideas-for-practice/533>
- [30] Tableau, 'Real-World Examples of Business Intelligence (BI) Dashboards'. [Online]. Available: <https://www.tableau.com/dashboard/business-intelligence-dashboard-examples>
- [31] TensorFlow Core, 'Pronóstico de series de tiempo'. [Online]. Available: https://www.tensorflow.org/tutorials/structured_data/time_series?hl=es-419
- [32] ProjectPro, '5 Real-World Machine Learning Projects with SciKit Learn'. [Online]. Available: <https://www.projectpro.io/article/scikit-learn-projects/638>
- [33] IBM Heritage, 'Deep Thunder'. [Online]. Available: <https://www.ibm.com/history/deep-thunder>
- [34] M. O. Fadeyi, 'The role of building information modeling (BIM) in delivering the sustainable building value', *International Journal of Sustainable Built Environment*, vol. 6, no. 2, pp. 711–722, 2017, doi: 10.1016/j.ijsbe.2017.08.003.
- [35] R. Ambriz Avelar, 'La gestión del valor ganado y su aplicación: Managing earned value and its application', *Paper presented at PMI® Global Congress 2008—Latin America, São Paulo, Brazil. Newtown Square, PA: Project Management Institute., 2008*, [Online]. Available: <https://www.pmi.org/learning/library/es-las-mejores-practicas-de-gestion-del-valor-ganado-7045>
- [36] J. Batselier and M. Vanhoucke, 'Construction and evaluation framework for a real-life project database', *International Journal of Project Management*, vol. 33, no. 3, pp. 697–710, 2015, [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S0263786314001410?via%3Dihub>
- [37] Operations Research & Scheduling Research Group, 'Welcome to the OR&S project database'. [Online]. Available: <https://www.projectmanagement.ugent.be/research/data>
- [38] Data.Gov, 'Capital Project Schedules and Budgets'. [Online]. Available: <https://catalog.data.gov/dataset/capital-project-schedules-and-budgets>
- [39] NYC OpenData, 'Capital Projects Dashboard - Citywide Budget and Schedule'. [Online]. Available: <https://catalog.data.gov/dataset/capital-projects-dashboard-budget-and-schedule-14148>
- [40] Z. Jin, J. Shang, Q. Zhu, C. Ling, W. Xie, and B. Qiang, 'RFRSF: Employee Turnover Prediction Based on Random Forests and Survival Analysis', *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 12343 LNCS, pp. 503–515, 2020, doi: 10.1007/978-3-030-62008-0_35.

- [41] D. Bryde, M. Broquetas, and J. M. Volm, 'ScienceDirect The project benefits of Building Information Modelling (BIM)', *International Journal of Project Management*, vol. 31, no. June 2011, pp. 971–980, 2014.
- [42] C. Benítez-Ávila, A. Hartmann, G. Dewulf, and J. Henseler, 'Interplay of relational and contractual governance in public-private partnerships: The mediating role of relational norms, trust and partners' contribution', *International Journal of Project Management*, vol. 36, no. 3, pp. 429–443, 2018, doi: 10.1016/j.ijproman.2017.12.005.
- [43] E. H. Kim, W. G. Wells, and M. R. Duffey, 'A model for effective implementation of Earned Value Management methodology', *International Journal of Project Management*, vol. 21, no. 5, pp. 375–382, 2003, doi: 10.1016/S0263-7863(02)00049-2.
- [44] B. G. Hwang, X. Zhao, and L. P. Toh, 'Risk management in small construction projects in Singapore: Status, barriers and impact', *International Journal of Project Management*, vol. 32, no. 1, pp. 116–124, 2014, doi: 10.1016/j.ijproman.2013.01.007.
- [45] FasterCapital, 'Desviacion estandar como medir y reducir la desviacion estandar de la estimacion de inversion'. [Online]. Available: <https://fastercapital.com/es/contenido/Desviacion-estandar--como-medir-y-reducir-la-desviacion-estandar-de-la-estimacion-de-inversion.html#:~:text=1,más baja sugiere menos variabilidad>
- [46] Zucchetti, '¿Qué es la Gestión del Valor Ganado?' [Online]. Available: <https://www.zucchetti.es/blog/gestion-valor-ganado.html#:~:text=Mejora de la previsibilidad del,proyecto>
- [47] F. Shoushtari, A. Daghighi, and E. Ghafourian, 'International Journal of Industrial Engineering Application of Artificial Intelligence in Project Management', no. November, pp. 49–63, 2024.
- [48] V. V. Tuhaise, J. H. M. Tah, and F. H. Abanda, 'Technologies for digital twin applications in construction', *Autom Constr*, vol. 152, no. May, p. 104931, 2023, doi: 10.1016/j.autcon.2023.104931.
- [49] PMI, 'AI Innovators: Cracking The Code on Project Performance', *PMI's Pulse of the Profession. In-Depth Report*, p. 4, 2019, [Online]. Available: <https://www.pmi.org/learning/thought-leadership/pulse/ai-innovators>



ANEXOS

```
##1º ANÁLISIS (PROYECTOS BIM)##

install.packages("readr")      # Para leer archivos CSV
install.packages("dplyr")      # Para manipular datos
install.packages("ggplot2")    # Para hacer gráficos

# Cargar paquetes
library(readr)
library(dplyr)
library(ggplot2)
library(readxl)

# Leer el archivo CSV con formato europeo y codificación correcta
df1 <- read.csv2(file.choose(), fileEncoding = "latin1", stringsAsFactors = FALSE)

# Lista de columnas con valores monetarios
cols_monedas <- c("Planned_Cost", "Actual_Cost", "Cost_Overrun")

# Limpiar símbolos y convertir a numérico
df1[cols_monedas] <- lapply(df1[cols_monedas], function(x) {
  x <- gsub("[^0-9,]", "", x)      # Elimina todo excepto dígitos y comas
  x <- gsub(",", ".", x)         # Cambia coma decimal a punto
  as.numeric(x)                  # Convierte a número
})

#Mostrar las primeras filas de la tabla
head(df1)

#Verificar estructura de los datos
glimpse(df1)
summary(df1)
head(df1)

#Resumen estadístico
summary(select(df1, Planned_Cost, Actual_Cost, Cost_Overrun, Planned_Duration, Actual_Duration,
Schedule_Deviation))

#Calcular EV (Earned Value)
df1$EV <- df1$Planned_Cost * (df1$Completion_Percentage / 100)

#Calcular PV (Planned Value)
df1$PV <- df1$Planned_Cost * (df1$Planned_Duration / df1$Actual_Duration)

#Calcular CV (Cost variance) y SV (Schedule Variance)
df1$CV <- df1$EV - df1$Actual_Cost
df1$SV <- df1$EV - df1$PV

# Schedule Performance Index
df1$SPI <- df1$Planned_Duration / df1$Actual_Duration

# Cost Performance Index
df1$CPI <- df1$Planned_Cost / df1$Actual_Cost

#Visualizar valores calculados
View(select(df1, EV, PV, CV, SV, SPI, CPI))

#Boxplot para visualizar outliers de SPI y CPI
library(tidyr)
library(ggplot2)

# Convertir a formato largo
df1_long <- df1 %>%
  pivot_longer(cols = c(SPI, CPI), names_to = "índice", values_to = "Valor")

# Graficar boxplot
```



```
ggplot(df1_long, aes(x = Índice, y = Valor, fill = Índice)) +
  geom_boxplot() +
  labs(title = "Distribución de SPI y CPI",
       x = "Índice de Rendimiento",
       y = "Valor") +
  theme_minimal() +
  scale_fill_manual(values = c("SPI" = "skyblue", "CPI" = "salmon"))

# Mostrar tabla con los nuevos cálculos
View(df1)

#Grafica de desempeño CPI y SPI
df1 <- df1 %>%
  mutate(Cumple_Coste = ifelse(CPI >= 1, "Sí", "No"))

library(ggplot2)

ggplot(df1, aes(x = SPI, y = CPI, color = Cumple_Coste)) +
  geom_point(size = 3) +
  geom_vline(xintercept = 1, linetype = "dashed", color = "red") +
  geom_hline(yintercept = 1, linetype = "dashed", color = "blue") +
  labs(
    title = "Comparación SPI vs CPI",
    x = "SPI (Índice de Plazo)",
    y = "CPI (Índice de Coste)"
  ) +
  theme_minimal()

# Crear clasificación por desempeño
df1$Cumple_Plazo <- ifelse(df1$SPI >= 1, "Sí", "No")
df1$Cumple_Coste <- ifelse(df1$CPI >= 1, "Sí", "No")

# Graficar el desempeño
print(
  ggplot(df1, aes(x = SPI, y = CPI, color = Cumple_Coste)) +
    geom_point(size = 4) +
    geom_hline(yintercept = 1, linetype = "dashed", color = "red") +
    geom_vline(xintercept = 1, linetype = "dashed", color = "blue") +
    labs(title = "Clasificación de Proyectos según SPI y CPI",
         x = "SPI (Índice de Plazo)", y = "CPI (Índice de Coste)") +
    theme_minimal()
)

#Histogramas por separado
ggplot(df1, aes(x = SPI)) + geom_histogram(bins = 30) + theme_minimal()
ggplot(df1, aes(x = CPI)) + geom_histogram(bins = 30) + theme_minimal()

##2 - ANALISIS EMPIRICAL PROJECT DATA##

# 1. Instalar y cargar paquetes necesarios
install.packages("readr")      # Para leer CSV
install.packages("dplyr")      # Manipulación de datos
install.packages("ggplot2")    # Gráficos
install.packages("tidyr")      # Manipulación formato largo

library(readr)
library(dplyr)
library(ggplot2)
library(tidyr)

install.packages("readxl")
library(readxl)

# 2. Importar el archivo con los datos de los proyectos reales
df2 <- read_excel(file.choose())

# 3. Visualizar la estructura de los datos
glimpse(df2)
View(df2)
```




```
names(df2)
install.packages("janitor")
library(janitor)

df2 <- df2 %>% clean_names()
names(df2)

# Convertir SPI y CPI a numérico eliminando símbolos
df2 <- df2 %>%
  mutate(
    `cpi_final` = as.numeric(gsub("[^0-9\\.]", "", `cpi_final`)),
    `spi_final` = as.numeric(gsub("[^0-9\\.]", "", `spi_final`))
  )

# Verifica que ahora son numéricas
str(select(df2, `cpi_final`, `spi_final`))

# Filtrar proyectos que tengan valores de CPI y SPI finales válidos
df2_filtrado <- df2 %>%
  filter(!is.na(`cpi_final`), !is.na(`spi_final`))

#Resumen estadístico de los datos
summary(df2)
str(df2)

# Resumen estadístico de SPI y CPI
summary(select(df2_filtrado, `cpi_final`, `spi_final`))

# Boxplot comparativo SPI y CPI
df2_long <- df2_filtrado %>%
  pivot_longer(cols = c(`cpi_final`, `spi_final`),
    names_to = "Índice",
    values_to = "Valor")

ggplot(df2_long, aes(x = Índice, y = Valor, fill = Índice)) +
  geom_boxplot() +
  labs(title = "Distribución de SPI y CPI",
    y = "Valor del índice", x = "Índice de desempeño") +
  scale_fill_manual(values = c("spi_final" = "skyblue", "cpi_final" = "salmon")) +
  theme_minimal()

#Comprobacion valores intercuartilicos de SPI
summary(df2_filtrado$spi_final)

# Clasificación por desempeño
df2_filtrado <- df2_filtrado %>%
  mutate(
    Cumple_Coste = ifelse(`cpi_final` >= 1, "Sí", "No"),
    Cumple_Plazo = ifelse(`spi_final` >= 1, "Sí", "No")
  )

# Gráfico de dispersión SPI vs CPI
ggplot(df2_filtrado, aes(x = `spi_final`, y = `cpi_final`, color = Cumple_Coste)) +
  geom_point(size = 3) +
  geom_vline(xintercept = 1, linetype = "dashed", color = "blue") +
  geom_hline(yintercept = 1, linetype = "dashed", color = "red") +
  labs(
    title = "Clasificación de Proyectos según SPI y CPI",
    x = "SPI (Índice de Plazo)",
    y = "CPI (Índice de Coste)"
  ) +
  theme_minimal()

#Histogramas por separado
ggplot(df2, aes(x = spi_final)) + geom_histogram(bins = 30) + theme_minimal()
ggplot(df2, aes(x = cpi_final)) + geom_histogram(bins = 30) + theme_minimal()
```



```
##----ARBOLES DE DECISION PARA DF1 Y DF2-----
# Renombrar columnas en df2 para que coincidan con df1
df2_renombrado <- df2_filtrado %>%
  rename(
    CPI = cpi_final,
    SPI = spi_final,
    Planned_Cost = budget_at_completion,
    Planned_Duration = duration_baseline
  )

# Seleccionar columnas comunes
variables_interes <- c("SPI", "CPI", "Planned_Cost", "Planned_Duration")

# Asegurar que df1 tenga solo esas columnas
df1_simple <- df1 %>% select(all_of(variables_interes))

# Igual para df2 ya renombrado
df2_simple <- df2_renombrado %>% select(all_of(variables_interes))

# Unir los dos conjuntos
df_avanzado_modelo <- bind_rows(df1_simple, df2_simple)

df_avanzado_modelo <- df_avanzado_modelo %>%
  mutate(
    SPI_Class = ifelse(SPI >= 1, "Cumple", "No_Cumple"),
    CPI_Class = ifelse(CPI >= 1, "Cumple", "No_Cumple")
  )

library(rpart)
library(rpart.plot)
#spi

# Balanceo
cumple_spi <- df_avanzado_modelo %>% filter(SPI_Class == "Cumple")
no_cumple_spi <- df_avanzado_modelo %>% filter(SPI_Class == "No_Cumple")
set.seed(123)
no_cumple_spi_sample <- no_cumple_spi %>% sample_n(nrow(cumple_spi))
df_spi_balanceado <- bind_rows(cumple_spi, no_cumple_spi_sample)

# Eliminar columnas no predictivas
df_spi_balanceado <- df_spi_balanceado %>%
  select(-SPI, -CPI, -CPI_Class) # eliminamos las métricas directas

# Crear árbol
arbol_spi <- rpart(SPI_Class ~ ., data = df_spi_balanceado, method = "class")
rpart.plot(arbol_spi, main = "Árbol de decisión - SPI (Proyectos Avanzados)")

#CPI

# Balanceo
cumple_cpi <- df_avanzado_modelo %>% filter(CPI_Class == "Cumple")
no_cumple_cpi <- df_avanzado_modelo %>% filter(CPI_Class == "No_Cumple")
set.seed(123)
no_cumple_cpi_sample <- no_cumple_cpi %>% sample_n(nrow(cumple_cpi))
df_cpi_balanceado <- bind_rows(cumple_cpi, no_cumple_cpi_sample)

# Eliminar columnas no predictivas
df_cpi_balanceado <- df_cpi_balanceado %>%
  select(-CPI, -SPI, -SPI_Class) # eliminamos las métricas directas

# Crear árbol
arbol_cpi <- rpart(CPI_Class ~ ., data = df_cpi_balanceado, method = "class")
rpart.plot(arbol_cpi, main = "Árbol de decisión - CPI (Proyectos Avanzados)")
```



```
##3º ANALISIS (PROYECTOS TRADICIONALES)##

#Cargar archivo
df3 <- read_csv(file.choose())

#Verificar estructura de los datos
glimpse(df3)
summary(df3)
head(df3)

# Mostrar tabla con los nuevos cálculos
View(df3)

#Limpiar nombres de columnas
#names(df3) <- make.names(names(df3))

#Convertir columna de texto a numérico
library(dplyr)

df3 <- df3 %>%
  mutate(
    `Project Budget Amount` = as.numeric(gsub("[^0-9.]", "", `Project Budget Amount`)),
    `Final Estimate of Actual Costs Through End of Phase Amount` = as.numeric(gsub("[^0-9.]",
    "", `Final Estimate of Actual Costs Through End of Phase Amount`)),
    `Total Phase Actual Spending Amount` = as.numeric(gsub("[^0-9.]", "", `Total Phase Actual
    Spending Amount`))
  )

#Resumen estadístico de los datos
summary(df3)
str(df3)

#Extraer variables para analisis
df3 <- df3 %>%
  mutate(
    # Limpia comas, comillas, espacios, letras
    Planned_Cost = as.numeric(gsub("[^0-9.]", "", `Project Budget Amount`)),
    Actual_Cost = as.numeric(gsub("[^0-9.]", "", `Final Estimate of Actual Costs Through End of
    Phase Amount`)),

    Cost_Overrun = Actual_Cost - Planned_Cost,

    Planned_Start = as.Date(`Project Phase Actual Start Date`, format = "%m/%d/%Y"),
    Planned_End = as.Date(`Project Phase Planned End Date`, format = "%m/%d/%Y"),
    Actual_End = as.Date(`Project Phase Actual End Date`, format = "%m/%d/%Y"),

    Planned_Duration = as.numeric(Planned_End - Planned_Start),
    Actual_Duration = as.numeric(Actual_End - Planned_Start),
    Schedule_Deviation = Actual_Duration - Planned_Duration
  )

# Mostrar tabla con los nuevos cálculos
View(df3)
```



```
#Eliminar filas con valores faltantes
df3 <- df3 %>% filter(!is.na(Planned_Cost), !is.na(Actual_Cost), !is.na(Planned_Duration),
!is.na(Actual_Duration))

# Mostrar tabla con los nuevos cálculos
View(df3)

#Resumen estadístico
summary(select(df3, Planned_Cost, Actual_Cost, Cost_Overrun, Planned_Duration, Actual_Duration,
Schedule_Deviation))

# Schedule Performance Index
df3$SPI <- df3$Planned_Duration / df3$Actual_Duration

# Cost Performance Index
df3$CPI <- df3$Planned_Cost / df3$Actual_Cost

#Boxplot para visualizar outliers de SPI y CPI
library(tidyr)
library(ggplot2)

# Convertir a formato largo
df3_long <- df3 %>%
  pivot_longer(cols = c(SPI, CPI), names_to = "Índice", values_to = "Valor")

# Graficar boxplot
ggplot(df3_long, aes(x = Índice, y = Valor, fill = Índice)) +
  geom_boxplot() +
  labs(title = "Distribución de SPI y CPI",
       x = "Índice de Rendimiento",
       y = "Valor") +
  theme_minimal() +
  scale_fill_manual(values = c("SPI" = "skyblue", "CPI" = "salmon"))

df3 <- df3 %>%
  filter(
    SPI > 0 & SPI < 2,
    CPI > 0 & CPI < 2,
    !is.na(SPI), !is.na(CPI)
  )

# Convertir a formato largo
df3_long <- df3 %>%
  pivot_longer(cols = c(SPI, CPI), names_to = "Índice", values_to = "Valor")

# Graficar boxplot
ggplot(df3_long, aes(x = Índice, y = Valor, fill = Índice)) +
  geom_boxplot() +
  labs(title = "Distribución de SPI y CPI",
       x = "Índice de Rendimiento",
       y = "Valor") +
  theme_minimal() +
  scale_fill_manual(values = c("SPI" = "skyblue", "CPI" = "salmon"))

# Mostrar tabla con los nuevos cálculos
View(df3)

#Grafica de desempeño CPI y SPI
df3 <- df3 %>%
  mutate(Cumple_Coste = ifelse(CPI >= 1, "Sí", "No"))

library(ggplot2)

ggplot(df3, aes(x = SPI, y = CPI, color = Cumple_Coste)) +
  geom_point(size = 3) +
  geom_vline(xintercept = 1, linetype = "dashed", color = "red") +
  geom_hline(yintercept = 1, linetype = "dashed", color = "blue") +
```



```
labs(
  title = "Comparación SPI vs CPI",
  x = "SPI (Índice de Plazo)",
  y = "CPI (Índice de Coste)"
) +
theme_minimal()

#Histogramas por separado
ggplot(df3, aes(x = SPI)) + geom_histogram(bins = 30) + theme_minimal()
ggplot(df3, aes(x = CPI)) + geom_histogram(bins = 30) + theme_minimal()

#4.ANALISIS CAPITAL PROJECT DASHBOARD#
install.packages("tidyverse") # Incluye dplyr, ggplot2, readr...
install.packages("janitor")   # Para limpiar nombres de columnas
library(tidyverse)
library(janitor)

# Cargar archivo CSV
df4 <- read_csv(file.choose()) # Te abrirá un explorador para elegir el archivo

# Limpiar nombres de columnas (por si tienen espacios o mayúsculas)
df4 <- clean_names(df4)

# Verificar columnas disponibles
names(df4)

# Selección y renombrado de columnas útiles (ajusta si es necesario)
df4_proyectos <- df4 %>%
  select(
    project_id = pid,
    project_title = agency_project_name, # O usa fms_project_name si prefieres
    managing_agency = managing_agency,
    planned_start_date = current_phase_start,
    planned_end_date = forecast_completion,
    actual_start_date = actual_construction_start,
    actual_end_date = actual_construction_end,
    budget_total = total_budget,
    total_project_spent = spend_to_date
  ) %>%
  filter(!is.na(budget_total), !is.na(total_project_spent))

# Asegurarse de que las fechas sean tipo Date
df4_proyectos <- df4_proyectos %>%
  mutate(
    planned_start_date = as.Date(planned_start_date, format = "%m/%d/%Y"),
    planned_end_date = as.Date(planned_end_date, format = "%m/%d/%Y"),
    actual_start_date = as.Date(actual_start_date, format = "%m/%d/%Y"),
    actual_end_date = as.Date(actual_end_date, format = "%m/%d/%Y")
  ) %>%
  mutate(
    planned_duration = as.numeric(planned_end_date - planned_start_date),
    actual_duration = as.numeric(actual_end_date - actual_start_date)
  ) %>%
  mutate(
    total_project_spent = as.numeric(total_project_spent),
    budget_total = as.numeric(budget_total)
  )

#Calcular SPI y CPI
df4_proyectos <- df4_proyectos %>%
  mutate(
    cpi = total_project_spent / budget_total, # Índice de coste
    spi = actual_duration / planned_duration # Índice de plazo (estimación)
  )

# Ver resumen de CPI y SPI
```



```
summary(select(df4_proyectos, cpi, spi))

# Boxplot comparativo
df4_long <- df4_proyectos %>%
  pivot_longer(cols = c("cpi", "spi"), names_to = "indice", values_to = "valor")

ggplot(df4_long, aes(x = indice, y = valor, fill = indice)) +
  geom_boxplot() +
  labs(title = "Distribución de SPI y CPI",
       x = "Índice de desempeño", y = "Valor del índice") +
  scale_fill_manual(values = c("spi" = "skyblue", "cpi" = "salmon")) +
  theme_minimal()

#Eliminar valores atípicos
df_plot_raw <- df4_proyectos %>%
  filter(cpi > 0, cpi < 2, spi > 0, spi < 2)

#Resumen de los valores CPI y SPI (eliminados los outliers)
summary(select(df_plot_raw, cpi, spi))

# Eliminar valores atípicos extremos (rango típico: 0 a 5)
df_plot <- df4_proyectos %>%
  filter(cpi > 0, cpi < 2, spi > 0, spi < 2) %>%
  select(cpi, spi) %>%
  pivot_longer(cols = everything(), names_to = "indice", values_to = "valor")

#Volver a graficar boxplot
ggplot(df_plot, aes(x = indice, y = valor, fill = indice)) +
  geom_boxplot() +
  labs(title = "Distribución de SPI y CPI sin valores atípicos extremos",
       x = "Índice de desempeño",
       y = "Valor del índice") +
  scale_fill_manual(values = c("spi" = "skyblue", "cpi" = "salmon")) +
  theme_minimal()

# Filtrar valores atípicos antes de clasificar
df_plot_raw <- df4_proyectos %>%
  filter(cpi > 0, cpi < 2, spi > 0, spi < 2) %>%
  mutate(
    cumple_coste = ifelse(cpi >= 1, "Sí", "No"),
    cumple_plazo = ifelse(spi >= 1, "Sí", "No")
  )

# Histogramas
ggplot(df_plot_raw, aes(x = cpi)) +
  geom_histogram(bins = 30, fill = "salmon", color = "black") +
  geom_vline(xintercept = 1, color = "red") +
  labs(title = "Histograma del CPI", x = "CPI", y = "Cantidad") +
  theme_minimal()

ggplot(df_plot_raw, aes(x = spi)) +
  geom_histogram(bins = 30, fill = "skyblue", color = "black") +
  geom_vline(xintercept = 1, color = "blue") +
  labs(title = "Histograma del SPI", x = "SPI", y = "Cantidad") +
  theme_minimal()

# Gráfico de dispersión CPI vs SPI sin valores atípicos
ggplot(df_plot_raw, aes(x = spi, y = cpi, color = cumple_coste)) +
  geom_point(size = 3) +
  geom_vline(xintercept = 1, linetype = "dashed", color = "blue") +
  geom_hline(yintercept = 1, linetype = "dashed", color = "red") +
  labs(
    title = "Clasificación de proyectos según SPI y CPI (sin valores atípicos)",
    x = "SPI (índice de Plazo)",
```



```
y = "CPI (Índice de Coste)"
) +
theme_minimal()

## COMPARATIVA FINAL DE LOS CUATRO CONJUNTOS DE DATOS ##

# Cargar paquetes necesarios
library(dplyr)
library(tidy)
library(ggplot2)

# Asignar tipo de gestión a cada dataframe
df1$Tipo <- "BIM"
df2_filtrado$Tipo <- "Valor Ganado"
df3$Tipo <- "Tradicional"
df_plot_raw$Tipo <- "Proyectos NYC"

#names(df2_filtrado)

# Homogeneizar nombres de columnas SPI y CPI
df1 <- df1 %>% rename(SPI = SPI, CPI = CPI)
df2_filtrado <- df2_filtrado %>% rename(SPI = spi_final, CPI = cpi_final)
df3 <- df3 %>% rename(SPI = SPI, CPI = CPI)
df_plot_raw <- df_plot_raw %>% rename(SPI = spi, CPI = cpi)

# Seleccionar columnas comunes
df1_sel <- df1 %>% select(SPI, CPI, Tipo)
df2_sel <- df2_filtrado %>% select(SPI, CPI, Tipo)
df3_sel <- df3 %>% select(SPI, CPI, Tipo)
df4_sel <- df_plot_raw %>% select(SPI, CPI, Tipo)

# Unir todos los dataframes
df_comparado <- bind_rows(df1_sel, df2_sel, df3_sel, df4_sel)

# Calcular estadísticos descriptivos
resumen_comparativo <- df_comparado %>%
  group_by(Tipo) %>%
  summarise(
    Media_SPI = mean(SPI, na.rm = TRUE),
    SD_SPI = sd(SPI, na.rm = TRUE),
    Media_CPI = mean(CPI, na.rm = TRUE),
    SD_CPI = sd(CPI, na.rm = TRUE)
  )
View(resumen_comparativo)

# Convertir a formato largo para graficar
df_largo <- df_comparado %>%
  pivot_longer(cols = c(SPI, CPI), names_to = "Indice", values_to = "Valor")

# Boxplot comparativo SPI y CPI por tipo de gestión
ggplot(df_largo, aes(x = Tipo, y = Valor, fill = Tipo)) +
  geom_boxplot() +
  facet_wrap(~Indice, scales = "free_y") +
  labs(title = "Comparación de SPI y CPI según Tipo de Gestión",
       y = "Valor del Índice", x = "Tipo de Gestión") +
  theme_minimal()

df_comparado$Indice <- df_comparado$Indicador

df_comparado$Categoria <- ifelse(df_comparado$Tipo %in% c("BIM", "Valor Ganado"),
                                "Técnicas Avanzadas", "Sin Técnicas Avanzadas")

library(tidy)

df_largo <- pivot_longer(df_comparado,
                        cols = c(SPI, CPI),
                        names_to = "Indice",
```



```
values_to = "Valor")
df_largo$Categoria <- ifelse(df_largo$Tipo %in% c("BIM", "Valor Ganado"),
                             "Técnicas Avanzadas", "Tradicional")

ggplot(df_largo, aes(x = Tipo, y = Valor, fill = Tipo)) +
  geom_boxplot() +
  facet_grid(Categoria ~ Indice, scales = "free_y", space = "free") +
  labs(title = "Comparación de SPI y CPI según Tipo de Gestión",
       x = "Tipo de Proyecto", y = "Valor del Índice") +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1, size = 12),
    plot.title = element_text(hjust = 0.5, size = 16, face = "bold")
  )

library(ggplot2)
library(grid) # para la función unit()

p <- ggplot(df_largo, aes(x = Tipo, y = Valor, fill = Tipo)) +
  geom_boxplot() +
  facet_grid(Categoria ~ Indice, scales = "free_y", space = "free_x") +
  labs(title = "Comparación de SPI y CPI según Tipo de Gestión",
       x = "Tipo de Proyecto", y = "Valor del Índice") +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1, size = 12),
    plot.title = element_text(hjust = 0.5, size = 16, face = "bold"),
    plot.margin = unit(c(1, 2, 1, 1), "cm") # top, right, bottom, left
  )

ggsave("grafico_spi_cpi_completo.png", plot = p, width = 12, height = 6, dpi = 300)

ggplot(df_largo, aes(x = Tipo, y = Valor, fill = Tipo, color = Categoria)) +
  geom_boxplot() +
  facet_wrap(~ Indice, scales = "free_y") +
  labs(title = "Comparación de SPI y CPI según Tipo de Gestión",
       x = "Tipo de Proyecto", y = "Valor del Índice") +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1, size = 12),
    plot.title = element_text(hjust = 0.5, size = 16, face = "bold")
  )

ggplot(df_largo, aes(x = Tipo, y = Valor, fill = Categoria)) +
  geom_boxplot() +
  facet_wrap(~ Indice) +
  labs(title = "Comparación de SPI y CPI según Tipo de Gestión",
       x = "Tipo de Proyecto", y = "Valor del Índice") +
  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    plot.title = element_text(hjust = 0.5, size = 16, face = "bold")
  )
```




```
# Añadir categoría según tipo de gestión
df_comparado$Categoría <- ifelse(df_comparado$Tipo %in% c("BIM", "Valor Ganado"),
                                "Técnicas Avanzadas", "Sin Técnicas Avanzadas")

# Convertir a formato largo
df_comparado <- df_comparado %>%
  pivot_longer(cols = c(SPI, CPI), names_to = "Indice", values_to = "Valor")

# Ahora sí: Boxplot con facetas
ggplot(df_comparado, aes(x = Tipo, y = Valor, fill = Tipo)) +
  geom_boxplot() +
  facet_grid(~ Indice + Categoría, scales = "free_y", space = "free_x") +
  labs(title = "Comparación de SPI y CPI según Tipo de Gestión",
       x = "Tipo de Proyecto", y = "Valor del Índice") +
  theme_minimal() +
  theme(strip.text = element_text(face = "bold"))

# Comparación de SPI entre tipos de gestión
t.test(
  Valor ~ Tipo,
  data = df_comparado %>% filter(Indice == "SPI", Tipo %in% c("BIM", "Valor Ganado"))
)

# Comparación de CPI entre tipos de gestión
t.test(
  Valor ~ Tipo,
  data = df_comparado %>% filter(Indice == "CPI", Tipo %in% c("BIM", "Valor Ganado"))
)

# Comparación de SPI para los no avanzados
t.test(
  Valor ~ Tipo,
  data = df_comparado %>% filter(Indice == "SPI", Tipo %in% c("Proyectos NYC", "Tradicional"))
)

# Comparación de CPI para los no avanzados
t.test(
  Valor ~ Tipo,
  data = df_comparado %>% filter(Indice == "CPI", Tipo %in% c("Proyectos NYC", "Tradicional"))
)

# Calcular medias y desviaciones por grupo
df_summary <- df_comparado %>%
  group_by(Categoría, Tipo, Indice) %>%
  summarise(
    Media = mean(Valor, na.rm = TRUE),
    SD = sd(Valor, na.rm = TRUE),
    .groups = 'drop'
  )

# Gráfico de barras con error bars
ggplot(df_summary, aes(x = Tipo, y = Media, fill = Categoría)) +
  geom_bar(stat = "identity", position = position_dodge(0.9)) +
  geom_errorbar(aes(ymin = Media - SD, ymax = Media + SD),
               width = 0.2, position = position_dodge(0.9)) +
  facet_wrap(~Indice) +
  labs(title = "Media y desviación estándar de SPI y CPI por tipo de gestión",
       x = "Tipo de Proyecto", y = "Valor del Índice") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 30, hjust = 1),
        strip.text = element_text(face = "bold")) +
  scale_fill_manual(values = c("Técnicas Avanzadas" = "#66c2a5", "Sin Técnicas Avanzadas" =
"#fc8d62"))

#Gráfico de dispersión bivariado por grupo (SPI vs CPI)
```



```
df_disp <- df_comparado %>%
  group_by(Tipo, Categoria, Indice) %>%
  summarise(Valor = mean(Valor, na.rm = TRUE), .groups = "drop") %>%
  pivot_wider(names_from = Indice, values_from = Valor)

ggplot(df_disp, aes(x = SPI, y = CPI, color = Categoria, shape = Tipo)) +
  geom_point(alpha = 0.7, size = 3) +
  geom_vline(xintercept = 1, linetype = "dashed", color = "gray30") +
  geom_hline(yintercept = 1, linetype = "dashed", color = "gray30") +
  labs(title = "Dispersión de SPI vs CPI por tipo de gestión",
       x = "SPI (Índice de Plazo)", y = "CPI (Índice de Coste)") +
  theme_minimal()

#Test t de diferencia de medias entre categorías

# Comparación solo por categoría (agrupando tipos)
df_comparado_cat <- df_comparado %>%
  group_by(Categoria, Proyecto = row_number()) %>%
  pivot_wider(names_from = Indice, values_from = Valor)

t.test(SPI ~ Categoria, data = df_comparado_cat)
t.test(CPI ~ Categoria, data = df_comparado_cat)

#DESARROLLO PREDICTIVO

# INSTALAR LIBRERÍAS SI ES NECESARIO
install.packages("rpart")
install.packages("rpart.plot")
install.packages("randomForest")

# CARGAR LIBRERÍAS
library(dplyr)
library(tidyr)
library(rpart)
library(rpart.plot)
library(randomForest)

# AÑADIR ETIQUETA DE TIPO A CADA CONJUNTO DE DATOS
df1$Tipo <- "BIM"
df2_filtrado$Tipo <- "Valor Ganado"
df3$Tipo <- "Tradicional"
df_plot_raw$Tipo <- "Proyectos NYC"

# SELECCIONAR COLUMNAS COMUNES PARA UNIFICAR DATOS
df1_sel <- df1 %>% select(SPI, CPI, Tipo)
df2_sel <- df2_filtrado %>% select(SPI, CPI, Tipo)
df3_sel <- df3 %>% select(SPI, CPI, Tipo)
df4_sel <- df_plot_raw %>% select(SPI, CPI, Tipo)

# UNIR TODOS LOS DATOS EN UN SOLO CONJUNTO PARA MODELADO
df_modelo <- bind_rows(df1_sel, df2_sel, df3_sel, df4_sel)

# OPCIONAL: ELIMINAR NAs
df_modelo <- df_modelo %>% filter(!is.na(SPI), !is.na(CPI))

# CONVERTIR 'Tipo' A FACTOR
df_modelo$Tipo <- as.factor(df_modelo$Tipo)

# VISUALIZAR DATOS
summary(df_modelo)
```



```
##----ARBOLES DE DECISION PARA DF1 Y DF2-----
# Renombrar columnas en df2 para que coincidan con df1
names(df2_filtrado)
View(df2_filtrado)
df2_renombrado <- df2_filtrado %>%
  rename(
    CPI = cpi_final,
    SPI = spi_final,
    Planned_Cost = bac,
    Planned_Duration = pd_days
  )

# Seleccionar columnas comunes
variables_interes <- c("SPI", "CPI", "Planned_Cost", "Planned_Duration")

# Asegurar que df1 tenga solo esas columnas
df1_simple <- df1 %>% select(all_of(variables_interes))

# Asegurar que Planned_Cost y Planned_Duration sean numéricos en df2
df2_renombrado <- df2_renombrado %>%
  mutate(
    Planned_Cost = as.numeric(gsub("[^0-9\\.]", "", Planned_Cost)),
    Planned_Duration = as.numeric(gsub("[^0-9\\.]", "", Planned_Duration))
  )

# Igual para df2 ya renombrado
df2_simple <- df2_renombrado %>% select(all_of(variables_interes))

# Unir los dos conjuntos
df_avanzado_modelo <- bind_rows(df1_simple, df2_simple)

df_avanzado_modelo <- df_avanzado_modelo %>%
  mutate(
    SPI_Class = ifelse(SPI >= 1, "Cumple", "No_Cumple"),
    CPI_Class = ifelse(CPI >= 1, "Cumple", "No_Cumple")
  )

View (df_avanzado_modelo)
```



```
##---ARBOLES DE DECISION PARA DF3 Y DF4-----
# Renombrar columnas en df2 para que coincidan con df1
names(df3)
View(df3)

names(df_plot_raw)
View(df_plot_raw)

df4_renombrado <- df_plot_raw %>%
  rename(
    CPI = CPI,
    SPI = SPI,
    Planned_Cost = budget_total,
    Planned_Duration = planned_duration
  )

# Seleccionar columnas comunes
variables_interes <- c("SPI", "CPI", "Planned_Cost", "Planned_Duration")

# Asegurar que df1 tenga solo esas columnas
df3_simple <- df3 %>% select(all_of(variables_interes))

# Asegurar que Planned_Cost y Planned_Duration sean numéricos en df2
df4_renombrado <- df4_renombrado %>%
  mutate(
    Planned_Cost = as.numeric(gsub("[^0-9\\.]", "", Planned_Cost)),
    Planned_Duration = as.numeric(gsub("[^0-9\\.]", "", Planned_Duration))
  )

# Igual para df2 ya renombrado
df4_simple <- df4_renombrado %>% select(all_of(variables_interes))

# Unir los dos conjuntos
df_avanzado_modelo2 <- bind_rows(df3_simple, df4_simple)

df_avanzado_modelo2 <- df_avanzado_modelo2 %>%
  mutate(
    SPI_Class = ifelse(SPI >= 1, "Cumple", "No_Cumple"),
    CPI_Class = ifelse(CPI >= 1, "Cumple", "No_Cumple")
  )

library(rpart)
library(rpart.plot)
#spi

# Balanceo
cumple_spi2 <- df_avanzado_modelo2 %>% filter(SPI_Class == "Cumple")
no_cumple_spi2 <- df_avanzado_modelo2 %>% filter(SPI_Class == "No_Cumple")
set.seed(123)
no_cumple_spi_sample2 <- no_cumple_spi2 %>% sample_n(nrow(cumple_spi2))
df_spi_balanceado2 <- bind_rows(cumple_spi2, no_cumple_spi_sample2)

# Eliminar columnas no predictivas
```



```
##-----ANALISIS RANDOM FOREST PARA SPI CON GESTION AVANZADA-----

# Unión de los datos y creación de df_avanzado_modelo
df_avanzado_modelo <- bind_rows(df1_simple, df2_simple)

df_avanzado_modelo <- df_avanzado_modelo %>%
  mutate(
    SPI_Class = ifelse(SPI >= 1, "Cumple", "No_Cumple"),
    CPI_Class = ifelse(CPI >= 1, "Cumple", "No_Cumple")
  )

head(df_avanzado_modelo)

#Convertir variables en factores
df_avanzado_modelo$SPI_Class <- as.factor(df_avanzado_modelo$SPI_Class)
df_avanzado_modelo$CPI_Class <- as.factor(df_avanzado_modelo$CPI_Class)

#Entrenar el Random Forest
install.packages("randomForest")
library(randomForest)

# Modelo para SPI
modelo_rf_spi <- randomForest(SPI_Class ~ Planned_Cost + Planned_Duration,
                              data = df_avanzado_modelo,

                              importance = TRUE,
                              ntree = 500)

# Ver resultados
importance(modelo_rf_spi)
varImpPlot(modelo_rf_spi,
            main = "Importancia de Variables - SPI (Proyectos Avanzados)",
            pch = 19, col = "steelblue")

##-----ANALISIS RANDOM FOREST PARA CPI EN PROYECTOS AVANZADOS-----

# Asegúrate de tener estos paquetes instalados y cargados
install.packages("randomForest")
library(randomForest)

# Convertir la variable objetivo a factor (si aún no se hizo)
df_avanzado_modelo$CPI_Class <- as.factor(df_avanzado_modelo$CPI_Class)

# Modelo Random Forest para CPI
modelo_rf_cpi <- randomForest(
  CPI_Class ~ Planned_Cost + Planned_Duration,
  data = df_avanzado_modelo,
  importance = TRUE,
  ntree = 500
)

# Ver la importancia de las variables numéricamente
importance(modelo_rf_cpi)

# Visualizar la importancia de las variables gráficamente
varImpPlot(modelo_rf_cpi,
            main = "Importancia de Variables - CPI (Proyectos Avanzados)",
            pch = 19,
            col = "darkgreen")
```



```
##-----ANALISIS RANDOM FOREST PARA SPI CON GESTION TRADICIONAL-----  
  
library(randomForest)  
  
# Convertir a factor  
df_spi_balanceado2$SPI_Class <- as.factor(df_spi_balanceado2$SPI_Class)  
df_cpi_balanceado2$CPI_Class <- as.factor(df_cpi_balanceado2$CPI_Class)  
  
# SPI  
rf_spi <- randomForest(SPI_Class ~ ., data = df_spi_balanceado2, ntree = 500)  
print(rf_spi)  
varImpPlot(rf_spi)  
  
# CPI  
rf_cpi <- randomForest(CPI_Class ~ ., data = df_cpi_balanceado2, ntree = 500)  
print(rf_cpi)  
varImpPlot(rf_cpi)
```