



Universidad Politécnica
de Madrid

**Escuela Técnica Superior de
Ingenieros Informáticos**



Máster Universitario en Inteligencia Artificial

Trabajo Fin de Máster

**Análisis y Predicción Individual del
Comportamiento de los Usuarios con
Abono Tercera Edad en el Transporte
Público de la Comunidad de Madrid**

Autor(a): Maite Puerta Beldarrain
Tutor(a): Oscar Corcho

Madrid, Junio - 2021

Este Trabajo Fin de Máster se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Máster
Máster Universitario en Inteligencia Artificial

Título: Análisis y Predicción Individual del Comportamiento de los Usuarios con
Abono Tercera Edad en el Transporte Público de la Comunidad de Madrid

Junio - 2021

Autor(a): Maite Puerta Beldarrain
Tutor(a): Oscar Corcho
Departamento de Inteligencia Artificial
ETSI Informáticos
Universidad Politécnica de Madrid

Agradecimientos

A aquellos que creyeron en mí aun sin conocerme, a aquellos que me quieren incondicionalmente, aquellos que me han acompañado en los malos y buenos momentos. A todos aquellos que me han enseñado, formado, educado, aconsejado o escuchado en los momentos determinantes de mi vida. A todos aquellos que me han visto crecer y que han formado parte de ese crecimiento. A todos los que están, siempre estuvieron o estarán.

En definitiva, a todos aquellos que han echo de mí quien soy, seré y siempre fui.

Resumen

Este trabajo es el resultado de la colaboración entre el Grupo de Ingeniería Ontológica de la Universidad Politécnica de Madrid y el Consorcio Regional de Transportes de Madrid, de acuerdo con el convenio de colaboración firmado por ambas entidades para la realización de trabajos de investigación. Esta colaboración nace de la necesidad de analizar el uso del transporte público en la comunidad de Madrid.

En este estudio se analizará la movilidad de la población de tercera edad utilizando como datos los registros de embarque realizados con un abono de tercera edad vigente en el momento del viaje y cargado en una tarjeta de transporte público personal. Estos datos están pseudo-anonimizados desde su origen, es decir por parte del CRTM, y por tanto no ha sido necesario solicitar la aprobación de estos estudios por parte del comité de ética de la UPM y además ha permitido respetar la confidencialidad y privacidad de los usuarios involucrados en el estudio.

El objetivo fundamental de este estudio es comprender el comportamiento de este segmento de la población en su uso del transporte público, mediante diversos algoritmos de representación, análisis y predicción. Para ello, se han diseñado diversas representaciones de los registros asociados a cada individuo, con el propósito de conocer y representar el comportamiento individual de los usuarios. También han sido implementados algoritmos de descomposición y análisis de series temporales que permitirán entender el comportamiento de los algoritmos de predicción y efectuar las predicciones. Se han examinado diferentes algoritmos de predicción de series temporales con el fin de extraer información de los datos y comparar la eficiencia de sus predicciones.

Abstract

This work results from the collaboration between the Ontological Engineering Group of the Universidad Politécnica de Madrid and the Consorcio Regional de Transportes de Madrid, in agreement with the collaboration agreement signed by both entities carry out research works. This collaboration comes from the need to analyze the use of public transport in the community of Madrid.

In this study, the mobility of the senior citizen will be analyzed using the boarding records made with a senior subscription as data. These data are pseudo-anonymized from their origin, i.e. by the CRTM, and therefore it has not been necessary to request the approval of these studies by the ethics committee of the UPM and has also allowed respect to the confidentiality and privacy of the users involved in the study.

The main goal of this study is to understand the behavior of this segment of the population in their use of public transport, by several representations, analysis, and forecast algorithms. For this purpose, several representations of the records of each individual have been designed, to know and represent the individual behavior of the users. Time series decomposition and analysis algorithms have also been implemented to understand the forecast algorithms' behavior and make predictions. Different forecast time series algorithms have been examined to extract information from the data and compare the efficiency of their predictions.

Tabla de contenidos

Agradecimientos	i
1. Introducción	1
1.1. Motivación	1
1.2. Objetivos	3
1.3. Sistemas de transporte público de la Comunidad de Madrid	3
1.3.1. Operadores de Transporte	3
1.3.2. Zonas Tarifarias	4
1.3.3. Tarifas y tarjetas de transporte	4
1.3.3.1. Tarjetas de transporte público	4
1.3.3.2. Tarifas de transporte	5
1.4. Metodología, reproducibilidad y ciencia abierta	6
1.4.1. Reproducibilidad y ciencia abierta	6
1.5. Organización de la tesis	7
2. Estado del arte	9
2.1. Preliminares	9
2.1.1. Series temporales	9
2.1.1.1. Series temporales estacionarias	10
2.1.2. Descomposición de series temporales	12
2.1.2.1. Descomposición estacional de la librería statsmodels	13
2.1.2.2. Descomposición de Hodrick-Prescott	13
2.1.2.3. STL: Descomposición tendencia-estacional utilizando la función LOESS	13
2.1.3. Predicción de series temporales	13
2.1.3.1. ARIMA	14
2.1.3.2. Prophet como algoritmo de predicción	14
2.1.3.3. Redes de neuronas como método de predicción de series temporales	15
2.1.4. Clustering	17
2.2. Estado del Arte del análisis de movilidad en el transporte público	18
2.2.1. Trabajos previos del CRTM y OEG para la caracterización de los usuarios de tercera edad	18
2.2.2. Clustering o clasificación	18
2.2.2.1. Clusters basados en las actividades de los usuarios	19
2.2.3. Análisis del comportamiento de las personas de tercera edad en el transporte público	19

2.2.4. Análisis del comportamiento individual en el uso del transporte público	20
3. Descripción de los datos, almacenamiento y preprocesado	21
3.1. Descripción de los datos	21
3.1.1. Registros de embarques	21
3.1.2. Topología de la red de transporte público	22
3.2. Almacenamiento	23
3.2.1. El sistema gestor de bases de datos: InfluxDb	24
3.2.1.1. Almacenamiento de los registros de embarque en la base de datos crtm de InfluxDb	24
3.2.1.2. Almacenamiento de la topología de la red de transporte en la base de datos top de InfluxDb	25
4. Materiales	27
4.1. Representaciones globales	27
4.1.1. Estaciones de transporte de la Comunidad de Madrid	27
4.1.2. Recuento de usuarios según el año de su primer y último viaje . .	30
4.2. Representaciones individuales	31
4.2.1. Representación basada en la frecuencia	31
4.2.2. Representación basada en las características espaciales	32
4.2.3. Representación basada en las características temporales	35
4.2.4. Representación según las diferencias de tiempo en los viajes . . .	37
4.2.5. Representaciones individuales con una limpieza de los viajes . . .	38
4.3. Análisis de las series temporales	40
4.3.1. Descomposición de una serie temporal	40
4.3.1.1. Descomposición estacional de la librería statsmodels . . .	40
4.3.1.2. Descomposición de Hodrick-Prescott	42
4.3.1.3. Descomposición de la tendencia-estacional usando LOESS (STL).	43
4.3.2. Comprobación de la estacionalidad	45
4.3.3. Cardinalidad de la frecuencia	46
4.4. Conclusiones	46
5. Métodos	47
5.1. Experimentos	50
5.1.1. Especificaciones de los experimentos basados en el Arima	51
5.1.1.1. Especificaciones de los experimentos basados en Prophet	51
5.1.1.2. Especificaciones de los experimentos basados en Redes neuronas LSTM	52
6. Resultados	53
6.1. Análisis de las predicciones obtenidas	56
6.1.1. Predicciones obtenidas por el ARIMA	56
6.1.2. Predicciones realizadas por el Prophet	58
6.1.3. Predicciones realizadas por la red LSTM	62
6.1.4. Predicción comparativa entre los algoritmos de predicción	66
7. Conclusiones	69

TABLA DE CONTENIDOS

8. Trabajos futuros	71
Bibliografía	72
Anexo	76

Capítulo 1

Introducción

El principal objetivo de esta investigación es la caracterización y predicción del uso del transporte público de la Comunidad de Madrid por parte de las personas mayores de 65 años. Para lograr este objetivo se analizarán los registros de embarque que hayan sido realizados, entre 01-10-2016 y el 31-12-2019, con un abono de tercera edad vigente en el momento del viaje y cargado en una tarjeta de transporte público personal. Estos registros, previamente anonimizados, fueron proporcionados por el CRTM gracias a la colaboración entre esta organización y el Grupo de Ingeniería Ontológica de la UPM [32]. Estos datos no contienen información personal de los usuarios involucrados en este estudio y tampoco contendrá información que haya podido verse afectada por la pandemia del COVID-19.

1.1. Motivación

En los últimos años se ha producido un aumento cercano al 2.8 %, según los datos del Eurostat [14], de las personas de tercera edad en España. Este aumento puede verse en la figura 1.1, extraída de epdata.es a partir de los datos del INE. Este segmento de la población forma una parte considerable, que ha aumentado en los últimos años, de la población general, por lo que es conveniente tenerla en cuenta en las medidas y reformas, de modo que estas sean beneficiosas para el mayor porcentaje de la población posible. Para ello son necesarias investigaciones que permitan comprender el comportamiento de la población, así como de los segmentos que la componen, en cada ámbito específico. En el ámbito del transporte público, en concreto, cada segmento de la población tiene su propio comportamiento, por lo que es importante que se analicen de forma individual para poder atender y comprender las necesidades de cada uno.




Figura 1.1: Aumento de la población de tercera edad en los últimos años. [13]

En el segmento de la población de tercera edad, el uso del transporte tiene una estrecha relación con su salud, ya que forma parte intrínseca de su estilo de vida y de sus posibilidades e independencia de movilidad por la ciudad o región en la que viven. Davis et. al. [11] determinaron que para una persona de tercera edad un viaje en transporte público está asociado a 412 pasos por viaje, que equivalen a unos 8 minutos andando. Por lo que el abandono del transporte público, sobretodo aquel que se produce de forma prematura, implica, en general para los individuos de este segmento en concreto, un decaimiento de salud. Uno de los objetivos de la colaboración entre CRTM y OEG es identificar los abandonos prematuros que puedan ser evitados, evitando de este modo el decaimiento de salud y la reducción de movilidad que conllevan.

En trabajos anteriores, las investigaciones realizadas tenían el objetivo de caracterizar los abandonos y la relación entre este suceso y la salud de las personas. Sin embargo, este trabajo se centrará en examinar diferentes técnicas de inteligencia artificial que permitan predecir el comportamiento de los usuarios en su uso del transporte público. Una vez el comportamiento de los individuos esté determinado se podrán desarrollar investigaciones que permitan, basándose en las predicciones, detectar futuros abandonos. De este modo se conseguirá una detección precoz que permitirá, en caso de que sea necesario, tomar las medidas oportunas para que no se produzca.

Con el fin de poder examinar el comportamiento de los usuarios, es imprescindible analizar los motivos y las relaciones subyacentes existentes entre los viajes que realiza una persona. De este modo se pueden observar diferentes características de este comportamiento como son sus pautas, los días de actividad e inactividad, los recorridos más frecuentes, etc. Toda esta información permite comprender el comportamiento de un usuario a la hora de usar el transporte público. Por tanto, modelar y analizar el comportamiento de los usuarios permitirá realizar predicciones sobre el uso del transporte público pero además será un primer paso para realizar proyectos futuros que permitan la predicción del abandono.

En este trabajo se estudia el comportamiento de las personas de tercera edad con el fin de predecir su comportamiento. A la vez se promueve la creación de nuevos

proyectos enfocados en la movilidad en este segmento de la población y se incentiva a que este proyecto sea un primer paso en estudios más complejos que permitan la caracterización y predicción del abandono.

1.2. Objetivos

Los objetivos de este trabajo son los siguientes:

- Almacenamiento apropiado de los registros de embarque realizados con un abono de tercera edad asociado a una tarjeta de transporte público personal.
- Análisis y representación eficaz de los registros de embarque realizados con un abono de tercera edad vinculado a una tarjeta de transporte público personal, así como su correcto tratamiento teórico durante el trabajo.
- Predicción individual del comportamiento de los usuarios.

1.3. Sistemas de transporte público de la Comunidad de Madrid

El sistema de transportes público de la Comunidad de Madrid está compuesto por múltiples operadores de transportes que permiten a los usuarios viajar por toda la ciudad de Madrid y regiones adyacentes de una manera sencilla, cómoda y adaptada a las necesidades de cada individuo. Los distintos operadores de transporte son los siguientes: Metro, Metro ligero, buses interurbanos, buses urbanos (EMT y otros), Cercanías y buses de largo recorrido. Asimismo, en los últimos años se ha observado un incremento de otras formas de movilidad y medios de transporte que paulatinamente deberán ser incorporados a este tipo de análisis (bicicleta de alquiler, patines eléctricos, coches compartidos, etc).

En las siguientes secciones se explicarán los operadores de transporte usados en este trabajo, las zonas tarifarias en las que se divide el sistema de transporte público de la Comunidad de Madrid y las diferentes tarjetas de transporte y billetes que están a disposición de los usuarios.

1.3.1. Operadores de Transporte

En el primer estudio que compone la colección de trabajos nacidos gracias a la colaboración entre CRTM y el OEG, [26] (2019), se decidió utilizar únicamente los datos de tres operadores de transporte, que fueron: **Metro, Empresa Municipal de Transportes de Madrid (EMT) y de autobuses interurbanos**. En esta investigación se ha mantenido esta decisión con el fin de conservar una mayor coherencia entre los diferentes estudios que componen esta colección de trabajos. De este modo, los resultados del análisis de la movilidad que se obtuvieron en proyectos anteriores seguirán siendo válidos. En el futuro deberá considerarse su extensión al resto de operadores de transporte, especialmente Metro ligero y Cercanías.

A continuación se describirán con más detalle los tres medios de transporte usados.

- **Metro:** Actualmente cuenta con 12 líneas, y 238 estaciones, que facilitan que alrededor de 2 millones de usuarios viajen diariamente. El parque de material

1.3. Sistemas de transporte público de la Comunidad de Madrid

móvil consta de 2.394 coches, que recorren más de 169 millones de km/año [9].

- **Autobuses urbanos de Madrid (EMT):** La red de autobuses urbanos consta de 203 líneas con una longitud-línea total de 3.562 km y más de 10.172 paradas-línea, canalizando más de 1,5 millones de viajes al día. La flota de 1.903 vehículos tiene una edad media de 6,6 años. Todos los autobuses de la flota son accesibles, cuentan con piso bajo, rampa desplegable y sistema de inclinación lateral para facilitar el acceso de personas con movilidad reducida [9].
- **Autobuses interurbanos:** La Comunidad de Madrid cuenta con una densa red de líneas de autobuses interurbanos que realizan más de 20.000 servicios al día, con 26 empresas privadas que operan 324 líneas. La red de autobuses interurbanos, de 19.065 km, transporta diariamente más de 800.000 personas [9].

1.3.2. Zonas Tarifarias

El sistema de transporte público de la comunidad de Madrid está compuesto por 8 zonas de tarifas, seis de ellas para la Comunidad de Madrid (A, B1, B2, B3, C1, C3) y dos de Castilla-La Mancha (E1,E2).

Cada zona incluye a las interiores; así, un abono de la zona B2 puede ser utilizado en las zonas A, B1 y B2; con excepción de los abonos interzonales B1-B2, B2-B3, B3-C1 y C1-C2 que solo son válidos en las zonas a las que se refiere el título. En secciones posteriores se hablará de los abonos.

1.3.3. Tarifas y tarjetas de transporte

El CRTM tiene diversos billetes o tarifas a disposición de los usuarios que pueden ser cargados en las diferentes tarjetas de transporte. Existe una gran gama de billetes y tarjetas de transporte, de modo que cada usuario puede elegir la combinación que más le convenga dependiendo de sus necesidades de movilidad. A continuación, se describirán algunos de los billetes y tarjetas de transportes que el CRTM tiene a disposición de los usuarios. En estas secciones únicamente se describirán aquellos con mayor relevancia para este estudio pero se puede encontrar más información en la web del CRTM [9].

1.3.3.1. Tarjetas de transporte público

El CRTM ofrece principalmente dos tipos de tarjetas a las que se les puede asociar diversos billetes o abonos, de los que se hablará en la siguiente sección:

- **Tarjeta multi:** Está diseñada para usuarios regulares en el uso del transporte. Su funcionalidad es cargar varios de los billetes, facilitando el uso de diferentes operadores de transporte.
- **Tarjeta de transporte personal:** Permite, además de realizar la misma función que la tarjeta multi, el tener abonos personalizados, de los cuales se hablará en la siguiente sección.



Figura 1.2: Zonas tarifarias [9]

1.3.3.2. Tarifas de transporte

Los billetes que se ponen a disposición del usuario para viajar por la región de Madrid y las regiones adyacentes se adaptan a las necesidades de los individuos así como a la combinación de los diferentes medios de transporte que necesiten o vayan a usar. La gama de abonos y tipos de billetes es extensa y puede consultarse en la página oficial del CRTM [9]. Entre la gran gama de billetes que se pueden asociar a una tarjeta de transporte personal están los siguientes:

- **Ticket simple:** Está diseñado para personas que no suelen viajar y que van a realizar un único viaje. Está disponible para metro, ETM, buses interurbanos y metro ligero.
- **Ticket de 10 viajes:** Está diseñado para los usuarios que se van a mover por la región usando el transporte más de una vez pero sin mucha regularidad. Está disponible para metro, metro ligero, EMT, interurbanos y buses urbanos.
- **Abono de transporte:** El Abono de Transporte es un título personal e intransferible, que permite realizar un número ilimitado de viajes dentro de su zona de validez espacial y temporal. Para poder utilizarse, este título se debe cargar en la Tarjeta Transporte Público Personal. Entre los diferentes abonos destacan los

siguientes:

- **Abono de 30 días:** Disponibles en tres modalidades: Joven, Normal y Tercera Edad.
- **Abono de anual:** Disponibles en tres modalidades: Joven, Normal y Tercera Edad.

La utilización de cada título deberá ser siempre dentro de su zona temporal y espacial de validez. **En este trabajo se analizarán los registros realizados con un abono de tercera edad vigente en el momento en el viaje.**

Este trabajo está enfocado en el sistema de transporte público de Madrid pero podría replicarse en otras ciudades o regiones con unos datos y estructura de transporte similares.

1.4. Metodología, reproducibilidad y ciencia abierta

Los datos usados en este proyecto han sido proporcionados por el CRTM, gracias a su colaboración con el grupo de investigación Ontology Engineering Group (OEG) [32] de la UPM, y consisten en dos tipos de datos:

- **Topología de la red de transporte:** Conjunto de datos que contienen la descripción de todas las paradas existentes de los medios de transporte Metro, EMT e Interurbanos.
- **Registro de los viajes:** Conjunto de datos compuestos por los registros de embarque realizados con un abono de tercera edad en los medios de transportes: Metro, EMT e Interurbano. Estos registros están disponibles desde 01-01-2016 hasta 31-02-2020. Sin embargo, como se comentará en el capítulo 3, en este trabajo sólo se han usado los registros desde 01-10-2016 hasta 31-12-2019.

Los datos de los registros y del sistema de transporte público de la comunidad de Madrid utilizados para la realización de este proyecto son anteriores a la pandemia del COVID-19.

Estos datos serán descritos con más detalles en el capítulo 3, donde además se describe el proceso de almacenamiento y preprocesado de los datos que ha sido requerido para la realización de este estudio.

1.4.1. Reproducibilidad y ciencia abierta

El código utilizado para la realización de este proyecto está disponible en el repositorio de GitHub <https://github.com/oeg-upm/crtm-pae>. Sin embargo, este repositorio es privado debido a que aunque los datos se han anonimizado, todavía no se han determinado formalmente como datos abiertos, por lo que no están a disposición pública.

En este repositorio también se encuentran diferentes jupyter-notebooks, donde se explica el código paso a paso, con el fin de permitir la replicabilidad de este trabajo y para garantizar la comprensión de las herramientas implementadas por parte de las personas que realicen investigaciones posteriores.

1.5. Organización de la tesis

Este trabajo está organizado del siguiente modo: en el capítulo 2 se expondrán diversos estudios realizados con el propósito de comprender el uso del transporte público por parte de la población, global o de tercera edad. En este capítulo también se explicarán los conceptos teóricos necesarios para una mejor comprensión de este trabajo. En el capítulo 3 se definirán los datos utilizados, su almacenaje y el preprocesamiento que han requerido. En el capítulo 4 se expondrán las diversas herramientas implementadas a lo largo de este trabajo para la representación y análisis de los registros de cada usuario. En el capítulo 5 se expondrá la metodología seguida junto con los experimentos propuestos. En el capítulo 6 se encuentran los resultados obtenidos.

Capítulo 2

Estado del arte

El avance de la tecnología en los últimos años ha permitido la evolución de muchos aspectos de nuestra vida. En el sector del transporte público, los sistemas de registros de embarques y desembarques, han sido uno de estos avances, permitiendo registrar y almacenar el uso del transporte por parte de la población. Estos datos permiten la realización de investigaciones, como esta, cuyo objetivo es comprender el comportamiento de los usuarios en la toma del transporte. En las siguientes secciones se expondrán algunas de estas investigaciones. Sin embargo, antes se explicarán los conceptos teóricos necesarios para abordar este trabajo.

2.1. Preliminares

A lo largo de esta sección se explicarán los conceptos básicos necesarios para un correcto entendimiento de este trabajo. Entre los conceptos que se verán se encuentran el de serie temporal, proceso estacionarios, estacionalidad y descomposición o predicción de series temporales.

2.1.1. Series temporales

El concepto de serie temporal, estrechamente relacionado con el de proceso estocástico, es el principal concepto teórico de este trabajo. A continuación, se definirán estos dos conceptos.

Un **proceso estocástico** es aquel cuyo comportamiento no es determinante sino que depende en cierto grado del azar. Un proceso estocástico se describe como una sucesión de variables aleatorias que evolucionan según una variable que normalmente es el tiempo [3]. Cada una de estas variables tiene su propia función de distribución y pueden o no estar correlacionadas entre sí [10]. El término correlación se explicará más adelante.

Una **serie temporal** es una secuencia de datos, denominados normalmente como observaciones, ordenados en el tiempo. Una serie temporal representa la evolución en el tiempo de un sistema dinámico. De este modo, sea $x = \{x_1, x_2, \dots, x_T\}$ una serie temporal que describe un sistema dinámico, entonces x es una realización del proceso estocástico $X = \{X_1, X_2, \dots\} = \{X_t\}_{t=1}^{\infty}$ [34], en el que cada observación x_i $i \in \{1, \dots, T\}$ es un dato de la variable aleatoria X_i del proceso estocástico X .

Las series temporales pueden dividirse en univariantes o multivariantes según el número de variables por cada observación. También pueden dividirse en discretas o continuas según si las observaciones se han obtenido cada cierto periodo de tiempo o de forma continua.

Existen infinidad de recursos que describen, ejemplifican y explican las series temporales, entre ellos está el artículo escrito por D.R. Brillinger, [5] o el escrito por P.J. Brockweel, [6]. También existen muchos libros que pueden ayudar al lector a entender en qué consiste una serie temporal, como [35] escrito por Peter J. Brockwell et. al. o [21] por Rob J. Hyndman et. al. o [18] de Aurélien Géron o [34] de Francisco Parra.

La importancia de las series temporales en este trabajo, como se comentará posteriormente, es que los registros de cada usuario están ordenados por el tiempo, es decir, son una serie temporal, que además es discreta. Cada una de estas series tiene una observación por cada viaje realizado por el usuario al que pertenezca la serie temporal.

Una serie temporal puede ser además de univariante o multivariante, discreta o continua, estacionaria o no. Dentro de las series temporales estacionarias se distinguen dos tipos, de los que se hablará en la siguiente sección, estacionalidad fuerte y débil

2.1.1.1. Series temporales estacionarias

Un proceso estocástico X es estacionario si sus propiedades estadísticas son independientes del tiempo. La estacionalidad significa que la distribución de X , $\mathbb{P}(X_1, X_2, \dots)$, es la misma a lo largo del tiempo, es decir, es invariante en cualquier intervalo de tiempo:

$$\mathbb{P}(X_1, X_2, \dots, X_T) = \mathbb{P}(X_{1+r}, X_{2+r}, \dots, X_{T+r}) \quad \forall T, r \in \mathbb{N}^*. \quad (2.1)$$

Instintivamente, la estacionalidad puede explicarse del siguiente modo: si el comportamiento de un sistema dinámico está representado por un proceso estocástico cuyo comportamiento en el tiempo t está caracterizado, entonces este comportamiento puede replicarse en el tiempo $t + 1$, es decir, el comportamiento en el futuro va a tener la misma caracterización. En otras palabras, el comportamiento del sistema es invariante del tiempo.

Sin embargo, en la práctica, es difícil probar que una serie temporal es estacionaria por lo que normalmente se utiliza el concepto de estacionalidad débil.

Un proceso estocástico, X , es débilmente estacionario (o de media-covarianza estacionaria) si su media y su varianza son invariables en el tiempo y además su varianza es finita.

La estacionalidad débil relaja la estacionalidad fuerte ya que en vez de exigir que la distribución estadística sea invariante en el tiempo solo exige que lo sea la media y la varianza. Por tanto, la estacionalidad fuerte implica estacionalidad débil. En este trabajo nos referiremos a estacionalidad como a la estacionalidad débil.

En la figura 2.1 se exponen diversos ejemplos de estacionalidad débil, media estacionaria y varianza estacionaria con el propósito de clarificar este concepto. En la imagen superior situada a la derecha, hay una serie temporal que exhibe una marcada tendencia creciente, por lo que su media es creciente en el tiempo, por lo que

no es estacionaria en media. Del mismo modo, en la imagen inferior situada a la izquierda hay una serie temporal que exhibe fluctuaciones de amplitudes desiguales en el tiempo, por lo que no es una serie estacionaria debido a que la varianza no es constante en el tiempo.




Figura 2.1: Series estacionarias [34]

Para evaluar la estacionalidad de un proceso estocástico X basándose en una cierta realización, es decir, basándose en una serie temporal $\{x_t\}_{t=1}^T$, se pueden usar métodos gráficos o test estadísticos.

Uno de los métodos gráficos más usados es el **correlograma**, el cual se compone de los valores de la función de autocorrelación (ACF) según se van incrementando los intervalos. Esta representación describe las dependencias temporales existentes entre las observaciones. La **correlación** permite saber cómo se reacciona una serie temporal con sus valores retardados. Informalmente, la autocorrelación es una medida que refleja el grado de dependencia entre los valores de una serie temporal en intervalos de tiempo sucesivos. Una correlación elevada significa que los valores dependen en gran medida de sus valores pasados.

Respecto a evaluar la estacionalidad de una serie temporal, este gráfico presenta un descenso lento cuando la serie temporal no es estacionaria, en caso contrario se observa un descenso rápido. En la figura 2.2 extraída de [23] se observa un ejemplo, la primera serie no es estacionaria ya que su descenso es lento mientras que la segunda sí lo es y su descenso es muy rápido.




Figura 2.2: Correlograma de dos series temporales. Imagen extraída de [23].

Sin embargo, los métodos visuales no son siempre concluyentes y exigen una supervisión manual que no siempre es posible, por ejemplo en los casos en el que se estén examinando muchas series temporales como en este estudio. En estos casos se usan tests estadísticos. Dentro de los tests estadísticos más usados para demostrar que una serie temporal es estacionaria están el test de Dickey-Fuller y el test Kwiatkowski-Phillips-Schmidt-Shin (denominado KPSS). En este trabajo no se profundizará en la explicación de los test estadísticos, pero se deja a disposición del lector el artículo [10] escrito por Fatoumata Dama et. al. donde se detallan.

2.1.2. Descomposición de series temporales

La descomposición tiene por objetivo preprocesar una serie temporal bruta para obtener un componente estocástico restante. Las series temporales no estacionarias pueden descomponerse en efectos no estacionarios (los componentes deterministas) y un componente restante (el componente estocástico). Dentro de los componentes en los que se suele descomponer la serie temporal están los siguientes:

- T_t Trend o tendencia de la serie temporal.
- C_t Componente cíclico: Tiene forma sinusoidal.
- S_t Componente estacional: Se repite constantemente, es un patrón pero no tiene que ser cíclico como el componente cíclico.
- R_t Residuos: Es el componente estocástico resultante, y se espera que tenga información sobre la autocorrelación de las observaciones. Se calculan restando a la serie original los otros tres componentes obtenidos.

No todas las descomposiciones tienen todos los elementos, en muchas descomposiciones la tendencia y el componente cíclico forman un único componente denominado tendencia o tendencia cíclica. El modelo en que la serie temporal se descomponen en sus componentes básicos puede ser de dos tipos:

- Modelo aditivo: $y_t = T_t + S_t + R_t$
- Modelo multiplicativo: $y_t = T_t * S_t * R_t$

Hay diversos algoritmos de descomposición de series temporales, algunos de ellos se describen a continuación.

2.1.2.1. Descomposición estacional de la librería statsmodels

Esta descomposición es la propuesta por la librería statsmodels [38]. El componente estacional se elimina aplicando un filtro de convolución a los datos. El promedio de esta serie suavizada en cada período es el componente estacional devuelto.

2.1.2.2. Descomposición de Hodrick-Prescott

Esta descomposición fue propuesta por Robert J. Hodrick y Edward C. Prescott en [20]. Esta descomposición se basa en el cálculo del componente de la tendencia y del componente cíclico. La tendencia se calcula como la suma de su segunda diferencia junto con algunas suposiciones conceptuales respecto al comportamiento de este suavizado. El componente cíclico se extrae en consecuencia del resultado del cálculo de la tendencia ya que en esta descomposición no existe el componente de residuo.

2.1.2.3. STL: Descomposición tendencia-estacional utilizando la función LOESS

La descomposición de la tendencia estacional mediante el uso de Loess (STL) es uno de los métodos de descomposición más utilizados y es capaz de adaptarse a cualquier tendencia y periodicidad. Este método de descomposición fue propuesto por Robert B Cleveland et. al. en [8]. Es un procedimiento iterativo que se basa en la realización recurrente del suavizado LOESS.

El método de suavizado de dispersión estimado localmente, LOESS, combina la sencillez de la regresión lineal por mínimos cuadrados con la flexibilidad de la regresión no lineal mediante el ajuste de un modelo sencillo sobre subconjuntos locales de datos para crear una función que describe la parte determinista de la variación en los datos punto a punto. Equivaldría a una regresión polinómica ponderada.

2.1.3. Predicción de series temporales

La predicción de series temporales se basa en el siguiente principio: conociendo el comportamiento pasado de un sistema, es posible realizar predicciones sobre su comportamiento a corto o largo plazo. El problema de predicción consiste en ajustar un modelo con el fin de obtener los valores futuros de la serie teniendo como datos los valores pasados, normalmente denominados lag o desfase.

Sea $x = \{x_1, x_2, \dots, x_T\}$ los valores pasados de una serie temporal y H el horizonte de predicción, la tarea de predicción consiste en obtener los valores $\{x_{T+1}, \dots, x_{T+H}\}$, de modo que si $\hat{x} = \{\hat{x}_{T+1}, \hat{x}_{T+2}, \dots, \hat{x}_{T+H}\}$ es el vector de valores reales de la serie, entonces los valores obtenidos deben minimizar la siguiente ecuación

$$E = \sum_{i=1}^{i=H} |x_{T+i} - \hat{x}_{T+i}| \quad (2.2)$$

Los métodos tradicionales estadísticos utilizados para predecir series temporales se basan en la construcción de funciones lineales a partir de las observaciones pasadas recientes para proporcionar predicciones futuras. Sin embargo, la aplicación de los métodos tradicionales debe hacerse teniendo en cuenta las consideraciones exigidas por los algoritmos, como por ejemplo el ARIMA, método con el cual las series introducidas deben ser estacionarias. Otro problema que tienen estos métodos es que la aplicabilidad de estos modelos se limita a situaciones en las que se dispone de suficientes datos históricos, con una estructura explicable. Cuando la disponibilidad de datos para una sola serie es escasa, estos modelos a menudo no logran extraer eficazmente las características y los patrones subyacentes. Además, como estos métodos crean un modelo para cada serie temporal individual, no es posible compartir el aprendizaje entre instancias similares. Por lo tanto, no es factible utilizar estas técnicas para tratar cantidades masivas de datos, ya que sería computacionalmente prohibitivo. De ahí que empezaran a ganar popularidad las técnicas de inteligencia artificial, que permiten construir modelos globales que comparten el conocimiento aprendido en múltiples series relacionadas.

En las últimas décadas, la inteligencia artificial ha incrementado su popularidad en la resolución del problema de predicción de series temporales [4], mientras que los métodos tradicionales estadísticos se han ido quedado como líneas base para la comparación del rendimiento con los modelos modernos.

Dentro de las técnicas de predicción tradicionales en este trabajo se utilizarán el ARIMA y el Prophet. Dentro de las técnicas de inteligencia artificial que se pueden utilizar para la predicción de series temporales se utilizará una red de neuronas LSTM. En las siguientes secciones se explicarán estos métodos y en el capítulo 5 se explicará como se han utilizado para predecir las series temporales de los usuarios.

2.1.3.1. ARIMA

El método ARIMA es un algoritmo de predicción clásico diseñado para ser utilizado con series temporales estacionarias, [42]. Este método se basa en la combinación de tres métodos que son:

- El método AR es un modelo autoregresivo, el cual se basa en la premisa de que el pasado predice el futuro, por lo que un valor de la serie temporal en el tiempo t es una función de los valores pasados.
- La parte de MA es el modelo de Moving Average. Este modelo postula que un punto de la serie puede definirse en función de los errores de los valores pasados. Estos errores son los obtenidos en el ajuste de la media móvil (media ponderada) respecto a la función original.
- Por último utiliza la diferenciación de la serie temporal para conseguir eliminar la tendencia de la serie temporal.

Se puede encontrar más información sobre este algoritmo en libros como [31] escrito por Alieen Nielsen o en [39] escrito por Robert Shumway.

2.1.3.2. Prophet como algoritmo de predicción

Prophet, [41], es un algoritmo de predicción de series temporales basado en un modelo aditivo donde la tendencia no es lineal sino que se ajusta con la estacionalidad

diaria, semanal y anual más el efecto de las vacaciones. **Este algoritmo funciona muy bien con series temporales que tienen mucho efecto estacional y varios ciclos estacionales en el historial.**

Este método de predicción va analizando y cambiando los parámetros dependiendo de lo bueno que haya sido el ajuste, permitiendo de este modo un ajuste automático de los parámetros del modelo. De este modo consigue una parametrización de las variables de forma automática gracias al aprendizaje realizado del comportamiento de la serie.

Por ejemplo, en [46], Prophet consigue pronosticar con precisión las ventas futuras y clasificar la cartera de productos con un nivel de confiabilidad apropiado.

2.1.3.3. Redes de neuronas como método de predicción de series temporales

Los algoritmos de predicción de series temporal basados en inteligencia artificial y sobretodo en redes de neuronas, han demostrado un mejor rendimiento que los métodos estadísticos en muchas situaciones, especialmente debido a su capacidad y flexibilidad para trazar relaciones no lineales a partir de los datos [27]. Otra ventaja de las redes neuronales es que pueden extraer patrones temporales de forma automática sin ninguna suposición teórica sobre la distribución de los datos, reduciendo los esfuerzos de preprocesamiento. Además, se puede construir un único modelo global que aprende de múltiples series temporales relacionadas, lo que mejora en gran medida el rendimiento de las predicciones cuando se tiene una gran cantidad de series temporales.

La predicción de series temporales mediante redes neuronales empezó a emplearse con técnicas muy básicas de Perceptrón Multicapa (MLP). Las MLP se han aplicado eficazmente en muchas circunstancias, pero no son capaces de captar el orden temporal de una serie temporal. El hecho de ignorar el orden temporal limita el rendimiento en la predicción de series temporales. Esto llevó a las redes neuronales recurrentes (RNN) y a las redes neuronales convolucionales (CNN) a suscitar interés [4].

Mientras que las MLP ignoran las relaciones temporales de los datos, las RNN conectan cada paso de tiempo con el anterior modelando la dependencia temporal de los datos, lo que proporciona a las RNN la capacidad de tratar con datos secuenciales. El elemento básico de una red RNN se denomina célula de memoria, es equivalente a la neurona en las MLP pero a diferencia de estas tienen un bucle de retroalimentación, véase 2.3, que les permite tratar con datos secuenciales. Esto implica que la salida del paso $t - 1$ es tomada como entrada en el paso t influenciando la actuación de este paso y permitiendo de este modo captar patrones temporales. Sin embargo, los entrenamientos con estas redes se vuelven inestables obteniendo una explosión o desvanecimiento del gradiente que permite a las redes actualizar los valores de los pesos. Por tanto, estas redes no son capaces de captar dependencias a largo plazo ya que el gradiente se desvanece o explota. Este es uno de los motivos por los que entrenar RNN es una tarea difícil, [28].




Figura 2.3: Red Neuronal recurrente [28]

Las redes LSTM son una subclase de RNN las cuales tienen un mejor rendimiento que las RNN simples en la captura de dependencias a largo plazo y en recordar información por grandes periodos de tiempo. Las LSTM son RNN intrínsecamente en las que se introdujeron cambios en el cálculo de los estados ocultos y las salidas con el fin de mejorar el rendimiento de las RNN clásicas. Este trabajo únicamente se centrará en las redes LSTM debido a que han demostrado su funcionamiento en muchos estudios y además es la arquitectura básica muy usada en los nuevos algoritmos que se están utilizando para resolver la tarea de predicción [4].




Figura 2.4: Red LSTM [28]

La celda de memoria de la LSTM se muestra en la figura 2.4. A diferencia de la célula de memoria de la red RNN, esta tiene cuatro módulos que se comunican de un modo único, Los siguientes pasos demuestran como funciona la interacción de estos

módulos:

- En el primer paso la célula de memoria calcula el factor de olvido del estado anterior para la obtención del nuevo estado.
- En el siguiente paso se decide y almacena la importancia del input recibido en ese paso en el cálculo del nuevo estado de memoria. Esto se realiza mediante dos subpasos:
 - Se decide si la información recibida va a ser ignorada o actualizada.
 - Se calcula los pesos o la importancia del valor recibido en el cálculo del nuevo estado de memoria.

Una vez se tengan estos dos valores se utilizan junto con el factor de olvido calculado en el paso anterior para obtener el nuevo estado de la célula.

- En el último paso se calcula el output, para ello primero con la función sigmoid se calcula la relevancia que la nueva observación tendrá en la salida y posteriormente con la tangente se calcula la importancia del nuevo estado de memoria en el output. La multiplicación de estos dos valores es el output.

De este modo la red LSTM mejora respecto a la célula recurrente utilizada en las RNN en que permite afinar la forma en que se añade la nueva información a la previamente almacenada y además permite el olvido de una parte de esta información previamente almacenada.

2.1.4. Clustering

El **clustering** consiste en agrupar un conjunto de objetos (no etiquetados) en subconjuntos llamados clusters, de modo que cada uno esté formado por una colección de objetos que son similares según alguna o varias de las características de los objetos.

En [2], Saeed Aghabozorgi et. al. proporcionan un resumen de los diferentes tipos de clustering que se pueden realizar con series temporales. En él se encuentra una extensa clasificación según su propósito y los diferentes componentes del algoritmo usado: la representación, la reducción de dimensión, funciones de similitud, algoritmos de clustering, prototipo de clustering y la función de evaluación. Los algoritmos de clustering puede tener uno o varios de estos elementos dependiendo del propósito con el que se esté realizando así como de los datos que se utilicen.

Otro tipo de clustering muy usado es aquel basado en actividades, lo que se realiza en ellos es una clasificación de la población según la participación de los individuos en las actividades determinadas en el estudio.

En [25], Anil NP Koushik et. al. presentan un resumen de las diversas técnicas de machine learning más utilizadas de clustering basados en actividades.

En este trabajo las actividades serían los embarques y las características que se podrían usar para realizar la clasificación podría ser la secuencia de los viajes, el tiempo entre viajes, las ubicaciones, entre otros.

2.2. Estado del Arte del análisis de movilidad en el transporte público

En esta sección se exponen diversos trabajos científicos realizados con el propósito de analizar el uso del transporte público por parte de la población.

2.2.1. Trabajos previos del CRTM y OEG para la caracterización de los usuarios de tercera edad

Este trabajo pertenece a una colección de trabajos realizados gracias a la colaboración entre el OEG y el CRTM. El primer trabajo fue un TFM realizado en 2019 por Alexander Lacki [26] y el segundo, un TFG realizado en 2020 por Miguel Ángel Riaño [37]. Ambos utilizaron los datos, que el CRTM proporcionó, de los registros de embarques de los usuarios de tercera edad en el periodo de 2016 a 2018. Los medios de transporte que se utilizaron fueron: Metro, Interurbanos, EMT.

En estos trabajos se expone una comparativa de la caracterización de la población de tercera edad frente a otros sectores de la población. También se realizó un estudio para la detección de conductas que podrían ser perjudiciales para un estilo de vida activo y saludable en relación con el uso del transporte público por parte de estas personas.

2.2.2. Clustering o clasificación

Una forma de analizar el transporte de los usuarios es realizando una clasificación o mejor dicho un clustering según la semejanza de sus patrones, o de su estilo de movilidad.

En el estudio [33] que realizó Ortega-Tong, se utilizaron los datos de las tarjetas de transporte de Londres para clasificar a los usuarios que utilizaban el transporte público. Las características que fueron usadas estaban relacionadas con la variabilidad temporal y espacial de los usuarios así como con el patrón de sus actividades y las características demográficas de estos mismos. Dentro de los diferentes clusters que se obtienen en este estudio se encuentran los clusters formados por usuarios cuyo uso es muy constante (personas trabajadoras o estudiantes) y los formados por aquellos cuyo uso del transporte es debido a ocio, turismo o comportamientos esporádicos.

Relacionado con este trabajo está el de Jason Gordon en [15]. Este estudio propone una metodología para inferir los orígenes y destinos en el transporte iBus de Londres. Esto es necesario porque este transporte es el único de Londres en el cual los usuarios no han de pasar la tarjeta en el desembarque de dicho transporte y por tanto analizar estos datos es una tarea más complicada.

He Li et. al. realizaron en [19] una clasificación de los usuarios teniendo en cuenta de manera conjunta tanto las características espaciales como temporales del comportamiento individual de los usuarios. En contraste con la clasificación realizada en [12] por M.K El Mahrssi et. al. en la que se realizan dos clasificaciones de la población cada una de ellas basada en una de estas características.

A diferencia de los anteriores, que buscan una caracterización dependiendo del comportamiento de los usuarios, también existen trabajos realizados con una finalidad de mercado. Este es el ejemplo del trabajo realizado por Minh Kieu en [24] en el

que la característica principal para la realización de la clasificación es la regularidad espacial y temporal de los usuarios.

En [30], Yeun-Youh Li et. al. analizan las series temporales formadas por los registros de los usuarios que han usado el transporte durante mucho tiempo con el fin de clasificarlos según la forma básica que tenga la tendencia de cada usuario. Además en este estudio se comparan los resultados con las encuestas que realizan a los usuarios sobre cómo creen que es su comportamiento global a la hora de usar el transporte público, dando unos resultados muy acertados.

2.2.2.1. Clusters basados en las actividades de los usuarios

Existen otros estudios que buscan una clasificación de la población según la semejanza de sus pautas de movimiento, para lo cual utilizan técnicas de clustering basadas en actividades.

En [17], Gabriel Goulet-Langlois et. al. realizaron un clustering basado en la similitud de las secuencias de las actividades que realizaron los individuos en la ciudad de Londres en un periodo de 4 semanas. Este trabajo destaca la conectividad entre los atributos demográficos y los patrones de actividades.

Otro estudio en el que se usa una metodología basada en la realización de clustering de actividades relacionadas con el transporte, también en la ciudad de Londres, con el fin de demostrar de nuevo la relación entre el patrón de actividades y la demografía es [44] escrito por Yang Zhang et. al.. La diferencia de este trabajo respecto al anterior es que en este se utilizan los datos de los viajes de los usuarios para inferir los datos demográficos.

2.2.3. Análisis del comportamiento de las personas de tercera edad en el transporte público

Como se demostró en [26], no es lo mismo la población joven u obrera que la población de tercera edad, no solo por sus características, las cuales serán diferentes, sino también por sus necesidades. Hay varios estudios que se centran en el transporte público en relación con las personas de tercera edad.

En [43], Linchuan Yang reivindica la necesidad de nuevas políticas en el transporte de Hong Kong enfocadas en la tercera edad. En este estudio se modeliza la elección de movilidad de los usuarios de tercera edad con el fin de encontrar las políticas que más pueden amoldarse a estas personas.

En [40], W.Y Szeto et. al. usan datos demográficos (sacados de entrevistas) junto con los datos de los viajes en transporte público para comparar los patrones espacio temporales de esta población con los de otras poblaciones. Este artículo tiene como fin impulsar nuevas políticas que aumenten la accesibilidad del transporte de Hong Kong para este segmento de la población.

Levin Lena entrevista a personas de tercera edad en [29] con el fin de analizar la visión que tienen estas personas respecto a sus posibilidades de usar el transporte público de Suecia. Este es un modo de analizar la relación entre el transporte público y las personas de tercera edad que tiene como propósito entender la visión de esta población sobre el transporte.

2.2. Estado del Arte del análisis de movilidad en el transporte público

En [36], Prayag Girish ofrece un estudio centrado en el turismo que realiza este segmento de la población en la ciudad de Nice. Entre los motivos destacados para la realización de turismo por parte de este segmento de la población se encuentran: pasar tiempo con la familia, descansar y relajarse.

2.2.4. Análisis del comportamiento individual en el uso del transporte público

Hay varios trabajos relacionados con el análisis del comportamiento individual de los usuarios en el transporte público. Algunas características básicas del comportamiento de un usuario son su regularidad o los cambios en su comportamiento.

En [16], Goulet-Langlois G. et. al. proponen un algoritmo para medir la regularidad de los individuos en el transporte público. Una de las características de este artículo es que no se define la regularidad de una persona según la periodicidad de sus viajes en un periodo concreto sino según la repetición de las subsecuencias de los eventos, es decir, elimina la unidad temporal que suele estar enlazada a la definición de regularidad.

Otros métodos de análisis del comportamiento se basan en saber cuándo éste ha sufrido un cambio. Esto es lo que realizan en [45] aplicando la red bayesiana definida en [1] al ámbito del transporte público. En esta propuesta la red bayesiana es capaz de detectar cuando se ha producido un cambio en el comportamiento individual de un sujeto.

Capítulo 3

Descripción de los datos, almacenamiento y preprocesado

En este capítulo se describirán los datos usados, los cuales, como ya se ha mencionado anteriormente no contiene datos se hayan visto afectados por la pandemia del COVID-19, ni datos personales de los usuarios de modo que se ha respetado la confidencialidad y privacidad de los usuarios. También se describe el proceso de almacenamiento y el pre-procesamiento requerido por los datos.

3.1. Descripción de los datos

Para la realización de esta investigación, el CRTM proporcionó dos tipos diferentes de datos: los registros de embarques realizados por usuarios con un abono de tercera edad y las topologías de los distintos medios de transporte utilizados en este proyecto. A continuación se describen ambos conjuntos de datos y sus características más relevantes.

3.1.1. Registros de embarques

Estos datos consisten en los registros de embarque realizados en Metro, EMT o autobuses interurbanos desde 01-01-2016 hasta 01-02-2020 con un abono de tercera edad. Este abono debe estar vigente en el momento del viaje y debe estar cargado en una tarjeta personal. Los viajes realizados sin este abono activo en una tarjeta personal no formaran parte de los registros a analizar. Esta decisión se ve apoyada por el hecho de que el precio del abono de tercera edad es muy bajo, y por tanto su uso es generalizado en la población de este segmento. De hecho, esta situación puede verse incrementada con la gratuidad del abono que se producirá a partir de 2021.

Cada registro de embarque consta de diferentes atributos, algunos de los más relevantes son los siguientes:

- **Id del usuario** Este número identificativo es el hash del ID de la tarjeta de transporte que contiene el abono de tercera edad con el que se realiza el viaje. Por cada tarjeta de transporte público existe un ID que identifica dicha tarjeta de manera única. Las propiedades de la función hash impiden que se identifique

la tarjeta de transporte con la que se realiza el viaje a partir de este id, lo que permite respetar la privacidad y confidencialidad de los usuarios.

- **Fecha de viaje**
- **Dpaypoint:** Este atributo nos permite unir la parada del medio en el que se ha realizado el viaje (dato que pertenece a las topologías) con los registros de embarque.
- **Código del título:** Es el tipo de tarjeta o de abono.
- **Código del perfil:** Es el tipo de perfil que tiene el usuario. Si un usuario es joven, se le podrán aplicar los títulos que están a disposición para las personas jóvenes, y lo mismo para las personas de tercera edad.
- **Código de descuento.**
- **Código tlv:** El campo TLV es un indicador para saber desde qué medio de transporte se lleva a cabo la transacción.
- **Código del resultado de la transacción:** Es un código de verificación del resultado de la transacción. Esto permite almacenar errores que se hayan podido producir.

En el siguiente cuadro se observa una ejemplificación de un registro de embarque con los atributos más relevantes.

Tarjeta	fecha del viaje	dpaypoint	código del título
Persona 1	2020-01-01T01:21:44	2F_*L501_*P32	1052
código de perfil	código de descuento	código tlv	Código transacción
02	00	c1	1

Cuadro 3.1: Ejemplo de un registro de viaje con sus atributos más relevantes.

3.1.2. Topología de la red de transporte público

En esta sección se explicará cómo son los datos de las topologías, las cuales definen para cada tipo de transporte involucrado en este proyecto (Metro, EMT e Interurbanos) los atributos de cada una de las paradas que componen la red de transporte de cada uno de estos medios.

Cada uno de estos registros (paradas) contienen atributos propios del operador. Entre los atributos de cada parada se pueden encontrar algunos que son comunes a todos los medios de transporte. Los más relevante para este proyecto son los siguientes:

- **Dpaypoint:** Identificador de la estación que permite relacionar los registros de embarque con la parada en la que se ha comenzado el viaje.
- **LATITUD y LONGITUD:** Estos dos atributos especifican la localización geográfica de la parada.

Cada parada (registro) tiene más atributos pero no se van a listar en este trabajo, por no ser relevantes.

A continuación se incluye el registro de una parada, en este caso de Metro, con sus atributos más relevantes para este trabajo. Todos los atributos mostrados son

Descripción de los datos, almacenamiento y preprocesado

comunes en las tres topologías utilizadas.

Latitud	Longitud	Id Parada	dpaypoint	Denominación	Código municipio	Código postal
40,38732	-3,63951	24	02_L1_P24	Miguel Hernández	28079	28038

Cuadro 3.2: Ejemplo de un registro de una parada con sus atributos más relevantes.

Sin embargo, no todos los registros de paradas contienen un dpaypoint, sino que hay registros en los que este atributo no está definido. Por lo tanto, los registros de embarque que se realicen en las paradas que carecen de este atributo no podrán relacionarse con los registros de las paradas y por tanto tampoco se podrá obtener la localización geográfica donde se realizó dicho viaje. En el siguiente cuadro se resume el número total de paradas que hay en cada medio de transporte usado en este estudio, así como cuántas paradas de cada medio no tienen definido el dpaypoint.

	Número de paradas	Numero de paradas con dpaypoint
EMT	10846	10430
Metro	782	511
Interurbano	32830	31248
TOTAL	44456	42189

Cuadro 3.3: Número de paradas de cada medio de transporte totales y sin dapypoint.

3.2. Almacenamiento

En esta sección se explicará cómo se han almacenado los datos, el preprocesado que ha sido requerido y algunas consideraciones a tener en cuenta relacionadas tanto con los datos como con su tratamiento y almacenamiento.

El propósito de este trabajo es examinar los viajes realizados con un abono de tercera edad vinculado a una tarjeta de transporte público personal en los medios de Metro, interurbano o EMT de la comunidad de Madrid. Teniendo en cuenta que la población de la comunidad de Madrid es de más de 6 millones de personas, según el INE, es lógico que la cantidad de viajes que se realizan en transporte público sea bastante grande. **Debido a la cantidad de datos y a los recursos disponibles por la autora del proyecto únicamente se almacenaron los registros comprendidos entre 1-10-2016 hasta 31-12-2019.** Sin embargo, aun con la reducción de datos que supone la concretización de la cuestión de estudio y la reducción del periodo de observación, la cantidad de datos a almacenar sigue siendo considerablemente grande. Entre los datos almacenados hay una media de 15 millones de registros mensuales y un total de 888.253 usuarios.

En la siguiente sección se explicará cómo se han almacenado estos datos y qué sistema gestor de bases de datos se ha utilizado, así como los razonamientos que han llevado a estas decisiones.

3.2.1. El sistema gestor de bases de datos: InfluxDb

Dada la cantidad de datos a analizar en este proyecto, un correcto almacenamiento es imprescindible para poder acceder a los datos de una manera rápida así como para poder almacenar la mayor cantidad de datos posible. Dado que el objetivo de este proyecto es la predicción individual y que los registros de cada individuo están ordenados temporalmente, es decir, forman una serie temporal, se debe utilizar un sistema de almacenamiento que permita almacenar series temporales. Debido a esto, se eligió el gestor de bases de datos InfluxDb [22] ya que está diseñado para almacenar series temporales.

Para almacenar los dos tipos de datos **se crearon dos bases de datos distintas, una cuyo fin es almacenar los registros de los usuarios y otra para almacenar la información de las paradas**. El motivo principal para la creación de dos bases de datos distintas, en vez de añadir la información de las paradas en cada registro, fue la ausencia de `dpoint` en algunos registros de la topología. Esta decisión facilitará la inserción de estos datos, cuando estén disponibles, sin la necesidad de tener que preprocesar de nuevo todos los registros de embarque.

La base de datos que almacena los registros de embarque se denominó *crtm* y la que almacena la información de las paradas se denominó *top*. La subida de los datos, tanto de los registros de embarque como de las topologías, se realiza con el código *B1_01_Preprocess.py*, que se encuentra en el repositorio de GitHub.

A continuación vamos a ver algunas características de estas bases y del preprocesamiento que se realizó para insertar los datos.

3.2.1.1. Almacenamiento de los registros de embarque en la base de datos *crtm* de InfluxDb

Esta base de datos almacena una serie temporal por cada usuario. Cada registro tendrá todos los atributos mencionados en la sección 3.1.1. Además por cada usuario los registros de embarque se ordenan temporalmente de una manera automática, lo cual facilita la extracción de información, ya que al reclamar los datos de un cierto usuario, InfluxDb devuelve directamente la serie temporal, es decir, los datos ordenados temporalmente. Esto se ha de tener en cuenta si se quiere reutilizar el software creado en este proyecto con otro gestor de bases de datos, ya que los datos no han necesitado ordenarse manualmente gracias a la funciones de InfluxDb.

Es importante tener cuidado con la subida de estos datos ya que es un proceso con mucho coste temporal y en el cual se pueden producir excepciones de tiempo por parte de InfluxDb. El periodo de observación de este proyecto se redujo debido al coste de inserción y a la falta de espacio de almacenamiento por parte de la autora de este trabajo, por lo que tener unos recursos apropiados para este almacenamiento es un factor clave si se quiere almacenar más datos. Hay que tener en cuenta que cuanto más cobertura temporal sea almacenada, las series temporales serán más largas y por tanto los algoritmos tendrán más observaciones de las que aprender. Esto es importante porque muchos algoritmos solo funcionan correctamente con series temporales con suficientes datos.

En este caso no fue necesario realizar ningún preproceso especial, ni siquiera se eliminaron usuarios con un número de registros menor que cierta cantidad como se

hizo en trabajos previos [26].

3.2.1.2. Almacenamiento de la topología de la red de transporte en la base de datos top de InfluxDb

En esta base de datos únicamente se almacenaron aquellos registros de paradas que tenían `dpaypoint`. Por tanto, el número de paradas de cada medio de transporte que se han almacenado son las que se encuentran en la última columna del cuadro 3.3. Hay que tener en cuenta que no se eliminaron de la base de datos `crtm` aquellos registros cuyo `dapypoint` no estaba contenido en ningún registro de la base top, ya que dependiendo de las características de la serie temporal que se quiera estudiar estos registros podrán ser valiosos. Por ejemplo, para realizar una predicción del número de viajes que un cierto usuario realizará la semana que viene, no es necesario saber el lugar en el que se produjeron los viajes. Sin embargo, si se quieren realizar estudios en los que intervenga el factor espacial, como por ejemplo, la predicción del barrio del siguiente viaje, entonces los registros cuyo `dpaypoint` no está en la base de datos top no pueden ser utilizados. Dado que en este proyecto se querían realizar varias representaciones, cada una centrada en una característica diferente de los datos, no se eliminaron los registros de embarques que no podían ser ubicados geográficamente.

A los registros almacenados se les añadió varios atributos para facilitar la búsqueda del barrio y distrito al que pertenecía dicha parada. **Los atributos que se añadieron fueron: tipo de transporte, nombre del barrio al que pertenecía dicha parada, nombre del distrito e id del barrio.** Todos los atributos relacionados con el barrio y el distrito que se han introducido únicamente son para aquellas paradas del municipio de Madrid, ya que los estudios espaciales de este trabajos se centrarán en este municipio. El motivo de incluir la información del tipo de transporte fue el de ofrecer la oportunidad, en trabajos futuros, de que únicamente se analicen los viajes de un único medio de transporte.

Capítulo 4

Materiales

En este capítulo se explicarán diversas herramientas desarrolladas en el transcurso de este trabajo, las cuales tienen como fin poder comprender el comportamiento de los usuarios, sobretudo a nivel individual aunque también se verán representaciones que permitirán cuantificar datos globales. También se expondrán herramientas que permitirán descomponer la serie temporal de un usuario, cuantificar su correlación o el número de semanas con un cierto número de viajes a lo largo de los registros de un usuario. Estas últimas herramientas permitirán entender las predicciones y extraer las características relevantes de las series temporales de este trabajo que permiten una correcta predicción.

Con el fin de poder realizar trabajos futuros, todas las herramientas se han implementado de modo que puedan ser utilizadas en este y en otros trabajos.

4.1. Representaciones globales

Con el fin de representar el comportamiento global de la población de estudio, se han creado dos representaciones. La primera permite visualizar geográficamente las paradas de transporte involucradas en este trabajo, por lo que permite identificar zonas geográficas con una alta concentración o dispersión de estaciones de transporte público a la vez que permitirá conocer los medios de transporte involucrados en dicha dispersión o aglomeración. La segunda nos permite visualizar el número de nuevos usuarios y de abandonos que se han producido cada año.

4.1.1. Estaciones de transporte de la Comunidad de Madrid

En esta representación se sitúa geográficamente las distintas paradas almacenadas en la base de datos top, según el tipo de medio de transporte al que pertenecen. Esta representación permite observar la distribución de los diferentes medios de transporte usados en este trabajo así como su dispersión y concentración. Esta representación se genera con el código *B3_01_representaciones_globales.py*, que se encuentra en el repositorio de GitHub.




Figura 4.1: Representación geográfica de todas las estaciones del transporte público de Madrid pertenecientes a los medios de Metro, EMT e Interurbanos.

En cuanto a la dispersión de las paradas, se observa una mayor concentración en el municipio de Madrid, en contraste con la dispersión y superioridad de los autobuses interurbanos en el resto de municipios de la comunidad de Madrid. Con el fin de poder observar esta concentración y examinar la presencia de los medios en este municipio se puede observar el siguiente gráfico.




Figura 4.2: Representación geográfica de todas las estaciones del transporte público de Madrid pertenecientes a los medios de Metro, EMT e Interurbanos, centrada en el municipio de Madrid.

Observando las dos figuras se puede concluir que los autobuses interurbanos están más dispersos por toda la comunidad de Madrid, pero su presencia en el municipio de Madrid es relativamente baja en comparación con la presencia de los otros medios de transporte, los cuales principalmente se encuentran en este municipio. Por tanto, el principal medio de transporte de los usuarios que viven en el municipio de Madrid son EMT y Metro, mientras que el principal medio de transporte de los usuarios que no viven en este municipio son los autobuses interurbanos.

También se puede observar que el número de paradas de los autobuses interurbanos es superior al número de paradas de los otros dos medios, del mismo modo que se observa que el número de paradas de Metro es bastante inferior. Este gráfico por tanto no solo nos permite observar la dispersión y concentración de las paradas sino que además nos permite observar la información expuesta en el cuadro 3.3 de una manera gráfica.

4.1.2. Recuento de usuarios según el año de su primer y último viaje

Estas imágenes muestran la cantidad de personas según el año en el que realizaron su primer y último viaje. Estas gráficas son meramente informativas, ya que sin más datos no pueden realizarse estadísticas ni estudios de predicción sobre ellos. Sin embargo, con más datos esta representación puede ser muy útil, permitiendo estudios globales relacionados con el número de nuevos individuos por año o con el número de abandonos por año. A su vez con estudios de predicción se podría saber cuántos individuos van a abandonar el transporte el próximo año. Estas imágenes se han realizado con el código *B3_01_representaciones_globales.py*, que se encuentra en el repositorio de GitHub.




Figura 4.3: Recuento de los usuarios según el año de su primer viaje.




Figura 4.4: Recuento de los usuarios según el año de su último viaje registrado.

En estas imágenes se observa que el número de usuarios que han dejado el transporte en 2017 y 2018 son muy similares. No se puede comparar estas cifras con las de 2019 ya que al ser este el último año almacenado en nuestra base de datos no se puede saber si los usuarios han abandonado el transporte o van a usarlo en 2020. Tampoco se puede comparar estas cifras con las de 2016 ya que solo están almacenados unos pocos meses de este año.

Por otra parte, también se aprecia que el número de nuevos usuarios en el 2017, 2018 y 2019 es similar. El número de usuarios que han empezado a usar el transporte en 2016 es tan grande ya que esta cifra engloba a todos los usuarios cuyo año de inicio es el 2016 o años anteriores y que a finales de 2016 siguen usando el transporte. Por tanto este año no puede compararse con los demás.

Estos resultados parecen indicar que tanto la cifra de abandonos como la cifra de ingresos es similar cada año. Se necesitan más datos para poder cuantificar y verificar si verdaderamente el número de nuevos usuarios y abandonos es similar. Sin embargo, según lo observado, se espera que esta hipótesis se verifique. En caso de que así sea, cuando una de estas cifras sufra un aumento o descenso drástico, se podrá concluir que ha sido debido a un acontecimiento que ha afectado a las personas a nivel global. Un ejemplo muy claro de esto se observaría en los datos de 2020 y 2021, ya que es evidente que la movilidad de las personas de tercera edad se ha reducido drásticamente debido al COVID-19. Aunque este caso es muy radical también permitiría detectar este aumento o descenso en casos menos radicales. Además

esta representación permite cuantificar dicho cambio, permitiendo saber la gravedad de este aumento o descenso.

4.2. Representaciones individuales

Esta sección se compone de diversas representaciones, cada una de ellas describe una característica diferente del comportamiento de cada individuo. Como los registros que un usuario ha realizado están ordenados por el tiempo, forman una serie temporal. Como los viajes que realiza un individuo no se producen cada cierto tiempo exacto, sino que son producidos en un tiempo aleatorio es necesario una agrupación por unidad temporal, sease días, semanas o meses. Dependiendo de la característica que se agrupe por unidad temporal obtendremos una u otra representación. Las representaciones que se expondrán en este trabajo se pueden dividir en cuatro: según la frecuencia de los viajes, según el sitio en el que se realizó el embarque, según la hora a la que se inician los viajes y según el tiempo transcurrido entre viajes. Además estas cuatro representaciones se podrán elegir con y sin limpieza dando un total de ocho representaciones que se calculan con el código *B3_02_User_representation.py*.

Todas las representaciones empiezan con el primer registro que se encuentre en la base de datos de dicho usuario y el último punto de la serie temporal será el día, la semana o el mes correspondiente a finales de diciembre de 2019. **Además únicamente los individuos que han realizado más de 30 viajes tienen una representación de sus registros en forma de serie temporal, en caso contrario no se realiza ninguna representación con dicho usuario.**

A continuación se verán estas representaciones con más detalle. Todas las imágenes que van a ser expuestas en esta sección, a excepción de que se mencione lo contrario, son del mismo individuo.

4.2.1. Representación basada en la frecuencia

La frecuencia es la cantidad de viajes que un usuario realiza por unidad de tiempo. Las unidades de tiempo posibles son días, semanas o meses. Esta representación por cada unidad de tiempo marca la cantidad de viajes realizados entre ese tiempo y el siguiente.

Esta representación es muy útil, ya que la frecuencia es una característica muy importante del comportamiento de un usuario. Como se observa en la figura 4.5, cada agrupación proporciona una visión diferente de la serie temporal. Por un lado, con la agrupación por días las fluctuaciones de los datos son muy grandes, mientras que por meses observamos una serie temporal más estable y con menos tendencia. Dentro de estos dos extremos se encuentra la agrupación por semanas, que nos permite tener un punto medio entre la varianza de la serie temporal por días y meses. Es importante tener en cuenta que cuanto más grande sea la unidad temporal menos registros tiene la serie temporal pero el comportamiento es más estable en relación con las fluctuación que se encuentran con unidades temporales más pequeñas.




Figura 4.5: Representación de la frecuencia de un usuario según las distintas unidades temporales.

4.2.2. Representación basada en las características espaciales

Esta representación resalta el factor espacial del comportamiento de un usuario. En concreto dentro del factor espacial se examinarán los barrios o distritos del **municipio de Madrid** en el que dicho usuario ha realizado cada viaje. En esta representación los viajes realizados a paradas cuyo `dppoint` no está en la base de datos `top` no pueden ser tomados en consideración, ya que estos viajes no pueden ser ubicados.

Los estudios espaciales están enfocados en el municipio de Madrid, más concretamente en los barrios y distritos de este municipio, por lo que todos los viajes producidos en las paradas que no pertenecen a este municipio se clasificaron como realizados en Outskirts. Esta consideración también se llevó a cabo en proyectos anteriores debido a la necesidad de acotar el terreno antes de realizar estudios más amplios, además de la necesidad de enfocarse en aquellos lugares espaciales en los que la concentración de paradas de los diversos medios de transporte analizados es mayor. En trabajos futuros se deberá ampliar estas representaciones a los barrios y municipios de toda la comunidad de Madrid.

Esta representación puede tener un enfoque global, es decir, se puede calcular el recuento de los viajes realizados a cada barrio o distrito del municipio de Madrid de un cierto usuario. En la primera figura observamos un recuento de los viajes según el distrito en el que se inició cada viaje de un usuario, mientras que en la segunda se observan los barrios del municipio de Madrid según la cantidad de embarques que el usuario ha realizado en cada uno de ellos.




Figura 4.6: Recuento total de los viajes realizados por el usuario según los distritos




Figura 4.7: Recuento total de los viajes realizados en los diferentes barrios

Además de estas representaciones globales también se puede realizar representa-

4.2. Representaciones individuales

ciones con las que no se pierda la serie temporal y cuyo objetivo sea resaltar las características espaciales de esta misma. Por un lado, tenemos una representación individual en la que se observan según los días, semanas o meses, la cantidad de viajes que dicho usuario ha realizado a cada barrio o distrito del municipio de Madrid. Hay tres posibles unidades temporales y además este gráfico se puede realizar tanto con los barrios como con los distritos. A continuación únicamente se muestran dos imágenes ambas con la unidad temporal de semanas, una de ellas según los distritos y otra según los barrios.




Figura 4.8: Diagrama espacio temporal por semanas según barrio




Figura 4.9: Diagrama espacio temporal por semanas según distritos

Por otro lado, también se puede representar la serie temporal de la frecuencia pero en este caso se representará una serie temporal por cada barrio o por cada distrito. De este modo la serie temporal representa la frecuencia de los viajes de una persona a un barrio o distrito concreto. Solo se mostrará el agrupamiento por semanas (según los barrios y los distritos) pero también se puede encontrar esta representación con una unidad temporal de días y meses.




Figura 4.10: Serie temporal de frecuencia por semanas de cada barrio




Figura 4.11: Serie temporal de frecuencia por semanas de cada distrito

Estas últimas imágenes permiten observar que serie temporal de un distrito o barrio es dominante respecto a las series temporales asociadas a los demás distritos o barrios. Esta comparativa de series temporales puede ser muy beneficiosa, por ejemplo, para realizar una limpieza de la serie temporal conjunta, eliminando todas aquellas series temporales que no son la dominante o eliminando aquellas que no tienen un número mínimo de viajes.

4.2.3. Representación basada en las características temporales

Esta representación resalta el factor temporal del comportamiento de un usuario, permitiendo observar las horas en las que el usuario suele viajar, así como patrones temporales respecto a la hora en la que el usuario observado coge el transporte.

La figura 4.12 muestra información global respecto a la característica temporal, en ella se observa el recuento de la cantidad de viajes que ha realizado el usuario a cada hora del día.




Figura 4.12: Recuento temporal total por horas

Además de esta representación se puede encontrar otra en la que se observa según los días, semanas o meses la cantidad de viajes que dicho usuario ha realizado a cada hora del día. De este modo, se puede saber, por ejemplo, las horas a las que más ha viajado un usuario el tercer día desde el inicio de su uso del transporte. Las unidades temporales posibles son días, semanas y meses aunque a continuación sólo se muestran por meses.




Figura 4.13: Diagrama temporal por meses

4.2.4. Representación según las diferencias de tiempo en los viajes

Esta última representación no está diseñada para presentarla al usuario de manera informativa, sino para conseguir que la media de la serie temporal resultante de la representación sea constante en el tiempo. Este objetivo se requiere debido a que hay algoritmos de predicción que necesitan que la serie temporal introducida sea estacionaria y por tanto deben tener una media y varianza constantes en el tiempo. Esta representación se basa en las diferencias de tiempo entre los viajes y en un agrupamiento de estas diferencias según los días para obtener una representación con media constante en el tiempo y eliminar la tendencia.




Figura 4.14: Representación basada en las diferencias de tiempo entre los viajes con una agrupación por días y una posterior compensación del tiempo en los días.

Los pasos para conseguir esta representación son los siguientes: primero se calculan las diferencia entre los tiempos de los viajes, después se realiza una agrupación por días de estos valores y como último paso se realiza una compensando entre los días cuyo valor en segundos es mayor a los segundos de un día entero con los días anteriores cuyo valor era 0. En esta compensación de tiempo no se pierden segundos sino que simplemente se quita de los días cuyo valor asociado en segundos es más que los segundo que tiene un día entero y se les da esta cantidad sobrante a cada uno de los días anteriores cuyo valor en segundos es 0. Este proceso se debe realizar hasta que no haya más días anteriores cuyo valor es 0 o hasta que el día del que se están quitando segundos pasa a contener menos segundos que los segundos que tiene un día. De este modo creamos una representación más equilibrada.

Por lo tanto, una vez realizada esta representación y una vez realizada una normalización de los datos aplicando la función logaritmo tenemos la imagen que acabamos de ver. Aquellos días cuyo valor es 0 es debido a que el usuario no realizó ningún viaje ese día, cuando es superior a 0 es debido a que el usuario llevaba más de un día sin realizar viajes cuando lo realizó y cuando son menores que cero implica que el viaje anterior en ese día.

Esta representación tiene algunas características interesantes, tales como que su media es constante en el tiempo y que se ha eliminado la tendencia. Por otro lado, la forma que tenga esta gráfica puede aportar información sobre la constancia de uso del transporte por parte del usuario. De modo que si la serie tiene rayas verticales espontáneas entonces la constancia puede tomarse como irregular mientras que si la gráfica muestra una gran densidad y agrupación de las líneas verticales estamos ante un usuario con mucha constancia en el uso del transporte, como es el ejemplo que se observa en la imagen.

4.2.5. Representaciones individuales con una limpieza de los viajes

En esta sección están las mismas representaciones que se pueden encontrar en las secciones anteriores pero con una diferencia, los viajes sobre los que se realizan las representaciones serán únicamente aquellos con una cierta repetición en el tiempo a la misma parada y en las mismas horas y solamente si este hecho se ha repetido en el tiempo más de un número concreto de veces. Por lo tanto, las series temporales contendrán menos viajes que las anteriores pero todos aquellos viajes tendrán una repetición plausible en el tiempo.

El principal motivo de esta limpieza, que es opcional, es debido al intento de conseguir obtener un esbozo del patrón general mínimo de los viajes del usuario. La población que se analiza en este trabajo tiene características diferentes respecto a otras poblaciones tal y como demostró Alexander Lacki en trabajos anteriores [26]. En cuestión de patrón plausible de movimiento estas gráficas no son comparables con las que se pueden observar en las personas que necesita coger el transporte para ir a trabajar cinco días a la semana, por lo que el principal objetivo de esta función es intentar discernir un patrón de movimiento rutinario de modo que los algoritmos de predicción aprendan mejor el comportamiento de uso del usuario debido a la eliminación previa de aquellos viajes realizados esporádicamente y que carecen de repetición en el tiempo.

Como las gráficas son las mismas que las anteriores no se expondrán todas ellas, sino que únicamente se expondrá una comparativa de la representación de la frecuencia con y sin limpieza de modo que se pueda ver el impacto de esta limpieza. Es importante tener en cuenta que dependiendo del comportamiento del usuario en su toma de transporte el impacto de esta limpieza será mayor o no.

En la figura 4.16 se pueden observar diversos cambios, los más obvios se ven en la gráfica de meses, por ejemplo en 2018-07 o en 2018-12 fechas en las cuales es normal que se salga de la rutina y se realicen viajes distintos e inusuales que no sirven para aprender el comportamiento general de un usuario. En la serie temporal por meses se nota mas visualmente pero en las otras dos series temporales también se pueden encontrar diversos picos cuyo valor ha disminuido. Si se observa el final de la serie temporal por días cuando tiene aplicada la limpieza se ve más regular sin tantas fluctuaciones irregulares dando un resultado más ordenado. Este es el objetivo de este limpieza. Se han resaltados ciertos cambios con el objetivo de facilitar la visualización de estos mismos.




Figura 4.15: Representación de la frecuencia según las distintas unidades temporales de un usuario en concreto.




Figura 4.16: Representación de la frecuencia según las distintas unidades temporales de un usuario en concreto con una limpieza previa de dichos viajes.

Hay muchas formas de conseguir limpiar una serie temporal de viajes anómalos. Sin embargo, hay que tener en cuenta que basarse en la repetitividad de los embarques de las personas de tercera edad para realizar una limpieza puede no ser beneficioso ya que son personas sin trabajo que de normal se mueven por ocio u obligaciones esporádicas que no tiene que implicar una repetitividad. Por tanto, muchas limpiezas típicamente usadas, y que en otros segmentos de la población se podrían aplicar sin problemas, pueden no ser idóneas para limpiar el ruido de estas series temporales. Tampoco es conveniente que esta limpieza conlleve una unidad temporal fija, ya que

en esta población cada individuo puede tener su propia unidad temporal. En trabajos futuros se recomienda estudiar diferentes funciones de limpieza examinando el efecto de estas sobre las predicción realizadas con los diferentes algoritmos de predicción.

4.3. Análisis de las series temporales

Estas herramientas de análisis permitirán entender las predicciones y extraer las características relevantes de las series temporales que permiten una correcta predicción. Por tanto, permitirán entender mejor los resultados de los algoritmos de predicción y ampliar el conocimiento sobre las series temporales examinadas.

4.3.1. Descomposición de una serie temporal

El análisis que se va a realizar en este apartado consiste en la descomposición de una serie temporal en sus componentes básicos los cuales se explicaron en el capítulo 2, más concretamente en la sección 2.1.2. En este trabajo se utilizarán tres tipos de algoritmos de descomposición: el algoritmo de descomposición estacional que proporciona la librería statsmodels [38], el filtrado de Hodrick-Prescott expuesto por Robert Hodrick y Edward Prescott en [20] y la descomposición de tendencia-estacional que se basa en la función LOES (STL) expuesta por Robert Cleveland et. al. en [8].

Estas descomposiciones pueden ser realizadas sobre la serie temporal de la frecuencia, con cualquier unidad temporal, de un usuario, así como su representación basada en las diferencias de tiempo. A estas cuatro representaciones se les puede añadir la opción de limpieza explicada anteriormente. El código que nos permite realizar estas descomposiciones es *B4_01_descomposicion.py*.

En las siguientes secciones se expondrá un ejemplo de la descomposición que proporciona cada uno de estos algoritmos con la serie temporal basada en la frecuencia por semanas de un mismo usuario.

4.3.1.1. Descomposición estacional de la librería statsmodels

En las siguientes imágenes podemos ver el resultado de la descomposición de statsmodels.




Figura 4.17: Descomposición de la serie temporal en elementos básicos de la librería statsmodels.




Figura 4.18: Representación conjunta de los elementos de la descomposición estacional de la librería statsmodels.

Lo primero que se observa en esta descomposición es que el componente de la tendencia no tiene los valores asociados a los primeros y últimos elementos. Esto es debido a que se realiza un moving average, por lo que al realizar la media con los valores pa-

sados y futuros se necesita que al menos haya un número mínimo de valores pasados o futuros para poder obtener dicho valor. Esto es un gran inconveniente porque se pierde parte de la serie temporal. La tendencia tiene una variación bastante notable y no es tan suave como se podría esperar. Además no parece que sea intuitiva, ya que al tener en cuenta para un valor tanto los valores futuros como los pasados la tendencia produce este efecto tan llamativo que se aprecia en la fecha de 2018-09 o 2019-01 (recuadro marcado en la figura 4.17), de tener subidas cuando los datos de la serie observada está decreciendo o al revés. Esto indica que la tendencia obtenida en esta descomposición tarda mucho en verse afectada por los datos observados.

Por otra parte, el componente estacional presenta una periodicidad en la que se observan los bucles repetidos a lo largo del tiempo. Los residuos de esta descomposición alcanzan la magnitud que tiene la serie observada indicando que esta descomposición no es demasiado adecuada.

4.3.1.2. Descomposición de Hodrick-Prescott

En las siguientes imágenes podemos ver el resultado de la descomposición de Hodrick-Prescott.




Figura 4.19: Representación de los elementos de la descomposición de la frecuencia semanal según la descomposición de Hodrick-Prescott.




Figura 4.20: Representación conjunta de todos los elementos de la descomposición de la frecuencia semanal según el filtrado de Hodrick-Prescott.

En contraste con la descomposición anterior el componente de la tendencia tiene la misma longitud que la serie observada por lo que no se pierden valores. Además de esto la tendencia no tarda en verse afectada cuando la serie temporal crece o decrece drásticamente, ajustándose bien a los cambios en la tendencia de la serie y sin tener un cierto retardo. Además la tendencia es más suave que la obtenida en la descomposición anterior.

Uno de los puntos a favor de esta descomposición es que los valores de los residuos son siempre cero o prácticamente cero, lo cual es muy bueno en comparación con otras descomposiciones. El componente cíclico es muy semejante a la serie observada sobretodo en cuestión de picos aunque estos son de menor magnitud debido a la extracción de la tendencia (recuadros rojos). No se aprecia ningún bucle repetitivo en este componente.

4.3.1.3. Descomposición de la tendencia-estacional usando LOESS (STL).

En las siguientes imágenes podemos ver el resultado de la descomposición STL.




Figura 4.21: Representación de los elementos de la descomposición de la frecuencia semanal con el filtrado STL.




Figura 4.22: Representación de los elementos de la descomposición de la frecuencia semanal con el método STL.

La principal característica de esta descomposición es la poca varianza que tiene la tendencia siendo muy suave. Define el movimiento de la serie observada de una manera muy general, permitiendo ver si el movimiento en sí es creciente o decreciente

a niveles generales. Por tanto, este componente es muy estable y se verá afectado únicamente por cambios muy grandes y prolongados en el tiempo. Además al igual que en la descomposición anterior no se pierden valores y es una curva suave, sin descensos dramáticos o cambios bruscos en la curvatura.

El componente estacional, al igual que pasaba en la descomposición anterior, se parece mucho a la forma que tiene la serie observada aunque se nota cierta diferencia en algunos momentos como por ejemplo en el pico central más alto (recuadro de la figura 4.21). Esta diferencia es resultado del método de descomposición ya que se observa el valor de dicho pico en el componente residual, mientras que en la descomposición anterior al no tener residuo este pico se obtiene en el componente cíclico

4.3.2. Comprobación de la estacionalidad

Dentro de las técnicas que se aplican para comprobar la estacionalidad de una serie, en este trabajo como métodos gráficos se implementó el correlograma que permite saber cuenta es la correlación de los datos. La correlación es una medición de lo relacionado que está un valor con sus valores pasados y puede resultar muy útil a la hora de entender algoritmos como el ARIMA. En concreto esta función está pensada únicamente para la representación de la frecuencia con cualquier unidad temporal y se realiza con el código *B4_04_caracteristicas.py*.




Figura 4.23: Correlograma de una serie temporal.

En esta imagen se observa una gran correlación entre los datos, al tener ese patrón circular marcado y un descenso lento, aunque no esta claro.

Dentro de los test estadísticos que pueden usarse para comprobar la estacionalidad de una serie, en este trabajo se utilizarán los test estadísticos Dickey-Fuller y Kwiatkowski-Phillips-Schmidt-Shin (KPSS) que están implementados en el código *B4_02_estacionalidad.py*.

4.3.3. Cardinalidad de la frecuencia

Por otro lado, se implementó una última herramienta de análisis la cual a pesar de ser muy sencilla puede ayudar a entender por qué una predicción ha dado un valor u otro. Este análisis también se basa en la representación de la frecuencia, en específico, por semanas y el código que permite este análisis es el de *B4_04_caracteristicas.py*.

Este gráfico nos muestra la cantidad de semanas que un usuario ha realizado un cierto número de viajes. Este gráfico permite entender mejor algunas predicciones. En este caso por ejemplo una predicción de un valor 0 o 2 sería normal debido a la gran superioridad de estos valores frente al resto. Es un análisis muy sencillo pero a la vez permite una visión de cuantas veces por semana dicho usuario suele usar el transporte y por ende también informa sobre su constancia en el uso del transporte.




Figura 4.24: Cardinalidad de la frecuencia.

4.4. Conclusiones

En esta sección se han analizado diversas herramientas desde representaciones globales, hasta representaciones de las series temporales de cada individuo, en las que en cada una se resalta alguna de las características básicas de la movilidad. También se encuentran diversas herramientas de análisis de series temporales, que permiten observar su descomponer o verificar la correlación y estacionalidad de la serie temporal. Además todas las herramientas fueron diseñadas de modo que puedan ser utilizadas en otros proyectos.

Capítulo 5

Métodos

El objetivo de este trabajo es la predicción individual del uso del transporte público por parte de los usuarios de tercera edad, con el propósito de que estas predicciones puedan ser usadas en trabajos futuros para detectar cambios, de forma prematura, en el comportamiento de los usuarios. Como se mencionó anteriormente uno de los cambios en el comportamiento que más interesa detectar es el abandono debido al decaimiento de salud que suele, generalmente, conllevar en este segmento de la población. Por tanto, los experimentos a realizar, en este caso las predicciones, han de ser individuales permitiendo examinar los motivos particulares que han llevado a cada usuario a un cambio en su conducta.

Es debido al enfoque individual que debe tener este estudio que los datos se agruparon según el individuo que realizó cada viaje. Como se comentó en el capítulo 3, por cada usuario el conjunto de sus viajes tiene una ordenación según el tiempo en el que fueron realizados, por lo que forman una serie temporal. Aunque este estudio tenga un enfoque individual, los datos usados están anonimizados en su origen, es decir, por parte de CRTM por lo que se ha respetado la confidencialidad y privacidad de los usuarios.

Tal y como se ha comentado en el transcurso de este trabajo existe una gran diferencia en el comportamiento de uso del transporte público por parte de las personas de tercera edad frente al de otros segmentos de la población. En la figura 5.5 hay cuatro imágenes, las de la columna izquierda son imágenes extraídas de [45], mientras que las de la derecha son de individuos de este trabajo, es decir, usuarios de tercera edad. Todas las imágenes son representaciones de la frecuencia semanal de distintos usuarios salvo que en vez de representar la serie temporal, como se hizo en la sección 4.2.1 de este trabajo, se ha representado la frecuencia mediante un gráfico de barras.




Figura 5.1: Imagen extraída de [45] .




Figura 5.3: Imagen extraída de [45] .




Figura 5.2: Representación de la frecuencia semanal mediante un gráfico de barras




Figura 5.4: Representación de la frecuencia semanal mediante un gráfico de barras

Figura 5.5: Imagen comparativa de la frecuencia semanal de usuarios de distintos segmentos de la población.

Como se puede observar las imágenes de la derecha son más caóticas y desordenadas, más irregulares en un uso constante, no tienen, como ocurre en las de la izquierda, una repetitividad y constancia marcada. Este comportamiento irregular es comprensible en la población de tercera edad ya que se mueven por ocio u obligaciones esporádicas que no tienen que repetirse cada cierto tiempo.

Otra de las diferencias plausibles es la unidad temporal en la que los patrones se repiten. En la figura 5.5 se puede observar que en las imágenes de la izquierda la mayoría de las semanas los usuarios realizan el mismo número de viajes, por lo que la unidad temporal, en la que los patrones de estos individuos se repiten, es semanal. Este es un comportamiento comprensible ya que la gran mayoría de la población, ya sea por trabajo o estudios, tiene obligaciones que se repiten semanalmente. Sin embargo, la población de tercera edad no tiene esta imposición rutinaria por lo que sus patrones tienen una unidad temporal distinta en cada usuario, en caso de tenerla. Esta diferencia dificulta mucho el análisis de las series temporales de esta población, ya que al no contener una pauta reiterada es más complicado realizar tareas como limpiar la serie de viajes inusuales. Debido a esto en la sección 4.2.5, se creó una limpieza en la que se observa la repetitividad de los eventos durante toda la serie temporal, con el fin de eliminar viajes inusuales

Esta diferencia de comportamiento también ha influido en la realización y planificación de los experimentos ya que normalmente antes de realizar una predicción se realizaría un clustering, agrupando los usuarios con comportamientos similares. Sin embargo, la aleatoriedad y falta de rutina de las series temporales impedía discernir

las características que podrían dar paso a una agrupación de individuos beneficiosa para una posterior predicción. Dado además el alto coste computacional de realizar clusters con series temporales se optó por primeramente examinar el comportamiento de los algoritmos de predicción con el fin de que estas predicciones permitan obtener características sobre los datos que puedan ser relevantes para en trabajos futuros realizar un clustering.

Hay que tener en cuenta que aunque el patrón no sea perceptible, no implica que no exista. Los algoritmos de predicción pueden encontrar patrones no visibles por el humano, aprender de ellos y replicarlos en el futuro. Sin embargo, hay que implementar restricciones que nos permitan verificar que los algoritmos verdaderamente están aprendiendo el comportamiento de la serie temporal. En este estudio se examinarán tres algoritmos de predicción distintos con el fin de comprobar la efectividad de cada uno de ellos, comparar las predicciones obtenidas para un mismo usuario y verificar si la limpieza propuesta permite obtener mejores resultados. Por tanto, en los experimentos a realizar se va a comprobar si los algoritmos verifican la siguiente hipótesis:

Hipótesis 1 *Es posible realizar una predicción efectiva del comportamiento individual de los usuarios.*

Se considerará que una predicción es efectiva cuando el algoritmo de predicción usado sea capaz de predecir la serie temporal y además de esta primera condición, para considerar que una predicción ha sido efectiva el error medio por semana no puede ser mayor que el error medio obtenido de la predicción de uno de estos dos algoritmos:

- (I) **Algoritmo de la media:** *Un algoritmo de predicción que siempre devuelve la media de la serie.*
- (II) **Algoritmo del valor más recurrente:** *Un algoritmo de predicción que siempre devuelve el número de viajes por semana que más se ha repetido durante toda la serie temporal.*

La comparativa de los errores se evaluará en hipótesis diferentes. El objetivo de que nuestra predicción mejore el error medio obtenido por alguno de estos algoritmos reside en la facilidad de estos algoritmos, cuyas predicciones son datos estadísticos muy sencillos de obtener. Por lo tanto, si el algoritmo no ha mejorado este error entonces no ha aprendido el comportamiento básico de la serie temporal y además se ha encontrado un algoritmo mucho más sencillo capaz de predecir la serie temporal con mayor precisión.

Limitación 1 *Únicamente se pueden analizar los usuarios que tienen al menos 60 semanas en la serie temporal elegida para la representación, ya que de este modo los algoritmos tienen como mínimo unos 50 datos para aprender el comportamiento del usuario. Además el usuario debe tener al menos 30 viajes en su registro ya que en caso contrario ni siquiera se podrá realizar la representación de dicho usuario, como se mencionó en el capítulo 4. En el caso en que no se cumpla alguna de estas características no se realizará la predicción de dicho usuario.*

El motivo fundamental para que las series temporales contengan al menos 50 datos de los que aprender es que los algoritmos de predicción necesitan tener una gran cantidad de datos para aprender el comportamiento de la serie temporal. Cuantos más datos tengan mejor podrán examinar y comprender la evolución de estos mis-

mos. Hay que tener en cuenta que si sólo se escogen usuarios cuya serie temporal empieza la primera semana almacenada en la base de datos, es decir las series temporales con la mayor longitud posible, no se estaría realizando la hipótesis con una muestra representativa de este segmento de la población.

Suposiciones: Para la realización de este trabajo se debe suponer que la red de transportes no varía, es decir en todos los años involucrados en este estudio la red de transportes es la de finales de 2019. Esta suposición no es realista sin embargo es necesaria.

Con el fin de verificar esta hipótesis teniendo en cuenta tanto las limitaciones como las suposiciones expuestas, se han creado unos experimentos que serán expuestos en la siguiente sección.

5.1. Experimentos

Para comprobar la hipótesis 1 se van a predecir 4 semanas (desde 2019-11-18 a 2019-12-09) con 3 algoritmos de predicción distintos de los 1000 primeros usuarios que cumplan las restricciones expuestas en las limitaciones. Se va a coger los primeros usuarios ya que estos usuarios están ordenados en la base de datos según el id de la tarjeta y al ser este un hash coger los primeros usuarios equivale a escoger aleatoriamente una muestra de 1000 usuarios.

A todas las series temporales se le han quitado las 3 últimas semanas, ya que coinciden con la navidad y se entiende que pueden ser fechas en las que el comportamiento de los usuarios se sale de lo rutinario. Además como predecimos 4 semanas, hay un total de 7 valores de los 60 que debe contener la serie temporal para ser examinada que los algoritmos de predicción no pueden utilizar para aprender el comportamiento de la serie, de aquí que en la sección anterior se haya comentado que tienen 50 valores para aprender.

Las predicciones se realizarán sobre la serie temporal de la frecuencia por semanas. Se ha elegido esta representación debido a que la varianza de esta serie es menor (en comparación con las representaciones de la frecuencia por días y según las diferencias de tiempo) pero sigue teniendo datos suficientes (a diferencia de la representación de la frecuencia por meses) para realizar una predicción. Sin embargo, se ha implementado un interfaz que permite realizar la predicción de cualquier usuario con cualquiera de las representaciones según la frecuencia o la representación de las diferencias de tiempo, con o sin limpieza. Esta interfaz también permite realizar cualquiera de las herramientas explicadas en el capítulo 4. Véase el Anexo 8 para más información. Todas las series temporales serán normalizadas entre 0 y 1 mediante una normalización Min-Max.

El error medio de una predicción se calculará con la media de las diferencia de cada uno de los valores que se han obtenido, $\{x_1, \dots, x_4\}$ menos los valores reales $\{\hat{x}_1, \dots, \hat{x}_4\}$ al cuadrados, es decir,

$$E = \frac{1}{4} \sum_{i=1}^4 (x_i - \hat{x}_i)^2$$

Es importante tener en cuenta que todos los algoritmos, a pesar de recibir los datos

de forma diferente, se juzgarán de manera igualitaria sin realizar restricciones que beneficien a un algoritmo respecto a otro. Esta consideración es de suma importancia y el principal motivo que permite comparar la efectividad de los tres algoritmos con un mismo usuario. Los resultados de estos experimentos se expondrán en el capítulo 6.

Cada algoritmo recibe los datos de un modo específico, en las siguientes secciones se hablará de cómo se van a realizar las predicciones con cada uno de los algoritmos.

5.1.1. Especificaciones de los experimentos basados en el Arima

Como se comentó en 2.1.3.1 el Arima tiene algunas limitaciones extra que se expondrán a continuación.

Limitación 2 *Además de las limitaciones globales que se han mencionado, el método ARIMA necesita que las series introducidas tengan una estacionalidad débil, es decir que su media y su varianza sean constantes en el tiempo. Esta limitación será testada con los tests estadísticos de Dickey-Fuller y Kwiatkowski-Phillips-Schmidt-Shin (KPSS).*

A pesar de esta limitación el Arima intentara predecir los mismo usuarios que los otros dos algoritmos, salvo que las series primeramente deben pasar el test estadístico que verifique que son estacionarias. En los casos en los que no se de la estacionalidad entonces se declarara que el arima no es capaz de realizar una predicción efectiva de dicho usuario. Es importante cuantificar el efecto de esta limitación si se quiere realizar una comparativa justa de los algoritmos de predicción.

Por cada usuario, se realizará la representación de la serie temporal, se normaliza y eliminaran los 7 valores mencionados anteriormente. Posteriormente se testará la estacionalidad de la serie temporal, en caso de que no sea estacionaria se declarará que la predicción no ha sido efectiva y en caso contrario el método arima deberá realizar una predicción de los siguientes 4 valores de la serie temporal. Se calculará el error medio de esta predicción junto con el error medio de la predicción de los algoritmos (I) y (II) explicados en la hipótesis 1. De este modo, al terminar de examinar los 1000 usuarios se tendrá el número de predicciones realizadas, el error medio semanal de todas las predicciones realizadas, el número de predicción efectivas en base a los algoritmos (I) y (II) .

Este proceso se realizará dos veces de formas independientes, en el primero las series no tendrán aplicada ninguna función de limpieza y en el segundo si. Por lo que se podrá comparar si la limpieza de la serie temporal mejora los resultados obtenidos por el Arima. Este proceso es realizado con el código *B5_01_Arima.py*. Véase los resultado en la cuadro 6.1.

5.1.1.1. Especificaciones de los experimentos basados en Prophet

Por cada usuario, se realizará la representación de la serie temporal, se normaliza y eliminaran los 7 valores mencionados anteriormente. Posteriormente Prophet deberá realizar una predicción de los siguientes 4 valores. Se calculará el error medio de esta predicción junto con el error medio de la predicción de los algoritmos (I) y (II) expuestos en la hipótesis 1. De este modo, al terminar de examinar los 1000 usuarios se tendrá el error medio semanal de todas las predicciones realizadas y el número de predicciones efectivas en base a los (I) y (II).

Este proceso se realizará dos veces de formas independientes, en el primero las series no tendrán aplicada ninguna función de limpieza y en el segundo si. Por lo que se podrá comparar si la limpieza de la serie temporal mejora los resultados obtenidos por el Prophet. Este proceso es realizado con el código *B5_02_Prophet.py*. Véase los resultado en la cuadro 6.1.

5.1.1.2. Especificaciones de los experimentos basados en Redes neuronas LSTM

Por cada usuario, se realizará la representación de la serie temporal, se normaliza y eliminaran los 7 valores mencionados anteriormente. Las redes de neuronas LSTM no admiten entrenar series de diferentes tamaños por lo que se partirán todas las series en subseries compuestas por 50 datos de entrenamiento y 1 de predicción. La red siempre recibirá 50 datos y devolverá 1, de modo que cuando se realicen las predicciones finales los resultados se irán encadenando para realizar por cada usuario 4 predicciones. Para crear las subseries se irá moviendo por la serie una ventana de 51 valores.

Por tanto primeramente se quita el conjunto de entrenamiento compuesto por 50 valores y el conjunto de test final compuesto por los últimos 4 valores a predecir. Dado que se hacen subseries en los que la ventana se mueve 1 valor únicamente debemos quitar los 4 últimos valores de test final y realizar las subseries de 51 valores de todas las series a examinar para obtener las cadenas que la red utilizará para entrenar. Una vez obtenidas todas las subseries se aleatorizaran y se entrenará la red LSTM. Para este entrenamiento se ha elegido un 80 % de los datos para entrenar y un 20 % para validación.

Después del entrenamiento a la red se le pasarán las subseries de test que se han retirado y se predecirá 4 valores, es decir por cada serie la red recibe 4 subseries que se van creando de manera dinámica añadiendo el valor predicho y eliminando el primer valor para que a red de neuronas tenga siempre 50 datos de input. Se calculará el error medio de esta predicción junto con el error medio de la predicción de los algoritmos (I) y (II) expuestos en la hipótesis 1. De este modo, al terminar de examinar los 1000 usuarios se tendrá el error medio semanal de todas las predicciones realizadas y el número de predicciones cuyo error ha sido menor que el error del algoritmo (I) y (II).

Este proceso se realizará dos veces de formas independientes, en el primero las series no tendrán aplicada ninguna función de limpieza y en el segundo si. Por lo que se podrá comparar si la limpieza de las series temporales mejora los resultados obtenidos. Este proceso es realizado con el código *B5_03_red_neuronal.py*. Véase los resultado en la cuadro 6.1.

Capítulo 6

Resultados

En este capítulo se expondrán los resultados obtenidos en la realización de los experimentos explicados en el capítulo 5. Además, con el fin de obtener características relevantes de los datos para la tarea de predicción, se analizaron diversas predicciones realizadas por cada algoritmo.

Como se ha explicado anteriormente los algoritmos usados serán el ARIMA, el Prophet y la red neuronal LSTM, todos ellos con y sin limpieza, dando un total de seis algoritmos. Por cada algoritmo se ha realizado la predicción de 1000 series temporales, obteniendo por cada uno los siguientes parámetros: el número de predicciones que cada algoritmo a sido capaz de realizar, el error semanal medio de todas las predicciones realizadas y el número de predicciones efectivas en base a los algoritmos (I) y (II). Los resultados obtenidos se exponen en el siguiente cuadro.

	Arima sin limpieza	Arima con limpieza	Prophet sin limpieza	Prophet con limpieza	LSTM sin limpieza	LSTM con limpieza
Predicciones efectuadas	479	464	1000	1000	1000	1000
Error medio semanal	0.1583	0.1527	0.1626	0.1645	0.1593	0.1542
Nº de predicciones efectivas en base al algoritmo (I)	312	307	530	493	549	558
Nº de predicciones efectivas en base al algoritmo (II)	306	259	414	368	445	349

Cuadro 6.1: Resultados de la predicción de 1000 usuarios por tres algoritmos de predicción distintos.

Respecto al **número de predicciones realizadas** por los algoritmos destaca negativamente el ARIMA, el cual con limpieza solo consigue realizar 464 predicciones y 479 sin limpieza frente a las 1000 predicciones realizadas por el Prophet y la red LSTM. Por tanto, el ARIMA debido a su limitación (Limitación 2), reduce en más de un 50 % la

cantidad de predicciones que puede realizar. Además el número de predicciones realizadas por el ARIMA con limpieza es menor que con la opción sin limpieza, es decir la cantidad de series que son estacionarias se ha reducido con la opción de limpieza. Esto es debido a que al limpiar las series se observa que a pesar de que ciertas series en un principio parecían estacionarias no lo son.

El **error semanal medio**, o equivalentemente, el porcentaje de error de todas las predicciones se encuentra entre el 17 % y 14 % en todos los algoritmos. Mientras que el ARIMA y la red de neuronas LSTM tiene errores cercanos al 15 %, Prophet destaca negativamente mostrando un porcentaje de error, tanto con limpieza como sin ella, cercano al 16 %. **Además, el error medio de las predicciones disminuye cuando las series tienen aplicada una limpieza en el caso del ARIMA y la red LSTM, pero aumenta con el Prophet.**

Respecto al **número de predicciones efectivas en base al algoritmo (I)**, la red LSTM es el algoritmo con un mayor recuento obteniendo 558 y 549 predicciones efectivas con y sin limpieza respectivamente. Seguidamente se encuentra el recuento obtenido por el Prophet con y sin limpieza. En el último lugar se encuentran los valores obtenidos por el ARIMA. Sin embargo, hay que tener en cuenta que los resultados obtenidos en el cuadro 6.1, se están evaluando respecto a las 1000 series que se les exigio a los algoritmos predecir. Desde esta perspectiva el ARIMA es el algoritmo con menos predicciones efectivas consiguiendo únicamente, en el caso de tener limpieza, 312 predicciones efectivas respecto a las 1000 deseadas, es decir un 31,2 %. Sin embargo, si se tiene en cuenta estos valores respecto al número de predicciones realizadas por cada algoritmo el ARIMA es el algoritmo con mejores resultados ya que, en el caso de que tenga limpieza, consigue 312 predicciones efectivas sobre las 479 realizadas, es decir, el 65 % de las predicciones realizadas son efectivas frente al 55,8 % obtenido por la red LSTM con limpieza. Los porcentajes de predicciones efectivas frente a las realizadas y a las 1000 deseadas se encuentran en el siguiente cuadro:

	Arima sin limpieza	Arima con limpieza	Prophet sin limpieza	Prophet con limpieza	LSTM sin limpieza	LSTM con limpieza
Predicciones efectuadas	479	464	1000	1000	1000	1000
Nº de predicciones efectivas en base al algoritmo (I)	312	307	530	493	549	558
% de predicciones efectivas respecto a las 1000 deseadas	31,2 %	30,7 %	53,0 %	49,3 %	54,9 %	55,8 %
% de predicciones efectivas respecto a las realizadas	65,1 %	66,1 %	53,0 %	49,3 %	54,9 %	55,8 %

Cuadro 6.2: Comparación de los porcentajes de error de los diversos algoritmos frente a los errores obtenidos por el algoritmo (I).

Respecto al **número de predicciones efectivas en base al algoritmo (II)** y respecto a las 1000 deseadas, la red LSTM sin limpieza es el algoritmo con un mayor recuento, obteniendo 445, seguido por el Prophet sin limpieza que ha obtenido 414. Al igual que

Resultados

ocurría con el número de predicciones efectivas en base al algoritmo (I), el ARIMA es el que ha obtenido los peores resultados en comparación. Sin embargo, al igual que pasaba con las predicciones efectivas en base al algoritmo (I), el ARIMA presenta el mejor porcentaje de predicciones efectivas respecto al número de predicciones realizadas. En el siguiente cuadro se muestran los porcentajes de predicciones efectivas respecto a las predicciones realizadas y a las 1000 deseadas.

	Arima sin limpieza	Arima con limpieza	Prophet sin limpieza	Prophet con limpieza	LSTM sin limpieza	LSTM con limpieza
Predicciones efectuadas	479	464	1000	1000	1000	1000
Nº de predicciones efectivas en base al algoritmo (II)	306	259	414	368	445	349
% de predicciones efectivas respecto a las 1000 deseadas	30,6 %	25,9 %	41,4 %	36,8 %	44,5 %	34,9 %
% de predicciones efectivas respecto al número de predicciones realizadas	63,8 %	55,8 %	41,4 %	36,8 %	44,5 %	34,9 %

Cuadro 6.3: Comparación de los porcentajes de error de los diversos algoritmos frente a los errores obtenidos por el algoritmo (II).

Destacar el hecho de que el número de predicciones efectivas en base al algoritmo (I) siempre es mayor que el número de predicciones efectivas en base al algoritmo (II). Por lo cual se concluye que el segundo algoritmo consigue predicciones con menor error en más casos.

El ARIMA tiene un error medio menor y un porcentaje de predicciones efectivas más elevado respecto al número de predicciones realizadas que los otros dos algoritmos. Lo que es necesario comprender es si estos datos son provocados por que el ARIMA no predice ciertas series o porque comprende mejor el comportamiento de las series realizando predicciones más parecidas a la real que las obtenidas por los otros dos algoritmos. Dado que el error medio del ARIMA no muestra un descenso del error tan significativo se puede suponer que obtener el error de las predicciones efectuadas por el Prophet y la red LSTM de las series estacionarias no sería tampoco suficientemente significativo como para clarificar esta cuestión.

Con el fin de clarificar esta y otras cuestiones que hayan podido observarse en el análisis de estos resultados, en la siguiente sección se visualizarán y analizarán las predicciones efectuadas por los distintos algoritmos. Este análisis ayudará a entender mejor estos resultados a la vez que permitirá extraer características relevantes de los datos para la tarea de predicción.

6.1. Análisis de las predicciones obtenidas

En esta sección se analizarán diversas predicciones obtenidas por los tres algoritmos con el objetivo de entender el comportamiento de los algoritmos usados, extraer características relevantes y comprender mejor los resultados obtenidos.

6.1.1. Predicciones obtenidas por el ARIMA

En las siguientes imágenes se observan dos **predicciones efectivas** realizadas por ARIMA. En ellas se puede apreciar que el ARIMA ha entendido el comportamiento de la serie, tanto en cuestión de tendencia como de varianza, proporcionando predicciones muy semejante a la real. Se entiende que un algoritmo ha aprendido la tendencia de una serie en concreto cuando la predicción de esta serie tiene la misma tendencia que la de los datos reales de la predicción. Del mismo modo, un algoritmo ha aprendido la varianza de una serie si la predicción obtenida de la misma forma o una similar en cuestión de amplitud a la real.




Figura 6.1: Predicción proporcionada por el Arima con limpieza.





Figura 6.2: Predicción proporcionada por el Arima sin limpieza

Resultados



Enfoque en la predicción expuesta en la figura 6.1

la figura 6.2

Figura 6.3: Predicciones eficaces proporcionadas por el método Arima.

Sin embargo, también se encuentran predicciones que demuestran que el ARIMA no aprende siempre la varianza de la serie temporal a examinar. Estas predicciones se caracterizan sobretodo por ser una línea recta con una cierta inclinación, en ocasiones, similar a la de la tendencia de los datos a predecir. Un ejemplo de esta conducta se puede observar en la figura 6.4. Esto indica que el método arima sabe por donde van a oscilar los datos, es decir, a aprendido el comportamiento de la serie lo suficiente para saber la tendencia que tendrán los valores en un futuro próximo, pero no ha aprendido su varianza, motivo por el cual la predicción es una línea recta a diferencia de lo observado en la figura 6.3




Figura 6.4: arima sin limpieza




Figura 6.5: Enfoque en la predicción expuesta en la figura 6.4

En otras ocasiones se puede observar que el ARIMA aprende la varianza pero no la

6.1. Análisis de las predicciones obtenidas

tendencia. Estas predicciones se caracterizan por tener la misma forma que los datos reales pero estar desplazada en el eje vertical. Un ejemplo de este comportamiento se observa en las siguientes figuras.




Figura 6.6: Predicción obtenida por el Arima con limpieza.




Figura 6.7: Predicción obtenida por el Arima con limpieza.




Figura 6.8: Enfoque en la predicción ex-
puesta en la figura 6.6




Figura 6.9: Enfoque en la predicción ex-
puesta en la figura 6.7

6.1.2. Predicciones realizadas por el Prophet

Este algoritmo aprende de los datos y obtiene un ajuste automático, parecido a un entrenamiento, el cual se expondrá junto con las predicciones obtenidas. Este ajuste ayudará a entender y explicar las predicciones realizadas por el Prophet. En las siguientes imágenes se muestra una **predicción efectiva** realizada por el Prophet.

Resultados




Figura 6.10: Ajuste realizado por el Prophet.




Figura 6.11: Predicción obtenida por el Prophet con limpieza.




Figura 6.12: Enfoque en la predicción expuesta en la figura 6.11

Una de las peculiaridades del ajuste que realiza el Prophet es la curvatura de este ajuste sin puntos bruscos que en muchos casos no se corresponde con el comportamiento observado de la serie. Esta peculiaridad produce perdicciones como la que se observa a continuación

6.1. Análisis de las predicciones obtenidas




Figura 6.13: Ajuste realizado por el Prophet.




Figura 6.14: Predicción obtenida por el Prophet con limpieza.




Figura 6.15: Enfoque en la predicción expuesta en la figura 6.14

Este comportamiento también produce predicciones con valores negativos cuando los últimos valores observados son secuencias con valor 0. Un ejemplo se expone a continuación.

Resultados




Figura 6.16: Ajuste realizado por el Prophet.




Figura 6.17: Predicción obtenida por el Prophet con limpieza.




Figura 6.18: Enfoque en la predicción expuesta en la figura 6.17

Otro comportamiento reiterado que se observa es un ajuste lineal que se obtiene cuando la serie no tiene suficientes valores. Esto ya se comentó cuando se hablaba de las desventajas de los métodos tradicionales para la tarea de predicción.

6.1. Análisis de las predicciones obtenidas




Figura 6.19: Ajuste realizado por el Prophet.




Figura 6.20: Predicción obtenida por el Prophet con limpieza.




Figura 6.21: Enfoque en la predicción expuesta en la figura 6.20

6.1.3. Predicciones realizadas por la red LSTM

La red LSTM hace las predicciones viendo únicamente 50 datos, lo cual reduce las observaciones que utiliza el algoritmo para realizar la predicción. En las siguientes imágenes se observan dos **predicción efectiva** realizada por esta red.

Resultados




Figura 6.22: Predicción realizada por la red LSTM sin limpieza.




Figura 6.23: Predicción realizada por la red LSTM sin limpieza.

Sin embargo, al igual que ocurría con el ARIMA también se encuentran predicciones en las que red LSTM no ha sido capaz de aprender la varianza (figura 6.26 y 6.25) o la tendencia (figura 6.24) de la serie.




Figura 6.24: Predicción realizada por la red LSTM sin limpieza.

6.1. Análisis de las predicciones obtenidas




Figura 6.25: Predicción realizada por la red LSTM sin limpieza.




Figura 6.26: Predicción realizada por la red LSTM sin limpieza

Dado que el número de observaciones que la red ve para predecir la serie temporal es menor, las predicciones realizadas se ven afectadas. El comportamiento de estas predicciones se caracteriza porque la predicción podría ser verosímil, podría ser la real dadas las observaciones que la red tiene para entrenar, como por ejemplo en la figura 6.27 en la cual la predicción tiene una varianza mucha más grande y es verosímil con lo observado. Este comportamiento también se ve cuando la serie de repente padece un periodo de inactividad que no era esperado como ocurre en la figura 6.28.

Resultados




Figura 6.27: Predicción realizada por la red LSTM sin limpieza.




Figura 6.28: Predicción realizada por la red LSTM sin limpieza.

Un comportamiento recurrente que se observa en algunas predicciones es que son simétricas a la real. Este comportamiento puede venir influenciado porque la red LSTM realiza el entrenamiento con todas las series temporales, que podría evitarse realizando un clustering y entrenando una red con una estructura diferente en cada uno de ellos.




Figura 6.29: Predicción realizada por la red LSTM con limpieza

6.1. Análisis de las predicciones obtenidas




Figura 6.30: Predicción realizada por la red LSTM con limpieza

6.1.4. Predicción comparativa entre los algoritmos de predicción


Con el fin de realizar una comparativa entre la predicción obtenida por los diferentes algoritmos para una misma serie, se va a exponer la predicción de varias series temporales por los tres algoritmos de predicción. Además en el cuadro 6.4 se observará el error de dichas predicciones por cada algoritmo

	Arima con limpieza	Prophet con limpieza	LSTM con limpieza
Error predicción figura 6.31	0'2202	0'2393	0'1797
Error predicción figura 6.32	0'1890	0'1101	0'2327


Cuadro 6.4: Errores obtenidos por cada algoritmo en la predicción de la misma serie.

En esta primera predicción comparativa se observa que ninguno de los algoritmos realiza una predicción precisa o muy parecida a la real. Sin embargo la red LSTM predice correctamente el primer valor, lo cual explica que su error sea el más bajo y el Prophet ha aprendido de la serie la varianza aunque no la tendencia.


Resultados



Predicción realizada por el ARIMA con limpieza.



Predicción realizada por Prophet con limpieza.




Predicción realizadas por la red LSTM con limpieza.


Figura 6.31: Figura comparativa

En esta segunda predicción destaca el Prhopheht que ha aprendido la tendencia, al igual que el ARIMA, y la forma de la predicción aunque la varianza es algo menos en la predicción proporcionada por el Prophet. Destaca negativamente la red LSTM que vuelve a mostrar un comportamiento inverso y simétrico al esperado.


6.1. Análisis de las predicciones obtenidas



Predicción realizada por el ARIMA con limpieza.



Predicción realizada por Prophet con limpieza.



Predicción realizadas por la red LSTM con limpieza.

Figura 6.32: Predicción comparativa

Observando las predicciones y los errores expuestos se ve que el ARIMA no tiene mejores predicciones que las obtenidas por los otros dos algorítmicos, por la disminución de su error no es debido a que entiende mejor las series temporales que los otros dos.

Capítulo 7

Conclusiones

Este trabajo ha sido fruto de la colaboración entre el OEG y el CRTM y tiene como objetivo ampliar el conocimiento existente sobre el uso del transporte público por parte de las personas de tercera edad en la comunidad de Madrid.

A lo largo de este estudio se ha explicado e implementado varias representaciones que pueden ser utilizadas para visualizar el comportamiento de los usuarios basándose en diferentes características. También se han visto varias herramientas de descomposición y se han implementado varias formas de comprobar si una serie es o no estacionaria. Se ha evaluado la predicción de 1000 series temporales por parte de tres algoritmos de predicción distintos, dos de ellos tradicionales y una red neuronal. Estos experimentos han sido llevados a cabo con las series con y sin limpieza. Dentro de los métodos utilizados para evaluar que una predicción ha sido efectiva se han utilizado las predicciones realizadas por algoritmos que simplemente se basaban en el cálculo de datos estadísticos simples de las series temporales. Los experimentos se diseñaron de modo que han permitido la comparación de una misma predicción llevada a cabo por los tres algoritmos. Las observaciones destacables de todo este trabajo son las siguientes:

- Menos de un 50 % de las series utilizadas en los experimentos muestran un comportamiento estacionario, es decir, invariante en el tiempo.
- La limitación del ARIMA causa una reducción de más del 50 % en el número de predicciones que puede realizar.
- El error medio de las predicciones disminuye cuando las series tienen aplicada una limpieza en el caso del ARIMA y la red LSTM, pero aumenta con el Prophet.
- El Prophet, dado su método de ajuste es el algoritmo con un mayor error medio obtenido tanto con como sin limpieza.
- El ARIMA es el algoritmo con menor error medio observado, aunque no se han visto evidencias que demuestren que esto es debido a un mejor aprendizaje del comportamiento de la serie por parte de este algoritmo frente al del resto de algoritmos de predicción usados.
- El comportamiento de la red LSTM se ve influenciado por la cantidad de observaciones vistas para realizar la predicción. Esto se puede solucionar aumentando el número de semanas mínimas que debe tener la serie para ser evaluada.

-
- El comportamiento de la red LSTM muestra comportamientos no deseados debido a la gran variedad de series con las que ha entrenado. Estos comportamientos pueden ser solventados con la realización de un clustering y un entrenamiento de una red por cada cluster resultante.
 - La volatilidad y los periodos de inactividad afectan significativamente a los algoritmos de predicción.
 - El Prophet se ve muy afectado por la series con pocas observaciones. Información que no destaca al tratarse de un método tradicional.
 - Destaca significativamente la diferencia existente entre la serie temporal de los individuos de tercera edad frente a la de otros sectores de la población.
 - El algoritmo con un mayor número de predicciones efectivas en base al algoritmo (I) es la red LSTM con limpieza, y en este caso solo el 55,8 % de las predicción realizadas fueron efectivas.
 - El algoritmo con un mayor número de predicciones efectivas en base al algoritmo (II) es la red LSTM sin limpieza, y en este caso solo el 44,5 % de las predicción realizadas fueron efectivas.

Existen diversas características o atributos de los datos que podrían ser interesantes captar para la realización de trabajos futuros, entre ellos están los siguientes:

- La edad de los individuos puede ser un atributo determinante para la realización de un clustering. La lógica indica las series temporales de los individuos se volverán más aleatorias, irregulares y con menos constancia, cuanto mayor sea la edad del usuario en cuestión.
- Los datos geográficos pueden ser relevantes y permitir la detección de viajes realizados con el propósito de evitar terrenos desiguales o con mucha inclinación.
- Los datos demográficos que tengan relación con la localización de la residencia de los individuos, tal y como se observa en el estado del arte, puede ser relevante.
- Determinar y catalogar los motivos de los comportamientos anómalos o cambios de conducta, por ejemplo mediante encuestas, permitirá tener un etiquetado de estos eventos. Este etiquetado permitiría a los algoritmos de machine learning aprender estas conductas y los motivos asociados.

Por último, es importante resaltar la importancia de examinar en ciertos ámbitos el comportamiento de los individuos de tercera edad de un modo especial, ya que el comportamiento de estos individuos puede no ser semejante al de otros sectores. Aprender el comportamiento de este sector es un factor clave para la creación de políticas y medidas que se adapten a sus necesidades y que siempre que se pueda estén enfocadas en ayudar a este sector de la población.

Capítulo 8

Trabajos futuros

A continuación se expondrán algunas ideas que pueden utilizarse para la continuación de este proyecto

- Es posible que muchos usuarios utilicen el transporte para evitar cuestras o trayectos que puedan resultar más complicados, por lo cual sería interesante realizar un estudio en el que se tengan en cuenta conjuntamente los viajes y la forma del terreno.
- Puede ser interesante aplicar distintas funciones de limpieza diseñadas más específicamente para estos usuarios.
- Realizar un clustering teniendo en cuenta la varianza de las series, su constancia, sus periodos de inactividad, la longitud de la serie, si es estacionaria o no.
- Realizar clustering mediante la extracción de características de los datos. Esto proporciona una clasificación en función de las características que se hayan elegido permitiendo adaptar los clusters a aquellas características que son relevantes para la correcta predicción de las series temporales. De modo que entre las características relevantes se podrían encontrar el número de periodos de inactividad y sus longitudes, la longitud de la serie, la varianza de los datos, su constancia y otras características que se crean relevantes para la realización de esta tarea.
- Diseñar encuestas para los usuarios mayores de 65 años con el fin de verificar si verdaderamente sus viajes son por motivos relacionados con el terreno, por ocio o rutinarios. Esto podría proporcionar una visión de cómo estas personas ven el transporte y sus posibilidades de movilidad con él. De este modo se podrá clasificar, por ejemplo, a aquellos usuarios cuyo principal motivo para coger transporte es acudir a un centro de día.
- En [7], Lei Chen et. al. exponen una investigación en la que permite la representación de la serie temporal mediante un histograma. Además realizan un algoritmo que permite encontrar todas las series temporales (sus representaciones en histogramas) que tengan características similares. Lo curioso de la técnica usada es que permite que dos series temporales se definen como semejantes teniendo en cuenta que pueden contener un dato con error, teniendo en cuenta la escala y la amplitud de estas series así como el desplazamiento. Esto

es algo que podría aplicarse a nuestras series temporales con el fin de encontrar una clasificación de los usuarios permitiendo que dos series temporales sean semejantes con esta flexibilidad.

- Se pueden realizar diversos estudios teniendo en cuenta los viajes de todos los usuarios en un único medio de transporte.
- Se pueden realizar estudios globales de modo que se analice el número de abandonos por mes. De este modo se realizarán estudios globales que aportaran información diferente sobre la movilidad de este sector de la población.
- Se propone intentar un clustering basado en actividades pero los resultados pueden no ser determinantes debido a la falta de rutina de este segmento de la población. Se recomienda utilizar una función de medición de la constancia que no imponga la existencia de una unidad temporal fija.

Bibliografía

- [1] Ryan Prescott Adams y David J. C. MacKay. “Bayesian Online Changepoint Detection”. En: (2007). eprint: 0710.3742.
- [2] Saeed Aghabozorgi, Ali Seyed Shirkhorshidi y Teh Ying Wah. “Time-series clustering – A decade review”. En: *Information Systems* 53 (2015), págs. 16 -38. ISSN: 0306-4379. URL: <http://www.sciencedirect.com/science/article/pii/S0306437915000733>.
- [3] F. Baudoin. “Stochastic Processes”. En: *International Encyclopedia of Education (Third Edition)*. Ed. por Penelope Peterson, Eva Baker y Barry McGaw. Third Edition. Oxford: Elsevier, 2010, págs. 451-452. ISBN: 978-0-08-044894-7. DOI: <https://doi.org/10.1016/B978-0-08-044894-7.01369-5>. URL: <https://www.sciencedirect.com/science/article/pii/B9780080448947013695>.
- [4] Konstantinos Benidis y col. “Neural forecasting: Introduction and literature overview”. En: *CoRR abs/2004.10240* (2020). arXiv: 2004.10240. URL: <https://arxiv.org/abs/2004.10240>.
- [5] David R. Brillinger. “Time series: general”. En: *International Encyclopedia of the Social and Behavioral Sciences* 23 (2001), págs. 15724-15731.
- [6] PJ Brockwell. “Time series analysis”. En: *Wiley StatsRef: Statistics Reference Online* (2014).
- [7] Lei Chen, M. Tamer Özsu y Vincent Oria. “Using Multi-Scale Histograms to Answer Pattern Existence and Shape Match Queries”. En: ene. de 2005.
- [8] Robert B. Cleveland y col. “STL: A Seasonal-Trend Decomposition Procedure Based on Loess with Discussion”. En: *Journal of Official Statistics* 6 (1990), págs. 3-73.
- [9] *Consorcio de Transporte de Madrid*. URL: <https://www.crtm.es>.
- [10] Fatoumata Dama y Christine Sinoquet. “Analysis and modeling to forecast in time series: a systematic review”. En: *CoRR abs/2104.00164* (2021). arXiv: 2104.00164. URL: <https://arxiv.org/abs/2104.00164>.
- [11] Mark Davis y col. “Getting out and about in older adults: The nature of daily trips and their association with objectively assessed physical activity”. En: *The international journal of behavioral nutrition and physical activity* 8 (oct. de 2011), pág. 116. DOI: 10.1186/1479-5868-8-116.
- [12] M. K. El Mahrsi y col. “Clustering Smart Card Data for Urban Mobility Analysis”. En: *IEEE Transactions on Intelligent Transportation Systems* 18.3 (2017), págs. 712-728. DOI: 10.1109/TITS.2016.2600515.
- [13] epdata. *Proporción de la población de España de 65 años y más*. URL: <https://www.epdata.es/proporcion-poblacion-espana-65-anos-mas/9db8c84b-0d61-4f7e-9f4c-30ba8a40f535>.

-
- [14] Eurostat. *Population structure and ageing*. URL: https://ec.europa.eu/eurostat/statistics-explained/index.php/Population_structure_and_ageing.
 - [15] Jason Gordon. "Intermodal passenger flows on London's public transport network : automated inference of full passenger journeys using fare-transaction and vehicle-location data". En: (mar. de 2013).
 - [16] G. Goulet-Langlois y col. "Measuring Regularity of Individual Travel Patterns". En: *IEEE Transactions on Intelligent Transportation Systems* 19.5 (2018). DOI: 10.1109/TITS.2017.2728704.
 - [17] Gabriel Goulet-Langlois, Haris N. Koutsopoulos y Jinhua Zhao. "Inferring patterns in the multi-week activity sequences of public transport users". En: *Transportation Research Part C: Emerging Technologies* 64 (2016), págs. 1 -16. ISSN: 0968-090X. DOI: <https://doi.org/10.1016/j.trc.2015.12.012>. URL: <http://www.sciencedirect.com/science/article/pii/S0968090X15004283>.
 - [18] Aurélien Géron. *Hands-on Machine Learning with Scikit-Learn, Keras and TensorFlow*. O'Reilly Media, Inc. ISBN: 978-1-492-03264-9.
 - [19] Li He, M. Trépanier y B. Agard. "Space-time classification of public transit smart card users ' activity locations from smart card data". En: 2018.
 - [20] Robert J. Hodrick y Edward Prescott. *Post-War U.S. Business Cycles: An Empirical Investigation*. Discussion Papers 451. Northwestern University, Center for Mathematical Studies in Economics y Management Science, 1981. URL: <https://ideas.repec.org/p/nwu/cmsems/451.html>.
 - [21] Rob J Hyndman y George Athanasopoulos. *Forecasting: Principles and Practice*.
 - [22] *InfluxData*. URL: <https://www.influxdata.com>.
 - [23] *Introducción a Series de Tiempo*. URL: http://www.estadisticas.gobierno.pr/iepr/LinkClick.aspx?fileticket=4_BxecUaZmg%3D.
 - [24] Minh Kieu, Ashish Bhaskar y Edward Chung. "Passenger Segmentation Using Smart Card Data". En: *IEEE Transactions on Intelligent Transport Systems* (dic. de 2013). DOI: 10.1109/TITS.2014.2368998.
 - [25] Anil NP Koushik, M. Manoj y N. Nezamuddin. "Machine learning applications in activity-travel behaviour research: a review". En: *Transport Reviews* 40.3 (2020), págs. 288-311. DOI: 10.1080/01441647.2019.1704307. eprint: <https://doi.org/10.1080/01441647.2019.1704307>. URL: <https://doi.org/10.1080/01441647.2019.1704307>.
 - [26] Alexander Lacki. "Analysis and Characterization of the Public Transport Mobility of Senior Citizens". Tesis doct.
 - [27] Pedro Lara-Benítez, Manuel Carranza-García y José C. Riquelme. "An Experimental Review on Deep Learning Architectures for Time Series Forecasting". En: *CoRR abs/2103.12057* (2021). arXiv: 2103.12057. URL: <https://arxiv.org/abs/2103.12057>.
 - [28] Xuan Hien Le y col. "Application of Long Short-Term Memory (LSTM) Neural Network for Flood Forecasting". En: *Water* 11 (jul. de 2019), pág. 1387. DOI: 10.3390/w11071387.
 - [29] Lena Levin. "Mobility patterns among older people in Sweden : a study of women's and men's experiences and modal choices from a life course perspective". En: 2012.
 - [30] Yeun-Touh Li y col. "Analyzing long-term travel behaviour: A comparison of smart card data and graphical usage patterns". En: *Transportation Research Procedia* 32 (2018). Transport Survey Methods in the era of big data:facing the

- challenges, págs. 34 -43. ISSN: 2352-1465. DOI: <https://doi.org/10.1016/j.trpro.2018.10.005>. URL: <http://www.sciencedirect.com/science/article/pii/S235214651830156X>.
- [31] Aileen Nielsen. *Practical Time Series Analysis*. O'Reilly Media, Inc. ISBN: 9781492041658.
- [32] *Ontology Engineering Group*. URL: <https://www.oeg-upm.net/>.
- [33] Meisy Ortega-Tong. "Classification of London's public transport users using smart card data". En: (dic. de 2013).
- [34] Francisco Parra. *Estadística y Machine Learning con R*. Editorial Académica Española. ISBN: 978-6-202-25216-4.
- [35] Richard A. Davis Peter J. Brockwell. *Introduction to Time Series and Forecasting*. Springer, 2016.
- [36] Girish Prayag. "Senior Travelers' Motivations and Future Behavioral Intentions: THE CASE OF NICE". En: *Journal of Travel and Tourism Marketing* 29 (oct. de 2012), págs. 665-681. DOI: 10.1080/10548408.2012.720153.
- [37] Miguel Ángel Riaño Sánchez. "Generación de Jupyter Notebooks y mejoras en la visualización de resultados en el tratamiento de datos relacionados con la movilidad en transporte público de personas mayores en la Comunidad de Madrid". Madrid, España, 2020. URL: <http://oa.upm.es/63127/>.
- [38] *statsmodels.tsa.seasonal.seasonal_decompose*. URL: https://www.statsmodels.org/stable/generated/statsmodels.tsa.seasonal.seasonal_decompose.html.
- [39] Robert H. ShumwayDavid S. Stoffer. *Time Series Analysis and Its Applications With R Examples*. Springer Science+Business Media, LLC 2006. ISBN: 978-0-387-29317-2.
- [40] W.Y. Szeto y col. "Spatio-temporal travel characteristics of the elderly in an ageing society". En: *Travel Behaviour and Society* 9 (2017), págs. 10 -20. ISSN: 2214-367X. DOI: <https://doi.org/10.1016/j.tbs.2017.07.005>. URL: <http://www.sciencedirect.com/science/article/pii/S2214367X16301430>.
- [41] Sean J Taylor y Benjamin Letham. "Forecasting at scale". 2017. DOI: 10.7287/peerj.preprints.3190v2.
- [42] G. C. Tiao. "Time Series: ARIMA Methods". En: 2001.
- [43] Linchuan Yang. "Modeling the mobility choices of older people in a transit-oriented city: Policy insights". En: *Habitat International* 76 (jun. de 2018). DOI: 10.1016/j.habitatint.2018.05.007.
- [44] Yang Zhang y col. "You are how you travel: A multi-task learning framework for Geodemographic inference using transit smart card data". En: *Computers, Environment and Urban Systems* 83 (2020), pág. 101517. ISSN: 0198-9715. DOI: <https://doi.org/10.1016/j.compenvurbsys.2020.101517>. URL: <http://www.sciencedirect.com/science/article/pii/S0198971520302507>.
- [45] Zhan Zhao, Haris N. Koutsopoulos y Jinhua Zhao. "Detecting pattern changes in individual travel behavior: A Bayesian approach". En: *Transportation Research Part B: Methodological* 112 (2018), págs. 73 -88. ISSN: 0191-2615. DOI: <https://doi.org/10.1016/j.trb.2018.03.017>.
- [46] Emir Zunic y col. "Application of Facebook's Prophet Algorithm for Successful Sales Forecasting Based on Real-world Data". En: *International Journal of Computer Science and Information Technology* 12 (abr. de 2020). DOI: 10.5121/ijcsit.2020.12203.

Anexo - Interfaz

Para facilitar al CRTM el poder explorar las diversas herramientas y algoritmos que se implementaron se creó un interfaz. Con él podemos realizar todo lo que se ha mencionado durante este trabajo. Se almacenó en el repositorio los registros de 10 usuarios junto con las paradas que habían sido visitadas por todos ellos de modo que aun sin tener los datos almacenados se pudiera explorar las diversas herramientas recorriendo los diversos menús y opciones que proporcionó este programa.

El interfaz se ejecuta con el código *interfaz.py* y nada mas ejecutarlo estas son las opciones que nos da:

Primer paso: Preajustes necesarios

Recuerde que si tiene la base de datos instalada deberá tener el atributo `self.base` de la clase `B1_02Conexion` a `True` así como los atributos de la conexión de este objeto rellenos de una manera adecuada. En caso contrario asegúrese de que esta opción está a `False`. Le recordamos que si esta opción está en `False` solo dispondrá de los datos de 10 usuarios y no podrá ejecutar el procesamiento de datos.

¿Has verificado que estas opciones están bien? Yes/No

Una vez verificado con un **Yes** nos pregunta lo siguiente:

MENU CENTRAR Selección de tema.

¿Que desea hacer? A continuación le exponemos las posibilidades pero teng a en cuenta que dentro de cada uno de los temas se le expondrá diferentes acciones a realizar.

OPCIONES:

- 01 - Preproceso de datos
- 02 - Visualizaciones globales
- 03 - Actividades con datos individuales
- 04 - Salir

Por favor escriba el número del tema relacionado con la operación deseada.

Se puede ir libremente por las diversas opciones siguiendo las indicaciones, en este caso únicamente iremos por la tercera opción para que vean algunos menús más. No se visitarán todos los menús para facilitar la comprensión.

03 - Actividades con datos individuales

Primeramente necesitamos seleccionar el usuario del que queremos información.
¿Tienes el id de un usuario en concreto? Yes/No
Introduce Salir para ir al menú anterior.

En caso de que se opte no se sepa el ID de ningún usuario se deberá escoger la opción No y el programa te dará los ID de los 10 usuarios almacenados en en local. No voy a exponer este paso para respetar la confidencialidad. En caso afirmativo únicamente se ha de poder Yes y el programa te gusta el ID del usuario.

MENU DE ANÁLISIS DE UN USUARIO

Acciones a realizar:

- 01- Representaciones
- 02- Representaciones con limpieza, es decir, únicamente los viajes que se repiten en el tiempo
- 03- Gráfico de ACF
- 04- Estacionalidad de una representación de la serie.
- 05- Descomposición de una representación de la serie.
- 06- Predicción de la serie.
- 07- Volver al menú centrar

Introduzca el número:

Si por ejemplo queremos representar una serie (1) tendríamos el siguiente menú.

REPRESENTACIÓN DE UN USUARIO

Representaciones:

- 01- Frecuencia por días, semana y mes
- 02- Recuento espacial global
- 03- Espacial por días, semanas y meses
- 04- Temporal
- 05- Representación en función de las diferencias de tiempo.
- 06- Todas
- 07- Cambiar la decisión de la limpieza
- 08- Salir al menú de acciones con el individuo seleccionado

Introduzca el número:

Como se puede ver en este menú se puede cambiar la opción de la limpieza que sería lo equivalente a haber seleccionado la opción 2 del menú anterior. Todas las opciones de este menú ya te imprimen la gráfica seleccionada del individuo seleccionado.

En relación con el menú anterior las opciones 3 y 4 te directamente muestran las

BIBLIOGRAFÍA

gráficas que has seleccionado. En la opción 5 se muestra un menú donde se puede elegir el método de descomposición. Como ejemplo se muestra el menú resultante de elegir la sexta opción.

Hay 4 representaciones con las que se puede realizar la operación deseada. Es ho

Opciones:

- 01- Representación de la frecuencia por días.
- 02- Representación de la frecuencia por semanas
- 03- Representación de la frecuencia por meses
- 04- Representación basada en las diferencias de tiempo
- 05- Representación de la frecuencia por días con la limpieza.
- 06- Representación de la frecuencia por semanas con limpieza
- 07- Representación de la frecuencia por meses con limpieza
- 08- Representación basada en las diferencias de tiempo con la limpieza.
- 09- Volver al menú anterior

Introduzca el número:

En este menú todas las opciones nos sacan gráficas. El resto de menús pueden encontrarse en el repositorio de GitHub.